ÓBUDAI EGYETEM

[Kar neve, pl. Neumann János Informatikai Kar]
[Intézet neve]

TUDOMÁNYOS DIÁKKÖRI DOLGOZAT

Vizsgakérdés-generálás helyben futtatható nyelvi modellekkel

A Mimir tervezésvezérelt, forráshivatkozásos RAG-módszere és kísérleti kiértékelése

Szerzők:

[Szerző 1 neve]
[szak, évfolyam]

[Szerző 2 neve]
[szak, évfolyam]

Konzulens:

[Konzulens neve]
[beosztás, intézet]

Budapest, 2026

64. Tudományos Diákköri Konferencia – 2026. őszi félév

Tartalmi összefoglaló

A vizsgakérdések írása lassú, hibalehetőségekkel teli munka: a megadott helyes válasznak a tananyagból kell következnie, a rossz válaszoknak (disztraktoroknak) pedig hihetőnek, de igazolhatóan hibásnak kell lenniük. A felhőben futó csevegő asszisztensek ezt nem ellenőrzik, a vizsga szerkezetét nem szabályozzák, és a tananyagot egy harmadik félnek adják át.

A Mimir helyben, fogyasztói GPU-n is futtatható vizsgagenerátor, amely jelenleg fejlesztési fázisban van: éles útvonala ma naiv visszakereséses generálást (naiv RAG) használ, a tervezett folyamat – vizsgaterv a kérdések témájáról és Bloom-szintjéről, kérdésenkénti keresés, forráshivatkozás és ellenőrző lánc – a saját kiértékelő keretrendszerünkben készült el. A dolgozat célja mérésen alapuló döntés arról, melyik megoldás kerüljön a rendszerbe. Ehhez egy nyílt keretrendszert építettünk: 14, egyszerre egy tényezőt változtató konfiguráció, független, bíróként pontozó nyelvi modell és dokumentumszintű statisztika. Három vizsgálatban, legfeljebb 30 dokumentumon és három 4 bites helyi modellen (Qwen2.5-7B, PULI-LlumiX 8B, Gemma 3 12B) mértünk.

Eredményeink szerint a minőséget elsősorban a választott modell és a visszakeresés lekérdezése határozza meg. A naiv RAG konkrét okból törékeny: a feladatleírást használja lekérdezésként, és a szemantikus darabolás rövid, tartalom nélküli darabjait találja meg. Rögzített méretű darabolással ugyanez a megoldás a Gemma 3 12B-nél 0,72-ről 0,97-re javult a minőségi indexen, vagyis az erős modellnél önmagában is elég volt. A vizsgaterv a szemantikus darabolású naiv RAG-hoz képest mindkét modellnél szignifikánsan javított a fő vizsgálatban. A lépésekre bontás haszna a modelltől függ: a gyenge PULI-LlumiX 8B-nél nélkülözhetetlen (0,28 → 0,67), a 8 GB-os kártyán futó Qwen2.5-7B a módszerrel a szervermodell teljes dokumentumos promptjának minőségét érte el (0,96, illetve 0,95), az erős Gemma 3 12B-nél pedig a teljes dokumentumos prompt is hasonlóan jó; itt a módszer értéke a kérdésenkénti ellenőrizhetőség. A mérés maga is eredmény: feltártuk a válaszszivárgást, a csendes tartalékágakat, az ellenőrző és a bíró ítéletének véletlenszerű egyezését és a forrásfüggően hiányzó bírói ítéleteket.

A mérések alapján a rendszerbe a vizsgaterv, a kérdésenkénti forráshivatkozás, a szabályalapú ellenőrzés és a rögzített vagy minimális méretű darabolás kerül, a nyelvi modellel végzett ellenőrzés pedig a modell erősségéhez igazodva; a fogalomgráf és a hibrid keresés kimarad. A bíró oktatói validálása folyamatban van.

Kulcsszavak: automatikus kérdésgenerálás, visszakereséssel kiegészített generálás (RAG), kis nyelvi modellek, ellenőrzés, nyelvi modell mint bíró, adatvédelem, oktatástechnológia, magyar nyelv

Tartalomjegyzék

Tartalmi összefoglaló ii

Tartalomjegyzék iii

Rövidítések és fogalmak vi

1. Bevezetés 1
1.1. Motiváció . . . 1
1.2. Problémafelvetés . . . 1
1.3. A rendszer állapota és a dolgozat célja . . . 2
1.4. Kutatási kérdések és hipotézisek . . . 2
1.5. Hozzájárulások . . . 3
1.6. A dolgozat felépítése . . . 3

2. Szakirodalmi áttekintés 4
2.1. A jó feleletválasztós kérdés és a Bloom-taxonómia . . . 4
2.2. Automatikus kérdésgenerálás: a szabályoktól a nagy nyelvi modellekig . . . 5
2.3. Nagy nyelvi modellek röviden . . . 6
2.4. Visszakereséssel kiegészített generálás . . . 7
2.5. Feladatfelbontás és ellenőrzés . . . 9
2.6. Kis nyelvi modellek helyi futtatása . . . 10
2.7. A kiértékelés: nyelvi modell mint bíró és a mérés megbízhatósága . . . 11
2.8. A magyar nyelv és a hazai előzmények . . . 12
2.9. Jogi keret: adatvédelem és MI-rendelet . . . 13
2.9.1. Az általános adatvédelmi rendelet . . . 13
2.9.2. Az Infotv. és a NAIH . . . 14
2.9.3. Az MI-rendelet . . . 14
2.9.4. A Mimir besorolása . . . 15
2.10. Összegzés és a kutatási rés . . . 16

3. A Mimir rendszer jelenlegi állapota és generálási módszere 18
3.1. Tervezési célok . . . 18
3.2. Architektúra és megvalósítás . . . 19
3.3. Adatvédelem: zéró megőrzés a feldolgozási adatokra . . . 20
3.4. Adatvédelem és MI-rendelet a megvalósításban . . . 21
3.5. A GPU-memória becslése . . . 21
3.6. A generálási módszer . . . 23
3.6.1. Szemantikus darabolás . . . 24
3.6.2. Indexelés és az alapvonalak . . . 24
3.6.3. A vizsgaterv . . . 24
3.6.4. Kérdéshelyenkénti keresés . . . 25
3.6.5. Forráshoz kötött kérdésgenerálás . . . 25
3.6.6. Az ellenőrző lánc . . . 25
3.6.7. Munkamenet-hatókörű fogalomgráf . . . 26
3.6.8. Összeállítás és emberi felügyelet . . . 26

4. Kiértékelési módszertan **28**
4.1. A tesztelés menete . . . 28
4.2. Adatkészlet . . . 29
4.3. A kísérleti konfigurációk . . . 29
4.4. A három vizsgálat . . . 30
4.5. Mutatók . . . 32
4.6. A bíró . . . 32
4.7. Oktatói értékelés . . . 33
4.8. Statisztikai elemzés . . . 33

5. A módszerek kiértékelése **35**
5.1. A pilot: három tanulság . . . 35
5.2. Az előzetes vizsgálat: a módszer egy 7B modellel . . . 35
5.3. A fő vizsgálat: összesített eredmények . . . 36
5.4. A komponensek hatása . . . 38
5.5. Darabolás és robusztusság . . . 39
5.6. Az ellenőrző működése . . . 41
5.7. Lefedettség, kognitív szint és felhasználhatóság . . . 41
5.8. Költség: relatív szorzók . . . 42
5.9. A mérés megbízhatósága . . . 42
5.10. A fejezet tanulsága . . . 43

6. A modellek kiértékelése **44**
6.1. A három helyi modell azonos dokumentumokon . . . 44
6.2. A szervermodell és a helyi modellek . . . 45
6.3. Miért bukik el a PULI-LlumiX? . . . 46
6.4. Erőforrásigény és GPU-szintek . . . 47
6.5. Modellválasztási tanulság . . . 48

7. Az eredmények értékelése és döntés: mit építünk be a rendszerbe **49**
7.1. A hipotézisek értékelése . . . 49
7.2. Összevetés az irodalommal . . . 50
7.3. Mikor éri meg a módszer? . . . 51
7.4. Döntés: mit építünk be . . . 52
7.5. Mit tanultunk az ellenőrzésről és a mérésről? . . . 54
7.6. Az érvényességet veszélyeztető tényezők . . . 54
7.7. Etikai és jogi szempontok . . . 55

8. Összefoglalás és további munka **56**
8.1. Összefoglalás . . . 56
8.2. További munka . . . 57

Irodalomjegyzék **58**

Ábrajegyzék **66**

Táblázatjegyzék **67**

A A módszer és a kiértékelés részletei **68**
A.1. Adatfajták életciklusa . . . 68
A.2. A GPU-memória becslése . . . 68
A.3. A szemantikus darabolás vágási szabálya . . . 69
A.4. A Bloom-szintek kiosztása . . . 69
A.5. A hibrid keresés . . . 70
A.6. Egy kérdéshely kitöltése . . . 70
A.7. A fogalomgráf . . . 71
A.8. Az adatkészlet . . . 71
A.9. A konfigurációk egytényezős fája . . . 71
A.10. Az oktatói értékelés protokollja . . . 72
A.11. A mutatók részletes definíciói . . . 72
A.12. A statisztikai eljárások részletei . . . 73

B Kiegészítő eredmények **74**
B.1. A pilot részletei . . . 74
B.2. Az előzetes vizsgálat helyi konfigurációi . . . 74
B.3. Az ellenőrző lánc részletei . . . 75
B.4. Lefedettség, kognitív szint és felhasználhatóság . . . 76
B.5. A bírói ítéletek lefedettsége . . . 76

C Promptok **78**
C.1. A naiv RAG (E0) és a teljes dokumentumos prompt (B-doc) . . . 78
C.2. A tervező . . . 78
C.3. A generátor . . . 78
C.4. A javító hívás . . . 79
C.5. Az ellenőrző . . . 79
C.6. A fogalomgráf (E3) . . . 80

D A bíró és az oktatók rubrikája **81**

E Paraméterek és reprodukálás **82**
E.1. A generálási folyamat paraméterei . . . 82
E.2. A reprodukálás lépései . . . 83

F Rezümé **85**

G Nyilatkozat a mesterséges intelligencia alapú eszközök használatáról **86**
G.1. A kutatás tárgyát képező modellek . . . 86
G.2. A dolgozat elkészítéséhez használt eszközök . . . 86
G.3. Ellenőrzés és felelősség . . . 87

H Eredménynyilatkozat **88**
H.1. A szerzők saját eredményei . . . 88
H.2. A témavezető és a tágabb kutatócsoport hozzájárulása . . . 88
H.3. Átvett, nem saját eredmények . . . 89

I Az adatok forrása és nyilvánossága **90**

Rövidítések és fogalmak

BM25	szógyakoriságon alapuló lexikális rangsoroló függvény
DPIA	*Data Protection Impact Assessment*, adatvédelmi hatásvizsgálat (GDPR 35. cikk)
GDPR	*General Data Protection Regulation*, általános adatvédelmi rendelet, (EU) 2016/679
GGUF, Q4_K_M	a `llama.cpp` kvantált modellformátuma, illetve annak kb. 4,8 bit/súly változata
GPU, VRAM	grafikus feldolgozóegység, illetve annak dedikált memóriája
Infotv.	az információs önrendelkezési jogról és az információszabadságról szóló 2011. évi CXII. törvény
KV-gyorsítótár	a szövegelőállítás közben tárolt kulcs- és értékvektorok
LLM	*Large Language Model*, nagy nyelvi modell
MCQ	*Multiple-Choice Question*, feleletválasztós kérdés
MI	mesterséges intelligencia
MI-rendelet	*AI Act*, a mesterséges intelligenciáról szóló (EU) 2024/1689 rendelet
NAIH	Nemzeti Adatvédelmi és Információszabadság Hatóság
RAG	*Retrieval-Augmented Generation*, visszakereséssel kiegészített generálás
RRF	*Reciprocal Rank Fusion*, reciprok rangfúzió
bíró	a kérdéseket pontozó, a generátoroktól független nyelvi modell (gpt-oss-120b)
darab	a dokumentum egy összefüggő, néhány mondatos részlete, a keresés egysége
disztraktor	a feleletválasztós kérdés helytelen, de hihető válaszlehetősége
ellenőrző	a Mimir saját ellenőrző lépése, amely a generált kérdést elfogadja vagy visszadobja
kérdéshely	a vizsgaterv egy pontja (fogalom, típus, Bloom-szint), amelyből egy kérdés készül
konfiguráció	a kísérlet egy beállítása (E0, E1, . . .), amely a referenciájától egy tényezőben tér el
kulcs	a feleletválasztós kérdés megjelölt helyes válasza
naiv RAG	az éles rendszer jelenlegi generálási módja (E0): a feladatleírással visszakeresett három darab és a kérés egy promptban
szivárgás	a kulcs szinte szó szerint szerepel a kérdés törzsében
teljes dokumentumos prompt	a teljes dokumentum és a kérés egy promptban (B-doc-L helyben, B-doc-S a szervermodellel)
vizsgaterv	a vizsga előre rögzített szerkezete kérdéshelyenként
F, G, A, V	formai megfelelés, alátámasztottság, vak megoldhatóság, disztraktor-validitás
Q	minőségi index, $(F + G + A + V)/4$
κ, α	Cohen-féle egyezési, illetve Krippendorff-féle megbízhatósági együttható
r_{rb}, $\tilde{p}$	rangbiszeriális hatásméret, illetve Holm-korrigált p-érték

1. Bevezetés

Ez a fejezet a problémát, a Mimir jelenlegi állapotát, a kutatási kérdéseket, a hipotéziseket és a hozzájárulásokat mutatja be.

1.1. Motiváció

A feleletválasztós kérdés (*multiple-choice question*, MCQ) gépi úton javítható és nagy létszámú kurzusokon is skálázható, előállítása azonban drága: egy jó kérdés törzse önmagában is érthető, pontosan egy válaszlehetősége helyes a tananyag szerint, a helytelen válaszok (*disztraktorok*) pedig hihetők, de igazolhatóan hibásak [1, 2]. A nagy nyelvi modellek (*large language model*, LLM) óta a legelterjedtebb megoldás, hogy az oktató egy felhőben futó csevegő asszisztenstől kér kérdéseket a jegyzetéből. A modellek képesek kérdéseket és disztraktorokat fogalmazni [3], de hajlamosak a forrás által nem alátámasztott állításokra [4]. Ezt a munkafolyamatot a továbbiakban *közvetlen megközelítésnek* nevezzük.

1.2. Problémafelvetés

A közvetlen megközelítés kényelmes, de az oktatási alkalmazás szempontjából négy gyengesége van.

(P1) **A helyesség nincs ellenőrizve.** Semmi sem garantálja, hogy a megjelölt helyes választ (a *kulcsot*) a dokumentum alátámasztja, és hogy a disztraktorok valóban hamisak; az önellenőrzés ezt csökkentheti, de nem szünteti meg [5].

(P2) **A szerkezet és a lefedettség nincs kontrollálva.** A kért darabszám, típus és nehézség csak kérés a promptban, és a hosszú bemenetet a modellek egyenetlenül használják [6], így a kérdések a dokumentum néhány részére tömörülhetnek.

(P3) **Adatvédelem.** A tananyag személyes adatot is tartalmazhat; a felhőszolgáltató az adatkezelés címzettjévé válik [7], és az intézmény elveszíti a kontrollt a tartalom felett.

(P4) **Függés a nagy, távoli modellektől.** A teljes dokumentum egyetlen promptban hosszú kontextust és nagy modellt igényel, a saját, fogyasztói hardveren futtatható kis modellek kontextusa és memóriája viszont korlátos.

A P1 és a P2 a *módszer* hiányából fakad: ha a vizsga szerkezete, a kérdések forrása és az ellenőrzés nem önálló lépések, sem mérni, sem kikényszeríteni nem lehet őket. A P3 és a P4 egymást erősíti: a helyi futtatás megoldaná az adatvédelmi problémát, de a kis modellek éppen a hosszú, egylépéses feladatban a leggyengébbek. Kiinduló gondolatunk ezért az, hogy rövid, egyenként ellenőrizhető lépésekre bontva egy fogyasztói grafikus kártyán (GPU) futó kis modell is megbízható vizsgát állíthat elő.

1.3. A rendszer állapota és a dolgozat célja

A Mimir fejlesztési fázisban lévő rendszer. Éles szolgáltatásai ma a naiv visszakereséses megoldást (*naiv RAG*, E0) futtatják: a modell a feladatleírással visszakeresett három dokumentumrészletet (darabot) kapja egy promptban. A lépésekre bontott tervezett folyamat a saját kiértékelő keretrendszerünkben készült el, ahol minden lépése külön mérhető. A dolgozat célja *mérésen alapuló döntés* arról, melyik megoldás kerüljön a rendszerbe – a legjobb, a leggyorsabb és a legrobusztusabb, külön a 8 és a 12 GB-os GPU-szinten. A mérések a kiinduló gondolatot pontosították; a dolgozat fő állítása:

> *Fogyasztói GPU-n futó kis modellekkel a vizsgakérdések minőségét elsősorban a választott modell és a visszakeresés lekérdezése határozza meg; a feladat lépésekre bontása gyenge modellnél nélkülözhetetlen, erős modellnél pedig az ellenőrizhetőséget adja. Ezt egy saját, nyílt kiértékelő keretrendszerrel, 30 dokumentumon és három modellen mértük, és ebből döntöttük el, mi kerül a rendszerbe.*

1.4. Kutatási kérdések és hipotézisek

RQ1 A strukturált generálás – tervezés, kérdésenkénti forráshoz kötés és ellenőrzés – érvényesebb és jobban lefedő vizsgát ad-e, mint ha a modellnek a dokumentumot (vagy annak visszakeresett részleteit) egyetlen promptban adjuk át?

RQ2 Mennyivel járulnak hozzá a minőséghez az egyes komponensek (tervező, ellenőrző, fogalomgráf, hibrid keresés, darabolás), és mennyibe kerülnek futási időben és modellhívásban?

RQ3 Mennyire közelíti meg egy fogyasztói GPU-n (8–12 GB) futó, 4 bitre kvantált kis modell egy nagy, szerveren futó modell teljesítményét, és hogyan függ az eredmény a választott helyi modelltől?

A hipotéziseket a 7.1. szakasz értékeli; a konfigurációk (E0, E1, ...) a kísérlet egy-egy beállítását jelölik (4.3. szakasz).

1. Hipotézis (Tervezés)**.** Azonos generátormodell mellett a vizsgaterv (E1) a naiv visszakereséses alapvonalhoz (E0: szemantikus darabolás, a teljes vizsgához három visszakeresett darab) képest növeli a kérdések alátámasztottságát és a vizsga lefedettségét, a formai megfelelés romlása nélkül.

2. Hipotézis (Ellenőrzés)**.** Az ellenőrző lánc (E2) a tervezéshez (E1) képest tovább növeli az alátámasztottságot és a vak megoldhatóságot; az ellenőrző ítélete pozitívan egyezik a független bíró ítéletével ($\kappa > 0$).

3. Hipotézis (Lefedettség)**.** A teljes dokumentumot egyetlen promptban kapó alapvonal lefedettsége – modellmérettől függetlenül – alacsonyabb, mint a tervezett változatoké.

4. Hipotézis (Helyi vs. szerver)**.** A helyi kis modell a tervezett és ellenőrzött folyamatban a szervermodell naiv változatának minőségi indexét megközelíti (különbség < 0,1), miközben fogyasztói GPU-n fut.

5. Hipotézis (Mérés)**.** A generátoroktól eltérő modellcsaládba tartozó nyelvi modell (bíró) ítéletei az oktatói értékelésekkel legalább elfogadható megbízhatósággal egyeznek (Krippendorff-$\alpha \geq$ $\geq 0{,}667$).

1.5. Hozzájárulások

(1) **Generálási módszer:** vizsgaterv, kérdéshelyenkénti keresés, forráshivatkozás, ellenőrző lánc (3. fejezet).
(2) **Helyi architektúra és megfelelés:** helyi modell, törlődő vektortár, GDPR és MI-rendelet (3. fejezet).
(3) **Saját, nyílt kiértékelő keretrendszer:** 14 egytényezős konfiguráció, független bíró, statisztika (4. fejezet).
(4) **A módszerek kiértékelése:** a naiv RAG törékenységének oka és a komponensek hatása (5. fejezet).
(5) **A modellek kiértékelése:** három helyi modell azonos dokumentumokon, két GPU-szint (6. fejezet).
(6) **Mérési tanulságok:** szivárgás, csendes tartalékágak, $\kappa \approx 0$, hiányzó bírói ítéletek (5. fejezet).
(7) **Gyakorlati eredmény:** a döntés arról, mi kerül a rendszerbe, GPU-szintenként (7. fejezet).

1.6. A dolgozat felépítése

A 2. fejezet a hazai és nemzetközi irodalmat és a jogi keretet tekinti át, és megfogalmazza a kutatási rést. A 3. fejezet a rendszert, a tervezett módszert és a megfelelés helyzetét, a 4. fejezet a kiértékelési módszertant mutatja be. Az 5. fejezet a módszer lépéseinek hatását, a 6. fejezet a modelleket értékeli; a 7. fejezet az eredményeket az irodalommal összeveti, és meghozza a döntést, a 8. fejezet pedig összefoglal. A függelék a módszer és az eredmények részleteit (A. és B. függelék), a promptokat, a rubrikát, a reprodukálás lépéseit és az OTDK kötelező elemeit tartalmazza.

2. Szakirodalmi áttekintés

Ebből a fejezetből az olvasó megtudja, mit vár el a szakirodalom egy jó feleletválasztós kérdéstől, mely megközelítések próbálták eddig gépi úton előállítani, és ezek mit oldanak meg a bevezetés négy problémájából: a kulcs helyességéből (P1), a vizsga szerkezetéből és lefedettségéből (P2), az adatvédelemből (P3) és a nagy, távoli modellektől való függésből (P4). A munkákat nem egyenként ismertetjük, hanem azt vizsgáljuk, mit visznek közelebb a megoldáshoz, és hol hagynak rést. A módszertani irodalom után a magyar nyelvtechnológiai előzmények, a jogi keret (GDPR, Infotv., MI-rendelet) és a kutatási rés összevetése következik.

2.1. A jó feleletválasztós kérdés és a Bloom-taxonómia

A feleletválasztós kérdés (*multiple-choice question*, MCQ) három részből áll: a *törzsből* (a kérdés vagy a befejezendő állítás), a *kulcsból* (a helyes válasz) és a *disztraktorokból* (a helytelen, de hihető válaszlehetőségek). Népszerűségét az adja, hogy gépileg, gyorsan és objektíven javítható; ára az, hogy jó kérdést írni nehéz.

A kérdésírás szabályait Haladyna, Downing és Rodriguez [1] foglalta össze 31 irányelvben. A tartalmi irányelvek szerint egy kérdés egyetlen, fontos tanulási célt mérjen; a formaiak szerint a törzs önmagában is érthető legyen és kerülje a tagadást; a disztraktorokra vonatkozók szerint a helytelen opciók legyenek hihetők, egymást kizárók, és formailag ne különbözzenek feltűnően a kulcstól, nehogy „árulkodó jelet” adjanak. Hogy ezek nem esztétikai kérdések, azt Downing [8] egy orvosi vizsgán mutatta meg: a szabálysértő kérdések miatt a hallgatók 10–15 %-a került a „nem felelt meg” kategóriába, akik a hibás kérdések nélkül átmentek volna. Egy gépi rendszernél tehát nem elég, hogy a kérdések „jónak tűnjenek”: a szabályok betartását ellenőrizni és mérni kell. Ez adja a P1 tartalmát: a helyes kérdéshez igaz kulcs, hamis, de hihető disztraktorok és árulkodó jel nélküli törzs kell.

A disztraktorok számáról Rodriguez [9] metaanalízise azt találta, hogy a legtöbb esetben három opció is elegendő, mert a negyedik és ötödik ritkán „működik”. Tarrant és munkatársai [10] szerint a disztraktorok jelentős része *nem funkcionáló*, vagyis a hallgatók kevesebb mint 5 %-a választja, Gierl és munkatársai [2] áttekintése pedig rámutat, hogy az ilyen disztraktor gyakorlatilag csökkenti az opciók számát, és növeli a találgatással elérhető pontszámot. A Mimir a Moodle-ban megszokott négyopciós formát követi, de a disztraktorok *minőségét* – hamisak és témába vágók-e – külön mutatóval méri (4.5. szakasz).

A kérdések kognitív szintjének leírására Bloom taxonómiáját használjuk Anderson és Krathwohl átdolgozott változatában [11]. Ez hat, egymásra épülő szintet különít el: *emlékezés*, *megértés*, *alkalmazás*, *elemzés*, *értékelés* és *alkotás*; feleletválasztós kérdéssel az első öt mérhető. Scully [12] szerint magasabb rendű gondolkodás is mérhető így, ha a törzs új helyzetet ír le, a gyakorlatban mégis a tényfelidéző kérdések dominálnak, mert ezeket a legkönnyebb megírni.

Ugyanez várható egy nyelvi modelltől is, ha maga dönti el, milyen kérdést ír. A Mimir ezért a kért nehézséghez előre rögzített Bloom-szint-eloszlást rendel, és azt a vizsgatervben kérdésenként kiosztja (3.6.3. szakasz); a lefedettség (P2) így a témák mellett a kognitív szintekre is vonatkozik.

Hogy a kérdésírás milyen munkaigényes, azt a hazai tudásmérés is mutatja. A Szegedi Tudományegyetem eDia online diagnosztikus mérési rendszerének [13] feladatbankjai összesen több mint 25 000 feladatot tartalmaznak; ezeket képzett feladatírók készítik tartalmi keretrendszerek alapján, több lépcsőben lektorálják, majd hallgatói mintán kipróbálják. Ehhez képest egy gépi rendszer *vázlatot* adhat: a lektorálást az oktatói jóváhagyás pótolhatja, a kipróbálást nem. A klasszikus *tételelemzés* (nehézség, megkülönböztető erő) ugyanis valódi hallgatói válaszokat igényel; a generált vizsgák ilyen vizsgálata a további munka része (8. fejezet).

2.2. Automatikus kérdésgenerálás: a szabályoktól a nagy nyelvi modellekig

Az automatikus kérdésgenerálás (*automatic question generation*, AQG) több évtizedes terület; Kurdi és munkatársai [3] szisztematikus áttekintése 93 oktatási célú rendszert elemzett. A fejlődésben három generáció különíthető el, és mindegyik másképp viszonyul a P1–P4 problémákhoz.

Szabály- és sablonalapú rendszerek. Az első generáció a szöveget nyelvtanilag elemzi, megkeresi a „kérdezhető” mondatrészeket, és transzformációs szabályokkal kérdő mondattá alakítja őket. Mitkov és Ha rendszere [14] a fontos főnévi csoportokat választja kulcsnak, és egy lexikai adatbázis rokon fogalmait ajánlja disztraktornak. Heilman és Smith [15] a *túlgenerálás és rangsorolás* elvét vezette be: a szabályok sok jelöltet adnak, amelyek közül egy statisztikai modell választja ki a legjobbakat. Hazai példa a Miskolci Egyetem rendszere [16], amely Python-programrészletekből ontológia és egy nyílt kérdésgeneráló keretrendszer segítségével ír kérdéseket. Ezek a rendszerek helyben futnak, és a kulcs a forrásból származik, így a P1-et részben, a P3-at és a P4-et teljesen megoldják. A kérdések viszont merevek, többnyire mondat-átfogalmazások, a vizsga szerkezetéről (P2) nem döntenek, és minden nyelvhez külön szabályrendszer kell – a toldalékoló magyarhoz különösen sok.

Neurális rendszerek. A második generációt a nagy, kézzel annotált adatkészletek tették lehetővé, például a Wikipédia-bekezdésekhez írt, több mint százezer kérdés–válasz párt tartalmazó SQuAD [17]. Du és munkatársai [18] ezeken tanítottak kódoló–dekódoló hálózatot, amely a bekezdésből és a kiválasztott válaszból szóról szóra állítja elő a kérdést. A kérdések folyékonyabbak, de a tanítóadat stílusát követik, és semmi sem garantálja, hogy a forrásból megválaszolhatók: a P1 itt romlik, mert a törzs és a kulcs kapcsolata már tanult valószínűségből adódik.

A *disztraktorgenerálás* külön irány; Alhazmi és munkatársai [19] újabb áttekintése a tudásbázisra épülő, a korpuszalapú és a generatív módszereket veti össze. Megállapításuk szerint a generatív módszerek adják a legtermészetesebb disztraktorokat, de gyakori hibájuk, hogy egy disztraktor valójában szintén helyes, vagy nyilvánvalóan abszurd. Pontosan ezt a két hibatípust

vizsgálja disztraktoronként a Mimir ellenőrzője és a bíró.

Nagy nyelvi modellek. A harmadik generációban a kérdéseket egy nagy nyelvi modell írja utasítás alapján. Wang és munkatársai [20] GPT-3-mal generáltak tankönyvi kérdéseket, amelyek egy része emberi értékelés szerint az emberek által írtakkal összemérhető volt. Doughty és munkatársai [21] programozási kurzusokon 651 GPT-4-es és 449 oktatói kérdést vetettek össze hatszempontos rubrikával. A gépi kérdések 81,7 %-a minden szempontnak megfelelt, 4,9 %-ukban viszont több helyes válasz is volt (az oktatóiaknál 1,1 %), 4,0 %-ukban pedig egy nyilvánvalóan hibás disztraktor elárulta a kulcsot (0,9 %); ezek átnézés nélkül a vizsgába kerültek volna. Bitew és munkatársai [22] a promptba tett, már jóváhagyott példakérdésekkel javították a disztraktorokat; ugyanez a csoport készítette az OpenStax-tankönyvekhez írt, szakértők által ellenőrzött EduQG adatkészletet [23], amelynek angol dokumentumait mi is használjuk. A kis modellek oldaláról Fawzi és munkatársai [24] kimutatták, hogy egy kis modell oktatási szövegeken végzett további tanítással a nagy modellekhez mérhető kérdéseket írhat.

Mit oldanak meg, és mit nem? A harmadik generáció a nyelvi minőséget megoldotta, a P1-et azonban csak statisztikailag javítja: a hibák aránya kicsi, de nem nulla, és a hibás kérdést semmi sem jelöli meg. A P2-t a munkák nem vizsgálják, mert egyenként kérnek kérdést, a vizsgát pedig ember állítja össze. A P3-at és a P4-et a felhőben futó nagy modellek előidézik; Fawzi és munkatársai kis modellje kivétel, de minden új tárgynál további tanítást igényel. A kész kérdéseket utólag, emberi értékeléssel mérik; arra, hogy a generálás *folyamata* hogyan biztosíthatja a helyességet és a lefedettséget, kevés figyelem jut. A Mimir ezen a ponton kíván hozzájárulni.

A kiértékelés problémája. Mulla és Gharpure [25] szerint a rendszerek jelentős részét a gépi fordításból átvett, referencia-átfedésen alapuló metrikákkal (BLEU, ROUGE) mérik, amelyek azt számolják, hány szó egyezik a generált és egy ember írta referenciakérdés között. Egy vizsgakérdés azonban egyetlen egyező szó nélkül is lehet kiváló, hibás kulccsal pedig használhatatlan. Kurdi és munkatársai [3] azt is kimutatták, hogy a humán értékelések jellemzően kis mintán készülnek, és ritkán ellenőrzik a kulcs helyességét. Munkánkban ezért a helyességet a forrással szembeni ítéletekkel mérjük, a referenciakérdéseket pedig csak segédmutatókhoz használjuk (4. fejezet).

2.3. Nagy nyelvi modellek röviden

A mai nyelvi modellek a transzformer-architektúrára [26] épülnek, és a szöveget *tokenekre* (szavakra vagy szódarabokra) bontva dolgozzák fel. A *kódoló* modellek (például a BERT [27]) egy szöveg jelentését egy vektorba (*beágyazásba*) sűrítik, és keresésre használják őket; a *dekódoló*, generatív modellek (például a GPT-család [28]) a szöveget tokenenként állítják elő, a csevegő változatokat pedig utasításkövetésre is hangolják [29]. A Mimir kódoló modellel darabol és keres, generatív modellel ír kérdést. A toldalékoló magyar szavak több tokenre bomlanak, mint az angolok, így ugyanaz a tartalom magyarul több helyet foglal a modell bemenetében

(*kontextusában*). Két szöveg hasonlóságát a beágyazásaik koszinuszával mérjük:

$$\cos(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \, \|\mathbf{v}\|}, \tag{2.1}$$

amelynek értéke 1, ha a két vektor azonos irányú, és annál kisebb, minél jobban eltér a két szöveg jelentése. A darabolás, a keresés, a duplikátumszűrés és a lefedettség mérése is erre épül.

Hallucináció. A nyelvi modellek legfontosabb gyengesége a *hallucináció*: folyékony, magabiztos, de a forrással vagy a valósággal ellentétes szöveg előállítása. Ji és munkatársai [4] két típust különítenek el. Az *intrinzikus* hallucináció ellentmond a forrásnak (például a forrás szerint a kávé a 17. században jutott el Európába, a modell a 9. századot írja), az *extrinzikus* pedig olyan állítás, amely a forrásból sem nem igazolható, sem nem cáfolható. A kérdésgenerálásban mindkét típus súlyos: ha a kulcs ellentmond a forrásnak, a felkészült hallgató veszít pontot; ha a forrásban nem szerepel, a kérdés a tananyagból nem válaszolható meg. Mivel a hallucináció a valószínűségi szövegelőállítás következménye, nem alkalmi hiba, a kulcs helyességét a forrásból kell eldönteni, nem a modell magabiztosságából. Ezért tekintjük a legfontosabb mutatónak az *alátámasztottságot*, vagyis azt, hogy a forrás igazolja-e a kulcsot.

Strukturált kimenet. A generátornak gépileg feldolgozható JSON-kimenetet kell adnia, de egy kis modell időnként hibás JSON-t ír. Ezt vagy utólagos ellenőrzéssel és újrakéréssel, vagy *korlátozott dekódolással* lehet kezelni, amely generálás közben csak a formátumnak megfelelő tokeneket engedi meg [30]. A Mimir az előbbit alkalmazza: a formai hibát az ellenőrző első lépése szűri.

2.4. Visszakereséssel kiegészített generálás

A hallucináció elleni első stratégia, hogy a modell ne csak a paramétereiben tárolt tudásra támaszkodjon. A visszakereséssel kiegészített generálás (*retrieval-augmented generation*, RAG) során a rendszer a válasz előtt releváns szövegrészleteket keres egy gyűjteményből, és ezeket a promptba téve kéri a választ. A RAG nevet Lewis és munkatársai [31] vezették be, akik egy sűrű keresőt és egy generatív modellt kapcsoltak össze.

Gao és munkatársai [32] áttekintése három paradigmát különít el. A *naiv RAG* egyetlen keresést és egyetlen generálást végez: a lekérdezéshez legjobban hasonló néhány részletet a promptba másolja. A *fejlett RAG* a keresés előtt és után is javít (például átírja a lekérdezést vagy újrarangsorolja a találatokat). A *moduláris RAG* a keresési, generálási és ellenőrzési lépéseket szabadon kombinálja. A Mimir tervezett generálási folyamata ebben a szóhasználatban moduláris RAG: a keresés a vizsgaterv minden pontjára külön fut, és az ellenőrzés eredménye visszahat rá.

Lexikális és sűrű keresés. A *lexikális* keresés szavak alapján indexel; legismertebb képviselője a BM25 [33], amely azokat a részleteket rangsorolja előre, amelyekben a lekérdezés szavai gyakoriak, de a gyűjteményben ritkák. Gyors, nem igényel tanítást, és jól kezeli a szakkifejezéseket

és tulajdonneveket, de a szinonimákat és a magyar ragozott alakokat nem ismeri fel. A *sűrű* keresés a szövegeket egy közös vektortérbe képezi, és a hasonlóságot (2.1) szerinti koszinusszal méri. A DPR [34] megmutatta, hogy ez a nyílt kérdésmegválaszolásban felülmúlhatja a BM25-öt. Az általunk használt többnyelvű E5 modell [35] nagy szövegpárgyűjteményen, kontrasztív tanítással készült, és a magyart is támogatja. A keresők összehasonlító mérései szerint azonban egyik módszer sem a legjobb minden adatkészleten [36], és magyarra sem egyértelmű a sűrű keresés előnye: a MILQA kérdés–válasz adatbázison a BM25 jobb visszakeresést adott a vizsgált vektoros megoldásoknál [37]. Ezért gyakori a *hibrid* keresés, amely a két rangsort a reciprok rangfúzióval (RRF) [38] egyesíti: egy részlet annál több pontot kap, minél előrébb áll az egyes rangsorokban. A Mimir egyik konfigurációja (E2h) ezt a változatot vizsgálja (4.3. szakasz).

Lekérdezés-átírás. A keresés minősége a lekérdezésen is múlik: ha az rövid, általános vagy más stílusú, mint a keresett szöveg, a legjobb kereső is rossz találatot ad. A HyDE [39] ezért egy nyelvi modellel előbb egy „hipotetikus” választ írat, és annak beágyazásával keres, mert az jobban hasonlít a keresett szövegre, mint maga a kérdés. Vizsgagenerálásban ez kulcskérdés. A naiv RAG lekérdezése ugyanis egy *feladatleírás* („10 feleletválasztós kérdés, könnyű”), amely semmit sem mond a keresett tartalomról. A Mimir vizsgaterve a tervező által javasolt tartalmi fogalmakkal keres, ami lényegében lekérdezés-átírás. Eredményeink szerint ez a különbség áll a naiv RAG leggyakoribb kudarca mögött (5. fejezet).

Darabolás. A keresés egysége a *darab*: a dokumentumot rövidebb részletekre kell bontani. A rögzített hosszúságú ablak mondatok közepén is vághat; a *szemantikus* darabolás ott vág, ahol a szomszédos mondatok beágyazásainak hasonlósága hirtelen lecsökken, vagyis valószínűleg témaváltás van. Qu, Tu és Bao [40] szerint a szemantikus darabolás előnye adatkészletfüggő és gyakran kisebb a vártnál. Ezért a darabolási stratégiát külön konfigurációkkal (E5a–E5c) vizsgáljuk, ahelyett hogy eleve jobbnak tekintenénk a szemantikus változatot (3.6.1. szakasz). Eredményeink szerint a szemantikus darabolás rövid, tartalom nélküli darabokat is létrehozhat, amelyekhez éppen a feladatleírás típusú lekérdezés áll a legközelebb.

Forráshivatkozás. A visszakeresés nem garantálja, hogy a válasz a visszakeresett szövegen alapul. Ezért egyre több rendszer kéri, hogy a modell *hivatkozzon* a felhasznált részletre. Az ALCE benchmark [41] azt méri, hogy a hivatkozások valóban alátámasztják-e az állításokat, és még a legjobb modelleknél is sok hiányos vagy pontatlan hivatkozást talált. Rashkin és munkatársai [42] szerint egy állítás akkor *tulajdonítható* egy forrásnak, ha egy átlagos olvasó a forrás alapján egyetértene vele. A Mimir minden kérdéshez megköveteli a kulcsot igazoló darabok azonosítóját, és a bíró is ehhez hasonló, olvasóközpontú definícióval dönt az alátámasztottságról.

Gráfalapú keresés és hosszú kontextus. A GraphRAG [43] a gyűjteményből nyelvi modellel fogalom- és kapcsolatgráfot épít, és ennek csoportjai alapján válaszol; a Mimir ennek egy könnyített, egyetlen dokumentumra korlátozott változatát vizsgálja (E3, 3.6.7. szakasz). A RAG valódi alternatívája az, hogy a teljes dokumentumot egyetlen promptban adjuk át, ahogy az oktatók a gyakorlatban teszik. A névleges kontextushossz viszont nem azonos a ténylegesen

kihasznált hosszal: Liu és munkatársai [6] szerint a modellek a bemenet elején és végén lévő információt jobban használják, mint a közepén lévőt, a RULER benchmark [44] szerint pedig a teljesítmény a hossz növelésével folyamatosan romlik. Li és munkatársai [45] összevetésében elegendő erőforrás mellett a hosszú kontextus átlagosan jobb, a RAG viszont lényegesen olcsóbb, és a lekérdezések több mint 60 %-án (elemzésük szerint 63 %-án) a két megközelítés pontosan azonos előrejelzést ad. Ebből két várakozás következik: a teljes dokumentumot kapó modell kérdései a dokumentum egyes részeire tömörülhetnek (3. hipotézis), és a hosszú kontextus egy kis kártyán a memóriaigény miatt korlátos (3.5. szakasz). Ugyanakkor egy erős modellnél a teljes dokumentumos prompt komoly versenytárs, ezért ezt is mérjük.

Mit old meg a visszakeresés, és mit nem? A RAG a P4-et kezeli a legközvetlenebbül: rövid kontextussal működik, ezért kis, helyi modell is használhatja, ami a P3-at is lehetővé teszi. A P1-et csak közvetve segíti, mert az ALCE mérései szerint a promptba tett forrásból nem következik, hogy a modell arra támaszkodik. A P2-t a naiv RAG kifejezetten rontja, mert tartalom nélküli lekérdezéssel a dokumentum kis részét látja. A fejlett és moduláris változatok egy-egy hiányt pótolnak, de jellemzően nagy modellel és kérdésmegválaszolásban értékelték őket, nem vizsgagenerálásban.

2.5. Feladatfelbontás és ellenőrzés

A dolgozat alapgondolata, hogy egy összetett feladatot rövid, jól körülhatárolt lépésekre bontva egy kisebb modell is megbízhatóbban teljesít. Wei és munkatársai [46] szerint a modell összetett feladatokban pontosabb, ha lépésenkénti gondolatmenetet ír (*chain-of-thought*). A *least-to-most* módszer [47] a problémát előbb részfeladatokra bontja, majd ezeket egymás után oldja meg, a *Plan-and-Solve* [48] pedig arra kéri a modellt, hogy előbb tervet készítsen, és csak utána hajtsa végre – ez a vizsgaterv gondolatának közvetlen megfelelője. Ezek a módszerek a felbontást a promptra bízzák, így a terv betartása ugyanúgy a modell utasításkövetésén múlik, mint a közvetlen megközelítésben. Wu, Terry és Cai [49] *MI-láncai* ezzel szemben a programban kötik össze a nyelvi modell egymásra épülő hívásait. Felhasználói vizsgálatuk szerint a láncok nemcsak jobb eredményt adtak, hanem *átláthatóbbak* és jobban *irányíthatók* is voltak, mert minden köztes lépés látható és módosítható.

A Mimir a második irányba tartozik: a szerkezeti döntéseket (hány kérdés, melyik témából, milyen szinten) a program hozza meg, a nyelvi modell csak jól körülhatárolt részfeladatot végez (fogalmak javaslása, egy kérdés megírása, egy ítélet). Így minden lépés rövid kontextussal dolgozik, ami egy kis modellnek kedvez (P4); a szerkezet a program által kikényszerített tulajdonság (P2); minden köztes eredmény visszakövethető; és a lépések egyenként cserélhetők, ami lehetővé teszi az egytényezős kísérleti tervet. Az ár a több modellhívás és a hosszabb futási idő. A hivatkozott eredményeket többnyire nagy modellekkel, érvelési feladatokon mérték; hogy a felbontás kis modellnél vizsgagenerálásban mennyit ér, azt az 5. és a 6. fejezet méri.

Ellenőrzés és önjavítás. A hallucináció elleni második stratégia a kimenet utólagos ellenőrzése. A Self-Refine [50] a modellel értékelteti és javíttatja saját kimenetét, a Chain-of-Verification [51] ellenőrző kérdéseket tesz fel a saját válaszáról, és az eltérések alapján javít. A FActScore [52] a szöveget atomi tényekre bontja, és mindegyiket külön veti össze egy tudásforrással. Egy másik ág a *természetes nyelvi következtetés* (*natural language inference*, NLI): annak eldöntése, hogy egy állítás következik-e egy szövegből, ellentmond-e neki, vagy egyik sem. Az ilyen modellek az összefoglalók tényszerűségének ellenőrzésére is alkalmasak [53]. Az alátámasztottság eldöntése pontosan ilyen feladat: következik-e a forrásból, hogy a megjelölt kulcs a helyes válasz?

Az önellenőrzésnek azonban korlátai vannak. Huang és munkatársai [5] szerint *külső visszajelzés nélkül* az önjavítás érvelési feladatokban nem javít, sőt ronthat is. Snell és munkatársai [54] ugyanakkor kimutatták, hogy a futás közben elköltött többletszámítás (több minta, ellenőrzés, újrapróbálkozás) bizonyos feladatokban helyettesítheti a nagyobb modellt. A két eredmény együtt azt sugallja, hogy az ellenőrzés akkor hasznos, ha *külső* információt visz a folyamatba: determinisztikus szabályokat, a forrásszöveget vagy egy másik modell ítéletét. A Mimir ellenőrzője ezért olcsó szabályokat (forma, hivatkozás, szivárgás, duplikátum) kombinál a forrással szembeni, nyelvi modellel végzett ítéletekkel, és a hibát visszajelzésként adja vissza a generátornak (3.6.6. szakasz).

A visszacsatolásnak saját veszélye is van. Goodhart törvénye Strathern megfogalmazásában: ha egy mérőszám céllá válik, megszűnik jó mérőszám lenni [55]. Ha a generátort addig javíttatjuk, amíg át nem megy az ellenőrzésen, olyan megoldást is találhat, amely az ellenőrzést kielégíti, a valódi célt viszont nem. A pilot vizsgálatunk egy ilyen esetet tárt fel: a legolcsóbb út a forrásmondat szinte szó szerinti bemásolása volt a törzsbe (*szivárgás*, 5.1. szakasz).

2.6. Kis nyelvi modellek helyi futtatása

A helyi futtatás feltétele, hogy a modell elférjen egy fogyasztói grafikus kártya memóriájában. Ma több nyílt modellcsalád ér el jó teljesítményt néhány milliárd paraméterrel, például a Qwen2.5 [56], a Llama 3.1 [57] és a Gemma 3 [58]; ezek a kisebb méretet több és jobb minőségű tanítóadattal ellensúlyozzák. A pilotban és az előzetes vizsgálatban a Qwen2.5-7B, a fő vizsgálatban a Gemma 3 12B és a NYTK magyarra továbbtanított PULI-LlumiX 8B modellje [59] a generátor (a magyar modellekről a 2.8. szakasz szól). Természetes várakozás, hogy egy magyarra hangolt modell magyar tananyagból jobb kérdéseket ír, mint egy általános többnyelvű modell; ezt a fő vizsgálatban közvetlenül teszteljük (6. fejezet).

A memóriaigény fő összetevője a súlyok mérete. Egy 7 milliárd paraméteres modell 16 bites ábrázolásban paraméterenként 2 bájtot, összesen 14 GB-ot foglal. A *kvantálás* a súlyokat kevesebb biten tárolja: a GPTQ [60] a tanítás után 3–4 bitre tömörít. A helyi futtatás de facto szabványa a `llama.cpp` [61] GGUF formátuma és csoportos K-kvantálása; az általunk használt Q4_K_M változat átlagosan kb. 4,8 bitet használ súlyonként, és erre épül az Ollama futtatókörnyezet [62] is. Átfogó kiértékelések szerint a 4 bites súlykvantálás általános feladatokon

csak kis pontosságvesztést okoz [63]. A memóriaigény második összetevője a *kulcs–érték (KV) gyorsítótár*, amely a már feldolgozott tokenek köztes eredményeit tárolja, így a kontextus hosszával arányosan nő. Mindezek alapján egy 7–8B modell 4 bites változata egy 8 GB-os, a Gemma 3 12B egy 12 GB-os fogyasztói kártyán futtatható; a számszerű becslést a 3.5. szakasz adja meg. A helyi futtatás tehát egyszerre kezeli a P3-at és a P4-et, de csak akkor, ha a módszer a kis modell rövidebb kontextusához és gyengébb utasításkövetéséhez igazodik; a kvantálási mérések pedig általános feladatokra szólnak, nem vizsgagenerálásra.

2.7. A kiértékelés: nyelvi modell mint bíró és a mérés megbízhatósága

Az emberi értékelés drága és lassú, ezért elterjedt, hogy egy erős nyelvi modell pontozza a kimenetet (*LLM-as-a-judge*); a dolgozatban ezt a kérdéseket pontozó, független nyelvi modellt *bírónak* nevezzük. Zheng és munkatársai [64] szerint egy erős bíró ítéletei közel annyira egyeznek az emberi preferenciákkal, mint az emberek ítéletei egymással. Chiang és Lee [65] hasonló eredményre jutott úgy, hogy a modell szó szerint ugyanazt az utasítást és értékelőlapot kapta, mint az emberi szakértők – ezt az elvet a mi rubrikánk is követi. A RAGAS [66] a RAG-rendszerek referencia nélküli, nyelvi modellel számolt hűség- és relevanciamutatóit javasolja. Ezek az egyezési eredmények főként párosított preferenciaítéletekre (melyik válasz a jobb) szólnak; a mi bíránk kérdésenként, egy forrásrészlethez mérve ítél, amire csak korlátozottan vihetők át.

A bírók torzításai jól dokumentáltak: a *pozíciós torzítás* az első vagy második helyen álló válasz előnyben részesítése [67], a *hossztorzítás* a hosszabb válaszoké, az *önpreferencia* pedig a saját modellcsalád szövegeié [68]. Ezért bíránk, a gpt-oss-120b [69] más modellcsaládba tartozik, mint bármelyik generátor (4.6. szakasz), ami az önpreferenciát csökkenti.

A bíró csak akkor érvényes mérőeszköz, ha ítéletei egyeznek az emberi szakértőkével. Két értékelő bináris ítéleteire Cohen-κ-t [70], több értékelőre és ordinális skálára Krippendorff-α-t [71] használnak; mindkettő azt méri, mennyivel nagyobb az egyezés a véletlenül várhatónál. Landis és Koch [72] skálája szerint 0,20 alatt csekély, 0,21–0,40 között gyenge, 0,41–0,60 között közepes, 0,60 felett erős az egyezés; Krippendorff szerint $\alpha \geq 0{,}8$ megbízható, 0,667 és 0,8 között óvatos következtetésre elegendő. A bíró oktatói validálását a 4.7. szakasz írja le.

A kísérletek megbízhatósága. Bouthillier és munkatársai [73] kimutatták, hogy a gépi tanulási eredményekben a véletlen tényezők okozta szórás gyakran összemérhető a közölt javulásokkal, így egyetlen futás alapján nem szabad két módszer között dönteni. Dror és munkatársai [74] szerint a nyelvtechnológiai cikkek jelentős része nem végez szignifikanciatesztet, vagy az adatokhoz nem illő próbát használ; a 0 és 1 közé szorított, ferde eloszlású mutatóknál a nemparaméteres próbák (például a Wilcoxon-próba) és a bootstrap a biztonságosabbak. Fontos a mérés *egysége* is: egy dokumentum tíz kérdése nem tíz független megfigyelés, ezért mi a dokumentumot tekintjük egységnek, és a sok összevetésből adódó véletlen „szignifikanciát” Holm-korrekcióval [75] szűrjük (4.8. szakasz). Veszélyt jelent az *adatszennyezés* is [76]: a nyilvános Wikipédia- és OpenStax-szövegek a modellek tanítóadatában is szerepelhettek, így a bíró a kérdést a forrás

nélkül, emlékezetből is megválaszolhatja.

Végül a mérés az oktatót is érinti. Parasuraman és Manzey [77] szerint a felhasználók hajlamosak túlságosan megbízni az automatikus rendszerek jelzéseiben (*automatizálási torzítás*): ha egy rendszer egy kérdést „ellenőrzöttnek" jelöl, az oktató kevésbé figyelmesen nézi át; a jelenséget az MI-rendelet is megnevezi (2.9. szakasz). Ezért az ellenőrző jelzéseit a Mimir felületén figyelmeztetésként, nem ítéletként jelenítjük meg, amíg megbízhatóságukat mérések nem igazolják.

2.8. A magyar nyelv és a hazai előzmények

A magyar két szempontból jelent külön kihívást. Agglutináló nyelv, így egy szótőnek sok alakja van („immunrendszer", „immunrendszert", „immunrendszerben"), ami a lexikális keresést nehezíti és a tokenszámot növeli. Emellett kis erőforrású nyelv: a MEGA kiértékelés [78] szerint a generatív modellek teljesítménye a kisebb erőforrású nyelveken jelentősen elmarad az angoltól, ezért egy kis modell magyar szövegében nyelvtani hibákra is számítani kell, amit a kiértékelésnek külön mérnie kell.

Magyar nyelvi modellek. Az első széles körben használt magyar kódoló a huBERT [79] volt. A HUN-REN Nyelvtudományi Kutatóközpont (NYTK) PULI-családjának első tagjairól az MSZNY 2023-on számoltak be [80]: egy BERT-Large, egy GPT-2 és egy 6,7 milliárd paraméteres GPT-3 típusú modellről; a BERT-Large több feladaton felülmúlta a huBERT-et, a GPT-3 típusú modellel pedig a szerzők az első magyar, néhány példás (*few-shot*) promptolási kísérleteket végezték. Ugyanebben az évben egy- és háromnyelvű GPT-modelljeiket is közölték [81]. A dolgozatban használt PULI-LlumiX 8B a Llama 3.1 magyar szövegeken folytatott további előtanításával készült [59]. A csoport 2025-ben a Llama 3.1 és a Qwen2.5 alapú, magyar utasításadatokon finomhangolt csevegő változatokat (ChatPULI) is leírt, amelyek mérésük szerint a magyar benchmarkokon és a többfordulós párbeszédben jobbak a korábbi PULI-modelleknél [82]. Ez a fő vizsgálat értelmezéséhez lényeges: mi az utólagos utasítás-hangolás nélküli, továbbelőtanított változatot mértük, így a PULI-ra vonatkozó következtetésünk erre a változatra szól (6. fejezet).

Magyar benchmarkok és kérdés–válasz rendszerek. A magyar nyelvértési feladatok egységes mérésére a HuLU benchmark [83] szolgál. A MILQA [37, 84] magyar Wikipédia-cikkekre épülő, az angol SQuAD 2.0 elveit követő kérdés–válasz adatbázis, eldöntendő, többrészes és számolást igénylő kérdéstípusokkal bővítve; adatforrásként mi is használjuk (4.2. szakasz). Erre épül a szegedi SHunQA nyíltkérdés-megválaszoló rendszer [85], amely a választ a forrásszövegben jelöli meg, hogy ellenőrizhető legyen. Ezek a munkák kérdésmegválaszolással foglalkoznak, de két tanulságuk átvihető: magyar szövegen a lexikális keresés erős alapvonal, és a forrásban megjelölt válasz teszi ellenőrizhetővé a rendszert.

Hazai kérdésgenerálás és oktatási MI-használat. Magyar nyelvű vizsgakérdés-generálásról publikált, rendszerszintű kiértékelést nem találtunk. A legközelebbi előzmény a Szegedi Tudo-

mányegyetem 2024–2025-ös, HUN-REN Cloudon futó projektje, amely a helyben futtatható nyelvi modellek tananyag alapú magyar kérdésgenerálását vizsgálta, és nehézségként a modellek eltérő magyar nyelvi képességét és a kérdésekkel szembeni összetett elvárásokat nevezte meg [86]; eredményeiről publikációt nem találtunk. Az igényt hazai felmérések is mutatják. Egy 1027 hallgatós felmérésben a válaszadók kb. 87 %-a használt már MI-eszközt, az aktív használat akadályai között pedig etikai (kb. 42 %) és adatvédelmi (kb. 30 %) aggályok is szerepeltek [87]. Egy 1103 egyetemi oktatót felölelő felmérés szerint az oktatók az MI-t főként rutinfeladatokra (fordítás, nyelvi ellenőrzés) használják, a mélyebb pedagógiai felhasználás háttérbe szorul [88]. A vizsgakészítés ilyen mélyebb felhasználás, amelyhez megbízható és adatvédelmi szempontból vállalható eszköz kell.

2.9. Jogi keret: adatvédelem és MI-rendelet

A P3 jogi kereteit két közvetlenül alkalmazandó uniós rendelet, a GDPR [7] és az MI-rendelet [89] adja, hazai kiegészítésekkel. Az áttekintés mérnöki olvasat, nem jogi tanácsadás: azt vizsgálja, milyen tervezési követelmények következnek ezekből. A megvalósítás állapotát a 3. fejezet tárgyalja.

2.9.1. Az általános adatvédelmi rendelet

Szerepek. A GDPR az *adatkezelőt* (aki a célt és az eszközöket meghatározza) és az *adatfeldolgozót* (aki az adatkezelő nevében, utasítása szerint dolgozik) különíti el. Az Európai Adatvédelmi Testület szerint a szerepet a tényleges tevékenység dönti el, és aki az adatot saját céljára is felhasználja, abban a körben maga is adatkezelő [90]. Egy felhőben futó csevegő asszisztens tehát akkor 28. cikk szerinti adatfeldolgozó, ha az intézménnyel kötött szerződés utasításhoz, titoktartáshoz, biztonsági intézkedésekhez, a további adatfeldolgozók jóváhagyásához és a szerződés végi törléshez köti. Ha az oktató saját fogyasztói fiókkal tölti fel a jegyzetét, ilyen garancia nincs; a szolgáltató címzett, és ha a tartalmat például modellfejlesztésre is felhasználja, e körben adatkezelő. A tananyagban szereplő harmadik személyek adatai így tudtuk nélkül kerülnek új adatkezeléshez.

Alapelvek, beépített adatvédelem, biztonság. Az 5. cikk alapelvei közül az *adattakarékosság* (csak a szükséges adat) és a *korlátozott tárolhatóság* (csak a szükséges ideig) hat közvetlenül a tervezésre: a dokumentum szövegére csak a generálás idejére van szükség, ezért a legkisebb kockázatú megoldás a feldolgozás utáni törlés. Az *elszámoltathatóság* naplózást kíván, de olyat, amely nem tárol tartalmat. A 25. cikk *beépített és alapértelmezett adatvédelmet* ír elő (például a vizsga mentése csak kérésre történjen), a 32. cikk a kockázattal arányos *biztonsági intézkedéseket* (álnevesítés, titkosítás, bizalmasság, integritás, rendszeres ellenőrzés). A helyi futtatás a továbbítás kockázatát szünteti meg, a hozzáférés-szabályozást nem pótolja.

Hatásvizsgálat, továbbítás, automatizált döntés. Valószínűleg magas kockázatú, különösen új technológiát alkalmazó adatkezelés előtt *adatvédelmi hatásvizsgálat* kell (35. cikk); generatív MI és esetleges hallgatói adatok mellett intézményi bevezetés előtt ez indokolt. A modell maga is kockázat: a tanítóadat egyes részletei a kész modellből visszanyerhetők [91], és az EDPB szerint egy MI-modell nem tekinthető automatikusan anonimnak [92]; ezért felhasználói tartalommal nem tanítunk modellt. Az EGT-n kívülre személyes adat csak a V. fejezet szerinti megfelelőségi határozat vagy megfelelő garanciák mellett továbbítható. Az Egyesült Államokba irányuló továbbítás alapja ma az EU–USA adatvédelmi keretrendszer [93], amelynek érvényességéről fellebbezési eljárás folyik [94]; a helyi futtatás ettől független. Végül a 22. cikk korlátozza a kizárólag automatizált, joghatással járó döntéseket: a kérdésgenerálás ilyet nem hoz, a hallgatói válaszok emberi felülvizsgálat nélküli pontozása viszont már ide tartozhat.

2.9.2. Az Infotv. és a NAIH

Az Infotv. (2011. évi CXII. törvény) [95] kijelöli a GDPR hatálya alá tartozó adatkezelésekre alkalmazandó hazai kiegészítő szabályokat (2. § (2) bekezdés), és létrehozza a felügyeleti hatóságot, a NAIH-ot; hazai üzemeltetésnél neki kell az incidenseket bejelenteni. A NAIH figyelemfelhívása szerint csevegőrobot használatakor lehetőleg ne töltsünk fel személyes adatot a szolgáltató felületére, mert ez előre nem látható adatkezeléshez vezethet, amelyért a feltöltő személyesen is felelhet [96]. A hazai bankok MI-használatáról szóló 2025-ös jelentése [97] az *árnyék-MI* jelenségét elemzi: a munkatársak a szervezet tudta nélkül használnak MI-eszközöket, így a szervezet elveszítheti a kontrollt az általa kezelt adatok felett. Jó gyakorlatként a nem saját infrastruktúrán futó eszközök korlátozását, illetve a felhasználási adatok modelltanítását kizáró vállalati szerződést említi. A jegyzetét saját fiókkal nyilvános csevegő asszisztensbe feltöltő oktató is árnyék-MI-t használ: a P3 a hazai hatóság által is megnevezett kockázat.

2.9.3. Az MI-rendelet

Hatály és kockázati osztályok. Az MI-rendelet a forgalomba hozott vagy üzembe helyezett rendszerekre vonatkozik; az azt megelőző kutatásra, tesztelésre és fejlesztésre – a valós körülmények közötti tesztelés kivételével – nem (2. cikk (8) bekezdés). A Mimir kiértékelő keretrendszere ebbe a körbe tartozik, egy egyetemi üzembe helyezés viszont már nem; ekkor a fejlesztő *szolgáltató*, az intézmény *alkalmazó*. A rendelet négy szintet különít el: (1) *tiltott gyakorlatok* (5. cikk), például az érzelemfelismerés oktatási intézményben; (2) *magas kockázatú* rendszerek (6. cikk, I. és III. melléklet) kockázatkezelési, dokumentációs, naplózási és emberi felügyeleti követelményekkel; (3) *átláthatósági kötelezettségek* (50. cikk); (4) *minimális kockázat*, külön kötelezettség nélkül. A beépített általános célú modellek (Qwen, Gemma, Llama-alapú PULI) kötelezettségei a modellek szolgáltatóit terhelik.

Oktatás a III. mellékletben. A III. melléklet 3. pontja szerint magas kockázatú (a) a felvétel eldöntése és a személyek intézményekhez rendelése; (b) a tanulási eredmények értékelése, akkor

is, ha az eredmény a tanulási folyamatot irányítja; (c) annak felmérése, milyen szintű oktatásban részesülhet valaki; és (d) a tiltott vizsgaviselkedés megfigyelése. A 6. cikk (3) bekezdése szerint egy ilyen rendszer mégsem magas kockázatú, ha nem jelent jelentős kockázatot, például mert egy értékelés *előkészítő feladatát* látja el – kivéve, ha profilalkotást végez; a kivételre hivatkozó értékelést dokumentálni kell (6. cikk (4) bekezdés).

Emberi felügyelet, MI-jártasság, átláthatóság. A 14. cikk szerint a magas kockázatú rendszer felügyelője értse a rendszer képességeit és korlátait, legyen tudatában az automatizálási torzításnak, és a kimenetet felülbírálhassa. A 4. cikk eredetileg 2025. február 2-tól a munkatársak megfelelő *MI-jártasságának* biztosítását írta elő; a 2026-os módosítás óta az MI-jártasság fejlesztésének *támogatását*, meghatározott szint nélkül [98]. Az 50. cikk szerint a felhasználót tájékoztatni kell, ha MI-rendszerrel érintkezik (1. bekezdés); a szintetikus szöveget generáló rendszer szolgáltatója a kimenetet géppel olvasható módon MI-generáltként jelöli (2. bekezdés); a nyilvánosság tájékoztatására közzétett MI-szöveget pedig fel kell tüntetni, kivéve, ha emberi szerkesztői ellenőrzésen ment át (4. bekezdés).

Alkalmazási határidők. A rendelet 2024. augusztus 1-jén lépett hatályba, és lépcsőzetesen alkalmazandó (2.1. táblázat). A Bizottság 2025. november 19-én „digitális omnibusz” csomagban (COM(2025) 836) javasolta egyebek mellett a magas kockázatú kötelezettségek halasztását. Ezt (EU) 2026/1744 rendeletként fogadták el; 2026. július 24-én hirdették ki, és 2026. július 27-én lépett hatályba [98]. A III. melléklet szerinti magas kockázatú kötelezettségek így 2027. december 2-tól alkalmazandók; az 50. cikk átláthatósági kötelezettségeit viszont nem halasztották el, a III. melléklet 3. pontját pedig a módosítás nem érintette. Mivel az ütemezés egyszer már változott, éles bevezetés előtt a hatályos szöveget újra ellenőrizni kell. A hazai végrehajtásról a 2025. évi LXXV. törvény [99] rendelkezik: létrehozta a Magyar Mesterséges Intelligencia Tanácsot, a NAIH jelentése szerint pedig a piacfelügyeleti feladatokat a nemzetgazdasági miniszter, a bejelentő hatóságiakat a Nemzeti Akkreditáló Hatóság látja el [97].

2.9.4. A Mimir besorolása

A Mimir kérdésgeneráló funkciója nem tartozik a III. melléklet 3. pontjába. Nem dönt felvételről vagy képzési szintről, nem figyeli a hallgatókat, és nem értékel tanulási eredményt: az oktatónak ad vázlatot, amelyet ő átnéz, szerkeszt, és csak kötelező jóváhagyás után exportálhat; a kimenet egy emberi döntés alapanyaga, nem maga a döntés. Ha egy szigorú értelmezés a vizsga előkészítését az értékelés részének tekintené, a 6. cikk (3) bekezdés d) pontja (előkészítő feladat) akkor is kivételt adna, mert a rendszer nem végez profilalkotást; ezt dokumentálni kell. A besorolás után is kötelező az 50. cikk (a csevegőfelület és az MI-generált kérdések jelölése), az MI-jártasság támogatása és a GDPR.

A besorolás a felhasználástól függ, nem a technikától. Ha a rendszer a hallgatói válaszokat automatikusan pontozná, vagy a kérdések kiválasztásával a tanulási folyamatot irányítaná, az a 3. b) pont szerint magas kockázatú felhasználás lenne, a teljes követelményrendszerrel, és

2.1. táblázat. Az MI-rendelet alkalmazási időpontjai a 2026-os módosítás (digitális omnibusz) után. Források: [89, 98]; a dőlt sorokat a módosítás vezette be vagy változtatta meg.

Időpont	Mi válik alkalmazandóvá
2024. aug. 1.	A rendelet hatálybalépése
2025. febr. 2.	Általános rendelkezések, MI-jártasság (4. cikk), tiltott gyakorlatok (5. cikk)
2025. aug. 2.	Az általános célú MI-modellek szolgáltatóinak kötelezettségei, irányítás, szankciók
2026. júl. 27.	*A módosító rendelet hatálybalépése, az új 4. cikk*
2026. aug. 2.	Általános alkalmazás, köztük az 50. cikk átláthatósági kötelezettségei
2026. dec. 2.	*Az 50. cikk (2) a korábban forgalomba hozott rendszerekre; új tilalmak (5. cikk)*
2027. dec. 2.	*III. melléklet szerinti magas kockázatú rendszerek (eredetileg 2026. aug. 2.)*
2028. aug. 2.	*I. melléklet szerinti magas kockázatú rendszerek (eredetileg 2027. aug. 2.)*

a GDPR 22. cikke is felmerülne. Ezért pontozási funkció nem kerül a rendszerbe, csak új kockázati értékelés után. A 14. cikk logikáját a jelenlegi besorolásban is követjük: az oktató a döntéshozó, az ellenőrző jelzései figyelmeztetések, mert az automatizálási torzítást a rendelet és a szakirodalom [77] egyaránt megnevezi; az UNESCO útmutatója [100] oktatáspolitikai szinten vár el emberi ellenőrzést és adatvédelmet. A Mimir tervezési céljai – helyi futtatás, zéró adatmegőrzés, kötelező oktatói jóváhagyás – ezekből következnek (3.1. szakasz).

2.10. Összegzés és a kutatási rés

A 2.2. táblázat a tárgyalt megközelítéseket a bevezetés P1–P4 problémái szerint veti össze. A korai rendszerek helyben futnak, de sem a helyességet, sem a szerkezetet nem ellenőrzik; a csevegő modell egyik problémát sem kezeli; a naiv RAG forráshoz köti a generálást, de a feladatleírásból készült lekérdezéssel a dokumentum kis részét látja; az önjavító, a hivatkozó és a gráfalapú módszerek egy-egy problémát részben kezelnek, de nagy modellt feltételeznek. A Mimir sorában a helyesség mérése csak részben teljesül: a bíró oktatói validálása még hátravan, és a saját ellenőrzőjének kérdésenkénti megbízhatósága is korlátozottnak bizonyult (5. fejezet).

Az összevetésből három hiányosság rajzolódik ki. (i) Tudomásunk szerint nincs olyan nyílt rendszer, amely a kérdésgenerálást explicit tervvel, kérdésenkénti forráshivatkozással és ellenőrzéssel, fogyasztói GPU-n (8–12 GB) futó kis modellel végezné. (ii) A kiértékelések ritkán mérik a kulcs helyességét és a vizsga lefedettségét, és hiányoznak az egytényezős kísérleti tervek, amelyek a komponensek hatását egyenként választják szét. (iii) A magyar nyelvű vizsgakérdés-generálás kiértékelése feltáratlan: a hazai nyelvtechnológia erős modelleket és kérdés–válasz adatbázisokat épített, de publikált kérdésgenerálási kiértékelést nem találtunk. Az első hiányosságra a 3., a másodikra a 4., a harmadikra – a rendelkezésre álló adatok korlátai között – az 5. és a 6. fejezet ad választ.

2.2. táblázat. A kérdésgenerálási megközelítések összevetése a P1–P4 problémák szempontjából (✓: kezeli, ∘: részben, –: nem kezeli). A táblázat azt mutatja, hogy egy megközelítés foglalkozik-e az adott szemponttal, nem azt, hogy milyen jól.

Megközelítés	Kulcs ellenőrzése	Szerkezet, lefedettség	Helyi futás	Kis modell	Forrás-hivatkozás	Helyesség mérése
Szabály/sablon alapú [14, 15]	∘	–	✓	✓	∘	–
Neurális seq2seq [18]	–	–	✓	✓	–	–
Dokumentum → csevegő LLM (status quo)	–	–	–	–	–	–
LLM-alapú kérdésgenerálás [20, 21]	–	∘	–	–	–	∘
Naiv RAG [31]	–	–	∘	∘	∘	–
Továbbtanított kis modell [24]	–	–	✓	✓	–	∘
Feladatfelbontó promptolás [47, 48]	–	∘	–	–	–	–
Önjavítás / CoVe [50, 51]	∘	–	–	–	–	–
Hivatkozó generálás [41]	∘	–	–	–	✓	✓
GraphRAG [43]	–	∘	–	–	∘	–
Mimir (jelen munka)	✓	✓	✓	✓	✓	∘

A fejezet tanulsága. A szakirodalom mind a négy problémára kínál részmegoldást, de egyik megközelítés sem kezeli egyszerre mindet. A nagy modellek a kérdések nyelvi minőségét megoldották, a kulcs helyességét (P1) azonban csak statisztikailag javítják, a vizsga szerkezetét (P2) pedig nem vizsgálják. A visszakeresés és a helyi futtatás a P3-at és a P4-et kezeli, de a naiv változat a P2-t rontja. A feladatfelbontás és a forráshoz mért ellenőrzés a P1-et és a P2-t célozza, de eddig főként nagy modellekkel vizsgálták. A jogi keret a helyi, emberi jóváhagyással működő megoldás felé mutat: a tanár által ellenőrzött kérdésgenerálás nem magas kockázatú felhasználás, a hallgatói válaszok automatikus pontozása az lenne.

3. A Mimir rendszer jelenlegi állapota és generálási módszere

Ebből a fejezetből az olvasó megtudja, hogyan épül fel ma a Mimir, hogyan kezeli a tananyagot, és hogyan felel meg az adatvédelmi és az MI-rendeleti követelményeknek (3.1–3.4. szakasz); mekkora GPU-memóriát igényel a helyi futtatás (3.5. szakasz); végül lépésenként megismeri a vizsgált generálási módszert (3.6. szakasz). A Mimir fejlesztési fázisban lévő rendszer: az éles szolgáltatások ma a naiv RAG-ot (E0) futtatják, a tervezett folyamat – vizsgaterv, kérdéshelyenkénti keresés, ellenőrző lánc, kérdésenkénti forráshivatkozás – a kiértékelő keretrendszerben készült el (`tests/new eval/mimir_eval/blueprint`), és hogy mely elemei kerülnek be, azt a 7. fejezet mérésen alapuló döntése határozza meg. A fejezet a szolgáltatások mai működését a forráskód, a módszert a keretrendszer implementációja alapján írja le; a részleteket az A. függelék, a paramétereket az E. függelék tartalmazza.

3.1. Tervezési célok

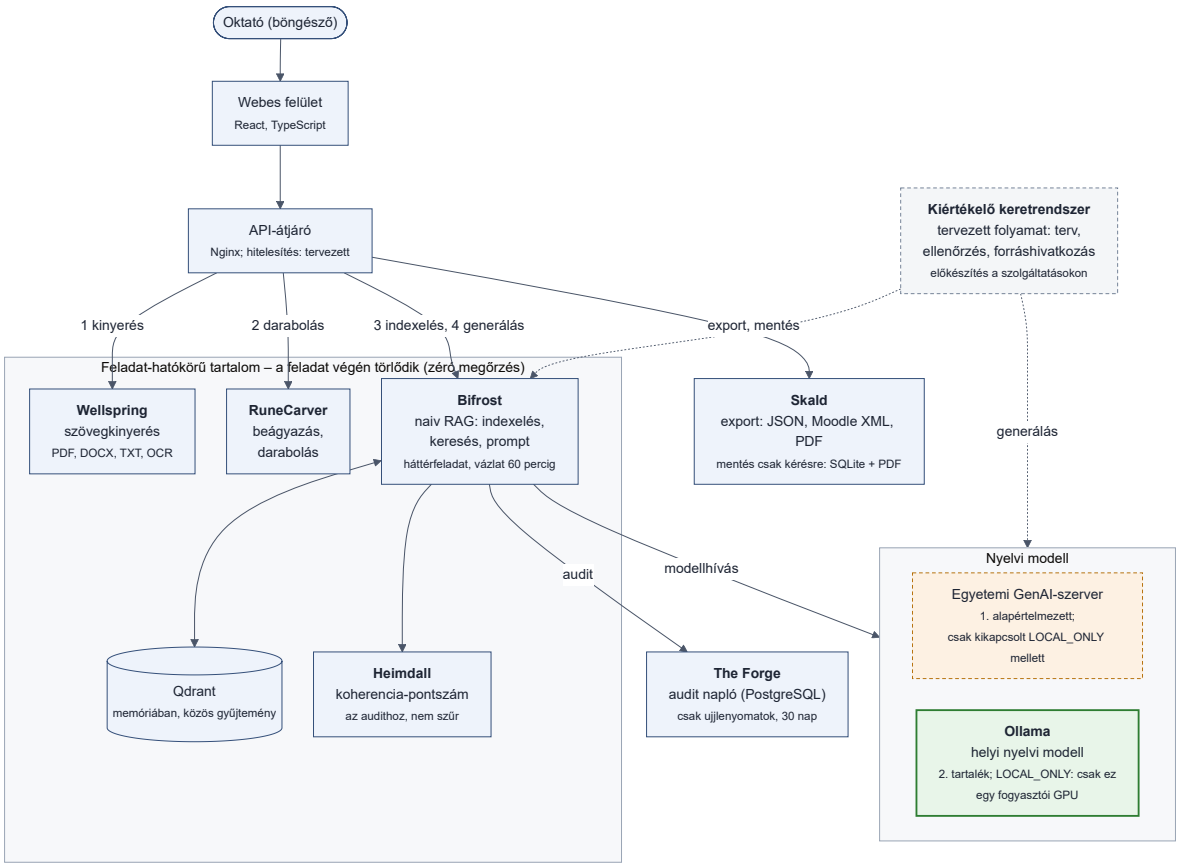
A bevezetés P1–P4 problémáiból és az MI-rendelet emberi felügyeletre vonatkozó elvárásából [89] öt tervezési célt vezettünk le (3.1. táblázat). A táblázat a célállapotot írja le: a G3 és a G5 elemei az éles rendszerben is működnek, a G1 és a G2 ma csak a kiértékelő keretrendszerben.

3.1. táblázat. Tervezési célok: a dokumentum csevegő nyelvi modellnek való átadása és a Mimir célállapota.

Cél	Dokumentum → csevegő modell	Mimir (célállapot)
G1 Ellenőrizhető	A kulcs nincs ellenőrizve, nincs forráshivatkozás	Minden kérdés a forrásrészletekre hivatkozik; alátámasztottsági és vak megoldási ellenőrzés; az ellenőrzésen át nem jutott kérdés megjelölve
G2 Kontrollált	Darabszám, típus, nehézség csak kérés	A vizsgaterv rögzíti a darabszámot, a típusokat és a Bloom-szinteket; lefedettségvezérelt fogalomválasztás
G3 Adatvédő	Az anyag a szolgáltatóhoz kerül	Választható helyi modell; a feldolgozási adatok a feladat végén törlődnek; kapcsolható, kizárólag helyi mód
G4 Megvalósítható	Hosszú kontextus, nagy modell	Rövid hívások 8 192 tokenes kontextusban; fogyasztói GPU (8–12 GiB)
G5 Felügyelt	A kimenet változtatás nélkül használható	Kötelező oktatói jóváhagyás szerkesztőben, a hivatkozott forrással; MI-közreműködés jelölése az exportban

3.2. Architektúra és megvalósítás

A rendszer konténerizált, verziózott (`/api/v1`) felületű FastAPI-szolgáltatásokból áll, amelyeket egy nginx-alapú API-átjáró fog össze (3.1. ábra); nevüket az északi mitológia tudással kapcsolatos alakjairól kapták: a *Wellspring* PDF-ből, DOCX-ből és szövegfájlból nyeri ki a szöveget (olvashatatlan oldalnál a GenAI-szerver képfelismerő modelljével, ennek hiányában vagy helyi módban Tesseract OCR-rel); a *RuneCarver* mondatokra bont, beágyaz és darabol (3.6.1. szakasz); a *Bifrost* indexel, keres, promptot épít, modellt választ és a generálási feladatokat kezeli; a *Heimdall* a kész vizsgát egy nyelvi modellel 1–10-es koherencia-pontszámmal értékeli, ez az audit naplóba kerül, de a kimenetet nem szűri; a *The Forge* az audit naplót és egy adatbázis-alapú feladatsort kezel; a *Skald* JSON, Moodle XML és PDF formátumba exportál, és kérésre elmenti a jóváhagyott vizsgát. A dokumentumfeldolgozás, a darabolás, a RAG-folyamat, a feladatkezelés és az export (Moodle XML CDATA-blokkokkal és MathJax-támogatással, PDF saját tördelőkóddal) saját implementáció. A kiértékelő keretrendszer az előkészítéshez ugyanezeket a végpontokat hívja, a generálást viszont a saját kódjában futtatja (4.1. szakasz).



3.1. ábra. A Mimir szolgáltatásai és adatfolyama. A feltöltött tartalmat a feldolgozó szolgáltatások csak a feladat élettartama alatt, memóriában tartják; a beágyazó modellek CPU-n futnak, a GPU-t csak a helyi nyelvi modell használja. Külső modellt a rendszer csak kikapcsolt `LOCAL_ONLY` kapcsoló mellett hív. A számok a webes felület hívási sorrendjét jelölik; a szürke, szaggatott keretes blokk a kiértékelő keretrendszer, amelyben a tervezett folyamat fut.

Az éles generálási útvonal. A webes felület a szolgáltatásokat az átjárón át, egymás után hívja: kinyerés, darabolás, indexelés, generálás, állapotlekérdezés. A `/api/v1/generate` végpont azonnal feladatazonosítót ad vissza, a generálást a FastAPI `BackgroundTasks` mechanizmusával, a Bifrost folyamatában indítja; az állapot (szakasz, haladás, becsült hátralévő idő) a `/api/v1/status` végponton kérdezhető le. A memóriabeli feladattár a feladatot és eredményét az indítás után 3 600 s-mal (`JOB_TTL_SECONDS`) eldobja. A modellt a Bifrost alapból az egyetemi GenAI-szerverről kéri (sorrendben `gpt-oss:120b`, `Qwen3.8-Flash-Next`); ha ez nem ad értelmezhető választ, vagy nincs API-kulcs, a helyi Ollamára vált (alapból PULI-LlumiX 8B, Q4_K_M, 16 384 tokenes kontextus, $T = 0$), és ha az is hibázik, rögzített hibaüzenet-vizsgát ad vissza; bekapcsolt `LOCAL_ONLY` mellett csak a helyi modellt hívja. A feladat végén – sikertől függetlenül – a `_purge_document_data` függvény kiüríti a vektortárat.

Feladatsor és egyidejű használat. A The Forge PostgreSQL-alapú feladatsora a `FOR UPDATE SKIP LOCKED` záradékra [101] épül: a munkás a legrégebbi, még nem zárolt feladatot veszi ki, így egy feladatot pontosan egy munkás kap meg, üzenetközvetítő nélkül. A sor ma egyetlen feladattípust ismer (darabok indexelése), és a webes folyamat nem használja. A Bifrost vektortára memóriában futó Qdrant [102] *egyetlen közös gyűjteménnyel*, amelyet minden indexelés és minden feladat vége kiürít. Ez egy felhasználónál a zéró megőrzést szolgálja, egyidejű felhasználóknál viszont a dokumentumok összekeveredhetnek, vagy egy új indexelés törölheti egy futó feladat darabjait: az éles rendszer ma egyfelhasználós, egydokumentumos üzemre alkalmas.

A webes felület. A React és TypeScript alapú, kétnyelvű felületen az oktató feltölti a dokumentumot, megadja a kérdések számát, típusát (feleletválasztós, igaz-hamis, kifejtős) és nehézségét, majd a vázlatot a szerkesztőben (3.6.8. szakasz) átnézi és exportálja. A *legacy* API-mód a mai backendet hívja, és éles buildben ez az alapértelmezett; a *v1* mód a témakör-munkaterületet valósítja meg egy új API-szerződésen (témakörök, fájlok, feladatok, kérdésenkénti forráshivatkozás). Ezt a szerződést a mai szolgáltatások még nem valósítják meg, ezért a v1 felület fejlesztéskor böngészőben futó ál-backenddel (MSW) működik; a tervezett folyamat élesítése a v1 szerződés szerveroldali megvalósítását is jelenti.

3.3. Adatvédelem: zéró megőrzés a feldolgozási adatokra

A G3 cél az adattakarékosság és a korlátozott tárolhatóság GDPR-elvén [7] alapul. A projekt ezt „zéró megőrzésnek” nevezi, pontosabban: a feltöltött tartalom és minden belőle számolt adat (darabok, beágyazások, prompt) csak a feladat végéig él, a generált vázlat legfeljebb 60 percig marad a szerveren, a jóváhagyott vizsgát pedig a Skald csak kifejezett kérésre, beállítható ideig (alapból 365 napig) tárolja. Az adatfajták részletes életciklusát az A.1. táblázat (A.1. függelék) foglalja össze.

Az audit napló az elszámoltathatóság miatt fontos, de nem tartalmazhat tananyagot: a feladat azonosítóját, a modell nevét, a promptverziót és a Heimdall pontszámát tárolja, a kérésből,

a promptból és a kontextusból pedig csak a SHA-256 *ujjlenyomatot* (kriptográfiai kivonatot) és a szöveg hosszát, 30 napig. Az ujjlenyomattal igazolható, hogy két futás ugyanazzal a kontextussal dolgozott-e, a tartalom azonban nem állítható vissza belőle; a korábbi, szöveget is tároló oszlopokat a The Forge induláskor kiüríti. A `LOCAL_ONLY` kapcsoló a Bifrostban, a Heimdallban és a Wellspringben minden külső modellhívást letilt. Alapértéke kikapcsolt, vagyis a mai telepítés a visszakeresett darabokat az egyetemi szervermodellnek küldi; a felület minden feltöltés előtt jelzi, hol történik a feldolgozás.

3.4. Adatvédelem és MI-rendelet a megvalósításban

A jogi keretet [7, 89] a 2.9. szakasz mutatja be; itt azt foglaljuk össze, hogyan jelennek meg a követelmények a kódban és az üzemeltetési dokumentációban. A projekt megfelelőségi dokumentációja (`docs/gdpr/compliance.hu.md`, 2026. szeptemberi tervezet) minden elemet *Megvalósítva*, *Részben megvalósítva* vagy *Tervezett* jelöléssel lát el; a 3.2. táblázat ezeket változtatás nélkül veszi át. A dokumentáció mérnöki tervezet, nem jogi vélemény: éles indulás előtt adatvédelmi tisztviselőnek vagy jogásznak kell átnéznie, és több adatkezelői adata (az adatkezelő neve, a tárhelyszolgáltató, az incidensfelelős) még kitöltetlen.

MI-rendeleti besorolás. Az MI-rendelet III. mellékletének 3. pontja az oktatásban a tanulási eredmények értékelésére és a tanulási folyamat irányítására használt rendszereket magas kockázatúnak minősíti. A dokumentáció értelmezése szerint a Mimir mai feladata, a tanár által teljes egészében ellenőrzött kérdések *generálása*, ezen kívül esik: a rendszer nem értékel és nem pontoz vizsgázókat, és nem hoz a GDPR 22. cikke szerinti automatizált döntést. A diákválaszok automatikus pontozása viszont a magas kockázatú kategóriába sorolná, ezért pontozási funkció csak új értékelés után vezethető be. A kötelező oktatói jóváhagyás (G5) így a besorolás egyik érve is.

Nyitott pontok. A bevezetés előtt három hiányt kell megszüntetni: a valódi hitelesítést (a mentett vizsgák végpontjai ma egy `user_id` paraméterben bíznak meg; a dokumentáció szerint ez a legmagasabb prioritás), a közös vektortár témakörönkénti elkülönítését (a feladat utáni törlés a kockázatot csak részben csökkenti) és az egyetemi GenAI-szerverrel kötendő írásos adatfeldolgozói megállapodást; addig csak a `LOCAL_ONLY` mód garantálja, hogy a szöveg nem hagyja el az üzemeltető szerverét. Az MI-jártasságra (4. cikk) vonatkozó teendőket a dokumentáció nem tárgyalja. A tervezett témakör-munkaterület a darabokat és a beágyazásokat témakörönként, titkosítva megőrizné (javaslat: 90 nap inaktivitásig), ami a zéró megőrzést módosítaná; kiadás előtt a dokumentációt és a tájékoztatót is frissíteni kell.

3.5. A GPU-memória becslése

A G4 cél kvantitatív kérdés: elfér-e a generátor egy fogyasztói videokártyán az asztali környezet mellett? A memóriát bináris egységekben adjuk meg (1 GiB = 2^{30} bájt), mert a GPU-memória

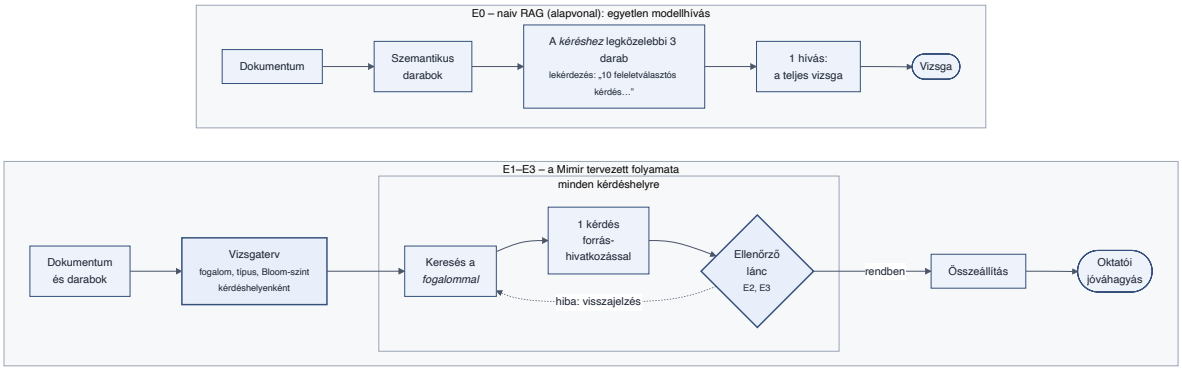
3.2. táblázat. Adatvédelmi és MI-rendeleti követelmények és megvalósításuk a Mimir rendszerben. Az állapot a megfelelőségi dokumentáció (`docs/gdpr/compliance.hu.md`) jelölése.

Követelmény	Megoldás a rendszerben	Állapot
GDPR 5. cikk (1) c), e): adattakarékosság, korlátozott tárolhatóság	A feldolgozási adatok törlése minden feladat után; a feladat eredménye 60 perc után lejár	Megvalósítva
GDPR 25. cikk: alapértelmezett adatvédelem	A vizsga mentése csak kérésre, a megőrzési idő jelzésével; mentett vizsga legfeljebb 12 hónapig	Megvalósítva
GDPR 5. cikk (2); MI-rendelet: naplózás	Csak metaadatot és ujjlenyomatot tartalmazó működési napló, 30 napos megőrzés, a régi adatok kiürítése	Megvalósítva
GDPR 28., 44–49. cikk: adatfeldolgozó, továbbítás	Helyi mód (`LOCAL_ONLY`): nincs hívás az egyetemi GenAI-szerver felé	Megvalósítva (alapból kikapcsolva)
	Adatfeldolgozói szerződések (tárhely, egyetem, e-mail)	Tervezett
GDPR 12–13. cikk: tájékoztatás	Adatkezelési tájékoztató magyarul és angolul; figyelmeztetés és megerősítés feltöltéskor; a feldolgozás helye minden feltöltés előtt látható	Megvalósítva (a tájékoztató kitöltendő mezőkkel)
GDPR 15–20. cikk: érintetti jogok	Mentett vizsga törlése; „Adataim” oldal a böngészőben tárolt adatokhoz	Megvalósítva (a törlés `user_id` alapú tulajdonos-ellenőrzéssel)
	Fiókexport és -törlés	Tervezett
GDPR 32. cikk: biztonság	Hozzáférési napló paraméterek nélkül, rövidített IP-címmel	Megvalósítva
	Naplórotáció: méretalapú rotáció kész, a 14 napos időkorlát üzemeltetési feladat	Részben megvalósítva
	Valódi hitelesítés és tulajdonos-ellenőrzés	Tervezett
	Vektoradatok elkülönítése (témakörönként)	Tervezett
GDPR 35. cikk: hatásvizsgálat	Előszűrés elkészült; teljes hatásvizsgálat a bevezetés előtt	Tervezett
MI-rendelet 50. cikk: átláthatóság	Figyelmeztetés a felületen; a tájékoztató MI-ről szóló pontja; a PDF metaadat-oldala jelzi az MI közreműködését és a modellt; a szerkesztő kiírja a modellt	Megvalósítva
MI-rendelet: emberi felügyelet (vö. 14. cikk)	Kötelező ellenőrzési lépés a szerkesztőben az export előtt	Megvalósítva

és az Ollama által jelzett foglalás is így értendő; a kereskedelemben „8 GB-os” és „12 GB-os” kártyák memóriája 8, illetve 12 GiB. Az igény a kvantált súlyok, a kontextussal arányos KV-gyorsítótár és a futtatókörnyezet többletének összege; a képletet, a Qwen2.5-7B-re végzett levezetést és öt modell becslését az A.1. egyenlet és az A.2. táblázat (A.2. függelék) tartalmazza. A Q4_K_M kvantálás kb. 4,8 bit/súllyal a súlyokat a 16 bites méret nagyjából harmadára csökkenti. A becslés szerint 8 192 tokenes kontextusnál a Qwen2.5-7B kb. 5,4 GiB-ot, a Llama-3.1-8B-vel azonos architektúrájú PULI-LlumiX 8B kb. 6,1 GiB-ot igényel, a Gemma 3 12B mért foglalása kb. 7,8 GiB (rétegeinek többsége csak egy rövid ablakra figyel, ezért a képlet nála túlbecsül). A következtetés két fogyasztói szint: a 7–8B modellek 4 bites kvantálással elférnek egy 8 GiB-os kártyán, a 12B modell az asztali környezettel együtt 12 GiB-os kártyát igényel. A kontextus növelése sem ingyenes (32 768 tokennél a Qwen2.5-7B gyorsítótára önmagában 1,75 GiB), ezért a helyi teljes dokumentumos alapvonal 16 384 tokennel és 30 000 karakterre csonkolt dokumentummal fut, a tervezett folyamat hívásai viszont rövidek. A mért értékeket a 6.4. szakasz közli.

3.6. A generálási módszer

A 3.2. ábra a két összehasonlított generálási folyamatot mutatja. A *naiv RAG* (E0, a mai éles útvonal) a felhasználói kéréshez leginkább hasonló három darabot keresi vissza, és egyetlen hívásban kéri a teljes vizsgát; ez a legolcsóbb ésszerű alapvonal. A *tervezett folyamat* (E1–E3) először explicit vizsgatervet készít, majd a terv minden pontjára (a továbbiakban: *kérdéshelyére*) külön keresést, egyetlen kérdés generálását és – az ellenőrző változatokban – ellenőrzést végez. A lényeg a feladat felbontása: a naiv alapvonalban a modell egy hívásban dönt a kérdések számáról, témájáról, nehézségéről és disztraktorairól (rossz válaszlehetőségeiről), a tervezett folyamatban a szerkezeti döntéseket determinisztikus program hozza meg, a modell pedig egy-egy rövid kérdést ír, csak a releváns kontextus alapján.



3.2. ábra. A naiv RAG és a Mimir tervezett generálási folyamata. A terv a vizsga szerkezetét még az első kérdés megírása előtt rögzíti, és minden kérdést a saját, hivatkozott kontextusával szemben ellenőriz.

A módszer modellfüggetlen: minden nyelvimodell-hívás OpenAI-kompatibilis felületen megy át, a generátor egy konfigurációs kulccsal cserélhető. A vizsgálatokban a Qwen2.5-7B [56] (pilot

és előzetes vizsgálat), valamint a NYTK magyarra továbbtanított, Llama-3.1 alapú PULI-LlumiX 8B [59] és a Gemma 3 12B [58] (fő vizsgálat) volt a generátor. Mindhárom 4 bites (Q4_K_M, kb. 4,8 bit/súly) kvantálással fut az Ollamán [62], $T = 0{,}2$ hőmérséklettel és 8 192 tokenes kontextussal (a B-doc-L 16 384 tokennel); a fő vizsgálatban a válasz legfeljebb 4 096 token (`num_predict`). A kísérleti E0 az éles útvonal promptját használja, de ezekkel a paraméterekkel, a keretrendszerben; az éles végponton át futó kontrollkonfiguráció nem futott (4.3. szakasz).

3.6.1. Szemantikus darabolás

A RuneCarver a szöveget mondatokra bontja, minden mondathoz 768 dimenziós vektort rendel a multilingual-E5-base [35] kódolóval (a mondat tokenjei vektorainak átlagát, hosszabb szöveg-ablakban, így a szomszédos mondatok jelentése is benne van), és ott vág, ahol két szomszédos mondat koszinusz-távolsága meghaladja a vágási küszöböt: alapértelmezésben a távolságok 85. percentilisét, vagyis a legnagyobb 15 % távolságnál. A célméret (1 000 karakter) túllépése után a küszöb arányosan csökken; ez a *puha korlát* mondat közepén soha nem vág (a képlet: A.3. függelék). A szemantikus darabolás az éles rendszerben és a kiértékelésben ugyanaz a kód; csak a rögzített darabolású E5c darabol a keretrendszerben.

A csonkolt kódoló hibája. A kódoló legfeljebb 512 tokenes bemenetet fogad. Az eredeti implementáció a teljes dokumentumot egy menetben, csonkolva kódolta, így az 512. token után kezdődő mondatok nullvektort kaptak, és hosszabb dokumentumon a vágás már nem a tartalomtól, csak a darab hosszától függött. A javított kódoló mondathatáron vágott, legfeljebb 510 tokenes ablakokban dolgozik (rövid szövegen az eredmény azonos). Az E5a a régi kódolót szándékosan megtartja, hogy a hiba hatása mérhető legyen.

3.6.2. Indexelés és az alapvonalak

A darabokat a Bifrost az E5 kódolóval beágyazza, és a Qdrant-vektortárba tölti, amely minden új dokumentum előtt kiürül; a *sűrű keresés* a lekérdezéshez koszinusz-hasonlóság szerint legközelebbi k darabot adja vissza. Az E0 lekérdezése a felhasználói kérés szövege („Készíts pontosan 10 darab vizsgakérdést, típus: feleletválasztós. . . ”), kontextusa a három leghasonlóbb darab, promptja a rendszer éles, v1.0-s promptja (C. függelék). A *teljes dokumentumos prompt* (B-doc-L helyben, B-doc-S a szerveren) ugyanezt a promptot használja a teljes dokumentummal (helyben legfeljebb 30 000, a szerveren 80 000 karakter; a levágott rész arányát rögzítjük).

3.6.3. A vizsgaterv

Fogalomtervezés. A tervező egyetlen hívásban a dokumentum *áttekintését* kapja: minden darab azonosítóját ($C_0, C_1, \ldots$) és elejét, összesen legfeljebb 12 000 karakterben (darabonként legalább 120 karaktert). A modell így folytonos szöveg helyett azonosítókkal tagolt felsorolást lát, ami a „lost in the middle” jelenség [6] ellen hat. A tervező $n+3$ fogalmat ad vissza (n a kért kérdésszám), mindegyikhez egy mondatos leírást (mit kell kérdezni), az alátámasztó darabok azonosítóit és egy

fontossági értéket (1: részlet, 2: fontos, 3: központi). Értelmezhetetlen válasznál darabonként egy álfogalom lép a helyükre, így a terv mindig létrejön.

Bloom-szintek és fogalomválasztás. A kért nehézséghez egy Bloom-szint-eloszlás tartozik [11], amelyet a legnagyobb maradék módszerével [103] alakítunk egész darabszámokká (A.3. táblázat, A.4. függelék). Az összeg mindig pontosan n, így a nehézség nem kérés a promptban, hanem a terv szerkezeti tulajdonsága. A kérdéshelyekhez egy *mohó* eljárás választ fogalmat: mindig azt, amely még le nem fedett darabot érint, ezen belül a legfontosabbat; ha minden darab le van fedve, a fontosság dönt. Ha a tervező legalább n fogalmat javasolt, a kérdések így nem tömörülhetnek a dokumentum egyetlen részére; kevesebb fogalomnál a fogalmakat más Bloom-szinttel újra felhasználjuk, a ki nem választottak alkotják a *tartaléklistát*.

3.6.4. Kérdéshelyenkénti keresés

Minden kérdéshely saját kontextust kap: a lekérdezés a fogalom neve és leírása, a kontextus a fogalomhoz a tervező által rendelt első két darab, kiegészítve a keresés $k = 3$ találatával (ismétlés nélkül), legfeljebb 6 000 karakterig. A lényegi különbség a naiv RAG-hoz képest, hogy a lekérdezés itt tartalmi fogalom („immunológiai memória: hogyan alakul ki”), nem feladatleírás („10 kérdés, könnyű”). A *hibrid* változat (E2h) a sűrű rangsort egy előtagtövesített BM25-rangsorral egyesíti reciprok rangfúzióval (A.3. egyenlet, A.5. függelék).

3.6.5. Forráshoz kötött kérdésgenerálás

A generátor egyetlen kérdést ír a kérdéshely terve szerint. A prompt (C. függelék) megadja a fogalmat, a kérdezendő tartalmat, a típusszabályt (négy válasz, egy helyes), a Bloom-szint magyar leírását, a nehézséget és a nyelvet; megismétli az éles prompt szabályait; felsorolja a már elfogadott kérdéseket; és megköveteli a `citations` mezőt, amelyben a modell megnevezi a kulcsot igazoló darabok azonosítóit. Így minden kérdés saját, ellenőrizhető forrásrészlethez kötődik (G1).

3.6.6. Az ellenőrző lánc

Az ellenőrzések a legolcsóbbtól a legdrágábbig futnak (3.3. táblázat; a visszacsatolás folyamatábrája: A.1. ábra, A.6. függelék): ha egy szabályalapú ellenőrzés hibát talál, a nyelvi modellt igénylő ellenőrzések el sem indulnak. A modellalapú ellenőrzések forrása a kérdés által hivatkozott darabok. A lánc a kiértékelő keretrendszer része, nem azonos a Heimdall mai, egyetlen pontszámot adó lépésével.

A *szivárgási szabály* akkor jelez, ha a legalább háromszavas kulcs szavainak legalább 80 %-a a törzsben (a kérdés szövegében) is szerepel, a *kérdésforma-szabály* akkor, ha a törzs sem kérdőjelre, sem kettőspontra nem végződik; mindkettőt a pilot hibamódja (5.1. szakasz) motiválta. Az *alátámasztottsági* hívás azt kérdezi, igazolja-e a forrás a kulcsot, hamis-e minden disztraktor és kétértelmű-e a kérdés; a *vak megoldásban* a modell a kulcs ismerete nélkül, összekevert

3.3. táblázat. Az ellenőrző lánc lépései végrehajtási sorrendben, a hiba esetén adott visszajelzéssel.

Ellenőrzés	LLM-hívás	Visszajelzés hiba esetén
Forma	–	feleletválasztós kérdés: 4 válasz, ebből 1 helyes
Meta-hivatkozás	–	fogalmazd meg „a szöveg szerint” jellegű hivatkozás nélkül
Szivárgás és kérdésforma *(a pilot után)*	–	a törzs ne tartalmazza a választ, és legyen valódi kérdés
Hivatkozás	–	hivatkozz a kontextus legalább egy darabjára
Alátámasztottság és disztraktorok	1	a kulcsot a részlet nem igazolja / egy disztraktor igaz lehet / kétértelmű
Vak megoldás	1	egy független megoldó más választ jelölt meg
Duplikátum	–	túl hasonló egy már elfogadott kérdéshez

válaszokkal dönt. *Duplikátum* a legalább 0,9 koszinusz-hasonlóságú kérdés. Az ellenőrzést maga a generátor végzi, az E2x-ben egy másik modell (Llama-3.1-8B [57]).

A hibák listája visszajelzésként a következő kísérlet promptjába kerül ($r = 1$ újrapróbálkozás, majd egy tartalékfogalom); ha a kulcs nem igazolt, a keresés két darabbal bővül. Ha így sem sikerül, a legjobb kísérlet *nem ellenőrzöttként* megjelölve marad meg, hogy az oktató lássa; hibás formánál egy *javító* hívás pótolja a hiányzó disztraktorokat (A.1. algoritmus, A.6. függelék). Az E1 csak a formát, a meta-hivatkozást és a duplikátumot vizsgálja. A technikai hiba miatt elmaradt ellenőrzés a kérdést nem tartja fel, de naplózzuk.

Költség. Az egyhívásos konfigurációk (E0, E5a–E5c, B-doc) egy hívással dolgoznak, az E1 legalább $1 + n$ (tervezés és kérdésenként egy generálás), az E2 legalább $1 + 3n$ hívással (kérdésenként generálás, alátámasztottsági ellenőrzés és vak megoldás). Tíz kérdésnél ez 11, illetve 31 hívás, ha minden kérdés elsőre átmegy; minden elutasítás további két-három hívással jár.

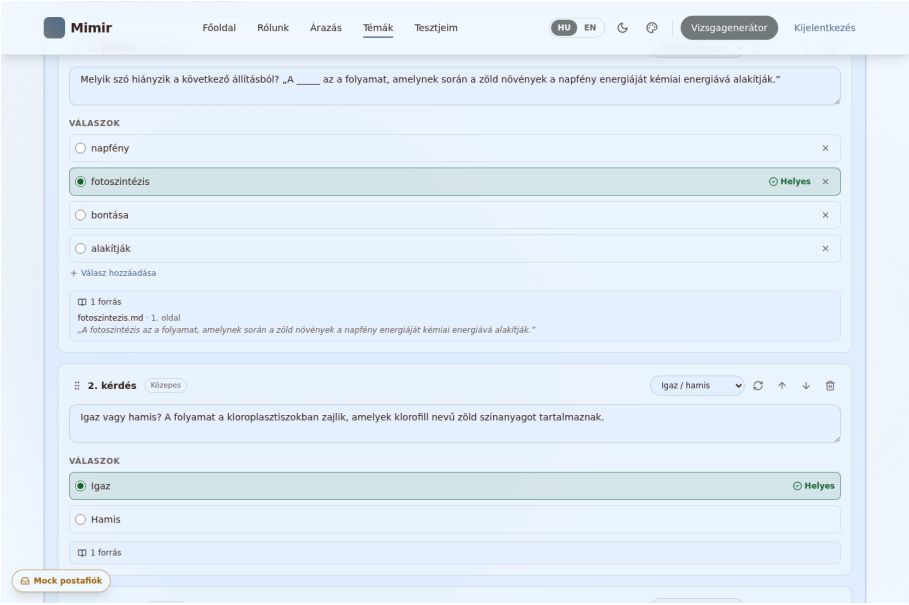
3.6.7. Munkamenet-hatókörű fogalomgráf

Az E3 a tervezőhívást egy fogalomgráffal váltja ki: kötegenként kinyeri a fogalmakat, a rövid tényeket és a fogalmak közötti kapcsolatokat, a fogalmakat centralitás szerint rendezi, és ez a lista lép a tervező helyébe; disztraktor-ötletként a generátor a fogalom testvérfogalmait kapja (A.7. függelék). A gráf csak a vizsga élettartamáig létezik, a memóriában.

3.6.8. Összeállítás és emberi felügyelet

Az elfogadott kérdéseket Bloom-szint szerint rendezzük, és mindegyikhez rögzítjük a hivatkozott darabokat, a tervezett fogalmat és az *ellenőrzött* jelzőt. A vázlat a webes szerkesztőbe kerül (3.3. ábra), ahol az oktató szerkesztheti, átrendezheti és törölheti a kérdéseket, módosíthatja a kulcsot, egyetlen kérdést újragenerálhat, és minden kérdés alatt látja a hivatkozott forrásrészletet a fájl nevével és oldalszámával. Jóváhagyás nélkül semmi sem exportálható, az export pedig feltünteti az MI-rendszer közreműködését és a modellt (G5). A szerkesztő a legacy és a v1

módban ugyanaz, a jóváhagyás mindkettőben kötelező; a forrásrészlet azonban csak hivatkozást hordozó kérdésnél jelenik meg, a mai naiv RAG-kimenetben ilyen nincs, ezért élesben az oktató ma forráshivatkozás nélkül hagyja jóvá a kérdéseket.



3.3. ábra. A webes szerkesztő egy generált feleletválasztós kérdéssel: a megjelölt helyes válasz, alatta a hivatkozott forrásrészlet („1 forrás", fájlnév és oldalszám); jobb felül a típusválasztó, az újragenerálás, az áthelyezés és a törlés gombja. A forrásrészlet a v1 API-szerződés kérdésenkénti hivatkozásából jelenik meg.

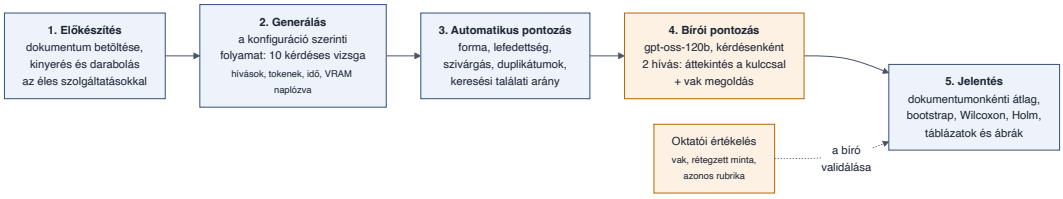
A fejezet tanulsága. A Mimir mai változata adatvédelmi szempontból gondosan kialakított naiv RAG-rendszer: a feldolgozási adatok a feladat végén törlődnek, az audit napló tartalmat nem tárol, a helyi mód kapcsolható, az oktatói jóváhagyás kötelező. Az ellenőrizhetőség (G1) és a kontrollált szerkezet (G2) a keretrendszerben elkészült módszerben van meg. Az élesítéshez el kell dönteni, mely lépések érik meg a költségüket (7. fejezet), meg kell valósítani a v1 API-szerződést, valamint a hitelesítést és a témakörönkénti adatelkülönítést, amelyek nélkül a rendszer többfelhasználós üzemre nem alkalmas.

4. Kiértékelési módszertan

Ebből a fejezetből az olvasó megtudja, milyen eszközzel, dokumentumokon, konfigurációkkal, mutatókkal és statisztikai eljárásokkal mértük a módszereket és a modelleket, és milyen szabályok szerint vethetők össze a három vizsgálat eredményei. A kérdésgenerálás kiértékelése az irodalomban többnyire szóegyezésre és kis, nem vak emberi értékelésre támaszkodik, és ritkán ellenőrzi a kulcs helyességét (2. fejezet). A mérés eszköze ezért egy saját fejlesztésű, nyílt forráskódú kiértékelő keretrendszer (`tests/eval`; a fő vizsgálat kódja `tests/new eval`), amely a dolgozat önálló hozzájárulása. Hat tulajdonságot egyesít: (i) *egytényezős konfigurációk*, amelyek egy-egy konfigurációs fájlban, egyetlen tényezőben térnek el, így a komponensek hatása szétválasztható; (ii) *forrásalapú mutatók*, amelyek a kulcs helyességét a forrásszöveghez, nem referenciakérdéshez mérik; (iii) a kérdéseket pontozó, a generátoroktól független nyelvi modell (a *bíró*), amelynek megbízhatóságát külön is ellenőrizzük; (iv) *dokumentumszintű statisztika*; (v) *folytatható futás*, amely egy megszakított, több napig tartó vizsgálatot a hiányzó vizsgáktól folytat; és (vi) *bírói gyorsítótár*, amellyel az újrapontozás determinisztikus, és nem igényel új bírói hívást. A mutatók és az eljárások részletes definícióit az A. függelék tartalmazza.

4.1. A tesztelés menete

A kiértékelés alapegysége a *teszt*: egy *konfiguráció* (a generálási folyamat egy rögzített beállítása, rövid jele például E0 vagy E2) egy dokumentumon, egy véletlenmaggal egy tízkérdéses feleletválasztós vizsgát állít elő, amelyet automatikus mutatókkal és a bíróval pontozunk (4.1. ábra). Az előkészítés (kinyerés, darabolás, indexelés) a futó szolgáltatások végpontjain át, az éles rendszerrel azonos módon történik; a generálás a keretrendszer kódjában fut, így a még nem élesített tervezett folyamat is mérhető. Minden modellhívás szakaszát, tokenszámát és idejét rögzítjük, a GPU-memóriát egy háttérszál mintavételezi.



4.1. ábra. Egy teszt lépései: előkészítés a szolgáltatásokon, generálás a konfiguráció szerint, automatikus mutatók, bírói pontozás és összesítés.

A reprodukálhatóságot négy mechanizmus biztosítja: (1) minden futás rögzíti a teljes konfigurációt, a kód és az adatkészlet verzióját és a hardvert; (2) a bíró válaszai lemezre, gyorsítótárba kerülnek, a bírómodell, a promptverzió, a gondolkodási szint és a teljes prompt kivonatával mint kulccsal, így újrapontozáskor ugyanarra a kérdésre ugyanaz az ítélet jön, és egy mutató utólagos módosítása nem igényel bírói hívást; (3) a `--resume` kapcsoló csak a hiányzó

vagy sikertelen vizsgákat futtatja újra; (4) a keretrendszert 43 automatikus teszt fedi le, köztük ál-szolgáltatásokkal és ál-nyelvi modellel a teljes folyamat.

4.2. Adatkészlet

Az `eval-v1` adatkészlet 39 dokumentumból áll (A.4. táblázat, A.8. függelék): három saját, rövid magyar oktatási szöveg (kávé, immunrendszer, játékelmélet) kézzel írt referenciakérdésekkel, 12 OpenStax-tankönyvrészlet az EduQG [23] szakértői kérdéseivel és 24 magyar Wikipédia-cikk a MILQA [37] szövegértési kérdéseivel, összesen 326 referenciakérdéssel. A fő vizsgálat ebből 30-at használt: mind a 24 MILQA-cikket, a 3 saját szöveget és 3 OpenStax-részletet (`en-economics-short-01`, `en-humanities-medium-02`, `en-law-long-03`), összesen 27 magyar és 3 angol dokumentumot, hosszúság szerint 12 rövid, 9 közepes és 9 hosszú dokumentummal. A szűkítés oka a futásidő volt; az elsődleges cél a magyar nyelvű kiértékelés, az angol részletek a nyelvi összevetést szolgálják. A referenciakérdések *nem* célok, hiszen egy jó vizsgakérdésnek nem kell hozzájuk hasonlítania; a keresés pontosságát és a tematikus egyezést mérjük velük.

4.3. A kísérleti konfigurációk

A kísérleti terv *egytényezős*: minden konfiguráció egy referenciakonfigurációhoz képest pontosan egy tényezőben tér el, így a kettő különbsége az adott tényezőnek tulajdonítható. A 4.1. táblázat a 14 konfigurációt három csoportban foglalja össze.

Az *alapvonalak* azt modellezik, amit egy oktató a Mimir nélkül tenne: a B-doc-S a mai gyakorlat (a jegyzet feltöltése egy csevegő asszisztensbe), a B-doc-L ugyanez a helyi modellel, 16 384 tokenes kontextussal, az E0 a rendszer mai működése. Az E1–E0 különbség a tervezés (1. és 3. hipotézis), az E2–E1 az ellenőrzés (2. hipotézis), az E3–E2 a fogalomgráf hatása; az E2-ben az ellenőrzést a kérdést író modell végzi. Az E2x ellenőrzője a PULI-LlumiX esetében a generátor alapmodellje, tehát nem független család; az E4 és az E4b a 4. hipotézist, az E5a–E5c a darabolás hatását vizsgálja (régi kódoló: 3.6.1. szakasz; rögzített darabolás [40]). A konfigurációk egytényezős fáját az A.2. ábra (A.9. függelék) mutatja.

A tervezett konfigurációk egy maggal futnak, mert egy vizsga perceket igényel, és a variancia fő forrása a dokumentum; az olcsó egyhívásos konfigurációk zaját három mag csökkenti. A tervben szereplő E0s (az E0 az éles végponton át) egyik vizsgálatban sem futott. Előre rögzített, a többszörös összehasonlítás korrekciójába tartozó páros összehasonlítás hat van: E1–E0 (tervezés), E2–E1 (ellenőrzés), E2–E0 (teljes módszer), E2–B-doc-L (módszer vs. teljes dokumentumos prompt), E2x–E2 (ellenőrző modell) és E3–E2 (gráf); a többi összevetés leíró jellegű.

4.1. táblázat. A kísérleti konfigurációk. Ref.: amelytől a konfiguráció egyetlen tényezőben eltér; Magok: dokumentumonkénti ismétlések száma az előzetes és a fő vizsgálatban (a pilotban mindenhol 3); Vizsg.: P = pilot, Ev = előzetes vizsgálat, F = fő vizsgálat.

Jel	Mit változtat	Ref.	Magok	Vizsg.
Alapvonalak				
B-doc-L	teljes dokumentum egy promptban, helyi modell (≤ 30 000 karakter)	–	3	Ev, F
B-doc-S	ugyanez a szervermodellel (≤ 80 000 karakter)	–	3	Ev
E0	naiv RAG: a kéréshez legközelebbi 3 darab, a vizsga egy hívásban	–	3	P, Ev, F
A módszer lépései				
E1	vizsgaterv, kérdéshelyenkénti keresés és generálás, ellenőrzés nélkül	E0	1	P, Ev, F
E2	E1 + ellenőrző lánc visszacsatolással (a teljes módszer)	E1	1	P, Ev, F
E3	E2 + fogalomgráf	E2	1	P, Ev, F
Kiegészítő ablációk				
E2f	E2 vak megoldási próba nélkül	E2	1	P, Ev, F
E2h	E2 hibrid (BM25 + sűrű) kereséssel	E2	1	P, Ev, F
E2x	E2, az ellenőrzést egy másik modell (Llama-3.1-8B) végzi	E2	1	Ev, F
E4	E0 a szervermodellel	E0	3	P, Ev
E4b	E2 a szervermodellel	E2	1	Ev
E5a	E0 a régi, 512 tokenre csonkolt kódolóval	E0	3	P, Ev, F
E5b	E0, vágási küszöb: átlag + 1,5 szórás	E0	3	P, Ev, F
E5c	E0 rögzített, 800 karakteres darabokkal	E0	3	P, Ev, F

4.4. A három vizsgálat

A kísérleteket három lépcsőben futtattuk (4.2. táblázat). A *pilot* a mérési láncot próbálta ki; egy dokumentumon hipotézist eldönteni elvileg sem lehet. Az *előzetes vizsgálat* a pilot után javított folyamattal (szivárgási szabályok, javító hívás, $r = 1$, a bíró a kérdés forrásdarabjait kapja), a *fő vizsgálat* ugyanezzel, 30 dokumentumon és két helyi generátorral futott.

Az előzetes vizsgálatban az E4 és az E4b hat angol dokumentumon futott (ebből három közös), a többi konfiguráció a közös hat dokumentumon. A PULI-LlumiX-nél azért kevesebb a pontozott kérdés, mert gyakran tíznél kevesebb kérdést adott vissza. A 20 GiB-os munkaállomás-kártyán a modell, a kvantálás és a kontextus ugyanaz, mint egy fogyasztói kártyán, így ez a minőséget nem befolyásolja, a memóriamérés pedig a modell saját foglalását adja.

Két összevetési szabály. A vizsgálatok eltérő dokumentumokon, generátorokkal és részben eltérő implementációval futottak, ezért az eredményeket két szabály szerint vetjük össze.

(1) *Összevetés csak azonos dokumentumokon.* Két konfigurációt, két modellt vagy két vizsgálatot csak ugyanazon a dokumentumhalmazon hasonlítunk össze, mert a variancia fő forrása a dokumentum (4.8. szakasz). Egy vizsgálaton belül ez a közös dokumentumokon teljesül. A három vizsgálat között az összevetés a *hat közös dokumentumon* megengedett (a

4.2. táblázat. A három vizsgálat beállításai. Pontozott kérdés: a generált vizsgákból pontozásra került kérdés; a bírói áttekintő ítélet ezek egy részénél hiányzik.

	Pilot	Előzetes vizsgálat	Fő vizsgálat
Időpont (2026)	szept. 23.	szept. 27–28.	okt. 7. – nov. 1.
Dokumentumok	1 (`hu-coffee`, 1 702 karakter)	9 (3 saját magyar, 6 angol); konfigurációnként 6	30 (24 MILQA, 3 saját, 3 OpenStax)
Konfigurációk	10	14	11 helyi, mindkét generátorral
Generátor	Qwen2.5-7B (E4: szervermodell)	Qwen2.5-7B; szervermodell (B-doc-S, E4, E4b)	PULI-LlumiX 8B és Gemma 3 12B
Ismétlés	3 mag mindenhol	3 mag (egyhívásos konfigurációk), 1 mag (tervezett konfigurációk)	mint az előzetes vizsgálatban
Pontozott kérdések	300	1 670 (mindegyik bírói áttekintő ítélettel)	PULI: 2 935; Gemma: 6 212; bírói áttekintő ítélet a kérdések 29–65 %-ánál (a PULI egyhívásos konfigurációinál 70–100 %-ánál), lásd 5.9. szakasz
Újrapróbálkozás (r)	2	1	1
Szivárgási szabály, javító hívás	nincs	van	van
Bíró forrása	a teljes dokumentum	a kérdés forrásdarabjai (teljes dokumentumos konfigurációknál a dokumentum első 24 000 karaktere)	mint az előzetes vizsgálatban
GPU	RTX 3070 Ti (8 GiB), asztali PC	RTX A4500 (20 GiB), egyetemi munkaállomás	RTX A4500 (20 GiB), egyetemi munkaállomás

három saját magyar szöveg és a fő vizsgálat három OpenStax-részlete), amelyen az előzetes vizsgálat Qwen2.5-7B-je és a fő vizsgálat két modellje egyaránt futott; ilyenkor ezt mindig jelezzük. A pilot az akkori, javítás előtti folyamatot méri, ezért vele számszerű összevetést nem végzünk.

(2) *A futásidő relatív szorzó.* A futásidőt azzal mérjük, hogy ugyanazon a GPU-n egy konfiguráció hányszor lassabb a referenciánál (például az E2 az E0-nál). Mivel a döntéshez a módszerek egymáshoz mért aránya kell, a GPU típusa ezt érdemben nem befolyásolja; az abszolút perceket csak mellékesen közöljük. A pilot RTX 3070 Ti-n, az előzetes és a fő vizsgálat RTX A4500-on futott, ezért a szorzókat is mindig egy vizsgálaton belül számoljuk (5.8. szakasz).

4.5. Mutatók

Minden ráta 0 és 1 (0 és 100 %) közötti, és a szivárgás, a nem kérdő törzs és a duplikátumok kivételével a nagyobb érték a jobb. A tartalmi mutatók a bíró ítéletén alapulnak. Az *alátámasztottság* (G) azon kérdések aránya, amelyeknél a forrás igazolja a megjelölt kulcsot (a bírónak az igazoló mondatot szó szerint idéznie kell); a *vak megoldhatóság* (A) azoké, amelyeket a bíró a kulcs ismerete nélkül, összekevert válaszokkal, csak a forrás alapján helyesen old meg – ez a kulcs helyességét és a kérdés egyértelműségét együtt méri; a *disztraktor-validitás* (V) a kérdésenkénti azon disztraktorok aránya, amelyek a forrás szerint hamisak *és* témába vágók. A *formai megfelelés* (F) vizsgaszintű igen/nem érték: a vizsga pontosan a kért számú kérdést tartalmazza, és minden kérdésnek pontosan négy válasza és egy kulcsa van. A négyet egy *minőségi indexbe* foglaljuk:

$$Q = \frac{F + G + A + V}{4}. \tag{4.1}$$

A Q szándékosan egyszerű, súlyozatlan átlag, amelyet vizsgánként számolunk; a sikertelen vizsga (értelmezhetetlen modellválasz) Q-ja 0, a technikai (szolgáltatás-) hibák kimaradnak. Egyetlen hibás formájú vagy hiányzó kérdés így a Q-t 0,25-tel csökkenti; ezt vállaljuk, mert egy hiányos vagy hibás kulcsú vizsga nem használható változtatás nélkül. A komponenseket külön is közöljük.

A bíró emellett négy szempontot 1–5 skálán pontoz (*helyesség*, *érthetőség*, *disztraktorok*, *szintillesztés*), és igen/nem ítéletet ad (*felhasználnám*: bekerülne-e egy valódi dolgozatba legfeljebb apró javítással). A rubrika (D. függelék) a bíró és az oktatók számára azonos, ami a bíró validálásának (5. hipotézis) előfeltétele. A *lefedettség* (A.4. egyenlet) a kérdésekhez legközelebbi különböző darabok aránya a dokumentum darabjai között (a P2 probléma mérőszáma); mivel tíz kérdésnél legfeljebb $10/K$ (K a darabszám), csak azonos dokumentumon, konfigurációk között hasonlítható, és szerkezeti mutatóként a Q-ba nem számít bele. A *szivárgást* és a *nem kérdő törzset* ugyanazzal a szabállyal mérjük, mint az ellenőrző (3.6.6. szakasz; vö. 5.1. szakasz). A duplikátumráta, a meta-hivatkozás, a keresési találati arány (recall@3), a tematikus hasonlóság és a költségmutatók definíciója az A.11. függelékben található.

4.6. A bíró

A bíró a gpt-oss-120b [69] modell az egyetemi GenAI-szerveren, nulla hőmérséklettel és alacsony („low”) gondolkodási szinttel. Más modellcsaládba tartozik, mint bármelyik generátor (Qwen, Llama/PULI, Gemma), ami az önpreferencia torzításának [68] kockázatát csökkenti. Kérdésenként két hívást végez: az *áttekintő* hívás látja a kulcsot (alátámasztottság szó szerinti idézettel, disztraktoronkénti ítélet, rubrikapontok, megvalósult Bloom-szint, „felhasználnám”), a *vak* hívás nem, és permutált válaszokkal kell megoldania a kérdést.

Forrásként a bíró a kérdéshez tartozó darabokat kapja (a tervezett konfigurációknál a

kérdéshely kontextusát, az E0-nál a visszakeresett darabokat), a megosztott szerver futásideje miatt nem a teljes dokumentumot; így a dokumentum más részeiben lévő ellentmondást nem látja. A teljes dokumentumos konfigurációknál a dokumentum első 24 000 karakterét kapja, ezért ott az alátámasztottság alsó becslés. A fő vizsgálatban a bíró szervere a kérések egy részére hibával válaszolt; a hiányzó áttekintő ítéletek aránya forrásonként és modellenként eltér (4.2. táblázat), a bírón alapuló mutatók csak az ítélettel rendelkező kérdésekre számolódnak, a hatást és egy érzékenységvizsgálatot az 5.9. szakasz mutatja be.

4.7. Oktatói értékelés

A bíró csak akkor érvényes mérőeszköz, ha ítéletei az emberi szakértőkével egyeznek (5. hipotézis). Az oktatói értékelés a dolgozat lezárásakor folyamatban van; protokollját a keretrendszer `rate-export` és `rate-import` lépése valósítja meg: konfigurációnként 30 vakon értékelt kérdés, 3 értékelő, a bíróéval azonos rubrika és forrásrészlet; az egyezést Krippendorff-α-val [71], Spearman-korrelációval és Cohen-κ-val mérjük (részletek: A.10. függelék). Az eredményeket az 5.9. szakasz közli.

4.8. Statisztikai elemzés

Az elemzés egysége a dokumentum. Egy vizsga tíz kérdése nem független: ugyanabból a dokumentumból, egy futáson belül készül, így független megfigyelésként kezelve a próbák a valósnál biztosabbnak mutatnák az eredményt. Ezért minden mutatót előbb dokumentumon belül átlagolunk (a kérdésekre és a magokra); a konfigurációnkénti érték a dokumentumonkénti átlagok átlaga. Bizonytalanságát *bootstrap*-módszerrel [104] becsüljük: a dokumentumokból 10 000-szer húzunk visszatevéssel, és a kapott átlagok középső 95 %-a adja a 95 %-os konfidenciaintervallumot.

Páros összehasonlítás és többszörös tesztelés. Két konfigurációt a páros Wilcoxon-féle előjeles rangpróbával [105] vetünk össze, amely a dokumentumonkénti különbségek rangjaival dolgozik, és nem feltételez normális eloszlást (ez a plafonhoz közeli rátáknál lényeges); a hatás nagysága a rangbiszeriális korreláció [106] (A.5. egyenlet, A.12. függelék), amely +1, ha az új konfiguráció minden dokumentumon jobb, és -1, ha mindenütt rosszabb. A hat előre rögzített összehasonlítás p-értékeit Holm módszerével [75] korrigáljuk: növekvő sorrendben a legkisebbet 6-tal, a következőt 5-tel stb. szorozzuk, és egy összevetés csak akkor szignifikáns, ha korrigált értéke (és minden nála kisebbé) 0,05 alatt van. A Wilcoxon-próba legkisebb elérhető p-értéke hat dokumentumnál 0,031, korrekció után 0,19 (levezetés: A.12. függelék): a pilot ezért csak leíró, az előzetes vizsgálatban egyetlen összevetés sem lehet korrekció után szignifikáns, a fő vizsgálat 30 dokumentumán viszont a szignifikancia elérhető.

Egyezés és az ellenőrző mint osztályozó. Két igen/nem ítéletsor (például az ellenőrzőé és a bíróé) egyezését Cohen-κ-val [70] mérjük (A.6. egyenlet; $\kappa = 0$ a véletlen szintje, $\kappa = 1$ a teljes egyezés, az értelmezés Landis és Koch [72] skáláját követi). Az ellenőrző minden kérdést

átengedett vagy *megjelölt* kategóriába sorol; a bíró alátámasztottsági ítéletét referenciának tekintve pontosságot és felidézést számolunk (A.7. egyenlet). Hasznos ellenőrzőtől mindkettő magas értéke és $\kappa \gg 0$ várható; $\kappa \approx 0$ esetén a jelzése az oktatónak nem hordoz információt.

A fejezet tanulsága. A kiértékelés nem egy szám, hanem egy mérési lánc: egytényezős konfigurációk, a forráshoz mért mutatók, egy független, de maga is ellenőrzött bíró és a dokumentumot egységnek tekintő statisztika együtt teszik lehetővé, hogy egy különbséget egyetlen tényezőnek tulajdonítsunk, és lássuk, mikor nem szignifikáns. A két összevetési szabály a vizsgálatok eltérő dokumentumaiból és hardveréből adódó torzítást zárja ki. A következő két fejezet ezzel a lánccal értékeli előbb a módszer lépéseit (5. fejezet), majd a modelleket (6. fejezet).

5. A módszerek kiértékelése

Ez a fejezet azt mutatja meg, hogy a generálási folyamat egyes lépései – a vizsgaterv, az ellenőrző lánc, a darabolás és a keresés – mennyit javítanak a kérdések minőségén, és mennyibe kerülnek. Az eredményeket modellenként bontva, de a módszer szemszögéből közöljük; a modellek összevetése, a szervermodell és a PULI-LlumiX kudarcának oka a 6. fejezetben, az értelmezés és a döntés a 7. fejezetben következik. Az olvasó megtudja belőle, melyik lépés hatása szignifikáns, miért törékeny a naiv RAG és mi javítja, hányszor drágább a tervezett folyamat, és mennyire megbízható maga a mérés. Minden szám a `tdk/elemzes/elemzes.py` szkripttel készült (E. függelék); a részletes táblázatok egy részét a B. függelék tartalmazza.

5.1. A pilot: három tanulság

A pilot egyetlen rövid magyar szövegen, a Qwen2.5-7B modellel, tíz konfigurációval futott; egy dokumentumon semmilyen különbség nem lehet szignifikáns (4.8. szakasz), célja a mérési lánc kipróbálása volt. Részleteit a B.1. függelékszakasz közli.

1. Csendes tartalékágak. A mérőrendszer több ponton hibát rejtett el: hiányos végső kérdéseket tartott meg, sikertelen hívásoknál beégetett „tartalékvizsgát” adott vissza, a kódoló pedig a hosszabb dokumentumokat a tartalomtól függetlenül vágta (3.6.1. szakasz). Mindhármat javítottuk; a hibás kódoló hatását az E5a méri.

2. Válaszszivárgás: egy új hibamód. Egyes ellenőrzött „kérdések” egy forrásmondatot másoltak a törzsbe, és ugyanezt ismételték meg kulcsként; a bíró ezeket mégis jónak pontozta. Értelmezésünk szerint az ellenőrző visszacsatolása a kis modellt a forrás szó szerinti átvétele felé tolta – a Goodhart-törvény [55] tankönyvi példája. Azóta a szivárgást és a nem kérdő törzset az ellenőrző lánc szabályként elutasítja, és mindkettőt mutatóként is mérjük.

3. A futásról futásra jelentkező zaj. Két azonos kontextust kapó konfiguráció 0,07-dal eltérő minőségi indexet ért el: a GPU-n végzett következtetés rögzített maggal sem bitre reprodukálható. Ezért futott a fő vizsgálat 30 dokumentumon.

5.2. Az előzetes vizsgálat: a módszer egy 7B modellel

Az előzetes vizsgálat a javított folyamattal, a Qwen2.5-7B modellel futott hat dokumentumon, mind a 11 helyi konfigurációval (B.1. táblázat, B.2. függelékszakasz; a szerveres konfigurációk a 6.2. szakaszban). A tervezett és ellenőrzött folyamat (E2, 0,96) itt is jobb volt a naiv RAG-nál (0,64) és a teljes dokumentumos promptnál (0,83), és a legrobusztusabb is. A naiv RAG az angol szövegeken omlott össze, a darabolás javítása viszont nagyrészt helyrehozta (5.5. szakasz). Hat dokumentumon Holm-korrekció után egyetlen összevetés sem lehet szignifikáns, ezért a fő vizsgálat 30 dokumentumon és két másik helyi modellel futott.

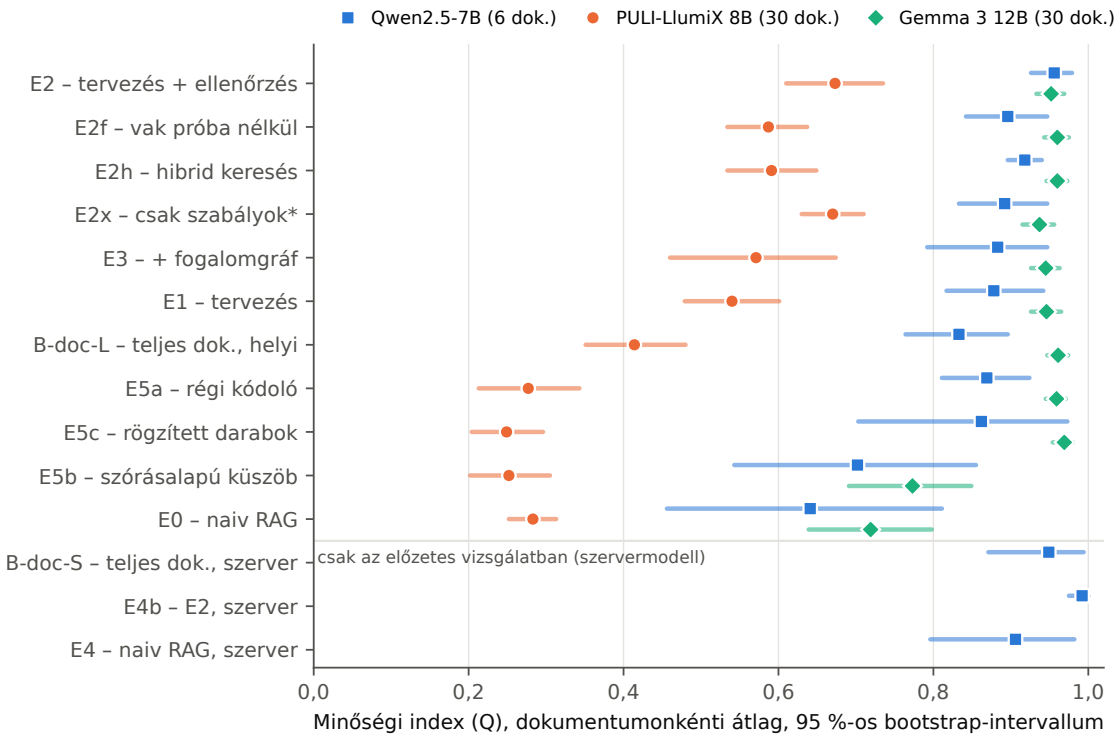
5.3. A fő vizsgálat: összesített eredmények

A fő vizsgálat 30 dokumentumon (24 magyar Wikipédia-cikk, három saját magyar és három angol OpenStax-szöveg) futtatta a 11 helyi konfigurációt mindkét modellel. A PULI-LlumiX 8B 2 935, a Gemma 3 12B 6 212 kérdést írt; a különbség oka, hogy a PULI az egyhívásos konfigurációkban a kért tíz kérdés töredékét adta vissza (6.3. szakasz). Az 5.1. táblázat a konfigurációnkénti eredményeket, az 5.1. ábra a minőségi indexet mindhárom helyi modellre mutatja.

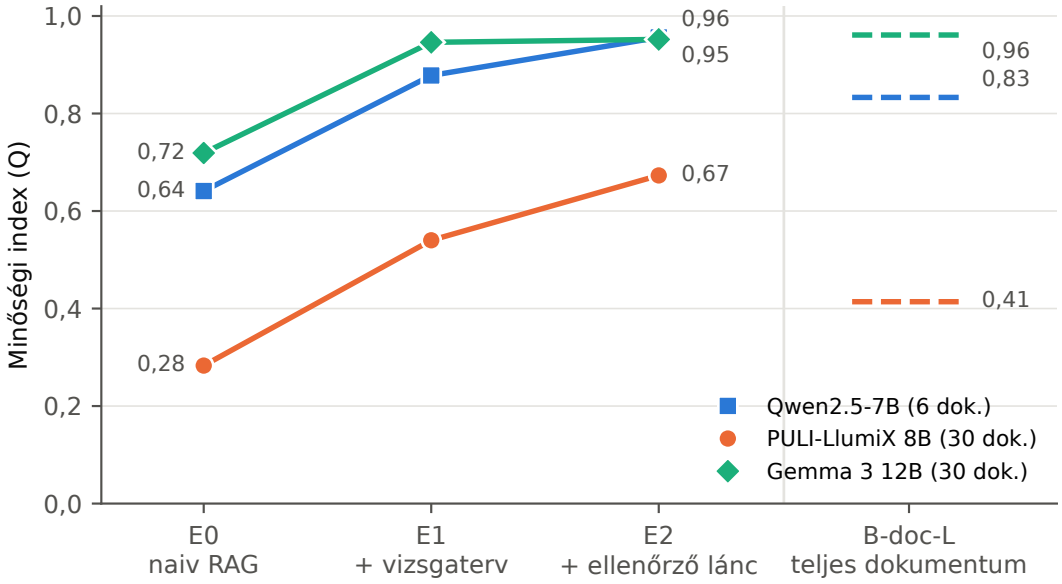
5.1. táblázat. A fő vizsgálat eredményei (30 dokumentum). Q: minőségi index 95 %-os bootstrap-intervallummal; F, G, V: formai megfelelés, alátámasztottság, disztraktor-validitás (%). Perc, Hívás: *csak a Gemma 3 12B* medián futási ideje (RTX A4500) és modellhívásainak száma vizsgánként; mindhárom modell relatív költségét az 5.4. táblázat adja. *Az E2x-ben a második modell ellenőrző hívásai hibával tértek vissza, így csak a szabályalapú ellenőrzés futott.

	PULI-LlumiX 8B					Gemma 3 12B						
Konfig.	Q	95 % CI	F	G	V	Q	95 % CI	F	G	V	Perc	Hívás
B-doc-L	0,41	0,35–0,48	3	48	32	0,96	0,95–0,97	100	93	95	0,6	1
E0	0,28	0,25–0,31	1	27	9	0,72	0,64–0,80	100	46	57	0,6	1
E1	0,54	0,48–0,60	47	58	49	0,95	0,93–0,96	100	88	93	2,9	14
E2	**0,67**	0,61–0,73	87	52	66	0,95	0,93–0,97	100	86	96	4,9	43
E3	0,57	0,46–0,67	80	67	60	0,94	0,93–0,96	100	92	90	6,1	56
E2f	0,59	0,53–0,64	80	47	55	0,96	0,94–0,97	100	91	96	3,9	28
E2h	0,59	0,53–0,65	77	47	59	0,96	0,95–0,97	100	92	95	4,6	42
E2x*	0,67	0,63–0,71	93	48	64	0,94	0,92–0,96	100	87	94	7,4	15
E5a	0,28	0,21–0,34	6	41	32	0,96	0,94–0,97	98	96	93	0,6	1
E5b	0,25	0,20–0,30	4	29	18	0,77	0,69–0,85	100	56	69	0,6	1
E5c	0,25	0,20–0,30	3	28	22	**0,97**	0,95–0,98	100	96	95	0,6	1

A két modell két egészen különböző képet ad. A **PULI-LlumiX** egyhívásos konfigurációi szinte teljesen elbuknak (formai megfelelés 1–6 %, $Q \leq 0{,}41$), és a módszer lépései fokozatosan javítanak: a naiv RAG-hoz képest a tervezés 0,28-ról 0,54-re, az ellenőrzés 0,67-re emeli a minőségi indexet, a teljes dokumentumos promptnál (0,41) is jóval jobb eredménnyel. A **Gemma 3 12B** viszont szinte minden konfigurációban 0,94–0,97 között teljesít: a teljes dokumentumos prompt (0,96) és a rögzített darabolású naiv RAG (E5c, 0,97) legalább olyan jó, mint a tervezett folyamat (0,95). Ennél a modellnél csak a szemantikus darabolású naiv változatok maradnak el (E0: 0,72, E5b: 0,77). Az 5.2. ábra a három helyi modell lépésenkénti útját mutatja: a vizsgaterv minden modellnél nagyot lép előre a (szemantikus darabolású) naiv RAG-hoz képest, az ellenőrzés a gyengébb modelleknél ad hozzá, a teljes dokumentumos prompt pedig annál jobb, minél erősebb a modell.



5.1. ábra. A minőségi index konfigurációnként és generátormodellenként, 95 %-os bootstrap-intervallummal. A Qwen2.5-7B az előzetes vizsgálat hat dokumentumán, a másik két modell a fő vizsgálat 30 dokumentumán futott, ezért a modellek az ábrán nem közvetlenül összevethetők; az azonos dokumentumokon végzett összevetést a 6.1. szakasz közli. A szerveres konfigurációk csak az előzetes vizsgálatban futottak.



5.2. ábra. A minőségi index a módszer lépései szerint (naiv RAG → vizsgaterv → ellenőrző lánc) és a teljes dokumentumos prompt (szaggatott vonal) a három helyi modellel (Qwen2.5-7B: hat, a másik kettő: 30 dokumentum). Minél gyengébb a modell, annál nagyobb a módszer haszna.

5.4. A komponensek hatása

Az 5.2. táblázat az előre rögzített hat páros összehasonlítást mutatja a fő vizsgálat két modelljére; a Qwen2.5-7B (hat dokumentum) értékeit a szövegben közöljük.

5.2. táblázat. Páros Wilcoxon-próbák a dokumentumonkénti minőségi indexen (fő vizsgálat, 30 dokumentum). Δ: az új és a referencia-konfiguráció különbsége; r_{rb}: rangbiszeriális hatásméret; J/R: hány dokumentumon javított (J), illetve rontott (R) az új konfiguráció; $\tilde{p}$: a hat összevetésre Holm-korrigált p-érték. Félkövér: $\tilde{p} < 0{,}05$.

	PULI-LlumiX 8B				Gemma 3 12B			
Összevetés	Δ	r_{rb}	J/R	$\tilde{p}$	Δ	r_{rb}	J/R	$\tilde{p}$
Tervezés (E1–E0)	+0,26	0,97	27/2	< **0,001**	+0,23	0,76	22/7	**0,002**
Ellenőrzés (E2–E1)	+0,13	0,48	19/10	0,066	+0,01	0,12	15/13	1,00
Teljes módszer (E2–E0)	+0,39	1,00	29/1	< **0,001**	+0,23	0,82	23/6	< **0,001**
Módszer vs. teljes dok. (E2–B-doc-L)	+0,26	0,83	24/5	< **0,001**	−0,01	−0,04	16/13	1,00
Csak szabályok (E2x–E2)	0,00	0,01	14/16	0,975	−0,02	−0,12	14/15	1,00
Fogalomgráf (E3–E2)	−0,10	−0,18	15/15	0,775	−0,01	−0,20	9/16	1,00

Tervezés. A vizsgaterv mindkét modellnél nagy és Holm-korrekció után is szignifikáns javulást hozott a naiv RAG-hoz képest; a Qwennél ugyanez +0,24 volt (négy javult, kettő romlott, $p = 0{,}22$). A referencia azonban a szemantikus darabolású E0, és az E1 több tényezőben is eltér tőle (vizsgaterv, kérdéshelyenkénti lekérdezés, kérdésenkénti generálás); e kitétel következményét az 5.5. és a 7.1. szakasz tárgyalja.

Ellenőrzés. Az ellenőrző lánc hatása a modelltől függ, és Holm-korrekció után egyik modellnél sem szignifikáns: a Qwennél öt dokumentumon javított és egyen sem rontott (+0,08, $\tilde{p} = 0{,}19$), a PULI-nál korrigálatlanul $p = 0{,}022$, a Gemmánál a hatás gyakorlatilag nulla. A PULI-nál a javulás főként a formából (F: 47 %→87 %) és a disztraktorokból (V: 49 %→66 %) ered; az alátámasztottság a fő vizsgálatban mindkét modellnél kissé csökkent (PULI: 58 %→52 %, Gemma: 88 %→86 %), a Qwennél nőtt (80 %→90 %).

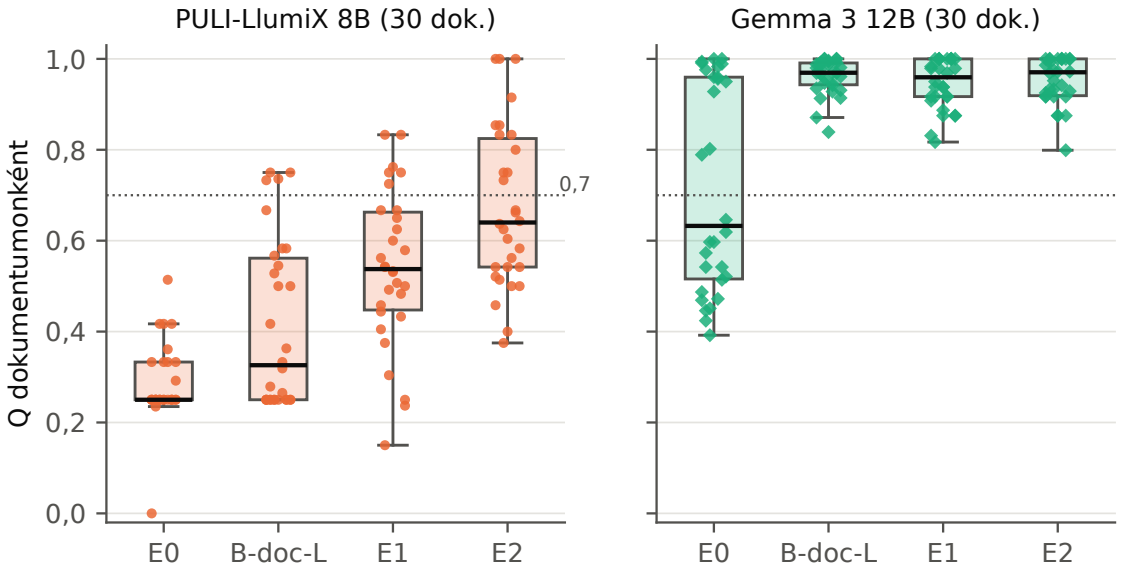
Vak próba. A vak megoldási próba elhagyása (E2f) a PULI-nál rontott (−0,09, 21 dokumentumon rosszabb, korrigálatlan $p = 0{,}014$), a Qwennél is (−0,06, egy javult, négy romlott, $p = 0{,}13$), a Gemmánál nem (+0,01, $p = 0{,}48$); az összevetés leíró jellegű.

Ellenőrző modell (E2x). A második modell (Llama-3.1-8B) ellenőrző hívásai mindkét vizsgálatban, amelyben az E2x futott, hibával tértek vissza (88, illetve 394 és 405 kihagyott ellenőrzés), és a folyamat ilyenkor – a tervezett hibakezelés szerint – nem blokkolja a kérdést. Az E2x így a „csak szabályalapú ellenőrzés” változatot mérte; a független ellenőrző kérdése nyitott maradt. Ez a PULI-nál és a Gemmánál nem tért el érdemben a teljes E2-től, a Qwennél rosszabb volt (0,89 vs. 0,96; egy javult, öt romlott, $\tilde{p} = 0{,}25$). Értelmezésünk szerint a PULI-nál a lánc hasznát főként a szabályok adják.

Fogalomgráf és hibrid keresés. A fogalomgráf (E3) egyik modellnél sem érte meg a többletköltségét (a Qwennél −0,07, egy javult, öt romlott), miközben a vizsgánkénti hívásszám 55–80 lett a 43–61 helyett (5.4. táblázat). A hibrid keresés (E2h) sem javított: a PULI-nál −0,08 (korrigálatlan $p = 0{,}061$), a Qwennél −0,04, a Gemmánál +0,01.

5.5. Darabolás és robusztusság

Egy oktató szempontjából nem az átlag, hanem az számít, mekkora a kudarc esélye egy új dokumentumon (5.3. ábra). A Gemmával a tervezett konfigurációk, a teljes dokumentumos prompt és az E5a, E5c egyetlen dokumentumon sem estek 0,79 alá (a leggyengébb dokumentum az E2-nél 0,799, az E2x-nél 0,798, a többinél 0,80–0,88), a naiv RAG viszont 16 dokumentumon 0,70 alatt maradt, a leggyengébben 0,39-en; az E5b 11 dokumentumon maradt 0,70 alatt.



5.3. ábra. A minőségi index dokumentumonkénti eloszlása a fő vizsgálatban (pontok: egy-egy dokumentum; doboz: interkvartilis tartomány, vastag vonal: medián). A pontozott vonal a 0,70-es szint.

A naiv RAG törékenységének oka. A hiba nem a keresésben van: a referenciakérdésekkel végzett próbában az igazoló mondatot tartalmazó darab a fő vizsgálatban a kérdések 86 %-ánál (az előzetes vizsgálatban 93 %-ánál) az első három találat között volt, és ez az arány a rögzített darabolással sem változott érdemben (Gemma E5c: 86 %). A hiba a *lekérdezésben* van, amely nem tartalmi kérdés, hanem egy feladatleírás („10 feleletválasztós kérdés, könnyű nehézség”). A Wikipédia-cikkek és az OpenStax-szövegek rövid szerkezeti sorokat (címeket, „Link to Learning”-dobozokat) tartalmaznak, amelyeket a szemantikus darabolás minimális darabméret nélkül önálló darabbá vág, és a tartalom nélküli lekérdezés éppen ezekhez a tartalom nélküli darabokhoz áll a legközelebb. A Gemma ilyenkor magáról a feladatról kérdez: egy, a sclerosis multiplexről szóló cikkből például ezt írta: „Mi a nehézségi szint a vizsgának?”, kulcsa: „Kezdő (könnyű).” A rögzített, 800 karakteres darabolás (E5c) ilyen darabot nem hoz létre. Valószínűleg

ugyanez magyarázza, hogy a „hibás” régi kódoló (E5a) is javít: hosszabb dokumentumon az 512. token után már csak a darab hossza szerint vág (3.6.1. szakasz). A magasabb vágási küszöb (E5b) a rövid darabokat nem szünteti meg, és csak kicsit javít.

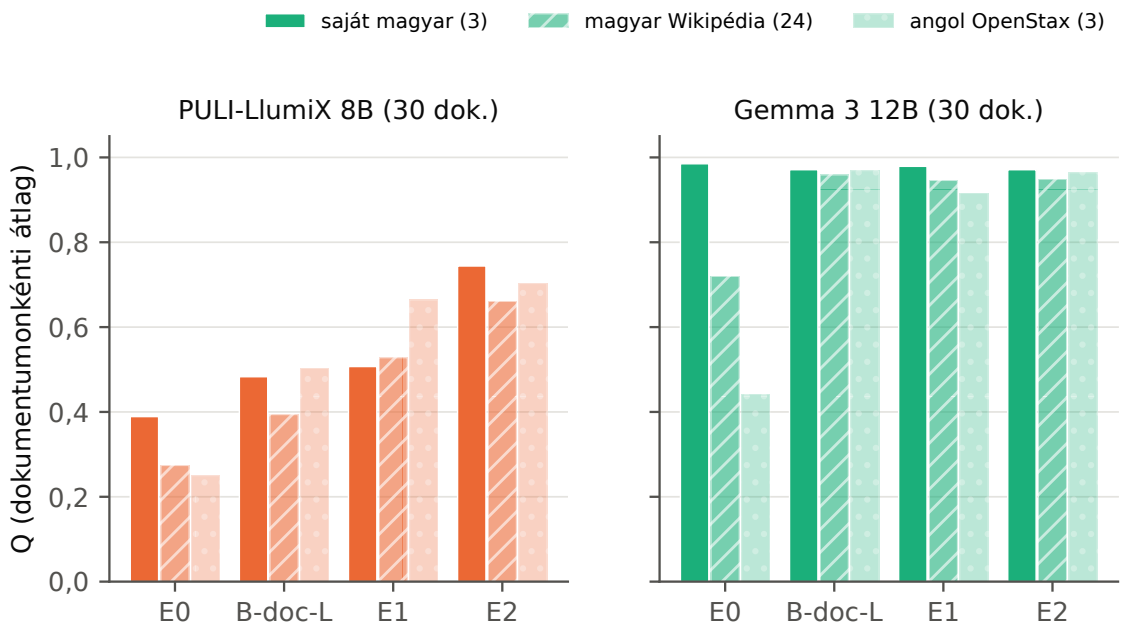
5.3. táblázat. A darabolási változatok hatása a naiv RAG-ra: az E5a–E5c és az E0 páros Wilcoxon-összevetése modellenként. Qwen2.5-7B: az előzetes vizsgálat hat dokumentuma; PULI-LlumiX 8B és Gemma 3 12B: a fő vizsgálat 30 dokumentuma. Δ: a minőségi index változása; J/R: javult, illetve romlott dokumentumok; p: korrigálatlan érték, mert ezek az összevetések nem tartoznak az előre rögzített hat közé (leíró jellegűek). Az abszolút értékeket a B.1. és az 5.1. táblázat adja.

	Qwen2.5-7B (6 dok.)			PULI-LlumiX 8B (30 dok.)			Gemma 3 12B (30 dok.)		
Változat	Δ	J/R	p	Δ	J/R	p	Δ	J/R	p
E5a (régi kódoló)	+0,23	5/1	0,16	−0,01	15/14	0,74	+0,24	23/5	< 0,001
E5b (magasabb küszöb)	+0,06	5/1	0,22	−0,03	6/12	0,20	+0,05	18/12	0,15
E5c (rögzített, 800 kar.)	+0,22	4/2	0,22	−0,03	9/17	0,22	+0,25	23/7	< 0,001

A három modell. *Kiemelendő eredmény, hogy a Gemmánál a rögzített darabolású naiv RAG (E5c) a legjobb konfiguráció (*0,97*), és egyben a leggyorsabb is* (ideje az E0-éval azonos, az E2 viszont 8,5-szer annyi ideig fut, 5.4. táblázat), és egyetlen dokumentumon sem maradt 0,70 alatt. Az E2-től (0,95) és a teljes dokumentumos prompttól (0,96) való különbsége azonban kicsi, a konfidenciaintervallumok átfednek, és ezt az összevetést nem teszteltük. A Qwennél a régi kódoló és a rögzített darabolás az E0 0,64-éhez képest 0,87-et, illetve 0,86-ot ért el, hat dokumentumon nem szignifikánsan; az E5c itt nem is robusztus (leggyengébb dokumentuma 0,50, a törzsek 44 %-a nem kérdés), és mindkét változat elmarad az E2-től (0,96). A PULI-nál a darabolás nem segít (nem szignifikáns): a darabolási változatok formai megfelelése 3–6 %, a szűk keresztmetszet a formátumkövetés (6.3. szakasz; az érzékenységvizsgálatban a különbség kissé nagyobb, 5.9. szakasz).

A „vizsgaterv javít a naiv RAG-hoz képest” állítás tehát a szemantikus darabolású, három darabot visszakereső E0-ra igaz. Hogy a tervezett folyamat *nem függ* a darabolástól, azt nem mértük, mert az E5a–E5c csak az E0-t változtatta; elvárásunk szerint a függés kicsi, mert a tervezett folyamat kérdéshelyenként tartalmi lekérdezéssel keres, de ennek ellenőrzése (az E2 rögzített darabolással) további munka.

Az 5.4. ábra ugyanezt forrásonként mutatja: a Gemma naiv RAG-ja a három rövid saját szövegen kiváló (0,99), a Wikipédia-cikkeken 0,72-re, az angol tankönyvi szövegeken 0,44-re esik, miközben a többi bemutatott konfiguráció minden forráson 0,91 felett marad (a legalacsonyabb az E1 az angol szövegeken, 0,916). Az angol részhalmaz mindössze három dokumentum, ezért nyelvi összevetésre nem elegendő.



5.4. ábra. A minőségi index dokumentumforrásonként a fő vizsgálat négy fő konfigurációjában. Zárójelben a dokumentumok száma.

5.6. Az ellenőrző működése

Az E2 ellenőrző láncának részletes mutatóit a B.2. táblázat (B.3. függelékszakasz) közli; az ellenőrzőt bináris osztályozóként is értékeltük, a bíró alátámasztottsági ítéletéhez képest (4.8. szakasz). A leggyakoribb elutasítási ok minden modellnél a *duplikátum*: tíz egymástól eltérő kérdés megírása egy rövid szövegből a kis modellek számára nehéz. Az ellenőrző terhelése a modell gyengeségét tükrözi: a kérdéshelyek első kísérletre a Gemmánál 70 %-ban, a Qwennél 23 %-ban, a PULI-nál 5 %-ban mentek át, így a Gemmánál a láncnak alig van mit javítania. Az ellenőrző kérdésenkénti ítélete egyik modellnél sem egyezik a bíróéval a véletlennél érdemben jobban (κ = 0,00–0,08); ennek értelmezését a 7.5. szakasz adja.

5.7. Lefedettség, kognitív szint és felhasználhatóság

A részletes, modellenkénti értékeket a B.4. függelékszakasz közli; itt a Gemma alapján összegzünk. A tervezett folyamat több darabot fed le, mint a naiv RAG (24 %→43 %), de nem többet, mint a teljes dokumentumos prompt (43 %): a kérdések egy szakaszra tömörülése a naiv RAG sajátja. A vizsgaterv a kérdések 43–45 %-át tervezte magasabb rendű Bloom-szintre, de a bíró szerint ebből a Gemmánál csak 7–11 %, a PULI-nál 0–2 % valósult meg: a kiosztás a *kért* szintet garantálja, a megvalósultat nem. A bíró „felhasználnám” ítélete a Gemma tervezett konfigurációiban 85–88 %, a naiv RAG-nál 42 %, a PULI E2-ben 29 %; a tervezett folyamat jellemzően hosszabb, összefüggést kérdező törzset ír.

5.8. Költség: relatív szorzók

A futási időt relatív szorzóként közöljük: egy konfiguráció medián vizsgaideje hányszorosa *ugyanazon modell* naiv RAG-jának (E0) ugyanazon a kártyán (5.4. táblázat). A szorzót mindkét oldalon ugyanaz a modell, kvantálás és kontextus, főként a hívások száma és hossza határozza meg, ezért a GPU típusa érdemben nem befolyásolja, csak az abszolút időt.

5.4. táblázat. A konfigurációk relatív futási ideje és modellhívásai. ×E0: a medián vizsgaidő az azonos modell E0-jának hányszorosa; Hívás: medián modellhívás vizsgánként. Qwen2.5-7B: előzetes vizsgálat, hat dokumentum; a másik kettő: fő vizsgálat, 30 dokumentum; mindhárom RTX A4500-on. Az utolsó sor az E0 abszolút medián ideje.

	Qwen2.5-7B		PULI-LlumiX 8B		Gemma 3 12B	
Konfig.	×E0	Hívás	×E0	Hívás	×E0	Hívás
E0	1,0	1	1,0	1	1,0	1
B-doc-L	1,2	1	1,1	1	1,0	1
E5a	1,1	1	1,4	1	1,0	1
E5b	1,0	1	0,9	1	1,0	1
E5c	1,1	1	1,3	1	1,0	1
E1	5,9	18	426†	24	5,0	14
E2	10,9	51	52,3	60,5	8,5	43
E2f	9,0	37	46,7	40	6,8	27,5
E2h	11,8	55	52,3	55,5	8,0	42
E2x*	23,9	20	76,2	33	12,8	14,5
E3	17,4	54,5	74,3	80	10,6	55,5
E0 (perc)	0,32		0,23		0,58	

† Kiugró érték: a PULI E1 futásában 103 modellhívás időtúllépéssel vagy hibával zárult, a medián vizsgaidő 96 perc lett (6.3. szakasz). * A második modell sikertelen ellenőrző hívásai a hívásszámban nem, az időben feltehetően szerepelnek (5.4. szakasz).

A Gemmánál az egyhívásos konfigurációk – köztük a legjobb E5c – az E0-val azonos idő alatt futnak, az E1 kb. ötször, az E2 8,5-ször, az E3 10,6-szor annyi ideig; a Qwennél a tervezett konfigurációk szorzója 6–17. A vak próba elhagyása (E2f) a Gemmánál az E2 idejének kb. 80 %-ára csökkenti a költséget, minőségvesztés nélkül. Az E2x hívásszáma kisebb, ideje mégis a leghosszabb, mert a hibával visszatérő második modelles hívások is időt vittek el (ezt külön nem mértük). A PULI szorzói azért kiugróak (47–76×), mert az E0-ja átlagosan csak 1,8 kérdést ír, így rendkívül gyors (6.4. szakasz). Abszolút értékben a tervezett folyamat a Gemmával vizsgánként 3–7 percig fut (5.1. táblázat).

5.9. A mérés megbízhatósága

Hiányzó bírói ítéletek. A fő vizsgálatban a bíró szervere a kérések egy részére hibával válaszolt (HTTP 400, újrapróbálás után is; az előzetes vizsgálatban ilyen hiba nem fordult elő). Az

áttekintő ítélet a tervezett konfigurációkban a kérdések 29–52 %-ánál van meg (a PULI E2-ben 85 kérdésnél), és a hiány *nem független a forrástól*: a Gemmánál az angol és a saját magyar szövegekből írt kérdések szinte mind kaptak ítéletet, a Wikipédia-kérdéseknek viszont csak 42–55 %-a, a dokumentum hossza szerint pedig nincs érdemi különbség; a PULI-nál a lefedettség minden forráson alacsony (B.3. táblázat, B.5. függelékszakasz). A szerver tehát a Wikipédia-kérdések egy részét elutasította; ennek oka nem ismert. Óvatos feltevésként felmerül egy szerveroldali tartalomszűrő, ezt azonban nem ellenőriztük. Ha egy vizsga minden bírói hívása sikertelen, a vizsgaszintű Q csak a formai megfelelésre (és a vak próbára) támaszkodik.

Érzékenységvizsgálat. Ezt úgy ellenőriztük, hogy az alátámasztottságot, a vak megoldhatóságot és a disztraktor-validitást a vizsgák helyett dokumentumonként, az összes bírált kérdésre összevonva számoltuk (Q_{pooled}). A minőségi index így a Gemma minden konfigurációjában és a PULI tervezett konfigurációiban legfeljebb 0,01-dal tér el, ezek összevetései tehát nem érzékenyek a hiányzó ítéletekre. A PULI egyhívásos konfigurációinál az eltérés – az E0 kivételével (0,00) – 0,03–0,08 (B-doc-L: 0,03, E5b: 0,05, E5a és E5c: 0,08), és a köztük lévő sorrend megfordul (összevont számítással E5a 0,36, E5c 0,33, E5b 0,30, E0 0,28). A PULI darabolási változatainak hatása ezért bizonytalan, de mindegyik egyhívásos PULI-konfiguráció 0,45 alatt marad, messze a tervezettek alatt.

A bíró vakfoltja. A teljes dokumentumos konfigurációknál a bíró a dokumentumnak csak az első 24 000 karakterét látja (4.6. szakasz), ezért ezek alátámasztottsága a hosszú dokumentumokon alsó becslés (példa: B.5. függelékszakasz).

Oktatói értékelés. A bíró oktatói validálása (4.7. szakasz) a dolgozat lezárásakor folyamatban van. [Ide kerül: az oktatók egymás közötti egyezése (Krippendorff-α), a bíró és az oktatók egyezése szempontonként (Spearman, α), a „felhasználnám” ítéletek Cohen-κ-ja, valamint az oktatók szerinti minőség konfigurációnként.]

5.10. A fejezet tanulsága

A módszer lépései közül egyedül a vizsgaterv hatása szignifikáns mindkét fő modellnél, a szemantikus darabolású naiv RAG-hoz mérve; a naiv RAG törékenységét a feladatleírás mint lekérdezés és a rövid szerkezeti darabok okozzák, és rögzített darabolással a Gemma naiv RAG-ja a legjobb és a leggyorsabb konfiguráció. Az ellenőrző lánc a gyenge modelleknél ad hozzá, Holm-korrekció után egyiknél sem szignifikánsan; a fogalomgráf és a hibrid keresés nem érte meg a többletköltséget, amely a tervezett folyamatnál ugyanazon a kártyán 5–17-szeres. A hiányzó bírói ítéletek forrásfüggők, de a fő következtetéseket nem változtatják meg. A modelleket a 6. fejezet veti össze.

6. A modellek kiértékelése

Az előző fejezet a módszer lépéseinek hatását vizsgálta modellenként; ez a fejezet a modelleket veti össze egymással. Az olvasó megtudja belőle, (1) hogyan teljesít a három helyi modell *azonos dokumentumokon*, (2) mennyire közelíti meg egy helyi modell a nagy szervermodellt, (3) miért bukott el a magyarra továbbelőtanított PULI-LlumiX, és (4) mekkora kártya kell az egyes modellekhez, és milyen relatív költséggel futnak. Mivel a három vizsgálat más dokumentumokon futott, modellek között csak azonos dokumentumhalmazon hasonlítunk, és mindenhol megnevezzük, melyiken.

6.1. A három helyi modell azonos dokumentumokon

Két dokumentumhalmazon futott több modell is. (a) Az előzetes vizsgálat hat dokumentumán (`en-economics-short-01`, `en-humanities-medium-02`, `en-law-long-03`, `hu-coffee`, `hu-gametheory`, `hu-immune`) a Qwen2.5-7B és a szervermodell futott, és mivel ez a hat dokumentum a fő vizsgálat 30 dokumentuma között is szerepel, a PULI-LlumiX és a Gemma eredménye ezekre leszűkítve is számolható. (b) A fő vizsgálat 30 dokumentumán a PULI-LlumiX és a Gemma futott. A 6.1. táblázat az (a) halmazt mutatja.

6.1. táblázat. A modellek minőségi indexe (Q) a hat közös dokumentumon (az előzetes vizsgálat dokumentumai; a PULI-LlumiX 8B és a Gemma 3 12B értéke a fő vizsgálat futásaiból, erre a hat dokumentumra leszűkítve). p: páros Wilcoxon-próba a hat dokumentumon, korrigálatlan, leíró jellegű (hat dokumentumon a legkisebb elérhető érték 0,031). Szerver: a szervermodell ugyanazzal a konfigurációval (B-doc-S, E4, E4b). [a]Csak a három közös angol dokumentumon.

Konfig.	Qwen2.5 7B	PULI-LlumiX 8B	Gemma 3 12B	p (Qwen–PULI)	p (Qwen–Gemma)	Szerver
B-doc-L	0,83	0,49	0,97	0,031	0,031	0,95 (B-doc-S)
E0	0,64	0,32	0,71	0,031	0,094	0,94[a] (E4)
E1	0,88	0,59	0,95	0,031	0,22	–
E2	0,96	0,72	0,97	0,063	0,66	1,00[a] (E4b)
E3	0,88	0,44	0,97	0,031	0,22	–
E2f	0,90	0,69	0,98	0,031	0,094	–
E2h	0,92	0,63	0,96	0,063	0,094	–
E2x	0,89	0,71	0,96	–	–	–
E5a	0,87	0,36	0,97	0,031	0,031	–
E5b	0,70	0,23	0,76	0,031	0,31	–
E5c	0,86	0,29	0,97	0,031	0,69	–

A hat közös dokumentumon a sorrend minden konfigurációban azonos: Gemma > Qwen > PULI. A Qwen a PULI-nál minden összevetett konfigurációban jobb, nyolcban mind a hat

dokumentumon ($p = 0{,}031$, a hat dokumentumon elérhető legkisebb érték), az E2-ben és az E2h-ban $p = 0{,}063$ mellett. A Gemma a Qwennél minden konfigurációban magasabb értéket ért el, de egyöntetűen csak a teljes dokumentumos promptnál és az E5a-nál; a különbség az E2-nél a legkisebb (0,96 vs. 0,97, $p = 0{,}66$), a teljes dokumentumos promptnál a legnagyobb (0,83 vs. 0,97). A három saját magyar szövegen is ez a kép: az E2-vel a Qwen 0,96-ot, a PULI 0,74-et, a Gemma 0,97-et ért el, a naiv RAG-gal 0,88-at, 0,39-et és 0,99-et. A magyar nyelvre specializált modell tehát a magyar szövegeken is a leggyengébb volt.

A fő vizsgálat 30 dokumentumán a Gemma a PULI-nál mind a tíz összevetett konfigurációban jobb (páros Wilcoxon, korrigálatlanul $p \leq 5{,}3 \cdot 10^{-6}$; az értékeket az 5.1. táblázat adja). A különbség a tervezett és ellenőrzött folyamatnál a legkisebb (E2: 0,67 vs. 0,95), és az egyhívásos konfigurációkban a legnagyobb (E5c: 0,25 vs. 0,97): a módszer a két modell közötti távolságot csökkenti, de nem tünteti el.

6.2. A szervermodell és a helyi modellek

A szervermodell (az egyetemi GenAI-szerver nagy Qwen-modellje) csak az előzetes vizsgálatban futott. A teljes dokumentumos prompttal (B-doc-S, a mai gyakorlat) a hat közös dokumentumon 0,95-öt ért el (95 %-os intervallum 0,87–0,99), a naiv RAG-gal (E4) a saját hat angol dokumentumán 0,91-et (0,80–0,98), a mi tervezett és ellenőrzött folyamatunkkal (E4b) 0,99-et (0,97–1,00); a három közös angol dokumentumon 0,94-et, illetve 1,00-t.

A helyi Qwen2.5-7B a tervezett és ellenőrzött folyamattal (E2, 0,96) a hat közös dokumentumon tehát eléri a szervermodell teljes dokumentumos promptját (0,95), a három közös angol dokumentumon pedig a szervermodell naiv RAG-ját (0,95 vs. 0,94). Ugyanezzel a módszerrel azonban a szervermodell is jobb lesz (0,99): a „helyi modell eléri a szervermodellt” állítás csak a szervermodell teljes dokumentumos promptjára igaz, a módszert alkalmazó szervermodellre nem. A különbségek hat, illetve három dokumentumon születtek, ezért leírók; szignifikanciát ezen a mintán Holm-korrekció után elvileg sem lehet kimutatni (4.8. szakasz).

A szervermodell a módszerrel minden más mutatón is a legjobb volt: kérdéshelyeinek 83 %-a elsőre átment az ellenőrzésen (a Qwennél 23 %), a bíró a kérdések 98 %-ára mondta, hogy felhasználná (Qwen E2: 80 %), és a tervezett és megvalósult Bloom-szint 62 %-ban egyezett (Qwen: 35 %). Naiv RAG-gal viszont a szervermodell is a naiv RAG hibáit mutatta: a kérdéspárok 49 %-a közel azonos volt, a lefedettség 9 % (E4b: 28 %), és formailag hibátlan, de tartalmilag üres kérdéseket is írt („Hány szóból áll a »Link to Learning« cím?”), amelyeket a bíró 5/5-re pontozott. Ez ugyanaz a szerkezeti darab, amely a helyi naiv RAG-ot is félrevitte (5.5. szakasz), és a szivárgáshoz hasonlóan a mérést felfelé torzítja. Futásidőt a megosztott szerveren mért értékekből nem hasonlítunk a helyiekhez; a szerver saját E4b/E4 szorzója kb. 9.

6.3. Miért bukik el a PULI-LlumiX?

A magyarra továbbelőtanított modelltől azt vártuk, hogy a magyar dokumentumokon jobb lesz a többnyelvű modelleknél. Ehelyett a vizsgálat leggyengébb modellje lett, a magyar szövegeken is (6.1. szakasz), és ennek oka nem a nyelv, hanem az *utasításkövetés*.

A modell. A modellkártya szerint a PULI-LlumiX-Llama-3.1 a Llama 3.1 8B *Instruct* modell magyar szövegeken folytatott továbbelőtanítása, utólagos utasítás-hangolás nélkül; a kártya „base” modellnek nevezi [59]. A vizsgálatban nem a fejlesztő által közzétett súlyok, hanem egy harmadik féltől származó, GGUF formátumú, kvantált változat futott (`hf.co/mradermacher/PULI-LlumiX-Llama-3.1-GGUF:Q4_K_M`, E. függelék).

A tünetek. Egyetlen hívásban a PULI a kért tíz kérdés helyett átlagosan 1,8-at (E0), illetve 5,6-ot (B-doc-L) adott vissza; az egyhívásos konfigurációk formai megfelelése 1–6 %, vagyis a vizsgák 94–99 %-a formailag hibás volt, a darabolási változatok vizsgáinak 14–29 %-ában pedig a válasz nem is volt értelmezhető JSON. A tervezett folyamat ezt részben megkerüli, mert egy hívásban csak egy kérdést kér, de a tervezett konfigurációk futása során is konfigurációnként 128–620 modellválasz nem volt értelmezhető (a Gemmánál és a Qwennél egy sem). A kérdések minősége így is gyenge marad: az ellenőrzés nélküli E1 kérdéseinek 34 %-a szivárogtatja a kulcsot, 45 %-ának törzse nem kérdés, a kérdéspárok 62 %-a közel azonos, a törzsek pedig átlagosan 252 karakteresek (a Gemma E1-ében 122). A modell jellemzően a forrás egy mondatát másolja be kérdésként és kulcsként is – ugyanazt a hibát mutatva, amelyet a pilot a Qwen-ellenőrző visszacsatolásánál talált (5.1. szakasz). A *Nürnbergi per* cikkből például a „kérdés” a forrás egy kijelentő mondata volt, és a négy válaszlehetőség közül kettő ugyanez a mondat; a bíró helyességi pontszáma 1/5 lett.

Az ellenőrző lánc a szivárgást (34 %→12 %) és a nem kérdő törzseket (45 %→22 %) mérsékli, de nem szünteti meg, a megvalósult Bloom-szint gyakorlatilag mindig az emlékezés marad, és a teljes módszerrel is 18 dokumentumon 0,70 alatt marad a minőségi index (a leggyengébben 0,38). Az E1 futása emellett instabil volt: 103 modellhívás időtúllépéssel vagy hibával zárult, és egy vizsga medián ideje 96 perc lett (a Gemmánál 2,9 perc).

Mire általánosítható? A következtetés erre a modellre szűkül: nem általában a magyar nyelvű továbbtanítás, hanem ez a továbbelőtanított, utána újra nem hangolt modell (ebben a kvantált változatban) nem követte a strukturált kimenet formátumát. Feltevésként megemlíthető, hogy a csevegési sablon (chat-sablon) is szerepet játszhatott, vagyis hogy a GGUF-fájlba ágyazott sablon eltért attól, amellyel a modell a legjobban működik; ezt nem vizsgáltuk, és a kvantálás hatását sem tudjuk elkülöníteni. A gyakorlati tanulság: a modellválasztásnál egy strukturált, formátumkövető feladathoz az utasításkövetés legalább olyan fontos, mint a nyelvi teljesítmény, és ezt a célfeladaton kell mérni.

6.4. Erőforrásigény és GPU-szintek

A 6.2. táblázat a három helyi modell mért memóriaigényét és azonos kártyán mért relatív futási idejét foglalja össze; a 6.1. ábra a minőséget a futási idő függvényében mutatja.

6.2. táblázat. A helyi modellek erőforrásigénye. Modell: az Ollama által jelentett, mért foglalás 8 192 tokenes kontextusnál (GiB; a A.2. táblázat becslésével összevetendő); Teljes dok.: ugyanez a 16 384 tokenes B-doc-L konfigurációnál; Kártya: a szükséges fogyasztói GPU az asztali környezet 1,6–1,9 GiB-os foglalása mellett (a pilot mérése); E2/E0: a medián vizsgaidő modellen belüli szorzója ugyanazon a kártyán (5.4. táblázat).

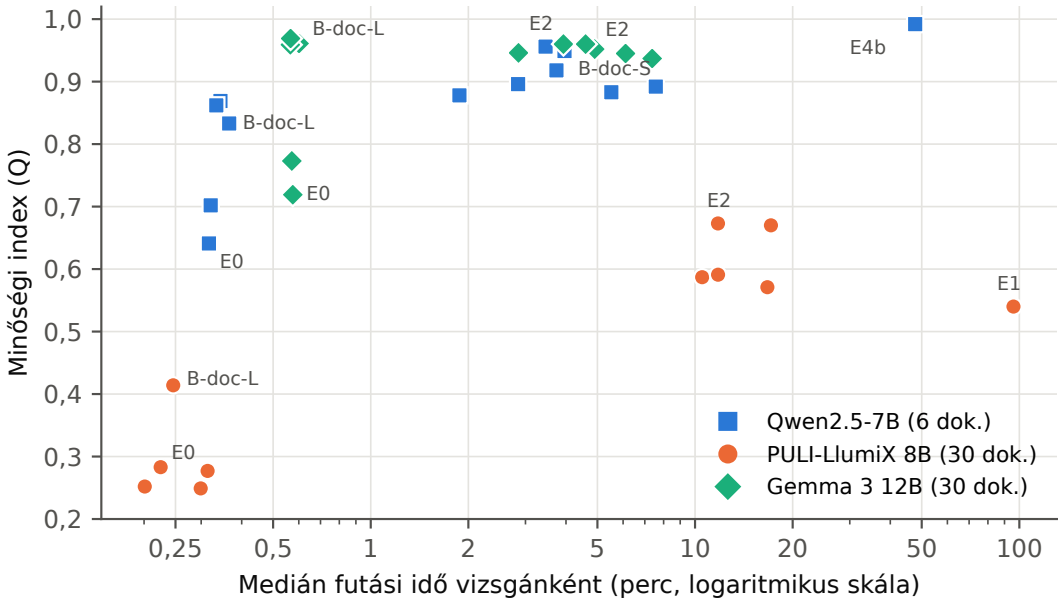
Modell	Modell (GiB)	Teljes dok. (GiB)	Kártya	E2/E0
Qwen2.5-7B (Q4_K_M)	4,8	5,2	8 GB-os	10,9×
PULI-LlumiX 8B (Q4_K_M)	5,5	6,5	8 GB-os*	52,3×
Gemma 3 12B (Q4_K_M)	7,8	7,8	12 GB-os	8,5×

* A 16 384 tokenes teljes dokumentumos konfigurációhoz a 8 GB-os kártya várhatóan nem elég (lásd a szöveget).

Memória. A Qwen2.5-7B (4,8 GiB) és a PULI-LlumiX 8B (5,5 GiB) 8 192 tokenes kontextussal egy 8 GB-os fogyasztói kártyán is elfér (a pilot asztali gépén, RTX 3070 Ti mellett a Qwennel a legrosszabb esetben is kb. 380 MiB tartalék maradt); a Gemma 3 12B 7,8 GiB-os foglalása az asztali környezettel együtt kb. 9,4–9,7 GiB, vagyis egy 12 GB-os fogyasztói kártyát igényel. A 16 384 tokenes teljes dokumentumos konfigurációnál a Qwen foglalása 464 MiB-tal nőtt, ami nagyságrendben egyezik a (A.1) becslés 448 MiB-os KV-többletével; a PULI-é 1 024 MiB-tal 6,5 GiB-ra, így az asztali környezettel együtt egy 8 GB-os kártya kapacitását meghaladná (fogyasztói kártyán ezt nem mértük). A Gemma foglalása gyakorlatilag nem nőtt (16 MiB); ezt feltehetően a modell csúszóablakos helyi figyelemrétegei magyarázzák [58], de nem vizsgáltuk.

Futási idő. A futásidőt relatív szorzóként, egy vizsgálaton belül értelmezzük (5.8. szakasz): az abszolút percek más kártyán mások lennének, a szorzók érdemben nem. A tervezett és ellenőrzött folyamat a Gemmánál az E0 idejének 8,5-szerese, a Qwennél 10,9-szerese. A PULI szorzója (52,3×) félrevezetően nagy, mert az E0-ja alig ír kérdést; a fő vizsgálaton belül, ugyanazon a 30 dokumentumon és kártyán mérve a PULI E0-ja a Gemmáénak kb. 0,4-szerese, az E2-je viszont kb. 2,4-szerese. A PULI tehát kisebb modell létére a tervezett folyamatban lassabb, mert szinte minden kérdéshelyet újra kell próbálnia (2,0 kísérlet a Gemma 1,3-ával szemben, B.2. táblázat), és sok válasza értelmezhetetlen. A Qwen és a fő vizsgálat modelljeinek idejét nem vetjük össze, mert más vizsgálatban, más dokumentumokon mértük.

GPU-szintek. A mérések alapján két szint különíthető el: egy 8 GB-os kártyán a 7–8B modellek futnak, ezek közül a vizsgált feladatra a Qwen2.5-7B alkalmas; egy 12 GB-os kártyán a Gemma 3 12B, amely minden konfigurációban a legjobb helyi eredményt adta. Hogy melyik szinten melyik konfiguráció kerüljön a rendszerbe, a 7. fejezet dönti el.



6.1. ábra. Minőség és futási idő. Az egyhívásos konfigurációk gyorsak, de minőségük a modelltől és a darabolástól függően erősen ingadozik; a tervezett konfigurációk lassabbak, de minden modellnél a legjobbak között vannak.

6.5. Modellválasztási tanulság

Két tanulság emelhető ki. *Először*, a vizsgált feladatban az utasításkövetés fontosabb volt a nyelvi specializációnál: a többnyelvű Qwen2.5-7B a hat közös dokumentumon – a magyar szövegeken is – minden konfigurációban jobb volt a magyarra továbbelőtanított PULI-LlumiX 8B-nél. *Másodszor*, minél erősebb a modell, annál kisebb a módszer haszna a minőségben: ugyanezen a hat dokumentumon a teljes módszer (E2–E0) a PULI-nál 0,41-dal, a Qwennél 0,32-vel, a Gemmánál 0,26-tal javított, a teljes dokumentumos prompthoz képest (E2–B-doc-L) pedig 0,23-dal, 0,12-vel, illetve egyáltalán nem. Az erős modellnél a módszer értéke ezért elsősorban az ellenőrizhetőség (kérdésenkénti forrás, terv, ellenőrzés), a gyenge modellnél maga a használható vizsga. Mivel e tulajdonságokat a modellkártya nem mutatja meg, a modellt a célfeladaton kell kiválasztani – erre szolgál a dolgozat kiértékelő keretrendszere.

7. Az eredmények értékelése és döntés: mit építünk be a rendszerbe

Ebben a fejezetben az 5. és a 6. fejezet méréseit értékeljük, és ezekből döntjük el, mi kerüljön a Mimir éles generálási útvonalába, amely ma a naiv RAG-ot (E0) futtatja. Az olvasó megtudja, mely hipotéziseket támasztják alá a mérések, hogyan viszonyulnak eredményeink az irodalomhoz, és GPU-szintenként melyik konfiguráció a legjobb, a leggyorsabb és a legrobusztusabb, valamint ebből mi kerül be a rendszerbe (7.4. szakasz). A fejezetet a mérés tanulságai, az érvényesség korlátai és az etikai szempontok zárják.

7.1. A hipotézisek értékelése

7.1. táblázat. A hipotézisek és a vizsgálatok bizonyítéka. Fő: a 30 dokumentumos fő vizsgálat (PULI-LlumiX 8B és Gemma 3 12B); Előzetes: a hat dokumentumos vizsgálat (Qwen2.5-7B és a szervermodell). $\tilde{p}$: Holm-korrigált p-érték; G: alátámasztottság; A: vak megoldhatóság.

Hipotézis	Bizonyíték	Értékelés
1. Tervezés	Fő: Q +0,26 (PULI) és +0,23 (Gemma), $\tilde{p} < 0{,}001$, illetve 0,002; G 27→58, illetve 46→88 %; lefedettség 10→23, illetve 24→43 %; a forma nem romlott. Előzetes: +0,24 (6 dok., nem szignifikáns). A rögzített darabolású naiv RAG (E5c) a Gemmánál 0,97	**támogatott** a szemantikus darabolású E0-hoz képest
2. Ellenőrzés	Fő: G csökkent (PULI 58→52 %, Gemma 88→86 %); Q +0,13 ($\tilde{p}$ = 0,066), illetve +0,01 ($\tilde{p}$ = 1,00). Előzetes (Qwen): G 80→90 %, A 80→97 %, Q +0,08 (5 dok. javult, 0 romlott, $\tilde{p}$ = 0,19). κ = 0,00–0,08 minden modellnél	**a fő vizsgálatban nem támogatott**; az előzetesben leíró szinten javult
3. Lefedettség	Gemma: teljes dok. 43 % vs. E2 43 %; Qwen: 45 vs. 44 %; a tömörülés a naiv RAG sajátja (10–25 %)	**nem támogatott**
4. Helyi vs. szerver	Előzetes, közös dokumentumokon: Qwen E2 0,95 vs. szerver E4 0,93 (három angol dok.), E2 0,96 vs. B-doc-S 0,95 (hat dok.). A szervermodell a saját módszerünkkel (E4b) 0,99. A hat dokumentumon a Gemma E2 0,97, a PULI E2 0,72. A modellek 4,8–7,8 GiB-ot foglalnak	**támogatott** (leíró, modellfüggő)
5. Mérés	Az oktatói értékelés folyamatban (5.9. szakasz)	**nyitott**

Megjegyzések a táblázathoz. **1.** Az E1 és az E0 több tényezőben különbözik (lekérdezés, kérdésenkénti generálás), ezért a javulást a vizsgaterv egészének tulajdonítjuk, nem egyetlen lépésének. **2.** A lánc a vizsga egészét javította (forma, szivárgás, nem kérdő törzsek; 5.6. szakasz), a kérdések tartalmi helyességét nem. **3.** A PULI teljes dokumentumos vizsgáinak alacsony lefedettsége a kevés kérdésből adódik, és tíz kérdésnél a hosszú dokumentumokon a felső korlát minden konfigurációt egyformán korlátoz. **4.** A hipotézis a szervermodell *naiv* változatához mér; a „helyi modell elérte a szervermodellt” állítás csak a szerveres teljes dokumentumos

promptra igaz, a saját módszerünkkel futó szervermodellre nem. **5.** Addig a bíró ítéleteit relatív, a konfigurációk összevetésére szolgáló mérésként kezeljük. [Az oktatói értékelés eredménye után: a hipotézis értékelése a Krippendorff-α alapján.]

7.2. Összevetés az irodalommal

Az alábbiakban eredményeinket a 2. fejezetben tárgyalt munkákkal vetjük össze. Az irodalmi eredményeket minőségileg idézzük, mert a feladatok, a modellek és a mutatók eltérnek a mieinktől; az összevetés ezért irányt és nem pontos nagyságot jelez.

Önellenőrzés külső visszajelzés nélkül. Huang és munkatársai [5] szerint a modellek külső visszajelzés nélkül nem tudják megbízhatóan javítani saját érvelésüket, és a teljesítmény az önjavítás után akár romolhat is. Eredményeink ezzel összhangban vannak: a PULI-nál az ellenőrző lánc haszna lényegében a szabályokból jött (a csak szabályalapú E2x ugyanannyit ért el, mint az E2: 0,67 és 0,67), a Gemmánál a különbség nem szignifikáns, a modellalapú ítélet pedig minden modellnél a véletlen szintjén egyezett a bíróval. A Qwennél az E2x rosszabb volt (0,89 vs. 0,96, egy dokumentumon jobb, ötön rosszabb), ami arra utal, hogy a forrásszöveggel szembeni ítélet – vagyis külső információ – egy közepes modellnél adhat hozzá. Ezt az E2x hibás futása miatt újra kell mérni (7.4. szakasz).

Darabolás. Qu, Tu és Bao [40] szerint a szemantikus darabolás többletköltségét a mért előnyök nem indokolják. Nálunk a rögzített, 800 karakteres darabolás (E5c) a Gemmánál (0,72 → 0,97, 23 dokumentumon jobb) és a Qwennél (0,64 → 0,86, leíró szinten) is jobb volt, mint a szemantikus E0; a PULI-nál egyik változat sem adott értékelhető vizsgát. Eredményünk a megállapításukat egy konkrét mechanizmussal egészíti ki: a minimális darabméret nélküli szemantikus darabolás rövid, tartalom nélküli darabokat hoz létre, és a feladatleírás típusú lekérdezés éppen ezeket találja meg (5.5. szakasz).

Lekérdezés-átírás. A HyDE [39] abból indul ki, hogy a lekérdezésnek a keresett szöveghez kell hasonlítania, ezért egy generált hipotetikus dokumentum beágyazásával keres. A mi eredményünk ugyanezt támasztja alá a vizsgagenerálásban: a kereső tartalmi kérdéssel jól működik (a referenciakérdések igazoló darabja a fő vizsgálat dokumentumain 86 %-ban az első három találat között volt), a naiv RAG kudarca tehát a feladatleírásból képzett lekérdezésből fakad. A vizsgaterv tartalmi fogalmai a lekérdezés-átírás egy egyszerű formájának tekinthetők; egy HyDE-szerű lekérdezés a naiv útvonalon továbbfejlesztési lehetőség.

Hosszú kontextus és RAG. Li és munkatársai [45] szerint elegendő erőforrás mellett a hosszú kontextus átlagosan jobb a RAG-nál, a RAG viszont jóval olcsóbb, a lekérdezések 63 %-án a kettő előrejelzése azonos, és a kérdésenként választó útválasztással a költség csökkenthető. Nálunk ez modellfüggő: a Gemma teljes dokumentumos promptja (0,96) versenyképes a tervezett folyamattal és a jól darabolt naiv RAG-gal, a gyengébb modelleknél viszont a teljes dokumentumos

prompt elmarad (Qwen 0,83, PULI 0,41). Az útválasztás gondolata a mi adaptív ellenőrzésünkkel rokon (7.4. szakasz).

A hosszú bemenet egyenetlen használata. Liu és munkatársai [6] eredménye alapján azt vártuk, hogy a teljes dokumentumot kapó modell kérdései a dokumentum egyes részeire tömörülnek (3. hipotézis). A lefedettségben ez nem jelent meg. Leíró szinten a Gemma teljes dokumentumos promptja a hosszú dokumentumokon valamivel gyengébb (0,94), mint a rövideken (0,98), ami a hossz növelésével romló teljesítmény irányába mutat [44], de a különbség kicsi, és a bíró 24 000 karakteres ablaka miatt a hosszú dokumentumokon az alátámasztottság alsó becslés.

Hibás kulcsok a generált kérdésekben. Doughty és munkatársai [21] szerint a GPT-4 kérdéseinek 81,7 %-a minden szempontnak megfelelt, de 4,9 %-ukban több helyes válasz volt (az oktatói kérdéseknél 1,1 %), 4,0 %-ukban pedig egy disztraktor elárulta a kulcsot (0,9 %); Wang és munkatársai [20] a GPT-3 kérdéseinek egy részét az emberiekkel összemérhetőnek találták. A mi méréseink ugyanezt a képet adják: a Gemma tervezett konfigurációiban a bíró a kérdések 85–88 %-át használná fel, a Qwen E2 kérdéseinek 80 %-át, a szervermodell E4b kérdéseinek 98 %-át, és még a legjobb helyi konfigurációk kérdéseinek is 4–14 %-a a bíró szerint nem alátámasztott. A mutatók és a tárgyterületek eltérnek, így ez nem közvetlen összevetés, de a következtetés azonos: oktatói átnézés nélkül hibás kérdések kerülnének a vizsgába.

A bíró érvényessége. Zheng és munkatársai [64] szerint egy erős bíró több mint 80 %-ban egyezik az emberi preferenciákkal, nagyjából annyira, mint az emberek egymással, és pozíciós, hossz- és önpreferencia-torzítást is azonosítottak; Chiang és Lee [65] az emberi szakértőkével azonos utasítással kapott hasonló egyezést. Ezek az eredmények páros preferenciákra és más feladatokra vonatkoznak, ezért nem vihetők át a mi forrásalapú, pontszámos rubrikánkra. A vizsgálatok több bírói vakfoltot is feltártak: a szivárgó és a tartalmilag üres kérdéseket a bíró magasra pontozta, a teljes dokumentumos kérdéseket a 24 000 karakteres ablak miatt alulpontozhatta, és ítéletei forrásfüggően hiányoztak (7.5. szakasz). A más modellcsaládba tartozó bíró az önpreferenciát csökkenti [68], de a bíró érvényességét csak az oktatói validálás döntheti el (5. hipotézis).

7.3. Mikor éri meg a módszer?

A módszer haszna a modell képességétől függ (5.2. ábra). Gyenge formátumkövető modellnél (PULI-LlumiX 8B) csak a felbontás ad értékelhető vizsgát, de a modellt ez sem teszi alkalmassá. Közepes modellnél (Qwen2.5-7B) éri meg a legjobban: a többlethívások árán a szerveres teljes dokumentumos prompt szintjét éri el, összhangban azzal, hogy a futás közbeni többletszámítás a nagyobb modellt részben helyettesítheti [54]. Erős modellnél (Gemma 3 12B) átlagos minőségben nem ad hozzá, értéke a kérdésenkénti forrás (P1) és a terv (P2). A szintenkénti számokat a 7.2. táblázat adja.

7.4. Döntés: mit építünk be

A 7.2. táblázat GPU-szintenként a legjobb minőségű, a leggyorsabb és a legrobusztusabb (a leggyengébb dokumentumon is legjobb) konfigurációt mutatja.

7.2. táblázat. Döntési táblázat GPU-szintenként. Q: minőségi index; Min.: a leggyengébb dokumentum Q-ja; Idő: a medián futási idő szorzója az azonos modellel futó E0-hoz képest. A 8 GB-os szint a hat dokumentumos előzetes, a 12 GB-os a 30 dokumentumos fő vizsgálat adatai. A szintén 8 GB-on futó PULI-LlumiX 8B egyik szempontból sem ajánlott (legjobb E2 0,67, a leggyengébb dokumentumon 0,38, 18 dokumentum 0,70 alatt).

Szempont	Konfig.	Q	Min.	Idő	Megjegyzés
8 GB: Qwen2.5-7B					
Legjobb minőség	E2	0,96	0,89	≈ 11×	a szerveres teljes dokumentumos prompt (0,95) szintje; kérdésenkénti forrás
Leggyorsabb	E5c	0,86	0,50	≈ 1×	a saját magyar szövegeken 0,77, a törzsek 44 %-a nem kérdés; csak vázlatnak
Legrobusztusabb	E2	0,96	0,89	≈ 11×	azonos a legjobb minőségűvel; a következő az E2h (0,88)
Beépül	E2	0,96	0,89	≈ 11×	adaptív ellenőrzéssel (lent)
12 GB: Gemma 3 12B					
Legjobb minőség	E5c	0,97	0,81	≈ 1×	a B-doc-L, E2f, E2h, E5a (0,96) a konfidencia-intervallumon belül; nincs kérdésenkénti forrás és terv
Leggyorsabb	E5c	0,97	0,81	≈ 1×	az E0, E5a és B-doc-L is ≈ 1×
Legrobusztusabb	E2h	0,96	0,88	≈ 8×	a tervezett konfigurációk minimuma 0,80–0,88, egy-egy dokumentumon múlik; a hibrid keresés más modelleknél rontott
Beépül	E1–E2	0,95	0,80–0,82	≈ 5–8,5×	tervezett folyamat adaptív ellenőrzéssel; gyors vázlathoz E5c

A 8 GB-os szinten a tervezett és ellenőrzött folyamat egyszerre a legjobb és a legrobusztusabb. A 12 GB-os szinten a győztesek minősége a konfidencia-intervallumokon belül azonos, ezért azt választjuk, amit csak a tervezett folyamat ad meg: a kérdésenkénti forrást és a tervet; a rögzített darabolású naiv RAG gyors vázlatként marad meg.

Mi kerül be

Kérdésenkénti forráshivatkozás (P1).

Még a legjobb helyi konfigurációk kérdéseinek egy része is alátámasztatlan (7.2. szakasz), és a bíró sem validált, ezért az oktatói ellenőrzés nem hagyható el. A forrásdarab megjelenítése ezt a szerkesztőben egy kattintásra rövidíti, és a hivatkozás az automatikus alátámasztottsági ellenőrzés feltétele is.

Vizsgaterv (P2).

A terv kikényszeríti a darabszámot, a típust és a Bloom-kiosztást, ami egy promptban csak

kérés: a PULI egy hívásban átlagosan 1,8 kérdést adott a kért tíz helyett, a tervvel 9,9-et. A Gemmánál a bíró szerint megvalósult magasabb rendű kérdések aránya az egyhívásos konfigurációk 1–4 %-áról 7–11 %-ra nőtt; ez is jóval elmarad a tervezett 43 %-tól, amit a felületen jelezni kell (5.7. szakasz).

Szabályalapú ellenőrzés.
A forma, a szivárgás, a kérdésforma és a duplikátum szabályai olcsók, determinisztikusak, és a lánc hasznának nagy részét adják (E2x ≈ E2, lásd az önellenőrzésről szóló bekezdést). A szivárgás szabályát a pilot tette szükségessé (5.1. szakasz).

Rögzített vagy minimális méretű darabolás a naiv útvonalon is.
A legolcsóbb mért javítás: a Gemmánál a 0,70 alatti dokumentumok száma 16-ról nullára csökkent, változatlan futási idő mellett. A minimális darabméretű szemantikus darabolást és a tervezett folyamat darabolásfüggését nem mértük, ezek elvárások.

Adaptív ellenőrzés.
Az elsőre elfogadott kérdéshelyek aránya a Gemmánál 70 %, a Qwennél 23 %, a PULI-nál 5 %; minél kisebb ez az arány, annál nagyobb az ellenőrzés haszna (7.1. táblázat), költsége viszont minden modellnél jelentős. A rendszer ezért az első kérdéshelyeken a teljes láncot futtatja, és ha az első kísérletek sikeraránya magas, a továbbiakon csak a szabályokat. A küszöb még meghatározandó ([küszöb: a bevezetés előtt mérendő]); a változatot nem mértük, hatása elvárás.

Mi marad ki

Fogalomgráf (E3).
Egyik modellnél sem javított (Gemma −0,01, PULI −0,10, Qwen −0,07), miközben a legdrágább tervezett változat (Gemma: ≈ 10,6×, 55,5 hívás az E2 43 hívásával szemben).

Hibrid keresés (E2h).
A Gemmánál nem szignifikánsan jobb (+0,01), a PULI-nál (−0,08, 17 dokumentumon rosszabb) és a Qwennél (−0,04, öt dokumentumon rosszabb) rontott, és külön lexikális indexet igényel; a Gemmánál mért legmagasabb minimuma egyetlen dokumentumon múlik.

Az LLM-alapú ellenőrzés mint kérdésenkénti ítélet.
Ítélete a bíróéval a véletlen szintjén egyezik; a Qwennél a bíró szerint alátámasztott kérdések közel felét is megjelölte, a Gemmánál szinte mindent átengedett. Figyelmeztetésként („ezt nézd meg alaposabban”) megmarad, de a felület nem jelöli a kérdést „ellenőrzöttnek”, mert ez az automatizálási torzítás [77] miatt éppen az átengedett kérdések átnézését gyengítené.

Modellválasztás. Strukturált feladatban az utasításkövetés fontosabb a magyar nyelvi specializációnál – ezt a PULI-LlumiX 8B esetére szűkítve állítjuk, amely a modellkártya szerint a Llama-3.1-8B-Instruct utólagos utasítás-hangolás nélküli magyar továbbelőtanítása, és amelynél a többnyelvű Gemma 3 12B minden konfigurációban, a Qwen2.5-7B a hat közös dokumentumon jobb volt (6. fejezet). A rendszer 8 GB-on a Qwen2.5-7B-t, 12 GB-on a Gemma 3 12B-t ajánlja.

Fejlesztési ütemterv (időpontok: [ütemezés a témavezetővel egyeztetve]). (1) Rögzített darabolás a meglévő naiv útvonalon. (2) A tervezett folyamat (vizsgaterv, forráshivatkozás, szabályalapú és adaptív ellenőrzés) integrálása a Bifrost háttérfeladatába, GPU-szint szerinti modellválasztással. (3) A v1 szerkesztő éles backendje az ál-backend helyett. (4) Ezekkel párhuzamosan a hiányzó mérések: a hiányzó bírói ítéletek újrapontozása, az E2x újramérése működő második ellenőrzővel, az oktatói validálás (5. hipotézis), a szervermodell a 30 dokumentumon, valamint az adaptív küszöb és a minimális darabméret mérése.

7.5. Mit tanultunk az ellenőrzésről és a mérésről?

Az ellenőrző lánc szűrőként és „második esélyként” működik, nem osztályozóként: jelzései egyenként zajosak, de az elutasított kérdés helyére írt új kérdés átlagosan jobb. A mérés több ponton csendben torzított volna (tartalékvizsga, csonkolt kódoló, szivárgás, a bíró ablaka, a hibás E2x-hívások), miközben hihető számokat adott; a nyers kimenetek kézi átolvasása ezért nem hagyható el. A bírói ítéletek forrásfüggően hiányoznak: a Wikipédia-cikkek kérdései kisebb arányban kaptak ítéletet (a Gemma E2-ben összesen 52 %, a PULI E2-ben 29 %). Ez a következtetéseket nem fordítja meg (5.9. szakasz), de a forrásonkénti összevetéseket gyengíti.

7.6. Az érvényességet veszélyeztető tényezők

Belső. Az E1 és az E0 több tényezőben különbözik, az ellenőrzés a kérdések hosszát is megváltoztatja, és a tervezett konfigurációk egy maggal futottak, így a dokumentumonkénti értékekben futási zaj is van. A vizsgálatok közötti összevetés minden esetben azonos dokumentumokon, a hat közös dokumentumon történt. Az E2x a tervezettől eltérő konfigurációt mért.

Konstrukciós. A formai megfelelés vizsgaszintű, ezért minden komponenst külön is közlünk. A tartalmi mutatók egyetlen, még nem validált bíróra épülnek, amely csak a kérdés saját forrását látja, és ítéletei forrásfüggően hiányoznak (5.9. szakasz).

Külső. A 30 dokumentumból 24 magyar Wikipédia-cikk, az angol részhalmaz három dokumentum; a szervermodell csak a hat dokumentumon futott; csak feleletválasztós kérdéseket értékeltünk; a nyílt dokumentumok a tanítóadatban is szerepelhettek [76]. A futási időt ugyanazon a GPU-n mért relatív szorzóként értelmezzük.

Következtetési. A 30 dokumentum a nagy hatások kimutatására elegendő, a kicsikére (például az ellenőrzés hatására a Gemmánál) nem; a hat dokumentumos vizsgálat következtetései leíró jellegűek.

7.7. Etikai és jogi szempontok

A döntés a jogi keret (2.9. szakasz) követelményeit is szolgálja: a beépülő változat helyben futtatható, így helyi módban (`LOCAL_ONLY`) a tananyag nem hagyja el az oktató gépét; a feltöltött tartalom a feladat végén törlődik (3.3. szakasz); a forráshivatkozás és a kötelező oktatói jóváhagyás az emberi felügyeletet konkrét munkafolyamattá teszi. A rendszer kérdést generál, nem értékeli a hallgatókat, és az export feltünteti az MI-közreműködést [89].

Tanulság. A Mimir a naiv RAG helyett a tervezett folyamatot építi be forráshivatkozással, szabályalapú és adaptív ellenőrzéssel, a naiv útvonalon rögzített darabolással; a fogalomgráf és a hibrid keresés kimarad. Az erős modellnél a döntés az ellenőrizhetőségen alapul, ezért az oktatói validálás erősítheti meg vagy módosíthatja.

8. Összefoglalás és további munka

Ez a fejezet a kutatási kérdésekre adott válaszokat és a belőlük hozott döntést foglalja össze, majd kijelöli a további munkát.

8.1. Összefoglalás

Dolgozatunkban a vizsgakérdés-generálás négy gyakorlati problémájából indultunk ki: a kulcsok helyessége nincs ellenőrizve (P1), a vizsga szerkezete és lefedettsége nincs kontrollálva (P2), a tananyag egy harmadik félhez kerül (P3), és a módszer nagy, távoli modellekre támaszkodik (P4). A fejlesztési fázisban lévő Mimir rendszerben ma a naiv RAG fut; a feladatot ellenőrizhető lépésekre bontó tervezett folyamatot egy saját, nyílt kiértékelő keretrendszerben valósítottuk meg, és 14 konfigurációval, három vizsgálatban, legfeljebb 30 dokumentumon és három helyi modellen mértük, hogy eldöntsük, mi kerüljön a rendszerbe.

RQ1. A vizsgaterv a szemantikus darabolású naiv RAG-hoz (E0) képest a fő vizsgálat mindkét modelljénél szignifikánsan javított (+0,26 és +0,23, Holm-korrekció után is), és a lefedettséget is növelte (5.3. szakasz). A rögzített méretű darabolású naiv RAG (E5c) azonban az erős Gemma 3 12B-nél önmagában is elég volt (0,97), a gyenge PULI-LlumiX 8B-nél nem (5.5. szakasz). A teljes dokumentumos prompttal szemben az előny a PULI-nál nagy (0,41 $\rightarrow$ 0,67), a Qwen2.5-7B-nél a hat dokumentumon leíró jellegű (0,83 $\rightarrow$ 0,96), a Gemmánál nincs (0,96 és 0,95); a teljes dokumentumos prompt lefedettsége sem volt alacsonyabb, így a 3. hipotézis nem teljesült.

RQ2. A legnagyobb hatású tényező a visszakeresés lekérdezése: a vizsgaterv kérdéshelyenként a tervezett fogalommal, vagyis tartalmi lekérdezéssel keres, a naiv RAG minőségét pedig a darabolás apró részletei is drámaian befolyásolták. Az ellenőrző lánc a gyengébb modelleknél javított a minőségi indexen (+0,08 és +0,13, ez utóbbi Holm után nem szignifikáns), az erősnél nem; az alátámasztottság a fő vizsgálatban mindkét modellnél csökkent, így a 2. hipotézis ott nem támogatott. Az ellenőrző kérdésenkénti ítélete a bíróéval a véletlen szintjén egyezik ($\kappa \approx 0$). A fogalomgráf és a hibrid keresés egyik modellnél sem javított érdemben, a teljes ellenőrzött folyamat pedig ugyanazon a GPU-n a naiv RAG futásidejének nagyjából 8,5-szeresét igényli (Gemma 3 12B; 6.4. szakasz).

RQ3. A 8 GB-os kártyán futó Qwen2.5-7B a módszerrel a szervermodell teljes dokumentumos promptjának minőségét érte el (0,96, illetve 0,95, hat dokumentumon); a saját módszerünkkel futó szervermodell (0,99) ennél is jobb volt, így az egyezés csak a teljes dokumentumos szerveres promptra igaz. A 12 GB-os szinten a Gemma 3 12B minden tervezett konfigurációval és a rögzített darabolású naiv RAG-gal is hasonlóan jó eredményt adott. A vizsgált magyarra továbbtanított PULI-LlumiX 8B viszont az utasítás- és formátumkövetésen bukott el (6. fejezet), így a magyar dokumentumokon is a többnyelvű modellek voltak jobbak; ezt a következtetést erre a modellre

szűkítjük.

Mérési tanulságok. A vizsgálatok feltárták a válaszszivárgást (5.1. szakasz), a csendes tartalékágakat (például a független ellenőrző kihagyott hívásait) és a forrásfüggően hiányzó bírói ítéleteket (5.9. szakasz), amelyek a mérést torzították volna. A tanulság általános: egy nyelvi modellekre épülő rendszer kiértékelésében minden tartalékágat láthatóvá kell tenni, és a nyers kimeneteket kézzel is át kell olvasni.

A döntés. A mérések alapján (7. fejezet) a rendszerbe a kérdésenkénti forráshivatkozás, a szabályalapú ellenőrzés és a rögzített vagy minimális méretű darabolás kerül, a nyelvi modellel végzett ellenőrzés a modell erősségéhez igazodva, adaptívan fut, a fogalomgráf és a hibrid keresés pedig kimarad.

8.2. További munka

- **A bíró validálása.** Az oktatói értékelés befejezése és elemzése (4.7. szakasz), amely eldönti az 5. hipotézist.
- **A hiányzó mérések pótlása.** A sikertelen bírói hívások újrapontozása, a független ellenőrző (E2x) újramérése úgy, hogy a keretrendszer a kihagyott ellenőrzést hibaként jelezze, és a szervermodell futtatása a fő vizsgálat 30 dokumentumán.
- **A darabolás hatása a tervezett folyamatra.** A darabolási változatokat (E5a–E5c) csak a naiv RAG-gal mértük; azt, hogy a tervezett folyamat a darabolástól kevésbé függ, egyelőre csak elvárásként fogalmazhatjuk meg, ezért a rögzített darabolást a tervezett folyamattal is mérni kell.
- **Integráció az éles rendszerbe.** A döntés szerinti komponensek beépítése a háttérszolgáltatásba és a forráshivatkozást megjelenítő szerkesztőbe a 7. fejezet ütemterve szerint, valamint a megfelelési táblázat még tervezett elemeinek megvalósítása (3. fejezet).
- **Adaptív folyamat.** Mivel az ellenőrzés haszna a modelltől függ, a rendszer a modell első kísérleteinek sikerarányából eldöntheti, szükség van-e nyelvi modellel végzett ellenőrzésre; erős modellnél így a futási idő a töredékére csökkenthető.
- **Megbízhatóbb ellenőrző és Bloom-szint.** Természetes nyelvi következtetésre tanított osztályozó [53] a kérdésenkénti jelzéshez, és egy szintosztályozó lépés, mert a kis modellek a kért magasabb rendű szintet ritkán valósították meg.
- **Tanórai kipróbálás.** Az igaz–hamis és a kifejtős kérdések kiértékelése, valamint a generált vizsgák tételelemzése (nehézség, megkülönböztető erő, nem működő disztraktorok [10]) valós hallgatói válaszokon.

A Mimir nyílt forráskódú (MIT-licenc): a kód, a konfigurációk, az adatkészlet-leírások és a vizsgálatok nyers kimenetei a reprodukáláshoz rendelkezésre állnak (E. és I. függelék).

Irodalomjegyzék

[1] T. M. Haladyna, S. M. Downing és M. C. Rodriguez. „A Review of Multiple-Choice Item-Writing Guidelines for Classroom Assessment”. *Applied Measurement in Education* 15.3 (2002), 309–333. old.

[2] M. J. Gierl, O. Bulut, Q. Guo és X. Zhang. „Developing, Analyzing, and Using Distractors for Multiple-Choice Tests in Education: A Comprehensive Review”. *Review of Educational Research* 87.6 (2017), 1082–1116. old.

[3] G. Kurdi, J. Leo, B. Parsia, U. Sattler és S. Al-Emari. „A Systematic Review of Automatic Question Generation for Educational Purposes”. *International Journal of Artificial Intelligence in Education* 30.1 (2020), 121–204. old. DOI: 10.1007/s40593-019-00186-y.

[4] Z. Ji, N. Lee, R. Frieske és tsai. „Survey of Hallucination in Natural Language Generation”. *ACM Computing Surveys* 55.12 (2023), 1–38. old.

[5] J. Huang, X. Chen, S. Mishra és tsai. „Large Language Models Cannot Self-Correct Reasoning Yet”. *International Conference on Learning Representations (ICLR)*. 2024.

[6] N. F. Liu, K. Lin, J. Hewitt és tsai. „Lost in the Middle: How Language Models Use Long Contexts”. *Transactions of the Association for Computational Linguistics* 12 (2024), 157–173. old.

[7] Európai Parlament és a Tanács. *Az Európai Parlament és a Tanács (EU) 2016/679 rendelete (általános adatvédelmi rendelet)*. Az Európai Unió Hivatalos Lapja, L 119. 2016.

[8] S. M. Downing. „The Effects of Violating Standard Item Writing Principles on Tests and Students: The Consequences of Using Flawed Test Items on Achievement Examinations in Medical Education”. *Advances in Health Sciences Education* 10.2 (2005), 133–143. old. DOI: 10.1007/s10459-004-4019-5.

[9] M. C. Rodriguez. „Three Options Are Optimal for Multiple-Choice Items: A Meta-Analysis of 80 Years of Research”. *Educational Measurement: Issues and Practice* 24.2 (2005), 3–13. old. DOI: 10.1111/j.1745-3992.2005.00006.x.

[10] M. Tarrant, J. Ware és A. M. Mohammed. „An Assessment of Functioning and Non-Functioning Distractors in Multiple-Choice Questions: A Descriptive Analysis”. *BMC Medical Education* 9 (2009), 40. old. DOI: 10.1186/1472-6920-9-40.

[11] L. W. Anderson és D. R. Krathwohl, szerk. *A Taxonomy for Learning, Teaching, and Assessing: A Revision of Bloom's Taxonomy of Educational Objectives*. New York: Longman, 2001.

[12] D. Scully. „Constructing Multiple-Choice Items to Measure Higher-Order Thinking”. *Practical Assessment, Research, and Evaluation* 22.4 (2017).

[13] B. Csapó és G. Molnár. „Online Diagnostic Assessment in Support of Personalized Teaching and Learning: The eDia System”. *Frontiers in Psychology* 10 (2019), 1522. old. DOI: 10.3389/fpsyg.2019.01522.

[14] R. Mitkov és L. A. Ha. „Computer-Aided Generation of Multiple-Choice Tests”. *Proceedings of the HLT-NAACL 03 Workshop on Building Educational Applications Using Natural Language Processing*. 2003, 17–22. old.

[15] M. Heilman és N. A. Smith. „Good Question! Statistical Ranking for Question Generation”. *Human Language Technologies: The 2010 Annual Conference of the North American Chapter of the Association for Computational Linguistics*. 2010, 609–617. old.

[16] J. Alshboul és E. Baksa-Varga. „A Hybrid Approach for Automatic Question Generation from Program Codes”. *International Journal of Advanced Computer Science and Applications* 15.1 (2024), 10–17. old.

[17] P. Rajpurkar, J. Zhang, K. Lopyrev és P. Liang. „SQuAD: 100,000+ Questions for Machine Comprehension of Text”. *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing*. 2016, 2383–2392. old.

[18] X. Du, J. Shao és C. Cardie. „Learning to Ask: Neural Question Generation for Reading Comprehension”. *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics*. 2017, 1342–1352. old.

[19] E. Alhazmi, Q. Z. Sheng, W. E. Zhang, M. Zaib és A. Alhazmi. „Distractor Generation in Multiple-Choice Tasks: A Survey of Methods, Datasets, and Evaluation”. *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. 2024, 14437–14458. old.

[20] Z. Wang, J. Valdez, D. Basu Mallick és R. G. Baraniuk. „Towards Human-Like Educational Question Generation with Large Language Models”. *Artificial Intelligence in Education (AIED 2022)*. 13355. köt. Lecture Notes in Computer Science. Springer, 2022, 153–166. old.

[21] J. Doughty, Z. Wan, A. Bompelli, J. Qayum, T. Wang, J. Zhang és tsai. „A Comparative Study of AI-Generated (GPT-4) and Human-crafted MCQs in Programming Education”. *Proceedings of the 26th Australasian Computing Education Conference*. 2024, 114–123. old.

[22] S. K. Bitew, J. Deleu, C. Develder és T. Demeester. *Distractor Generation for Multiple-Choice Questions with Predictive Prompting and Large Language Models*. arXiv:2307.16338. 2023.

[23] A. Hadifar, S. K. Bitew, J. Deleu, C. Develder és T. Demeester. „EduQG: A Multi-Format Multiple-Choice Dataset for the Educational Domain”. *IEEE Access* 11 (2023), 20885–20896. old.

[24] F. Fawzi, S. Amini és S. Bulathwela. „Small Generative Language Models for Educational Question Generation”. *NeurIPS 2023 Workshop on Generative AI for Education (GAIED)*. 2023.

[25] N. Mulla és P. Gharpure. „Automatic Question Generation: A Review of Methodologies, Datasets, Evaluation Metrics, and Applications”. *Progress in Artificial Intelligence* 12.1 (2023), 1–32. old.

[26] A. Vaswani, N. Shazeer, N. Parmar és tsai. „Attention Is All You Need”. *Advances in Neural Information Processing Systems*. 30. köt. 2017.

[27] J. Devlin, M.-W. Chang, K. Lee és K. Toutanova. „BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”. *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics*. 2019, 4171–4186. old.

[28] T. B. Brown, B. Mann, N. Ryder, M. Subbiah, J. Kaplan, P. Dhariwal és tsai. „Language Models are Few-Shot Learners”. *Advances in Neural Information Processing Systems*. 33. köt. 2020, 1877–1901. old.

[29] L. Ouyang, J. Wu, X. Jiang, D. Almeida, C. L. Wainwright, P. Mishkin és tsai. „Training Language Models to Follow Instructions with Human Feedback". *Advances in Neural Information Processing Systems*. 35. köt. 2022.

[30] B. T. Willard és R. Louf. *Efficient Guided Generation for Large Language Models*. arXiv:2307.09702. 2023.

[31] P. Lewis, E. Perez, A. Piktus és tsai. „Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks". *Advances in Neural Information Processing Systems*. 33. köt. 2020, 9459–9474. old.

[32] Y. Gao, Y. Xiong, X. Gao és tsai. *Retrieval-Augmented Generation for Large Language Models: A Survey*. 2023. arXiv: 2312.10997.

[33] S. Robertson és H. Zaragoza. „The Probabilistic Relevance Framework: BM25 and Beyond". *Foundations and Trends in Information Retrieval* 3.4 (2009), 333–389. old.

[34] V. Karpukhin, B. Oğuz, S. Min és tsai. „Dense Passage Retrieval for Open-Domain Question Answering". *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. 2020, 6769–6781. old.

[35] L. Wang, N. Yang, X. Huang, L. Yang, R. Majumder és F. Wei. *Multilingual E5 Text Embeddings: A Technical Report*. 2024. arXiv: 2402.05672.

[36] N. Thakur, N. Reimers, A. Rücklé, A. Srivastava és I. Gurevych. „BEIR: A Heterogeneous Benchmark for Zero-shot Evaluation of Information Retrieval Models". *Thirty-fifth Conference on Neural Information Processing Systems Datasets and Benchmarks Track*. 2021.

[37] A. Novák, B. Novák, D. Zombori, G. Szabó, Z. Szántó és R. Farkas. „A Question Answering Benchmark Database for Hungarian". *Proceedings of the 17th Linguistic Annotation Workshop (LAW-XVII)*. 2023, 188–198. old.

[38] G. V. Cormack, C. L. A. Clarke és S. Buettcher. „Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods". *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval*. 2009, 758–759. old.

[39] L. Gao, X. Ma, J. Lin és J. Callan. „Precise Zero-Shot Dense Retrieval without Relevance Labels". *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics*. 2023, 1762–1777. old.

[40] R. Qu, R. Tu és F. Bao. *Is Semantic Chunking Worth the Computational Cost?* 2024. arXiv: 2410.13070.

[41] T. Gao, H. Yen, J. Yu és D. Chen. „Enabling Large Language Models to Generate Text with Citations". *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. 2023, 6465–6488. old.

[42] H. Rashkin, V. Nikolaev, M. Lamm, L. Aroyo, M. Collins, D. Das és tsai. „Measuring Attribution in Natural Language Generation Models". *Computational Linguistics* 49.4 (2023), 777–840. old.

[43] D. Edge, H. Trinh, N. Cheng és tsai. *From Local to Global: A Graph RAG Approach to Query-Focused Summarization*. 2024. arXiv: 2404.16130.

[44] C.-P. Hsieh, S. Sun, S. Kriman és tsai. „RULER: What's the Real Context Size of Your Long-Context Language Models?": *Conference on Language Modeling (COLM)*. 2024.

[45] Z. Li, C. Li, M. Zhang, Q. Mei és M. Bendersky. „Retrieval Augmented Generation or Long-Context LLMs? A Comprehensive Study and Hybrid Approach”. *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing: Industry Track*. 2024.

[46] J. Wei, X. Wang, D. Schuurmans és tsai. „Chain-of-Thought Prompting Elicits Reasoning in Large Language Models”. *Advances in Neural Information Processing Systems*. 35. köt. 2022.

[47] D. Zhou, N. Schärli, L. Hou, J. Wei, N. Scales, X. Wang és tsai. „Least-to-Most Prompting Enables Complex Reasoning in Large Language Models”. *International Conference on Learning Representations (ICLR)*. 2023.

[48] L. Wang, W. Xu, Y. Lan és tsai. „Plan-and-Solve Prompting: Improving Zero-Shot Chain-of-Thought Reasoning by Large Language Models”. *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics*. 2023, 2609–2634. old.

[49] T. Wu, M. Terry és C. J. Cai. „AI Chains: Transparent and Controllable Human-AI Interaction by Chaining Large Language Model Prompts”. *Proceedings of the 2022 CHI Conference on Human Factors in Computing Systems*. 2022.

[50] A. Madaan, N. Tandon, P. Gupta, S. Hallinan, L. Gao, S. Wiegreffe és tsai. „Self-Refine: Iterative Refinement with Self-Feedback”. *Advances in Neural Information Processing Systems*. 36. köt. 2023.

[51] S. Dhuliawala, M. Komeili, J. Xu és tsai. „Chain-of-Verification Reduces Hallucination in Large Language Models”. *Findings of the Association for Computational Linguistics: ACL 2024*. 2024.

[52] S. Min, K. Krishna, X. Lyu és tsai. „FActScore: Fine-grained Atomic Evaluation of Factual Precision in Long Form Text Generation”. *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. 2023, 12076–12100. old.

[53] P. Laban, T. Schnabel, P. N. Bennett és M. A. Hearst. „SummaC: Re-Visiting NLI-based Models for Inconsistency Detection in Summarization”. *Transactions of the Association for Computational Linguistics* 10 (2022), 163–177. old.

[54] C. Snell, J. Lee, K. Xu és A. Kumar. „Scaling LLM Test-Time Compute Optimally Can be More Effective than Scaling Parameters for Reasoning”. *International Conference on Learning Representations (ICLR)*. 2025.

[55] M. Strathern. „‘Improving Ratings’: Audit in the British University System”. *European Review* 5.3 (1997), 305–321. old.

[56] Qwen Team. *Qwen2.5 Technical Report*. 2024. arXiv: 2412.15115.

[57] A. Grattafiori és tsai. *The Llama 3 Herd of Models*. 2024. arXiv: 2407.21783.

[58] Gemma Team. *Gemma 3 Technical Report*. 2025. arXiv: 2503.19786.

[59] NYTK – HUN-REN Nyelvtudományi Kutatóközpont. *PULI-LlumiX-Llama-3.1: magyar–angol nyelvi modell (8B), a Llama 3.1 továbbtanításával*. https://huggingface.co/NYTK/PULI-LlumiX-Llama-3.1. Modellkártya. 2024.

[60] E. Frantar, S. Ashkboos, T. Hoefler és D. Alistarh. „GPTQ: Accurate Post-Training Quantization for Generative Pre-trained Transformers”. *International Conference on Learning Representations (ICLR)*. 2023.

[61] G. Gerganov és tsai. *llama.cpp: LLM inference in C/C++*. `https://github.com/ggml-org/llama.cpp`. Szoftver, GGUF formátum és K-kvantálás. 2023.

[62] Ollama. *Ollama: Get up and running with large language models locally*. `https://github.com/ollama/ollama`. Szoftver. 2024.

[63] S. Li, X. Ning, L. Wang és tsai. „Evaluating Quantized Large Language Models”. *Proceedings of the 41st International Conference on Machine Learning (ICML)*. 235. köt. PMLR. 2024, 28480–28524. old.

[64] L. Zheng, W.-L. Chiang, Y. Sheng, S. Zhuang, Z. Wu, Y. Zhuang és tsai. „Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena”. *Advances in Neural Information Processing Systems (Datasets and Benchmarks Track)*. 36. köt. 2023.

[65] C.-H. Chiang és H.-y. Lee. „Can Large Language Models Be an Alternative to Human Evaluations?”: *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics*. 2023, 15607–15631. old.

[66] S. Es, J. James, L. Espinosa-Anke és S. Schockaert. „RAGAs: Automated Evaluation of Retrieval Augmented Generation”. *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations*. 2024, 150–158. old.

[67] P. Wang, L. Li, L. Chen és tsai. „Large Language Models are not Fair Evaluators”. *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics*. 2024, 9440–9450. old.

[68] A. Panickssery, S. R. Bowman és S. Feng. „LLM Evaluators Recognize and Favor Their Own Generations”. *Advances in Neural Information Processing Systems*. 37. köt. 2024.

[69] OpenAI. *gpt-oss-120b & gpt-oss-20b Model Card*. 2025. arXiv: `2508.10925`.

[70] J. Cohen. „A Coefficient of Agreement for Nominal Scales”. *Educational and Psychological Measurement* 20.1 (1960), 37–46. old.

[71] K. Krippendorff. *Content Analysis: An Introduction to Its Methodology*. 2. kiad. Thousand Oaks, CA: Sage, 2004.

[72] J. R. Landis és G. G. Koch. „The Measurement of Observer Agreement for Categorical Data”. *Biometrics* 33.1 (1977), 159–174. old.

[73] X. Bouthillier, P. Delaunay, M. Bronzi, A. Trofimov, B. Nichyporuk, J. Szeto és tsai. „Accounting for Variance in Machine Learning Benchmarks”. *Proceedings of Machine Learning and Systems (MLSys)*. 2021.

[74] R. Dror, G. Baumer, S. Shlomov és R. Reichart. „The Hitchhiker’s Guide to Testing Statistical Significance in Natural Language Processing”. *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics*. 2018, 1383–1392. old.

[75] S. Holm. „A Simple Sequentially Rejective Multiple Test Procedure”. *Scandinavian Journal of Statistics* 6.2 (1979), 65–70. old.

[76] O. Sainz, J. A. Campos, I. García-Ferrero, J. Etxaniz, O. Lopez de Lacalle és E. Agirre. „NLP Evaluation in Trouble: On the Need to Measure LLM Data Contamination for each Benchmark”. *Findings of the Association for Computational Linguistics: EMNLP 2023*. 2023.

[77] R. Parasuraman és D. H. Manzey. „Complacency and Bias in Human Use of Automation: An Attentional Integration”. *Human Factors* 52.3 (2010), 381–410. old.

[78] K. Ahuja, H. Diddee, R. Hada, M. Ochieng, K. Ramesh, P. Jain és tsai. „MEGA: Multilingual Evaluation of Generative AI". *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. 2023.

[79] D. M. Nemeskey. „Introducing huBERT". *XVII. Magyar Számítógépes Nyelvészeti Konferencia (MSZNY 2021)*. Szeged, 2021, 3–14. old.

[80] Z. G. Yang, R. Dodé, G. Ferenczi és tsai. „Jönnek a nagyok! BERT-Large, GPT-2 és GPT-3 nyelvmodellek magyar nyelvre". *XIX. Magyar Számítógépes Nyelvészeti Konferencia (MSZNY 2023)*. Szeged, 2023, 247–262. old.

[81] Z. G. Yang, L. J. Laki, T. Váradi és G. Prószéky. „Mono- and Multilingual GPT-3 Models for Hungarian". *Text, Speech, and Dialogue (TSD 2023)*. 14102. köt. Lecture Notes in Computer Science. Cham: Springer, 2023, 94–104. old. DOI: 10.1007/978-3-031-40498-6_9.

[82] Z. G. Yang, Á. Bánfi, R. Dodé, G. Ferenczi, F. Földesi, P. Hatvani és tsai. „ChatPULI: Enhancement to the First Hungarian Conversational Model". *Annales Mathematicae et Informaticae* 61 (2025), 261–274. old. DOI: 10.33039/ami.2025.10.010.

[83] N. Ligeti-Nagy, G. Ferenczi, E. Héja és tsai. „HuLU: Hungarian Language Understanding Benchmark Kit". *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*. 2024, 8360–8371. old.

[84] A. Novák és B. Novák. „MILQA kérdés-válasz benchmark adatbázis". *XIX. Magyar Számítógépes Nyelvészeti Konferencia (MSZNY 2023)*. Szeged, 2023, 203–216. old.

[85] P. Berkecz, T. Zombori, G. Banga és tsai. „SHunQA: egy nyíltkérdés-megválaszoló rendszer". *XX. Magyar Számítógépes Nyelvészeti Konferencia (MSZNY 2024)*. Szeged, 2024, 73–84. old.

[86] Szegedi Tudományegyetem és Z. Szántó. *Kérdés generálás tananyag alapon (kutatási projekt a HUN-REN Cloud infrastruktúráján, 2024. november – 2025. február)*. https://science-cloud.hu/projektek/kerdes-generalas-tananyag-alapon. Projektoldal, letöltve: 2026. november 6. 2025.

[87] Z. Rajki, J. T. Nagy és I. Dringó-Horváth. „A mesterséges intelligencia a felsőoktatásban: hallgatói hozzáférés, attitűd és felhasználási gyakorlat". *Iskolakultúra* 34.7 (2024), 3–22. old. DOI: 10.14232/iskkult.2024.7.3.

[88] J. T. Nagy, Z. Rajki és I. Dringó-Horváth. „Mesterséges intelligencia a felsőoktatásban: oktatói hozzáférés, attitűd és felhasználási gyakorlat". *Iskolakultúra* 35.7 (2025), 3–20. old. DOI: 10.14232/iskkult.2025.7.3.

[89] Európai Parlament és a Tanács. *Az Európai Parlament és a Tanács (EU) 2024/1689 rendelete a mesterséges intelligenciára vonatkozó harmonizált szabályok megállapításáról (mesterséges intelligenciáról szóló rendelet)*. Az Európai Unió Hivatalos Lapja, L sorozat. 2024.

[90] Európai Adatvédelmi Testület (EDPB). *Guidelines 07/2020 on the Concepts of Controller and Processor in the GDPR (Version 2.0)*. https://www.edpb.europa.eu/our-work-tools/our-documents/guidelines/guidelines-072020-concepts-controller-and-processor-gdpr_en. Elfogadva: 2021. július 7. 2021.

[91] N. Carlini, F. Tramèr, E. Wallace, M. Jagielski, A. Herbert-Voss, K. Lee és tsai. „Extracting Training Data from Large Language Models”. *30th USENIX Security Symposium*. 2021, 2633–2650. old.

[92] Európai Adatvédelmi Testület (EDPB). *Opinion 28/2024 on Certain Data Protection Aspects Related to the Processing of Personal Data in the Context of AI Models*. https://www.edpb.europa.eu/our-work-tools/our-documents/opinion-board-art-64/opinion-282024-certain-data-protection-aspects_en. 2024.

[93] Európai Bizottság. *A Bizottság (EU) 2023/1795 végrehajtási határozata (2023. július 10.) a személyes adatok EU–USA adatvédelmi keretrendszer szerinti megfelelő szintű védelméről*. Az Európai Unió Hivatalos Lapja, L 231, 2023.9.20., 118–229. o., https://eur-lex.europa.eu/eli/dec_impl/2023/1795/oj. 2023.

[94] Az Európai Unió Bírósága. *C-703/25 P. sz. ügy: Philippe Latombe által a Törvényszék T-553/23. sz., Latombe kontra Bizottság ügyben 2025. szeptember 3-án hozott ítélete ellen 2025. október 31-én benyújtott fellebbezés*. Az Európai Unió Hivatalos Lapja, C sorozat, C/2025/6610, 2025.12.22., https://eur-lex.europa.eu/eli/C/2025/6610/oj. 2025.

[95] Országgyűlés. *2011. évi CXII. törvény az információs önrendelkezési jogról és az információszabadságról (Infotv.)* Nemzeti Jogszabálytár, https://njt.jog.gov.hu/jogszabaly/2011-112-00-00. 2011.

[96] Nemzeti Adatvédelmi és Információszabadság Hatóság (NAIH). *Figyelemfelhívás az MI használatának kockázataira a beadványok készítésénél*. https://www.naih.hu/. A hatóság honlapján közzétett, dátum nélküli közlemény; letöltve: 2026. november 6. 2026.

[97] Nemzeti Adatvédelmi és Információszabadság Hatóság (NAIH). *Jelentés magyarországi bankok MI használatáról*. https://www.naih.hu/hirek/802-jelentes-magyarorszagi-bankok-mi-hasznalatarol. Közzétéve: 2025. december 22.; angol változata: Report on the Processing of Personal Data by Artificial Intelligence (AI) Systems Used by Banks in Hungary. 2025.

[98] Európai Parlament és a Tanács. *Az Európai Parlament és a Tanács (EU) 2026/1744 rendelete (2026. július 8.) az (EU) 2024/1689, az (EU) 2018/1139 és az (EU) 2023/1230 rendeletnek a mesterséges intelligenciára vonatkozó harmonizált szabályok végrehajtásának egyszerűsítése tekintetében történő módosításáról (a mesterséges intelligenciáról szóló digitális omnibusz csomag)*. Az Európai Unió Hivatalos Lapja, L sorozat, 2026.7.24., https://eur-lex.europa.eu/eli/reg/2026/1744/oj. 2026.

[99] Országgyűlés. *2025. évi LXXV. törvény az Európai Unió mesterséges intelligenciáról szóló rendeletének magyarországi végrehajtásáról*. Nemzeti Jogszabálytár, https://njt.jog.gov.hu/jogszabaly/2025-75-00-00. 2025.

[100] F. Miao és W. Holmes. *Guidance for Generative AI in Education and Research*. Paris: UNESCO, 2023.

[101] The PostgreSQL Global Development Group. *PostgreSQL 16 Documentation: SELECT – The Locking Clause (FOR UPDATE SKIP LOCKED)*. https://www.postgresql.org/docs/16/sql-select.html. 2024.

[102] Qdrant. *Qdrant: Vector Similarity Search Engine*. https://github.com/qdrant/qdrant. Szoftver. 2024.

[103] M. L. Balinski és H. P. Young. *Fair Representation: Meeting the Ideal of One Man, One Vote*. 2. kiad. Washington, D.C.: Brookings Institution Press, 2001.

[104] B. Efron és R. J. Tibshirani. *An Introduction to the Bootstrap*. New York: Chapman & Hall, 1993.

[105] F. Wilcoxon. „Individual Comparisons by Ranking Methods”. *Biometrics Bulletin* 1.6 (1945), 80–83. old.

[106] D. S. Kerby. „The Simple Difference Formula: An Approach to Teaching Nonparametric Correlation”. *Comprehensive Psychology* 3 (2014).

Ábrák jegyzéke

3.1. A Mimir szolgáltatásai és adatfolyama. 19
3.2. A naiv RAG és a Mimir tervezett generálási folyamata. 23
3.3. A webes szerkesztő egy generált feleletválasztós kérdéssel. 27

4.1. Egy teszt lépései. 28

5.1. A minőségi index konfigurációnként és generátormodellenként. 37
5.2. A minőségi index a módszer lépései szerint a három helyi modellel. 37
5.3. A minőségi index dokumentumonkénti eloszlása a fő vizsgálatban. 39
5.4. A minőségi index dokumentumforrásonként a fő vizsgálat négy fő konfigurációjában. 41

6.1. Minőség és futási idő. 48

A.1. Az ellenőrző lánc visszacsatolással. 70
A.2. A konfigurációk egytényezős fája: minden él egyetlen tényező megváltoztatása. 72

Táblázatok jegyzéke

2.1. Az MI-rendelet alkalmazási időpontjai a 2026-os módosítás után. 16
2.2. A kérdésgenerálási megközelítések összevetése a P1–P4 problémák szempontjából. 17

3.1. Tervezési célok: a csevegő nyelvi modell és a Mimir összevetése. 18
3.2. Adatvédelmi és MI-rendeleti követelmények és megvalósításuk. 22
3.3. Az ellenőrző lánc lépései végrehajtási sorrendben, a hiba esetén adott visszajelzéssel. 26

4.1. A kísérleti konfigurációk. 30
4.2. A három vizsgálat beállításai. 31

5.1. A fő vizsgálat eredményei (30 dokumentum). 36
5.2. Páros Wilcoxon-próbák a dokumentumonkénti minőségi indexen (fő vizsgálat, 30 dokumentum). 38
5.3. A darabolási változatok hatása a naiv RAG-ra. 40
5.4. A konfigurációk relatív futási ideje és modellhívásai. 42

6.1. A modellek minőségi indexe a hat közös dokumentumon. 44
6.2. A helyi modellek erőforrásigénye. 47

7.1. A hipotézisek és a vizsgálatok bizonyítéka. 49
7.2. Döntési táblázat GPU-szintenként. 52

A.1. Adatfajták életciklusa a Mimir rendszerben. 68
A.2. Becsült GPU-memóriaigény (8 192 tokenes kontextus, Q4_K_M kvantálás). . . 69
A.3. A nehézségi szintekhez rendelt Bloom-eloszlások és egy 10 kérdéses vizsga kiosztása. 70
A.4. Az `eval-v1` adatkészlet és a fő vizsgálatban használt része. 72

B.1. Az előzetes vizsgálat helyi konfigurációi (Qwen2.5-7B, hat dokumentum). . . . 75
B.2. Az E2 ellenőrző láncának működése modellenként. 75
B.3. A bírói ítélettel rendelkező kérdések forrásonként. 76

E.1. A generálási folyamat paraméterei és alapértékei az előzetes és a fő vizsgálatban. 82

I.1. Az adatok forrása, licence és nyilvánossága. 90
I.2. A vizsgálatokban használt modellek. 91

A. A módszer és a kiértékelés részletei

Ez a függelék a 3. és a 4. fejezet azon részleteit tartalmazza, amelyek a főszöveg megértéséhez nem szükségesek, de a módszer és a mérés reprodukálásához igen. A paraméterek alapértékeit az E. függelék foglalja össze.

A.1. Adatfajták életciklusa

Az A.1. táblázat a Mimir által kezelt adatfajtákat, tárolási helyüket és élettartamukat foglalja össze a szolgáltatások mai kódja szerint (vö. 3.3. szakasz).

A.1. táblázat. Adatfajták életciklusa a Mimir rendszerben, a szolgáltatások mai kódja szerint. Az élettartamok környezeti változóval állíthatók; zárójelben az alapérték.

Adat	Tárolás	Élettartam
Fájl, kinyert szöveg	a Wellspring és a RuneCarver memóriája	a kérés végéig; lemezre nem kerül
Darabok és beágyazásaik	Bifrost: memóriában futó Qdrant, egy közös gyűjtemény	a feladat végén (sikeres vagy hibás) törlődnek, és új dokumentum indexelésekor is
Prompt, nyers modellválasz	a Bifrost memóriája	a modellhívás végéig; kikapcsolt `LOCAL_ONLY` mellett a szervermodellhez is eljut
Generált vizsga (vázlat)	a Bifrost memóriabeli feladattára; a szerkesztés a böngészőben	az indítástól 60 perc (`JOB_TTL_SECONDS`), utána a következő kérés törli
Jóváhagyott, mentett vizsga	Skald: PDF-fájl és SQLite-sor, csak kérésre	amíg az oktató nem törli, legfeljebb beállítható ideig (365 nap)
Audit napló	The Forge, PostgreSQL	csak metaadat és ujjlenyomat; óránkénti törlés (30 nap)

A.2. A GPU-memória becslése

A szövegelőállítás közbeni memóriaigény három tag összege:

$$M \;=\; W \;+\; \mathrm{ctx} \cdot m_{kv} \;+\; M_0, \tag{A.1}$$

ahol W a kvantált súlyok mérete, ctx a kontextus hossza tokenben, m_{kv} a KV-gyorsítótár (a már feldolgozott tokenek kulcs- és értékvektorainak tára) tokenenkénti mérete, M_0 pedig a futtatókörnyezet többletigénye. Minden rétegben (L réteg) minden kulcs–érték fejhez (H_{kv} fej) egy kulcs- és egy értékvektort kell tárolni, egyenként d_h elemmel és elemenként 2 bájttal. A Qwen2.5-7B modellre [56] ($L = 28$, $H_{kv} = 4$, $d_h = 128$):

$$m_{kv} = 2 \cdot 28 \cdot 4 \cdot 128 \cdot 2 \text{ bájt} = 57\,344 \text{ bájt} = 56 \text{ KiB},$$

így 8 192 tokenes kontextusnál a gyorsítótár 448 MiB, 16 384 tokennél 896 MiB, 32 768 tokennél 1,75 GiB. Az A.2. táblázat több helyi generátorra mutatja a becslést. A Q4_K_M kvantálás súlyonként átlagosan kb. 4,8 bitet használ, ezért a súlyok mérete a 16 bites változatának nagyjából harmada.

A.2. táblázat. Becsült GPU-memóriaigény 8 192 tokenes kontextusnál, Q4_K_M kvantálással (kb. 4,8 bit/súly) és $M_0 \approx 0{,}56$ GiB többlettel. A súlyok a GGUF-fájlok GiB-ra átszámított mérete, m_{kv} a publikált architektúrákból számolt érték. A Gemma 3 12B sorában mért érték áll (lásd a szöveget).

Modell	L/H_{kv}	Súlyok	m_{kv}	Összesen	Kártya
Qwen2.5-3B	36/2	1,8 GiB	36 KiB	2,6 GiB	8 GiB
Qwen2.5-7B	28/4	4,4 GiB	56 KiB	5,4 GiB	8 GiB
Llama-3.1-8B [57] (= PULI-LlumiX 8B)	32/8	4,6 GiB	128 KiB	6,1 GiB	8 GiB
Gemma 3 12B [58]	48/8	7,5 GiB	($\leq$ 384 KiB)	$\approx$ 7,8 GiB (mért)	12 GiB
Qwen2.5-14B	48/8	8,4 GiB	192 KiB	10,4 GiB	12 GiB

A PULI-LlumiX 8B [59] a Llama-3.1-8B architektúráját örökli, így memóriaigénye azonos vele. A Gemma 3 12B-nél az egyszerű képlet túlbecsül: a modell rétegeinek többsége csak egy rövid, helyi ablakra (*sliding window*) figyel, és csak minden hatodik réteg lát a teljes kontextusra, ezért a gyorsítótár jóval kisebb, mint $\text{ctx} \cdot m_{kv}$. Ennél a modellnél ezért a mért értéket használjuk: az Ollama 8 192 tokenes kontextusnál kb. 7,8 GiB-ot foglal.

A.3. A szemantikus darabolás vágási szabálya

Két szomszédos mondat *szemantikus távolsága*

$$\delta_i = 1 - \cos\bigl(\mathbf{v}_i, \mathbf{v}_{i+1}\bigr), \tag{A.2}$$

ahol $\mathbf{v}_i$ az i-edik mondat 768 dimenziós vektora (a mondat tokenjei vektorainak átlaga). A darabolás ott vág, ahol δ_i meghaladja a τ vágási küszöböt; alapértelmezésben τ a távolságok 85. percentilise (az E5b-ben az átlag + 1,5 szórás). A célméret (1 000 karakter) túllépése után a hatásos küszöb $\tau/(\ell/1\,000)$, ahol ℓ az aktuális darab hossza karakterben; egy kétszeres hosszúságú darab tehát már fele akkora távolságnál is lezárul.

A.4. A Bloom-szintek kiosztása

A kért nehézséghez egy Bloom-szint-eloszlás tartozik [11] (A.3. táblázat), amelyet a *legnagyobb maradék módszerével* (Hamilton-módszer [103]) alakítunk egész darabszámokká: minden szint először a kérdésszám és az arány szorzatának egészrészét kapja, a maradék helyeket pedig a legnagyobb törtrészű szintek. Közepes nehézségnél $n = 7$ kérdésre a szorzatok (2,8; 2,8; 1,4), az egészrészek (2,2,1), a két maradék hely a két legnagyobb törtrészű szinthez kerül, így a kiosztás (3,3,1). A szinteket véletlenszerűen rendeljük a kérdéshelyekhez, a kész vizsgát pedig a

könnyebbtől a nehezebb felé rendezzük.

A.3. táblázat. A nehézségi szintekhez rendelt Bloom-eloszlások és egy 10 kérdéses vizsga kiosztása.

Nehézség	Emlékezés	Megértés	Alkalmazás	Elemzés	Értékelés	Kiosztás ($n = 10$)
Könnyű	0,5	0,5	–	–	–	(5, 5, 0, 0, 0)
Közepes	–	0,4	0,4	0,2	–	(0, 4, 4, 2, 0)
Nehéz	–	–	0,3	0,4	0,3	(0, 0, 3, 4, 3)

A.5. A hibrid keresés

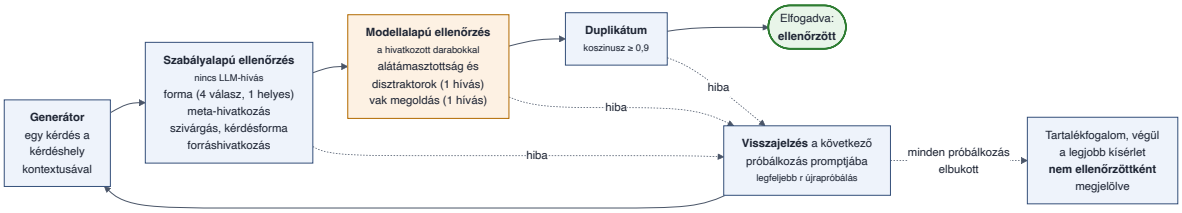
Az E2h a sűrű rangsort egy lexikális BM25-rangsorral [33] egyesíti. A magyar ragozás miatt a szavakat egyszerű *előtagtövesítéssel* normalizáljuk: a hat karakternél hosszabb szavakból az első hat karaktert tartjuk meg, így az „immunrendszer”, „immunrendszert”, „immunrendszerben” alakok közös kulcsot kapnak. A két rangsort a reciprok rangfúzió [38] egyesíti; a c darab pontszáma

$$\mathrm{RRF}(c) = \frac{1}{60 + \mathrm{rang}_{\text{sűrű}}(c)} + \frac{1}{60 + \mathrm{rang}_{\mathrm{BM25}}(c)}, \tag{A.3}$$

ahol a rang az 1-től számozott helyezés, a 60-as konstans pedig az irodalomban bevett érték, amely csökkenti az első helyek túlzott súlyát.

A.6. Egy kérdéshely kitöltése

Az A.1. algoritmus az E2 egy kérdéshelyének kitöltését írja le (vö. 3.6.6. szakasz). A hibák listája visszajelzésként („Az előző próbálkozás hibás volt, javítsd: . . . ”) a következő kísérlet promptjába kerül; ha a kulcs nem igazolt, a keresés két darabbal bővül. Ha egy tartalékfogalommal sem sikerül, a *legjobb* kísérlet (formailag helyes, szivárgásmentes, legkevesebb hibájú) marad meg *nem ellenőrzöttként* megjelölve; hibás formánál egy *javító* hívás pótolja a hiányzó disztraktorokat. Az A.1. ábra ugyanezt folyamatábraként mutatja.



A.1. ábra. Az ellenőrző lánc visszacsatolással. Az olcsó szabályalapú ellenőrzések előbb futnak; a hiba szövege a következő generálási kísérlet promptjába kerül.

Algoritmus A.1: Egy kérdéshely kitöltése visszacsatolással (E2).

Bemenet: kérdéshely s (fogalom, típus, Bloom-szint); elfogadott kérdések $\mathcal{A}$; $k = 3$; $r = 1$
Kimenet: kérdés q és az *ellenőrzött* jelző

$q^* \leftarrow \emptyset$;
minden *fogalom* $c \in$ (*s.fogalom, az első tartalékfogalom*) **elemre**
  $h \leftarrow \emptyset$; $k' \leftarrow k$;
  ciklus $t = 0, \ldots, r$ **:**
    $K \leftarrow$ Kontextus(c, k') ; // ≤ 6 000 karakter
    $q \leftarrow$ Generál$(s, c, K, \mathcal{A}, h)$; // h: az előző hibák
    $h \leftarrow$ Ellenőriz$(q, K) \cup$ Duplikátum$(q, \mathcal{A})$;
    ha $h = \emptyset$ **akkor visszatér** $(q,$ igaz$)$;
    $q^* \leftarrow$ a jobb q^* és q közül;
    ha *a kulcs nem igazolt* **akkor** $k' \leftarrow k' + 2$;
ha q^* *formája hibás* **akkor** $q^* \leftarrow$ Javít(q^*);
visszatér $(q^*,$ hamis$)$;

A.7. A fogalomgráf

Az E3 a darabokat legfeljebb 3 000 karakteres kötegekbe csoportosítja, és kötegenként egy hívásban kinyeri a fogalmakat (definícióval, szülőfogalommal, darabazonosítókkal), a rövid tényeket és a fogalmak közötti kapcsolatokat (*fajtája*, *része*, *okozza*, *ellentéte* stb.). A nagyon hasonló nevű fogalmakat (névbeágyazásuk koszinusz-hasonlósága legalább 0,92) összevonja, ami a ragozott alakokat is egyesíti. A fogalmakat a $\text{cent}(v) =$ kapcsolatok száma $+ \frac{1}{2} \cdot$ darabok száma $+ \frac{1}{2} \cdot$ tények száma centralitás szerint rendezi, és ez a lista lép a tervező helyébe. A generátor disztraktor-ötletként a fogalom *testvérfogalmait* kapja (azonos szülőjű fogalmakat, például a „T-sejt” mellett a „B-sejtet”), a kontextus pedig a szomszédos fogalmak darabjaival bővül.

A.8. Az adatkészlet

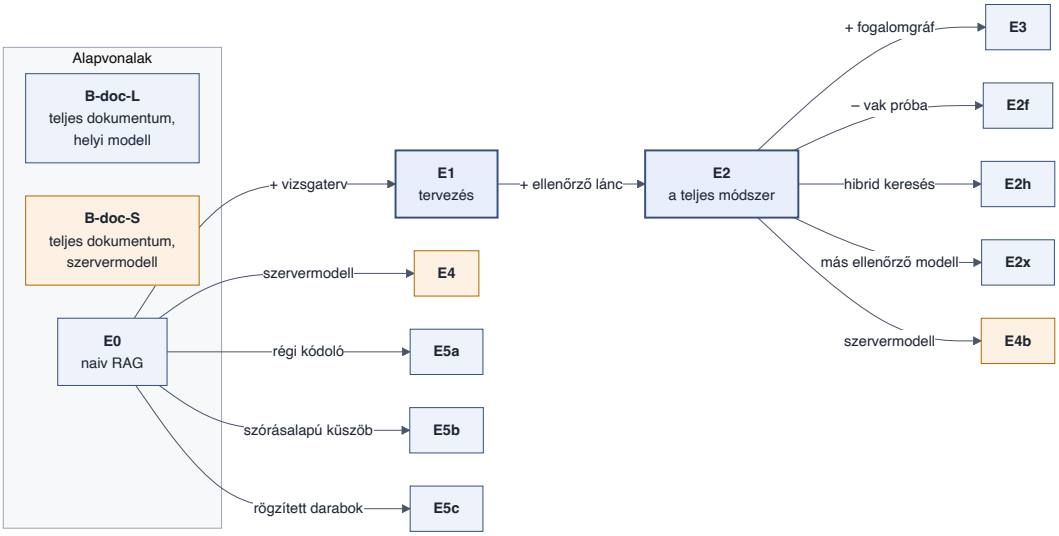
Az `eval-v1` adatkészlet 39 dokumentumból áll, három forrásból (A.4. táblázat). Minden referenciakérdéshez rendelkezésre áll a forrásszakasz *és* a választ igazoló mondat, mert a keresési mutatók ezt igénylik. A három saját szöveghez négy-négy kézzel írt referenciakérdés tartozik; az importált forrásokból csak azokat a kérdéseket tartottuk meg, amelyek igazoló mondata szó szerint szerepel a dokumentumban.

A.9. A konfigurációk egytényezős fája

Az A.2. ábra a 4.1. táblázat konfigurációit mutatja: minden konfiguráció pontosan egy tényezőben tér el a szülőjétől (vö. 4.3. szakasz).

A.4. táblázat. Az `eval-v1` adatkészlet és a fő vizsgálatban használt része. R/K/H: rövid (≤ 6 000), közepes (6 000–25 000) és hosszú (25 000–90 000 karakteres) dokumentumok.

		`eval-v1`			Fő vizsgálat		
Forrás	Nyelv	Dok.	R/K/H	Ref. kérdés	Dok.	R/K/H	Licenc
Saját oktatási szövegek	magyar	3	3/0/0	12	3	3/0/0	saját
OpenStax, EduQG	angol	12	4/4/4	74	3	1/1/1	CC BY 4.0
Wikipédia, MILQA	magyar	24	8/8/8	240	24	8/8/8	CC BY-SA 4.0
Összesen		39	15/12/12	326	30	12/9/9	



A.2. ábra. A konfigurációk egytényezős fája: minden él egyetlen tényező megváltoztatása.

A.10. Az oktatói értékelés protokollja

Alapbeállításban a kiválasztott konfigurációkból konfigurációnként 30 kérdést mintavételezünk (előbb minden dokumentumból egyet), 3 értékelővel és 10 közös kalibrációs kérdéssel. Az xlsx-lapok vakok (a konfiguráció neve nem szerepel, a sorrend értékelőnként eltérő véletlen sorrend); minden kérdés mellett egy, minden konfigurációnál azonos módon kiválasztott forrásrészlet áll, a rubrika a bíróéval azonos. Az oktatók egymás közötti egyezését szempontonként Krippendorff-α-val [71], a bíró és az oktatók egyezését Spearman-féle rangkorrelációval és Krippendorff-α-val, a bináris ítéletekre (a bíró „alátámasztott” ítélete vs. oktatói helyesség ≥ 4) Cohen-κ-val mérjük.

A.11. A mutatók részletes definíciói

Lefedettség. Minden kérdéshez (törzs és kulcs együtt) megkeressük a beágyazás szerint legközelebbi darabot:

$$\text{Lef} = \frac{\text{a kérdésekhez legközelebbi különböző darabok száma}}{K}, \tag{A.4}$$

ahol K a dokumentum darabjainak száma. Egy tízkérdéses vizsga lefedettsége legfeljebb $10/K$, így egy százdarabos dokumentumon legfeljebb 10 %.

Szivárgás és nem kérdő törzs. *Szivárgás*, ha a legalább háromszavas kulcs szavainak legalább 80 %-a a törzsben is szerepel (egy egyszavas tulajdonnév így nem ad téves jelzést); *nem kérdés* a törzs, ha sem kérdőjelre, sem kettőspontra nem végződik.

További mutatók. A *duplikátumráta* azon kérdéspárok aránya, amelyek koszinusz-hasonlósága meghaladja a 0,9-et; a *meta-hivatkozás* aránya azoké, amelyek „a szöveg szerint” jellegű fordulatot tartalmaznak. A *keresési találati arány* (recall@3) azt méri, hogy a referenciakérdésekkel futtatott keresés első három találata között szerepel-e az igazoló mondatot tartalmazó darab; a *tematikus hasonlóság* azt, hogy a referenciakérdések mekkora részéhez van beágyazás szerint közeli generált kérdés. *Költségmutató* a futási idő (szakaszonként), a modellhívások és tokenek száma, valamint a GPU-memória alapszintje és csúcsa.

A.12. A statisztikai eljárások részletei

Hatásnagyság. A páros Wilcoxon-próba [105] mellett a hatás nagysága a rangbiszeriális korreláció [106]:

$$r_{rb} = \frac{W^+ - W^-}{W^+ + W^-}, \tag{A.5}$$

ahol W^+ és W^- a pozitív, illetve a negatív különbségek rangösszege; +1, ha az új konfiguráció minden dokumentumon jobb, −1, ha mindenütt rosszabb.

A minimális mintaméret. D dokumentum esetén a legkisebb elérhető kétoldali p-érték $2 \cdot 2^{-D}$, amelyet akkor kapunk, ha minden különbség azonos előjelű. Hat dokumentumnál ez 0,031, ötnél 0,0625: hat dokumentum a legkisebb szám, amelyen egy összevetés egyáltalán szignifikáns lehet. Holm-korrekció [75] után a hat előre rögzített összehasonlítás közül a legkisebb p-értéket 6-tal szorozzuk, így hat dokumentumnál a legkisebb elérhető korrigált érték 0,19.

Egyezés és az ellenőrző mint osztályozó. Két igen/nem ítéletsor (például az ellenőrzőé és a bíróé) egyezését Cohen-κ-val [70] mérjük:

$$\kappa = \frac{p_o - p_e}{1 - p_e}, \tag{A.6}$$

ahol p_o a megfigyelt, p_e a véletlenül várható egyezési arány; $\kappa = 0$ a véletlen szintje, $\kappa = 1$ a teljes egyezés, az értelmezés Landis és Koch [72] skáláját követi. Az ellenőrző lánc minden kérdést *átengedett* vagy *megjelölt* kategóriába sorol; a bíró alátámasztottsági ítéletét referenciának tekintve

$$\text{pontosság} = \frac{\text{átengedett és alátámasztott}}{\text{átengedett}}, \qquad \text{felidézés} = \frac{\text{átengedett és alátámasztott}}{\text{alátámasztott}}. \tag{A.7}$$

B. Kiegészítő eredmények

Ez a függelék az 5. fejezet részletes táblázatait és számait tartalmazza; a főszöveg ezekre hivatkozik, és csak az összegzésüket közli. Minden szám forrása a `tdk/elemzes/elemzes.py` kimenete (E. függelék).

B.1. A pilot részletei

A pilot egyetlen rövid magyar szövegen (`hu-coffee`, 1 702 karakter, négy darab) futott tíz konfigurációval, konfigurációnként három vizsgával, összesen 300 kérdéssel, a Qwen2.5-7B modellel.

Csendes tartalékágak. Ha egy kérdéshely minden kísérlete elbukott, a megtartott végső kérdésnek néha csak két-három válaszlehetősége volt, ami a vizsga formai megfelelését nullára, minőségi indexét 0,25-tel csökkentette. Javításként a végső kérdés kiválasztása a formát is figyeli, és egy javító hívás pótolja a hiányzó disztraktorokat. A keretrendszer építése során talált másik két hiba: sikertelen modellhívások esetén a háttérrendszer egy beégetett, egykérdéses „tartalékvizsgát” adott vissza hibaüzenet helyett, a darabolás kódolója pedig a hosszabb dokumentumokat a tartalomtól függetlenül vágta (3.6.1. szakasz).

Válaszszivárgás. Az E3 egyik kérdése szó szerint ez volt: „A kávéfogyasztás szokása Etiópiából hamar átterjedt a szomszédos Jemenbe, majd az arab világba, Európába pedig a 17. században jutott el a velencei kereskedők révén.” A kulcs ugyanez a mondat volt, a disztraktorok ugyanez a 16., 18., illetve 15. századdal. A szivárgás ott volt a legerősebb, ahol a legtöbb újrapróbálkozás történt: az E3 kérdéseinek 20 %-a szivárgott, 47 %-uk törzse nem is kérdés volt, a bíró mégis többnyire 5-ös helyességi pontot adott, hiszen a kulcs valóban a forrásból származik, és a kérdés vakon is megoldható.

Zaj. Az E0 és az E5a a pilotban azonos darabokat és azonos kontextust kapott (512 tokennél rövidebb szövegen a régi és az új kódoló ugyanazt adja), mégis 0,83, illetve 0,90 minőségi indexet ért el; egyetlen dokumentumon ezért a 0,07-nél kisebb különbségek zajnak tekintendők.

B.2. Az előzetes vizsgálat helyi konfigurációi

A B.1. táblázat a Qwen2.5-7B mind a 11 helyi konfigurációjának eredményét közli az előzetes vizsgálat hat dokumentumán; a szerveres konfigurációkat a 6.2. szakasz tárgyalja.

A táblázatból négy megfigyelés emelhető ki. (1) A tervezett és ellenőrzött folyamat (E2) a legrobusztusabb: leggyengébb dokumentuma is 0,89. (2) Az ellenőrzés az E1-hez képest öt dokumentumon javított, egyen sem rontott (+0,08). (3) A naiv RAG a három angol dokumentumon összeomlott (0,40; a magyar szövegeken 0,88). (4) A kiegészítő ablációk (E2f, E2h, E2x, E3)

B.1. táblázat. Az előzetes vizsgálat helyi konfigurációi (Qwen2.5-7B, hat dokumentum; az egyhívásos konfigurációk három, a tervezettek egy maggal). Q: minőségi index 95 %-os bootstrap-intervallummal; F, G, A, V: formai megfelelés, alátámasztottság, vak megoldhatóság, disztraktor-validitás (%); Lef.: lefedettség (%); Min.: a leggyengébb dokumentum Q-ja. A futási időket az 5.4. táblázat adja.

Konfiguráció	Q	95 % CI	F	G	A	V	Lef.	Min.
B-doc-L (teljes dok.)	0,83	0,76–0,90	83	79	86	85	45	0,71
E0 (naiv RAG)	0,64	0,46–0,81	100	43	62	52	25	0,34
E1 (tervezés)	0,88	0,82–0,94	100	80	80	91	46	0,76
E2 (tervezés + ellenőrzés)	**0,96**	0,93–0,98	100	90	97	96	44	**0,89**
E3 (+ fogalomgráf)	0,88	0,79–0,95	100	83	87	83	40	0,68
E2f (vak próba nélkül)	0,90	0,84–0,95	100	78	88	92	44	0,81
E2h (hibrid keresés)	0,92	0,90–0,94	100	82	92	94	42	0,88
E2x (csak szabályok)*	0,89	0,83–0,95	100	78	83	95	42	0,77
E5a (régi kódoló)	0,87	0,81–0,92	100	74	84	90	36	0,76
E5b (magasabb küszöb)	0,70	0,54–0,86	100	39	78	63	35	0,45
E5c (rögzített darabolás)	0,86	0,70–0,97	100	82	82	81	51	0,50

* A második modell ellenőrző hívásai hibával tértek vissza (5.4. szakasz).

mind elmaradtak az E2-től. A legnagyobb hatások (E2–E0: mind a hat dokumentumon javulás; E2–E1: öt javulás, romlás nélkül) korrigálatlanul $p = 0{,}031$-et adnak, Holm-korrekció után egyik sem szignifikáns (a hat dokumentumon elérhető legkisebb korrigált érték 0,19).

B.3. Az ellenőrző lánc részletei

B.2. táblázat. Az E2 ellenőrző láncának működése modellenként. n: bírói ítélettel rendelkező kérdések (5.9. szakasz); Első kísérlet: az első próbálkozásra elfogadott kérdéshelyek aránya; Átengedett: az ellenőrzöttként elfogadott kérdések aránya; pontosság, felidézés és Cohen-κ a bíró alátámasztottsági ítéletéhez képest (4.8. szakasz). Az elutasítási okok az összes kísérletre vonatkoznak.

Modell	n	Első kísérlet	Kísérlet/ kérdéshely	Átengedett	Pontosság	Felidézés	κ	Leggyakoribb elutasítási okok
Qwen2.5-7B	60	23 %	1,8	52 %	0,94	0,54	0,08	duplikátum, igaz lehet egy disztraktor, nem kérdés
PULI-LlumiX 8B	85	5 %	2,0	19 %	0,56	0,21	0,05	duplikátum, forma, nem kérdés, vak eltérés, szivárgás
Gemma 3 12B	157	70 %	1,3	95 %	0,88	0,95	0,00	duplikátum, vak eltérés

A Qwen ellenőrzője pontos, de szigorú: amit átenged, az 94 %-ban alátámasztott, de a jó kérdések közel felét is megjelöli; a Gemma ellenőrzője szinte mindent átenged. A PULI-nál az osztályozói mutatók mindössze 85 bírált kérdésen alapulnak, ezért bizonytalanok. A többi ellenőrzött konfigurációban a κ legfeljebb 0,22 (Qwen E2h).

B.4. Lefedettség, kognitív szint és felhasználhatóság

Lefedettség. E0→E2: Qwen 25 %→44 %, PULI 10 %→21 %, Gemma 24 %→43 %. A teljes dokumentumos prompt lefedettsége a Gemmánál 43 % (E1, E2: 43 %), a Qwennél 45 %. A lefedettség felső korlátja tíz kérdésnél $10/K$, ezért a hosszú dokumentumokon a mutató egyik módszert sem különbözteti meg.

Kognitív szint. A vizsgaterv a fő vizsgálatban a kérdések 43–45 %-át, az előzetes vizsgálatban 27 %-át tervezte magasabb rendű (alkalmazás, elemzés, értékelés) szintre. A bíró szerint ebből a tervezett konfigurációkban a Gemmánál 7–11 %, a Qwennél 5–13 %, a PULI-nál 0–2 % valósult meg; a tervezett és a megvalósult szint a Gemmánál a kérdések 12–20 %-ánál, a PULI-nál 6–10 %-ánál, a Qwennél 33–45 %-ánál egyezett.

Felhasználhatóság. A „felhasználnám” ítélet (bekerülne-e a kérdés egy valódi dolgozatba legfeljebb apró javítással) aránya a Gemmánál a tervezett konfigurációkban 85–88 %, a teljes dokumentumos promptnál 83 %, az E5c-nél 80 %, a naiv RAG-nál 42 %; a Qwennél az E2-ben 80 %, a B-doc-L-ben 68 %, az E0-ban 34 %; a PULI-nál legfeljebb 38 % (E5a, ahol vizsgánként átlagosan csak 2,3 kérdés készült), az E2-ben 29 %. Az arány csak a bírói ítélettel rendelkező kérdésekre számolódik. A Gemma törzsei a tervezett konfigurációkban átlagosan 122–125 karakteresek (az E3-ban 106), a teljes dokumentumos kérdéseknél 63, a naiv RAG-nál 54: a tervezett folyamat jellemzően magyarázó, összefüggést kérdező törzset ír.

B.5. A bírói ítéletek lefedettsége

A fő vizsgálatban az áttekintő bírói ítélet a tervezett konfigurációknál a kérdések 44–52 %-ánál (Gemma), illetve 29–48 %-ánál (PULI), az egyhívásos konfigurációknál 47–65 %-ánál (Gemma), illetve 70–100 %-ánál (PULI) van meg; az előzetes vizsgálatban minden kérdés kapott ítéletet. Az ítélettel rendelkező kérdések száma konfigurációnként 85 (PULI E2) és 574 (Gemma E0) között van, a tervezett konfigurációknál a PULI-nál 85–138, a Gemmánál 132–157. A B.3. táblázat a forrásonkénti bontást mutatja. Hossz szerint nincs érdemi különbség: a Gemma E2 Wikipédia- és angol dokumentumain a rövid, közepes és hosszú dokumentumokból írt kérdések 46/90, 42/90, illetve 43/90 arányban kaptak ítéletet.

B.3. táblázat. A bírói ítélettel rendelkező kérdések forrásonként (ítélettel rendelkező / összes kérdés) három jellemző konfigurációban.

Konfiguráció	Angol (3 dok.)	Saját magyar (3 dok.)	Wikipédia (24 dok.)	Összesen
Gemma E2	30/30 (100 %)	26/30 (87 %)	101/240 (42 %)	157/300 (52 %)
Gemma E0	90/90 (100 %)	90/90 (100 %)	394/720 (55 %)	574/900 (64 %)
PULI E2	9/30 (30 %)	5/30 (17 %)	71/238 (30 %)	85/298 (29 %)

A hiánynak három következménye van. (1) A Wikipédia-dokumentumok G, A és V értéke kevesebb kérdésen alapul, tehát zajosabb. (2) Ha az elutasítás a tartalomtól függ, a bírált kérdések

nem véletlen mintát alkotnak, így e mutatók a bírált részhalmazra érvényesek. (3) Ha egy vizsga minden bírói hívása sikertelen volt, a vizsgaszintű Q csak a formai megfelelésre (és a vak próbára) támaszkodik; ezt ellenőrzi az érzékenységvizsgálat (5.9. szakasz).

A bíró vakfoltja. A teljes dokumentumos konfigurációknál a bíró a dokumentumnak csak az első 24 000 karakterét látja (4.6. szakasz). Az előzetes vizsgálatban ezért a 68 000 karakteres jogi szövegen a szervermodell egy helyes kérdését („What is the access economy?”) alá nem támasztottnak ítélte, mert a fogalom a 38 603. karakternél áll.

C. Promptok

Ez a függelék a generálási folyamatok promptjainak lényegi sorait közli; a kihagyásokat [. . .] jelöli, a kapcsos zárójelben álló részek helyére a program illeszti be az aktuális értéket. A belső lépések (tervező, gráf, ellenőrző) promptjai angol nyelvűek, mert a kis helyi modellek ezeket megbízhatóbban követik; a generátor promptja magyar, és megismétli az éles prompt szabályait, így az E0 és az E1–E3 konfigurációk szerkezetben, nem szabályokban különböznek. A teljes szövegek a `services/bifrost/prompts.py` és a `tests/eval/mimir_eval/blueprint/prompts.py` fájlban találhatók.

C.1. A naiv RAG (E0) és a teljes dokumentumos prompt (B-doc)

```
Te egy kiemelkedő tudású oktatásmódszertani szakértő és professzionális vizsgakészítő vagy.
KÖTELEZŐ SZABÁLYOK, AMIKET SZIGORÚAN BE KELL TARTANOD:
1. ZÉRÓ HALLUCINÁCIÓ: KIZÁRÓLAG a megadott KONTEXTUS alapján dolgozz! [...]
2. FELHASZNÁLÓI UTASÍTÁS KÖVETÉSE: [...] Pontosan a kért mennyiséget és típust generáld le!
3. DISZTRAKTOROK: Feleletválasztós (mcq) kérdés esetén 1 helyes és 3 hihető, de helytelen
↪  válasz.
4. NO LATEX: Szigorúan TILOS LaTeX formázást vagy dollárjeleket ($) használni!
5. META-REFERENCIA TILALOM: Szigorúan TILOS a dokumentum szerkezetére kérdezni. [...]
KONTEXTUS:
{context_text}            (E0: a 3 legközelebbi darab; B-doc: a teljes dokumentum)
FELADAT (A felhasználó pontos kérése):
"Készíts pontosan 10 darab vizsgakérdést, típus: feleletválasztós (mcq). Nehézségi szint:
↪  ..."
KIMENETI FORMÁTUM: [...] kizárólag egy érvényes JSON objektum:
{"title": "Mimir AI Vizsga", "format": "pdf", "questions": [
  {"type": "mcq", "text": "...?", "answers": [{"text": "...", "is_correct": true}, ...]}]}
```

C.2. A tervező

```
[planner] You design exam blueprints. Reply with one valid JSON object only.
Below is a document split into numbered chunks (C0, C1, ...). Some chunks are shortened.
{overview}                (darabonként az eleje, összesen legfeljebb 12 000 karakter)
List the {n+3} most important, clearly distinct concepts, facts or ideas a student should be
tested on. Cover the whole document: every major part should have at least one concept.
↪  Prefer
central ideas over trivia. [...]
JSON shape: {"concepts": [{"concept": "short name", "description": "one sentence: what
↪  exactly
  should be tested", "chunk_ids": ["C0"], "importance": 3}]}
importance: 3 = central, 2 = important, 1 = detail.
```

C.3. A generátor

```
[generator] Te egy kiemelkedő tudású oktatásmódszertani szakértő és professzionális
↪  vizsgakészítő
```

```
vagy. Kizárólag érvényes JSON formátumban válaszolj, markdown formázás nélkül!
Készíts PONTOSAN EGY vizsgakérdést az alábbi terv szerint.
TERV:
- Fogalom: {concept}       - Mit kérdezzen: {description}
- Kérdéstípus: feleletválasztós ("mcq"): pontosan 4 válasz, ebből pontosan 1 helyes és 3
↪  hihető,
  de a kontextus szerint egyértelműen helytelen disztraktor; [...] hossza és formája legyen
  ↪  hasonló.
- Bloom-szint: {pl. Megértés (magyarázat, összehasonlítás, saját szavakkal)}
- Vizsga nehézsége: {difficulty}    - Nyelv: [...] {magyar} nyelven írd.
KÖTELEZŐ SZABÁLYOK:
1. ZÉRÓ HALLUCINÁCIÓ: KIZÁRÓLAG a KONTEXTUS alapján dolgozz. [...]
2. HIVATKOZÁS: a "citations" mezőbe írd azoknak a részleteknek az azonosítóját (pl. "C3"),
   amelyek igazolják a helyes választ.
3. NO LATEX. [...]  4. META-REFERENCIA TILALOM: [...]
5. NE ISMÉTELD a már elkészült kérdéseket: {existing}
[DISZTRAKTOR-ÖTLETEK (rokon fogalmak a dokumentumból) ...]          (csak E3)
[AZ ELŐZŐ PRÓBÁLKOZÁS HIBÁS VOLT, JAVÍTSD: {feedback}]             (csak újrapróbálkozáskor)
KONTEXTUS:
[C3] ...
[C1] ...
KIMENETI FORMÁTUM (csak ez a JSON objektum):
{"type": "mcq", "text": "A kérdés szövege?", "answers": [...], "citations": ["C0"],
 "bloom": "understand", "explanation": "egy mondat: miért ez a helyes válasz"}
```

C.4. A javító hívás

```
[repair] Te egy gondos vizsgakészítő vagy, aki hibás formájú kérdéseket javít. [...]
Az alábbi feleletválasztós kérdés formája hibás. Javítsd ki úgy, hogy PONTOSAN 4 válasz
↪  legyen,
ebből PONTOSAN 1 helyes; a hiányzó rossz válaszokat a kontextus alapján egyértelműen hibás,
↪  de
hihető állításokkal pótold. A kérdés tartalmán és a helyes válaszon ne változtass [...]. A
↪  kérdés ne
tartalmazza a helyes választ, és kérdőjellel végződjön.
KÉRDÉS: {text}   VÁLASZOK: {options}   KONTEXTUS: {chunks}   KIMENETI FORMÁTUM: [...]
```

C.5. Az ellenőrző

```
[verifier] You check exam questions against source text. Reply with one valid JSON object
↪  only.
--- alátámasztottság és disztraktorok ---
SOURCE: """{a hivatkozott darabok}"""
QUESTION (mcq): {text}
A. ...   <-- marked correct
B. ...  [...]
Check strictly against the SOURCE only:
1. key_supported: is the marked-correct answer clearly supported by the SOURCE?
2. For every option NOT marked correct: is it clearly wrong according to the SOURCE? [...]
3. ambiguous: could a careful reader argue that more than one option is correct?
4. problems: one short sentence describing any problem ("" if none).
JSON shape: {"key_supported": true, "options_wrong": [true, true, true], "ambiguous": false,
             "problems": ""}
--- vak megoldás ---
SOURCE: """{a hivatkozott darabok}"""
```

```
Answer the question using only the SOURCE. Exactly one option is correct.
{text}
A. ...  B. ...  C. ...  D. ...        (véletlen permutáció)
JSON shape: {"answer": "A"}
```

C.6. A fogalomgráf (E3)

```
[graph] You extract knowledge graphs from teaching material. Reply with one valid JSON object
↪  only.
Extract the knowledge in these chunks as a small concept graph. Chunk ids are in brackets.
{chunks_block}            (legfeljebb 3 000 karakteres köteg)
Rules:
- concepts: the key terms, entities, processes or ideas (max 8 per chunk). "parent" is the
↪  broader
  category the concept belongs to (e.g. "T-sejt" -> "limfocita"), or "" if none. [...]
- facts: short atomic statements from the text (max 6 per chunk), [...]
- relations: typed links between concepts: is_a, part_of, causes, contrasts_with, used_for,
  related_to. [...]
JSON shape: {"concepts": [...], "facts": [...], "relations": [...]}
```

D. A bíró és az oktatók rubrikája

A rubrika szövege a bíró és az oktatói értékelőlap számára azonos (a bíró az angol, az oktatók a magyar változatot kapják).

Helyesség

A megjelölt válasz a forrás szerint helyes, és más opció nem helyes. 1 = hibás kulcs vagy két helyes opció; 3 = helyes, de pontatlan; 5 = teljesen helyes, egyértelmű.

Érthetőség

A kérdés önmagában érthető, nyelvtanilag helyes, egyértelmű, nem hivatkozik „a szövegre” vagy a dokumentum szerkezetére. 1 = zavaros; 3 = nehezen érthető; 5 = vizsgakész megfogalmazás.

Disztraktorok

A rossz válaszok a forrás szerint egyértelműen rosszak, de egy felkészületlen diák számára hihetők (azonos téma, hasonló hossz és forma). 1 = abszurd vagy szintén helyes; 3 = részben hihető; 5 = mind hihető és rossz. Kifejtős kérdésnél üresen marad.

Szintillesztés

A kognitív szint megfelel a kért nehézségnek (könnyű: felidézés/megértés; közepes: alkalmazás/megértés; nehéz: elemzés/értékelés). 1 = egyértelműen rossz szint; 3 = határeset; 5 = illik.

Felhasználnám

Beraknád ezt a kérdést egy valódi dolgozatba legfeljebb apró javítással? (igen/nem)

A bíró áttekintő hívása ezen felül kéri a kulcsot igazoló mondat szó szerinti idézését (`key_evidence` mező), disztraktoronként az `is_wrong` és az `on_topic` ítéletet, a kérdés Bloom-szintjét és egy-két mondatos indoklást.

E. Paraméterek és reprodukálás

E.1. A generálási folyamat paraméterei

E.1. táblázat. A generálási folyamat paraméterei és alapértékei az előzetes és a fő vizsgálatban.

Paraméter	Alapérték	Megjegyzés
darabolás	percentilis, 85	célméret 1 000 karakter, puha korlát; E5b: átlag + 1,5 szórás; E5c: rögzített 800 karakter
visszakeresett darabok (k)	3	E0: a teljes vizsgához; tervezett folyamat: kérdéshelyenként
keresés módja	sűrű	E2h: BM25 + sűrű, RRF (c = 60), 6 karakteres előtagtövesítés
áttekintés kerete	12 000 karakter	a tervező ennyit lát; darabonként legalább 120 karakter
fogalmak száma	n + 3	3 tartalékfogalom
kérdéshely-kontextus kerete	6 000 karakter	+ 2 darab, ha a kulcs nem igazolt
újrapróbálkozás (r)	1	pilot: 2; utána 1 tartalékfogalom
ellenőrző lánc	E1: ki; E2, E3: be	vak megoldás: be (E2f: ki)
szivárgási szabályok, javító hívás	be	a pilot után bevezetve
duplikátumküszöb	0,9	koszinusz-hasonlóság (E5-beágyazás)
fogalomgráf (E3)	3 000 karakteres köteg	összevonás 0,92 hasonlóság felett
teljes dokumentum (B-doc)	30 000 / 80 000 karakter	helyi / szerver; helyben 16 384 tokenes kontextus
generátor	Q4_K_M, T = 0,2	8 192 tokenes kontextus; `num_predict` 4 096 (fő vizsgálat)
bíró	gpt-oss-120b, T = 0	„low” gondolkodás; forrás legfeljebb 24 000 karakter

Minden konfiguráció egy YAML-fájl a `tests/eval/configs` könyvtárban, amely csak az alapértékektől (`mimir_eval/config.py`) eltérő kulcsokat adja meg. Az egyenyezős terv a fájlok szintjén is látható: az E2 és az E3 konfiguráció például egyetlen kulcsban (`graph`) különbözik.

```
# E2 - E1 + verifier chain: schema, meta-reference, citations, grounding + distractor check,
# blind answer test; max 1 retry per slot with feedback, then 1 replacement.
name: E2
seeds: [1]
```

```
exam:
  n_questions: 10
  types: [mcq]
pipeline:
  kind: blueprint        # retrieval: dense, retrieval_k: 3
  verifier: true
  blind_test: true
  max_retries: 1
  graph: false           # E3: true
chunking:
  method: percentile     # threshold: 85, target_size: 1000
generator:
  provider: ollama
  model: "hf.co/mradermacher/PULI-LlumiX-Llama-3.1-GGUF:Q4_K_M"
  temperature: 0.2
  num_ctx: 8192
```

E.2. A reprodukálás lépései

A keretrendszernek a tárolóban két változata van. A fő vizsgálatot a `tests/new eval` könyvtárban lévő változat futtatta. Ebben a generátor válaszának hossza `num_predict : 4096` tokenre korlátozott (e nélkül egy JSON-módú válasz az időkorlátig is futhat), és egy sikertelen vizsgát (hibás JSON, tartalékvizsga vagy szolgáltatáshiba) a folytatott futás (`-resume`) újra lefuttat, de két sikertelen kísérlet után nem próbálja újra (`-max-attempts`, alapértéke 2), és az utolsó sikertelen rekordot tartja meg. A `tests/eval` könyvtár a keretrendszer jelenlegi fejlesztői változata; a fő vizsgálat pontos megismétléséhez az alábbi lépéseket a `tests/new eval` könyvtárban kell futtatni.

A nyers eredmények a tárolóban vannak. A pilot a `tests/eval/results_pilot` könyvtárban található; a fő vizsgálat a `tests/eval/results_fo_2026-10.zip`, az előzetes vizsgálat a `tests/new eval/results.zip` archívumban, amelyeket a `tests/eval/results`, illetve a `tests/eval/results_qwen_2026-09` könyvtárba kell kibontani. Konfigurációnként egy-egy futáskönyvtár tartozik hozzájuk `run.json`, `exams.jsonl`, `questions.jsonl` és `exam_metrics.csv` fájlokkal. A dolgozat minden száma egyetlen szkriptből származik: a `python tdk/elemzes/elemzes.py` parancs a három futáskészletből a `tdk/elemzes/szamok.md` (olvasható) és a `szamok.json` (gépi) fájlt állítja elő.

```
# 1. Szolgáltatások és helyi modellek
docker-compose up -d --build
ollama pull hf.co/mradermacher/PULI-LlumiX-Llama-3.1-GGUF:Q4_K_M
ollama pull gemma3:12b
ollama pull llama3.1:8b                      # az E2x ellenőrzője

# 2. Kiértékelő környezet és ellenőrzés
cd tests/eval            # fejlesztői változat; a fő vizsgálathoz: cd "tests/new eval"
pip install -r requirements.txt
python -m pytest tests_unit -q               # a keretrendszer saját tesztjei
python -m mimir_eval check configs/e0_naive_local.yaml --judge-model gpt-oss:120b

# 3. Egy konfiguráció: futtatás, pontozás
```

```
python -m mimir_eval run   configs/e2_blueprint_verifier.yaml
python -m mimir_eval score results/E2_<időbélyeg> --judge-model gpt-oss:120b

# 4. A teljes mátrix (Windows PowerShell); megszakítás után folytatható
./run_all.ps1                                  # PULI-LlumiX 8B (alapértelmezett generátor)
./run_all.ps1 -Model gemma3:12b                # a helyi konfigurációk a második generátorral

# 5. A dolgozat számai (a tároló gyökeréből)
python tdk/elemzes/elemzes.py                  # -> tdk/elemzes/szamok.md, szamok.json
```

A `-Model` kapcsoló a helyi konfigurációkat egy másik Ollama-modellel futtatja új néven (például E2 → `E2-gemma3-12b`), így a két generátor eredményei egymás mellett maradnak; a szerverkonfigurációkat (B-doc-S, E4, E4b) ilyenkor kihagyja. Az előzetes vizsgálat ugyanígy, `-Model qwen2.5:7b` kapcsolóval ismételhető meg. A bíró a GenAI-szerver kulcsát a tároló `.env` fájljából (`OE_GENAI_API_KEY`) olvassa; válaszai a futáskönyvtár `judge_cache.jsonl` fájljába kerülnek, így az újrapontozás nem igényel új bírói hívást.

F. Rezümé

A 38. OTDK Informatikatudományi Szekció 1. számú melléklete szerinti rezümé.

A feleletválasztós vizsgakérdések írása az oktatói munka egyik legidőigényesebb része. A felhőben futó nyelvi modellek gyors segítséget adnak, de nem ellenőrzik, hogy a helyes választ a tananyag alátámasztja-e, nem szabályozzák a vizsga szerkezetét, és a tananyagot harmadik félhez juttatják. Helyben futó kis modellekkel az adatvédelmi probléma megszűnik, de nem ismert, melyik generálási megoldás ad velük megbízható vizsgát. A fejlesztés alatt álló Mimir rendszerhez ezt mérésekkel kellett eldönteni.

Saját, nyílt kiértékelő keretrendszert építettünk. Ennek 14 konfigurációja egyszerre egy tényezőben tér el: vizsgaterv, kérdésenkénti keresés és forráshivatkozás, ellenőrző lánc, fogalomgráf, hibrid keresés és darabolás. A kérdéseket forrásalapú mutatókkal és egy független, bíróként pontozó nyelvi modellel értékeltük, a konfigurációkat dokumentumszintű páros próbákkal hasonlítottuk össze. Három vizsgálatban, legfeljebb 30 magyar és angol dokumentumon, három fogyasztói GPU-n futó, 4 bites modellel mértünk.

Saját eredményünk a Mimir tervezett generálási módszere, a kiértékelő keretrendszer, a vizsgálatok elvégzése és elemzése, valamint a belőlük hozott döntés. Kimutattuk, hogy a naiv visszakeresés konkrét okból törékeny: a feladatleírást használja lekérdezésként, és rövid, tartalom nélküli darabokat talál meg. A lépésekre bontás gyenge modellnél nélkülözhetetlen (0,28 → 0,67), a Qwen2.5-7B vele a szervermodell teljes dokumentumos promptjának minőségét érte el, az erős Gemma 3 12B-nél pedig a rögzített darabolás önmagában is elég volt. [A témavezető hozzájárulása egy mondatban.]

Fogyasztói GPU-n a vizsgakérdések minőségét elsősorban a választott modell és a visszakeresés lekérdezése határozza meg; a lépésekre bontás gyenge modellnél a minőséget, erős modellnél az ellenőrizhetőséget adja. A rendszerbe ezért a kérdésenkénti forráshivatkozás, a szabályalapú ellenőrzés és a rögzített darabolás kerül. Módszertani tanulság, hogy az ellenőrző és a bíró ítélete véletlenszerűen egyezett, és több csendes hiba, köztük a válaszszivárgás, a valósnál jobbnak mutatta volna az eredményt.

Kulcsszavak: feleletválasztós teszt, kvantálás, adatvédelem, oktatástechnológia, magyar nyelvtechnológia

G. Nyilatkozat a mesterséges intelligencia alapú eszközök használatáról

A 38. OTDK Informatikatudományi Szekció 1. számú melléklete szerint nyilatkozunk a mesterséges intelligencia (MI) alapú eszközök használatáról. Az alábbiakat a tároló verziótörténete alapján rögzítettük; a pirossal jelölt részeket a szerzők pontosítják.

G.1. A kutatás tárgyát képező modellek

A dolgozatban vizsgált nyelvi modellek (Qwen2.5-7B, PULI-LlumiX 8B, Gemma 3 12B, az E2x ellenőrzőjeként a Llama-3.1-8B, valamint a szervermodell) és a bíró (gpt-oss-120b) a kutatás tárgyai, illetve mérőeszközei, nem a dolgozat elkészítésének segédeszközei; szerepüket a 3. és a 4. fejezet írja le. Az általuk generált kérdések a vizsgálatok nyers adatai, a dolgozat szövegébe csak idézett példaként kerültek.

G.2. A dolgozat elkészítéséhez használt eszközök

Eszköz

A Claude (Anthropic) kódolási asszisztens (Claude Code). A tároló commitjainak `Co-Authored-By` sora szerint a Claude Opus 5.5 modell. [Ha más modellváltozat vagy felület (például webes csevegőfelület) is szerepet kapott, itt kell feltüntetni.]

Szoftverfejlesztés

A kiértékelő keretrendszer (`tests/eval`, `tests/new eval`) és az elemző szkriptek (`tdk/elemzes`) fejlesztésében: kódírás, hibakeresés, egységtesztek. A verziótörténet szerint az asszisztens a webes felület, egyes háttérszolgáltatások és az adatvédelmi dokumentáció egyes vázlatainak (például adatfeldolgozói szerződés, érdekmérlegelési teszt) elkészítésében is közreműködött. [A szerzők pontosítják, mely részeket írták saját kezűleg, és hogyan ellenőrizték a generált kódot (kódátnézés, tesztek, kézi futtatás).]

A dolgozat szövege

A dolgozat szövegének megírásában és átdolgozásában: a fejezetek megfogalmazása és szerkesztése, a LaTeX-forrás, a diagramforrások és az ábrákat előállító szkriptek elkészítése. [A szerzők pontosítják, mely fejezeteket és szakaszokat írták saját kezűleg, melyeket fogalmazott meg az asszisztens az ő irányításukkal, és milyen ellenőrzésen ment át a szöveg.]

Mérték

[A használat mértéke fejezetenként vagy összesítve, a szerzők becslése szerint.]

Más eszközök

[Más MI-alapú eszközök, ha voltak (például fordító, helyesírás-ellenőrző, képgenerálás a

felület illusztrációihoz, más csevegő asszisztens), és felhasználásuk módja.]

G.3. Ellenőrzés és felelősség

A dolgozat minden számát egyetlen szkript (`tdk/elemzes/elemzes.py`) állítja elő a vizsgálatok nyers kimeneteiből; a szövegbe a számok ennek kimenetéből (`tdk/elemzes/szamok.md`) kerültek, nem nyelvi modell által írt szövegből. Csak az irodalomjegyzékben felvett forrásokra hivatkozunk. [A szerzők megerősítik, hogy a hivatkozott forrásokat és az MI-vel írt részeket ellenőrizték.] A dolgozat tartalmáért és következtetéseiért a szerzők felelnek. [Hely, dátum, a szerzők aláírása.]

H. Eredménynyilatkozat

A 38. OTDK Informatikatudományi Szekció 1. számú melléklete szerint az alábbiakban elhatároljuk a szerzők saját eredményeit a témavezető és a tágabb kutatócsoport eredményeitől. A szerzők közötti munkamegosztást és a témavezető szerepét a pirossal jelölt helyeken a szerzők töltik ki.

H.1. A szerzők saját eredményei

A rendszer. A MIMIR architektúrájának megtervezése és megvalósítása: a dokumentumfeldolgozást, a darabolást, a generálást és az auditot végző mikroszolgáltatások, a forráshivatkozást megjelenítő webes szerkesztő, az export, az adatvédelmi intézkedések és a GPU-memóriaigény becslése (3. fejezet). [Munkamegosztás a szerzők között.]

A generálási módszer. A vizsgaterv, a kérdéshelyenkénti keresés, a forrásrészletekre hivatkozó egyenkénti generálás, az ellenőrző lánc és a szivárgás elleni szabályok megtervezése és megvalósítása (3. fejezet). [Munkamegosztás a szerzők között.]

A kiértékelő keretrendszer. Az egytényezős konfigurációk, a forrásalapú mutatók (szivárgás, lefedettség, vak megoldhatóság), a bíró bekötése, az oktatói értékelési protokoll és a dokumentumszintű statisztikai elemzés, valamint a 30 dokumentumos adatkészlet összeállítása a két nyílt adatkészletből és a saját szövegekből (4. fejezet). [Munkamegosztás a szerzők között.]

A vizsgálatok és az elemzés. A pilot, az előzetes és a fő vizsgálat megtervezése és futtatása, a nyers kimenetek kézi átolvasása, a mérési hibák (válaszszivárgás, csendes tartalékágak, hiányzó bírói ítéletek) feltárása, valamint az eredmények elemzése és a dolgozat összes számát a nyers kimenetekből előállító elemző szkript (5. és 6. fejezet). [Munkamegosztás a szerzők között.]

A döntés. A mérések alapján hozott döntés arról, mely komponensek kerülnek a rendszerbe, és melyek maradnak ki, GPU-szintenként (7. fejezet).

H.2. A témavezető és a tágabb kutatócsoport hozzájárulása

[A témavezető szerepe (például a téma kijelölése, konzultációk, a dolgozat átnézése, az egyetemi GenAI-szerver hozzáférésének biztosítása).] [A tágabb kutatócsoport vagy más hallgatók hozzájárulása, ha volt; ha nem volt, ennek kimondása.] [Az oktatói értékelésben részt vevő oktatók szerepe (4.7. szakasz).]

H.3. Átvett, nem saját eredmények

Nem saját eredmény a vizsgált nyelvi modellek (Qwen2.5-7B, PULI-LlumiX 8B, Gemma 3 12B, Llama-3.1-8B, gpt-oss-120b, a szervermodell) és a beágyazó modell (multilingual-e5-base); az EduQG és a MILQA adatkészlet, amelyből a 27 nyílt dokumentum és a referenciakérdések származnak; a felhasznált nyílt forrású szoftverek (például az Ollama, a `llama.cpp` és a Qdrant); valamint az egyetemi GenAI-szerver, amelyen a szervermodell és a bíró futott. A kódolási asszisztens használatát a G. függelék írja le.

I. Az adatok forrása és nyilvánossága

Ez a függelék a vizsgálatokban használt dokumentumok, modellek és eredmények forrását, licencét és nyilvánosságát foglalja össze; az adatkészlet összetételét a 4.2. szakasz írja le. A dokumentumok licencét az adatkészlet leírófájljai (`tests/eval/dataset/manifest*.yaml`) is rögzítik.

I.1. táblázat. Az adatok forrása, licence és nyilvánossága. A dokumentumok a fő vizsgálat 30 dokumentuma; az előzetes vizsgálat hat dokumentuma ezek közül való.

Adat	Forrás	Licenc	Nyilvánosság
3 saját magyar szöveg	a szerzők saját szövegei (`tests/TestDocs`)	saját	a tárolóban nyilvános
3 angol tankönyvi szöveg	OpenStax-tankönyvek az EduQG adatkészletből [23]	CC BY 4.0	nyilvános, a forrás megjelölésével
24 magyar szöveg	magyar Wikipédia-cikkek a MILQA adatkészletből [37]	CC BY-SA 4.0	nyilvános, a forrás megjelölésével
referenciakérdések	EduQG és MILQA; a saját szövegekhez saját	a forrás licence	a tárolóban
nyers eredmények (vizsgák, mutatók, bírói ítéletek)	saját futások (E. függelék)	[a tároló MIT-licence alá tartoznak-e]	a tárolóban
oktatói értékelések	részt vevő oktatók	–	[nyilvánosság; az értékelők adatai nélkül]

Az egyetemi GenAI-szerver. A szervermodell és a bíró az egyetem saját infrastruktúráján futott, amely nem nyilvános; a hozzáférés egyetemi kulccsal történik. A kiértékelés során így a dokumentumok nem kerültek külső szolgáltatóhoz, a két modell pontos változata viszont kívülről nem reprodukálható. A bírói válaszok a futáskönyvtárak `judge_cache.jsonl` fájljaiban megmaradtak, ezért az újrapontozás és az elemzés a szerver nélkül is megismételhető.

Kód és eredmények. A Mimir, a kiértékelő keretrendszer és az elemző szkriptek MIT-licenc alatt érhetők el [a nyilvános tároló címe]. A nyers eredmények helyét és a reprodukálás lépéseit az E. függelék adja meg.

I.2. táblázat. A vizsgálatokban használt modellek. A helyi modellek 4 bites (Q4_K_M) kvantálással futottak az Ollamán; a licenceket a modellkártyák alapján még ellenőrizni kell.

Modell	Szerep	Forrás	Licenc
Qwen2.5-7B	generátor (pilot, előzetes vizsgálat)	[56]; `qwen2.5:7b`	[várhatóan Apache 2.0]
PULI-LlumiX 8B	generátor (fő vizsgálat)	[59]; `hf.co/mradermacher/PULI-LlumiX-Llama-3.1-GGUF`	[várhatóan Llama 3.1 Community License]
Gemma 3 12B	generátor (fő vizsgálat)	[58]; `gemma3:12b`	[várhatóan Gemma Terms of Use]
Llama-3.1-8B	az E2x ellenőrzője	[57]; `llama3.1:8b`	[várhatóan Llama 3.1 Community License]
gpt-oss-120b	bíró	[69]; egyetemi GenAI-szerver	[várhatóan Apache 2.0]
szervermodell	B-doc-S, E4, E4b	egyetemi GenAI-szerver (`qwen38udq8xl`)	[a pontos modell és licence]
multilingual-e5-base	beágyazás (darabolás, keresés, duplikátumszűrés)	[35]; `intfloat/multilingual-e5-base`	[várhatóan MIT]