ÓBUDAI EGYETEM

Neumann János Informatikai Kar

TUDOMÁNYOS DIÁKKÖRI DOLGOZAT

Vizsgakérdés-generálás helyben futtatható nyelvi modellekkel

A Mimir tervezésvezérelt, forráshivatkozásos RAG-módszere és kísérleti kiértékelése

Szerzők:

Nagy István Bence
BSc III. évfolyam

Hindulák Bálint
BSc III. évfolyam

Szegedi Achilles Károly
BSc I. évfolyam

Konzulens:

Hartveg Ádám
doktorandusz

Budapest, 2026

64. Tudományos Diákköri Konferencia – 2026. őszi félév

Tartalmi összefoglaló

A TDK dolgozat fő témája a vizsgakérdések nagy nyelvi modellekre (LLM) épülő, automatikus előállítása és ellenőrzése. A jelenlegi gyakorlatban az oktatók a tananyagot felhőalapú csevegőasszisztensekbe töltik fel, ez a megoldás azonban nem védi ki a modell hallucinációit, nem szabályozza a vizsga szerkezetét, a tananyagot pedig egy harmadik félnek szolgáltatja ki. A dolgozat részletesen ismerteti a Mimir rendszert, amely az egyetlen kérést visszakereséssel kiegészített generálásra (RAG) épülő, ellenőrizhető lépésekre bontott módszerrel váltja fel, és fogyasztói GPU-n helyben futtatható, kvantált kis nyelvi modellekkel működik.

A mikroszolgáltatás-alapú rendszer feleletválasztós, igaz–hamis és kifejtős kérdéseket egyaránt előállít, a feltöltött tartalmat a GDPR adatminimalizálási elvének megfelelően csak a feladat idejére tárolja, a végső döntést pedig az oktatóra bízza (*human-in-the-loop*). A kidolgozott algoritmus szemantikus darabolás után vizsgatervet készít a kérdések típusáról, témájáról és kognitív (Bloom-féle) szintjéről, majd kérdésenként vektoros vagy hibrid keresést végez, forráshivatkozással ellátott kérdéseket generál, végül egy ellenőrző lánccal vizsgálja, hogy a forrás alátámasztja-e a helyes választ, és hogy a helytelen válaszlehetőségek (disztraktorok) valóban hibásak-e.

A dolgozat bemutatja a kiértékelési módszertant is, amely kísérleti konfigurációkat hasonlít össze magyar és angol nyelvű dokumentumokon, egy független, bíróként működő nyelvi modell (*LLM-as-a-judge*) és dokumentumszintű statisztika segítségével. A kísérleti kiértékelés számszerűsíti a vizsgatervezés és a többlépcsős ellenőrzés hatását a kérdések forráshűségére és szerkezeti megfelelőségére, összevetve az eredményeket a naiv RAG-megközelítéssel és nagy, szerveroldali referenciamodellekkel. A befejező rész összegzi és értékeli az eredményeket, feltárja a mérés korlátait, valamint kijelöli a további kutatási és fejlesztési irányokat.

Kulcsszavak: automatikus kérdésgenerálás, visszakereséssel kiegészített generálás (RAG), kis nyelvi modellek, ellenőrzés, nyelvi modell mint bíró, adatvédelem, oktatástechnológia, magyar nyelv

Tartalomjegyzék

Tartalmi összefoglaló ii

Tartalomjegyzék iii

Rövidítések és fogalmak vi

1. Bevezetés 1
1.1. Motiváció . . . 1
1.2. Problémafelvetés . . . 1
1.3. A kutatás célja és megközelítése . . . 2
1.4. Kutatási kérdések és hipotézisek . . . 2
1.5. Hozzájárulások . . . 3
1.6. A dolgozat felépítése . . . 3

2. Szakirodalmi áttekintés 4
2.1. A jó feleletválasztós kérdés és a Bloom-taxonómia . . . 4
2.2. Automatikus kérdésgenerálás: a szabályoktól a nagy nyelvi modellekig . . . 5
2.3. Nagy nyelvi modellek röviden . . . 6
2.4. Visszakereséssel kiegészített generálás . . . 7
2.5. Feladatfelbontás és ellenőrzés . . . 8
2.6. Kis nyelvi modellek helyi futtatása . . . 9
2.7. A kiértékelés: nyelvi modell mint bíró és a mérés megbízhatósága . . . 10
2.8. A magyar nyelv és a hazai előzmények . . . 11
2.9. Jogi keret: adatvédelem és MI-rendelet . . . 12
2.10. Összegzés és a kutatási rés . . . 13

3. A javasolt generálási módszer 15
3.1. Tervezési elvek . . . 15
3.2. Helyi futtatás és adatkezelés . . . 15
3.3. A GPU-memória becslése . . . 16
3.4. A generálási módszer áttekintése . . . 16
3.4.1. Szemantikus darabolás . . . 17
3.4.2. Indexelés és az alapvonalak . . . 17
3.4.3. A vizsgaterv . . . 18
3.4.4. Kérdéshelyenkénti keresés . . . 18
3.4.5. Forráshoz kötött kérdésgenerálás . . . 18
3.4.6. Az ellenőrző lánc . . . 19
3.4.7. Munkamenet-hatókörű fogalomgráf . . . 20
3.4.8. Összeállítás és emberi felügyelet . . . 20

4. Kísérleti módszertan 21
4.1. A tesztelés menete . . . 21
4.2. Adatkészlet . . . 22
4.3. A kísérleti konfigurációk . . . 22
4.4. A három vizsgálat . . . 24
4.5. Mutatók . . . 25

4.6. A bíró . . . 26
4.7. Oktatói értékelés . . . 27
4.8. Statisztikai elemzés . . . 27

5. Eredmények: a módszer komponensei **29**
5.1. A pilot tanulságai . . . 29
5.2. Az előzetes vizsgálat: a módszer egy 7B modellel . . . 29
5.3. A fő vizsgálat: összesített eredmények . . . 30
5.4. A komponensek hatása . . . 32
5.5. Darabolás és robusztusság . . . 33
5.6. Az ellenőrző működése . . . 35
5.7. Lefedettség, kognitív szint és felhasználhatóság . . . 35
5.8. Költség: relatív szorzók . . . 36
5.9. A mérés megbízhatósága . . . 36
5.10. Az oktatói értékelés . . . 37
5.11. A fejezet tanulsága . . . 39

6. Eredmények: a generátormodellek **40**
6.1. A három helyi modell azonos dokumentumokon . . . 40
6.2. A szervermodell és a helyi modellek . . . 40
6.3. Miért bukik el a PULI-LlumiX? . . . 42
6.4. Memóriaigény és futási idő . . . 43
6.5. Modellválasztási tanulság . . . 44

7. Az eredmények értékelése **45**
7.1. A hipotézisek értékelése . . . 45
7.2. Összevetés az irodalommal . . . 46
7.3. Mikor éri meg a módszer? . . . 48
7.4. Gyakorlati következmények . . . 48
7.5. Mit tanultunk az ellenőrzésről és a mérésről? . . . 49
7.6. Az érvényességet veszélyeztető tényezők . . . 50
7.7. Etikai és jogi szempontok . . . 50

8. Összefoglalás és további munka **51**
8.1. Összefoglalás . . . 51
8.2. További munka . . . 52

Irodalomjegyzék **53**

Ábrajegyzék **60**

Táblázatjegyzék **61**

A A módszer és a kiértékelés részletei **62**
A.1. A GPU-memória becslése . . . 62
A.2. A generálási módszer részletei . . . 62
A.3. A mérés részletei . . . 63

B Kiegészítő eredmények **66**
B.1. A pilot részletei 66
B.2. Az előzetes vizsgálat helyi konfigurációi 66
B.3. Az ellenőrző lánc részletei 66
B.4. Lefedettség, kognitív szint és felhasználhatóság 66
B.5. A bírói ítéletek lefedettsége 68

C A generátor promptja **69**

D A bíró és az oktatók rubrikája **70**

E A generálási folyamat paraméterei **71**

Rövidítések és fogalmak

BM25	szógyakoriságon alapuló lexikális rangsoroló függvény
GDPR	*General Data Protection Regulation*, általános adatvédelmi rendelet, (EU) 2016/679
GGUF, Q4_K_M	a `llama.cpp` kvantált modellformátuma, illetve annak kb. 4,8 bit/súly változata
GPU	grafikus feldolgozóegység
Infotv.	az információs önrendelkezési jogról és az információszabadságról szóló 2011. évi CXII. törvény
KI	konfidenciaintervallum (a táblázatokban: 95 % KI)
KV-gyorsítótár	a szövegelőállítás közben tárolt kulcs- és értékvektorok
LLM	*Large Language Model*, nagy nyelvi modell
MCQ	*Multiple-Choice Question*, feleletválasztós kérdés
MI	mesterséges intelligencia
MI-rendelet	a mesterséges intelligenciáról szóló (EU) 2024/1689 rendelet
NAIH	Nemzeti Adatvédelmi és Információszabadság Hatóság
RAG	*Retrieval-Augmented Generation*, visszakereséssel kiegészített generálás
RRF	*Reciprocal Rank Fusion*, reciprok rangfúzió
bíró	a kérdéseket pontozó, a generátoroktól független nyelvi modell (gpt-oss-120b)
darab	a dokumentum egy összefüggő, néhány mondatos részlete, a keresés egysége
disztraktor	a feleletválasztós kérdés helytelen, de hihető válaszlehetősége
ellenőrző	a Mimir módszer ellenőrző lépése, amely a generált kérdést elfogadja vagy visszadobja
kérdéshely	a vizsgaterv egy pontja (fogalom, típus, Bloom-szint), amelyből egy kérdés készül
konfiguráció	a kísérlet egy beállítása (**E0**, **E1**, . . .), amely a referenciájától egy tényezőben tér el
kulcs	a feleletválasztós kérdés megjelölt helyes válasza
naiv RAG	alapvonal (**E0**): a feladatleírással visszakeresett három darab és a kérés egy promptban
szivárgás	a kulcs szinte szó szerint szerepel a kérdés törzsében
teljes dokumentumos prompt	a teljes dokumentum és a kérés egy promptban (**B-doc-L** helyben, **B-doc-S** a szervermodellel)
vizsgaterv	a vizsga előre rögzített szerkezete kérdéshelyenként
P1–**P4**	a közvetlen kérdésgenerálás négy alapvető problémája (1.2. szakasz): **P1** a kulcs és a disztraktorok ellenőrizetlensége, **P2** a szerkezet és a lefedettség kontrollálatlansága, **P3** az adatvédelmi kockázat, **P4** a nagy, távoli modellektől való függés
F, G, A, V	formai megfelelés, alátámasztottság, vak megoldhatóság, disztraktor-validitás
Q	minőségi index, $(F + G + A + V)/4$
κ, α	Cohen-féle egyezési, illetve Krippendorff-féle megbízhatósági együttható
r_{rb}, $\tilde{p}$	rangbiszeriális hatásméret, illetve Holm-korrigált p-érték

Kísérleti konfigurációk (tesztesetek)

Az alábbi áttekintés a dolgozatban vizsgált 14 kísérleti konfigurációt (tesztesetet) foglalja össze. A konfigurációk jelölésére kattintva közvetlenül az összefoglaló táblázatra ugorhatunk.

Konfig.	A teszteset jelentése és beállítása	Részletes leírás
B-doc-L	Teljes dokumentumos alapvonal helyi modellel (≤ ≤ 30 000 karakter, 16 384 tokenes kontextus)	4.1. táblázat, 3.4.2. szakasz
B-doc-S	Teljes dokumentumos alapvonal a szervermodellel (≤ ≤ 80 000 karakter)	4.1. táblázat, 3.4.2. szakasz
E0	Naiv RAG alapvonal: szemantikus darabolás, a kéréshez legközelebbi 3 darab, a teljes vizsga egyetlen hívásban	4.1. táblázat, 3.4.2. szakasz
E1	Tervezésvezérelt generálás: explicit vizsgaterv, kérdéshelyenkénti keresés és forráshoz kötött generálás, ellenőrzés nélkül	4.1. táblázat, 3.4.3–3.4.5. szakasz
E2	A teljes Mimir módszer: **E1** + többlépcsős ellenőrző lánc visszacsatolással	4.1. táblázat, 3.4.6. szakasz
E2f	Abláció vak próba nélkül: **E2** a vak megoldási ellenőrző lépés elhagyásával	4.1. táblázat, 3.4.6. szakasz
E2h	Hibrid kereséses abláció: **E2** BM25 és sűrű vektoros keresés RRF-rangfúziójával	4.1. táblázat, 3.4.4. szakasz
E2x	Keresztellenőrzéses abláció: **E2**, amelyben az ellenőrzést egy másik helyi modell (Llama-3.1-8B) végzi	4.1. táblázat, 3.4.6. szakasz
E3	Fogalomgráfos változat: **E2** + munkamenet-hatókörű fogalomgráf a tervezéshez és a disztraktorokhoz	4.1. táblázat, 3.4.7. szakasz
E4	Szerveroldali naiv RAG: az **E0** konfiguráció a nagy szervermodellel futtatva	4.1. táblázat, 4.3. szakasz
E4b	Szerveroldali teljes módszer: az **E2** konfiguráció a nagy szervermodellel futtatva	4.1. táblázat, 4.3. szakasz
E5a	Darabolási abláció (régi kódoló): **E0** az 512 tokenre csonkolt kódolóval	4.1. táblázat, 3.4.1. szakasz
E5b	Darabolási abláció (magasabb küszöb): **E0** átlag + 1,5 szórásos szemantikus vágási küszöbbel	4.1. táblázat, 3.4.1. szakasz
E5c	Darabolási abláció (rögzített ablak): **E0** rögzített, 800 karakteres darabokkal	4.1. táblázat, 3.4.1. szakasz

1. Bevezetés

Ez a fejezet a problémát, a kutatás célját és a javasolt megközelítést, a kutatási kérdéseket, a hipotéziseket és a hozzájárulásokat mutatja be.

1.1. Motiváció

A feleletválasztós kérdés (*multiple-choice question*, MCQ) gépi úton javítható és nagy létszámú kurzusokon is skálázható, előállítása azonban drága: egy jó kérdés törzse önmagában is érthető, pontosan egy válaszlehetősége helyes a tananyag szerint, a helytelen válaszok (*disztraktorok*) pedig hihetők, de igazolhatóan hibásak [1, 2]. A nagy nyelvi modellek (*large language model*, LLM) óta a legelterjedtebb megoldás, hogy az oktató egy felhőben futó csevegőasszisztenstől kér kérdéseket a jegyzetéből. A modellek képesek kérdéseket és disztraktorokat fogalmazni [3], de hajlamosak a forrás által nem alátámasztott állításokra [4]. Ezt a munkafolyamatot a továbbiakban *közvetlen megközelítésnek* nevezzük.

1.2. Problémafelvetés

A közvetlen megközelítés kényelmes, de az oktatási alkalmazás szempontjából négy gyengesége van.

(P1) **A helyesség nincs ellenőrizve.** Semmi sem garantálja, hogy a megjelölt helyes választ (a *kulcsot*) a dokumentum alátámasztja, és hogy a disztraktorok valóban hamisak; az önellenőrzés ezt csökkentheti, de nem szünteti meg [5].

(P2) **A szerkezet és a lefedettség nincs kontrollálva.** A kért darabszám, típus és nehézség csak kérés a promptban, és a hosszú bemenetet a modellek egyenetlenül használják [6], így a kérdések a dokumentum néhány részére tömörülhetnek.

(P3) **Adatvédelem.** A tananyag személyes adatot is tartalmazhat; a felhőszolgáltató az adatkezelés címzettjévé válik [7], és az intézmény elveszíti a kontrollt a tartalom felett.

(P4) **Függés a nagy, távoli modellektől.** A teljes dokumentum egyetlen promptban hosszú kontextust és nagy modellt igényel, a saját, fogyasztói hardveren futtatható kis modellek kontextusa és memóriája viszont korlátos.

A **P1** és a **P2** a *módszer* hiányából fakad: ha a vizsga szerkezete, a kérdések forrása és az ellenőrzés nem önálló lépések, sem mérni, sem kikényszeríteni nem lehet őket. A **P3** és a **P4** egymást erősíti: a helyi futtatás megoldaná az adatvédelmi problémát, de a kis modellek éppen a hosszú, egylépéses feladatban a leggyengébbek. Kiinduló gondolatunk ezért az, hogy rövid, egyenként ellenőrizhető lépésekre bontva egy fogyasztói grafikus kártyán (GPU) futó kis modell is megbízható vizsgát állíthat elő.

1.3. A kutatás célja és megközelítése

A dolgozat ezt a gondolatot vizsgálja. Javaslunk egy lépésekre bontott generálási módszert (Mimir: vizsgaterv, kérdéshelyenkénti keresés, forráshoz kötött generálás és ellenőrző lánc), amelyet kutatási prototípusként, egy saját, nyílt kiértékelő keretrendszerben valósítottunk meg. A keretrendszerben a módszer minden lépése külön be- és kikapcsolható, így a lépések hatása egyenként mérhető, és összevethető két alapvonallal: a naiv visszakereséses generálással (*naiv RAG*, **E0**), amelyben a modell a feladatleírással visszakeresett három dokumentumrészletet (darabot) kapja egy promptban, és a teljes dokumentumos prompttal. A kísérletekből azt is levezetjük, melyik konfiguráció ajánlott a 8- és a 12 GB-os GPU-szinten. A mérések a kiinduló gondolatot pontosították; a dolgozat fő állítása:

> *Fogyasztói GPU-n futó kis modellekkel a vizsgakérdések minőségét elsősorban a választott modell és a visszakeresés lekérdezése határozza meg; a feladat lépésekre bontása gyenge modellnél nélkülözhetetlen, erős modellnél pedig az ellenőrizhetőséget adja. Ezt egy saját, nyílt kiértékelő keretrendszerrel, 30 dokumentumon és három modellen mértük, és ebből vezettük le a mérések alapján ajánlott konfigurációt.*

1.4. Kutatási kérdések és hipotézisek

RQ1 A strukturált generálás – tervezés, kérdésenkénti forráshoz kötés és ellenőrzés – érvényesebb és jobban lefedő vizsgát ad-e, mint ha a modellnek a dokumentumot (vagy annak visszakeresett részleteit) egyetlen promptban adjuk át?

RQ2 Mennyivel járulnak hozzá a minőséghez az egyes komponensek (tervező, ellenőrző, fogalomgráf, hibrid keresés, darabolás), és mennyibe kerülnek futási időben és modellhívásban?

RQ3 Mennyire közelíti meg egy fogyasztói GPU-n (8–12 GB) futó, 4 bitre kvantált kis modell egy nagy, szerveren futó modell teljesítményét, és hogyan függ az eredmény a választott helyi modelltől?

A hipotéziseket a 7.1. szakasz értékeli; a konfigurációk (**E0**, **E1**, . . .) a kísérlet egy-egy beállítását jelölik (4.3. szakasz).

1. Hipotézis (Tervezés)**.** Azonos generátormodell mellett a vizsgaterv (**E1**) a naiv visszakereséses alapvonalhoz (**E0**: szemantikus darabolás, a teljes vizsgához három visszakeresett darab) képest növeli a kérdések alátámasztottságát és a vizsga lefedettségét, a formai megfelelés romlása nélkül.

2. Hipotézis (Ellenőrzés)**.** Az ellenőrző lánc (**E2**) a tervezéshez (**E1**) képest tovább növeli az alátámasztottságot és a vak megoldhatóságot; az ellenőrző ítélete pozitívan egyezik a független bíró ítéletével ($\kappa > 0$).

3. Hipotézis (Lefedettség)**.** A teljes dokumentumot egyetlen promptban kapó alapvonal lefedettsége – modellmérettől függetlenül – alacsonyabb, mint a tervezett változatoké.

4. Hipotézis (Helyi vs. szerver)**.** A helyi kis modell a tervezett és ellenőrzött folyamatban a szervermodell naiv változatának minőségi indexét megközelíti (különbség $< 0{,}1$), miközben fogyasztói GPU-n fut.

5. Hipotézis (Mérés)**.** A generátoroktól eltérő modellcsaládba tartozó nyelvi modell (bíró) ítéletei az oktatói értékelésekkel legalább elfogadható megbízhatósággal egyeznek (Krippendorff-$\alpha \geq$ $\geq 0{,}667$).

1.5. Hozzájárulások

(1) **Generálási módszer:** vizsgaterv Bloom-szintekkel, kérdéshelyenkénti keresés, forráshoz kötött generálás és szivárgásszűrő ellenőrző lánc (3. fejezet).
(2) **Nyílt kiértékelő keretrendszer:** 14 egytényezős konfiguráció, forrásalapú mutatók, független bíró és dokumentumszintű statisztika (4. fejezet).
(3) **Empirikus eredmények:** a naiv RAG törékenységének oka, a komponensek hatása és a módszer haszna három helyi modellen (5. és 6. fejezet).
(4) **Mérési tanulságok:** válaszszivárgás, csendes tartalékágak, az ellenőrző és a bíró véletlenszerű egyezése, forrásfüggően hiányzó bírói ítéletek (5. fejezet).

1.6. A dolgozat felépítése

A 2. fejezet a hazai és nemzetközi irodalmat és a jogi keretet tekinti át, és megfogalmazza a kutatási rést. A 3. fejezet a javasolt generálási módszert, a 4. fejezet a kísérleti módszertant mutatja be. Az 5. fejezet a módszer komponenseinek hatását, a 6. fejezet a generátormodelleket értékeli. A 7. fejezet az eredményeket a hipotézisek és az irodalom fényében értékeli, és levezeti a gyakorlati következményeket; a 8. fejezet összefoglal. A függelék a módszer és az eredmények részleteit (A. és B. függelék), a generátor promptját, a rubrikát és a generálási folyamat paramétereit tartalmazza.

2. Szakirodalmi áttekintés

Ebből a fejezetből az olvasó megtudja, mit vár el a szakirodalom egy jó feleletválasztós kérdéstől, mely megközelítések próbálták eddig gépi úton előállítani, és ezek mit oldanak meg a bevezetés négy problémájából: a kulcs helyességéből (**P1**), a vizsga szerkezetéből és lefedettségéből (**P2**), az adatvédelemből (**P3**) és a nagy, távoli modellektől való függésből (**P4**). A módszertani irodalom után a hazai előzmények, a jogi keret és a kutatási rés összevetése következik.

2.1. A jó feleletválasztós kérdés és a Bloom-taxonómia

A feleletválasztós kérdés (*multiple-choice question*, MCQ) három részből áll: a *törzsből* (a kérdés vagy a befejezendő állítás), a *kulcsból* (a helyes válasz) és a *disztraktorokból* (a helytelen, de hihető válaszlehetőségek). Gépileg, gyorsan és objektíven javítható, jó kérdést írni viszont nehéz.

A kérdésírás szabályait Haladyna, Downing és Rodriguez [1] foglalta össze 31 irányelvben, amelyek három fő követelmény köré rendeződnek:

– egy kérdés egyetlen, fontos tanulási célt mérjen;
– a törzs önmagában is érthető legyen, és kerülje a tagadást;
– a helytelen opciók legyenek hihetők, egymást kizárók, és formailag ne különbözzenek feltűnően a kulcstól, nehogy „árulkodó jelet” adjanak.

Hogy ezek nem esztétikai kérdések, azt Downing [8] egy orvosi vizsgán mutatta meg: a szabálysértő kérdések miatt a hallgatók 10–15 %-a került a „nem felelt meg” kategóriába, akik a hibás kérdések nélkül átmentek volna. Ez adja a **P1** tartalmát: a helyes kérdéshez igaz kulcs, hamis, de hihető disztraktorok és árulkodó jel nélküli törzs kell, és ennek betartását egy gépi rendszernél mérni kell.

A disztraktorok számáról Rodriguez [9] metaanalízise azt találta, hogy a legtöbb esetben három opció is elegendő, mert a negyedik és ötödik ritkán „működik”. Tarrant és munkatársai [10] szerint a disztraktorok jelentős része *nem funkcionáló* (a hallgatók kevesebb mint 5 %-a választja), Gierl és munkatársai [2] szerint pedig az ilyen disztraktor gyakorlatilag csökkenti az opciók számát, és növeli a találgatással elérhető pontszámot. Mi a megszokott négyopciós formát követjük, de a disztraktorok *minőségét* külön mutatóval mérjük (4.5. szakasz).

A kognitív szintek leírására Bloom taxonómiáját használjuk Anderson és Krathwohl átdolgozott változatában [11]: *emlékezés*, *megértés*, *alkalmazás*, *elemzés*, *értékelés* és *alkotás*; feleletválasztós kérdéssel az első öt mérhető. Scully [12] szerint magasabb rendű gondolkodás is mérhető így, ha a törzs új helyzetet ír le, a gyakorlatban mégis a tényfelidéző kérdések dominálnak, mert ezeket a legkönnyebb megírni. Ugyanez várható egy nyelvi modelltől is, ezért a javasolt módszer a kért nehézséghez rögzített Bloom-szint-eloszlást rendel, és azt kérdésenként kiosztja (3.4.3. szakasz); a lefedettség (**P2**) így a témák mellett a kognitív szintekre is vonatkozik.

A kézi kérdésírás munkaigényét a hazai tudásmérés is mutatja: a szegedi eDia online

diagnosztikus rendszer [13] több mint 25 000 feladatát képzett feladatírók készítik, több lépcsőben lektorálják, majd hallgatói mintán kipróbálják. Ehhez képest egy gépi rendszer *vázlatot* adhat: a lektorálást az oktatói jóváhagyás pótolhatja, a kipróbálást nem, mert a klasszikus *tételelemzés* (nehézség, megkülönböztető erő) valódi hallgatói válaszokat igényel; ez a további munka része (8. fejezet).

2.2. Automatikus kérdésgenerálás: a szabályoktól a nagy nyelvi modellekig

Az automatikus kérdésgenerálás (*automatic question generation*, AQG) több évtizedes terület; Kurdi és munkatársai [3] szisztematikus áttekintése 93 oktatási célú rendszert elemzett. A fejlődésben három generáció különíthető el, és mindegyik másképp viszonyul a **P1**–**P4** problémákhoz.

Szabály- és sablonalapú rendszerek. Az első generáció a szöveget nyelvtanilag elemzi, és transzformációs szabályokkal alakítja kérdéssé. Mitkov és Ha rendszere [14] a fontos főnévi csoportokat választja kulcsnak, és egy lexikai adatbázis rokon fogalmait ajánlja disztraktornak; Heilman és Smith [15] a *túlgenerálás és rangsorolás* elvét vezette be. Hazai példa a Miskolci Egyetem rendszere [16], amely Python-programrészletekből ontológia segítségével ír kérdéseket. Ezek a rendszerek helyben futnak, és a kulcs a forrásból származik, így a **P1**-et részben, a **P3**-at és a **P4**-et teljesen megoldják. A kérdések viszont merevek, többnyire mondat-átfogalmazások, a vizsga szerkezetéről (**P2**) nem döntenek, és minden nyelvhez külön szabályrendszer kell – a toldalékoló magyarhoz különösen sok.

Neurális rendszerek. A második generációt a nagy, kézzel annotált adatkészletek, például a több mint százezer kérdés–válasz párt tartalmazó SQuAD [17] tették lehetővé. Du és munkatársai [18] ezeken tanítottak kódoló–dekódoló hálózatot, amely a bekezdésből és a kiválasztott válaszból állítja elő a kérdést. A kérdések folyékonyabbak, de semmi sem garantálja, hogy a forrásból megválaszolhatók: a **P1** romlik, mert a törzs és a kulcs kapcsolata tanult valószínűségből adódik. A *disztraktorgenerálás* módszereit Alhazmi és munkatársai [19] vetik össze: a generatív módszerek adják a legtermészetesebb disztraktorokat, de gyakori hibájuk, hogy egy disztraktor valójában szintén helyes, vagy nyilvánvalóan abszurd – pontosan ezt a két hibát vizsgálja disztraktoronként az ellenőrzőnk és a bíró.

Nagy nyelvi modellek. A harmadik generációban egy nagy nyelvi modell írja a kérdést utasítás alapján. Wang és munkatársai [20] GPT-3-mal generált tankönyvi kérdéseinek egy része emberi értékelés szerint az ember által írtakkal összemérhető volt. Doughty és munkatársai [21] programozási kurzusokon 651 GPT-4-es és 449 oktatói kérdést vetettek össze hatszempontos rubrikával: a gépi kérdések 81,7 %-a minden szempontnak megfelelt, de 4,9 %-ukban több helyes válasz is volt (az oktatóiaknál 1,1 %), 4,0 %-ukban pedig egy nyilvánvalóan hibás disztraktor elárulta a kulcsot (0,9 %). Bitew és munkatársai [22] jóváhagyott példakérdésekkel javították a disztraktorokat; ugyanez a csoport készítette az OpenStax-tankönyvekhez írt EduQG

adatkészletet [23], amelynek angol dokumentumait mi is használjuk. Fawzi és munkatársai [24] szerint egy kis modell oktatási szövegeken végzett további tanítással a nagy modellekhez mérhető kérdéseket írhat.

Mit oldanak meg, és mit nem? A harmadik generáció a nyelvi minőséget megoldotta, a **P1**-et azonban csak statisztikailag javítja: a hibák aránya kicsi, de nem nulla, és a hibás kérdést semmi sem jelöli meg. A **P2**-t a munkák nem vizsgálják, mert egyenként kérnek kérdést, a vizsgát ember állítja össze. A **P3**-at és a **P4**-et a felhőben futó nagy modellek előidézik; Fawzi és munkatársai kis modellje kivétel, de minden új tárgynál további tanítást igényel. A kész kérdéseket utólag, emberi értékeléssel mérik; arra, hogy a generálás *folyamata* hogyan biztosíthatja a helyességet és a lefedettséget, kevés figyelem jut. Munkánk ezen a ponton kíván hozzájárulni.

A kiértékelés problémája. Mulla és Gharpure [25] szerint a rendszerek jelentős részét a referenciával való átfedésen alapuló metrikákkal (BLEU, ROUGE) mérik, amelyek a generált és egy ember írta kérdés közös szavait számolják. Egy vizsgakérdés azonban egyező szó nélkül is lehet kiváló, hibás kulccsal pedig használhatatlan; Kurdi és munkatársai [3] szerint a humán értékelések is kis mintán készülnek, és ritkán ellenőrzik a kulcsot. Mi ezért a helyességet a forrással szembeni ítéletekkel mérjük (4. fejezet).

2.3. Nagy nyelvi modellek röviden

A mai nyelvi modellek a transzformer-architektúrára [26] épülnek, és a szöveget *tokenekre* (szódarabokra) bontva dolgozzák fel. A *kódoló* modellek (például a BERT [27]) a szöveg jelentését egy vektorba (*beágyazásba*) sűrítik, és keresésre használják őket; a *dekódoló*, generatív modellek (például a GPT-család [28]) tokenenként írnak, csevegő változataikat utasításkövetésre is hangolják [29]. A toldalékoló magyar szavak több tokenre bomlanak, mint az angolok, így ugyanaz a tartalom magyarul több helyet foglal a modell bemenetében (*kontextusában*). Két szöveg hasonlóságát a beágyazásaik koszinuszával mérjük:

$$\cos(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \, \|\mathbf{v}\|}, \tag{2.1}$$

amelynek értéke 1, ha a két vektor azonos irányú; a darabolás, a keresés, a duplikátumszűrés és a lefedettség mérése is erre épül.

Hallucináció. A nyelvi modellek legfontosabb gyengesége a *hallucináció*: folyékony, magabiztos, de a forrással vagy a valósággal ellentétes szöveg. Ji és munkatársai [4] szerint az *intrinzikus* hallucináció ellentmond a forrásnak (a forrás szerint a kávé a 17. században jutott el Európába, a modell a 9. századot írja), az *extrinzikus* pedig a forrásból sem igazolni, sem cáfolni nem lehet. A kérdésgenerálásban mindkettő súlyos: az első a felkészült hallgatótól vesz el pontot, a második a tananyagból megválaszolhatatlan kérdést ad. Mivel a hallucináció a valószínűségi szövegelőállítás következménye, a kulcs helyességét a forrásból kell eldönteni, nem a modell magabiztosságából;

ezért legfontosabb mutatónk az *alátámasztottság*, vagyis hogy a forrás igazolja-e a kulcsot.

Strukturált kimenet. A generátornak gépileg feldolgozható JSON-t kell adnia, de egy kis modell időnként hibásat ír. Ezt utólagos ellenőrzéssel és újrakéréssel, vagy *korlátozott dekódolással* lehet kezelni, amely csak a formátumnak megfelelő tokeneket engedi meg [30]; mi az előbbit alkalmazzuk, a formai hibát az ellenőrző első lépése szűri.

2.4. Visszakereséssel kiegészített generálás

A hallucináció elleni első stratégia, hogy a modell ne csak a paramétereiben tárolt tudásra támaszkodjon. A visszakereséssel kiegészített generálás (*retrieval-augmented generation*, RAG) során a rendszer releváns szövegrészleteket keres, és ezeket a promptba téve kéri a választ; a nevet Lewis és munkatársai [31] vezették be. Gao és munkatársai [32] három paradigmát különítenek el:

– a *naiv RAG* egyetlen keresést és generálást végez;
– a *fejlett RAG* a keresés előtt és után is javít (lekérdezés-átírás, újrarangsorolás);
– a *moduláris RAG* a keresési, generálási és ellenőrzési lépéseket szabadon kombinálja.

A javasolt generálási folyamat ebben a szóhasználatban moduláris RAG: a keresés a vizsgaterv minden pontjára külön fut, és az ellenőrzés visszahat rá.

Lexikális és sűrű keresés. A *lexikális* keresés legismertebb képviselője, a BM25 [33] azokat a részleteket rangsorolja előre, amelyekben a lekérdezés szavai gyakoriak, de a gyűjteményben ritkák. Gyors, tanítást nem igényel, jól kezeli a szakkifejezéseket és tulajdonneveket, a szinonimákat és a magyar ragozott alakokat viszont nem ismeri fel. A *sűrű* keresés a szövegeket közös vektortérbe képezi, és (2.1) szerint méri a hasonlóságot; a DPR [34] szerint ez a nyílt kérdésmegválaszolásban felülmúlhatja a BM25-öt. Az általunk használt többnyelvű E5 modell [35] kontrasztív tanítással készült, és a magyart is támogatja. Egyik módszer sem a legjobb minden adatkészleten [36], és magyarra sem egyértelmű a sűrű keresés előnye: a MILQA kérdés–válasz adatbázison a BM25 jobb visszakeresést adott a vizsgált vektoros megoldásoknál [37]. Ezért gyakori a *hibrid* keresés, amely a két rangsort reciprok rangfúzióval (RRF) [38] egyesíti; ezt az **E2h** konfiguráció vizsgálja (4.3. szakasz).

Lekérdezés-átírás. A keresés minősége a lekérdezésen is múlik. A HyDE [39] egy nyelvi modellel előbb „hipotetikus” választ írat, és annak beágyazásával keres, mert az jobban hasonlít a keresett szövegre, mint maga a kérdés. Vizsgagenerálásban ez kulcskérdés: a naiv RAG lekérdezése egy *feladatleírás* („10 feleletválasztós kérdés, könnyű”), amely semmit sem mond a keresett tartalomról. A vizsgaterv a tervező által javasolt tartalmi fogalmakkal keres, ami lényegében lekérdezés-átírás; eredményeink szerint ez a különbség áll a naiv RAG leggyakoribb kudarca mögött (5. fejezet).

Darabolás. A keresés egysége a *darab*. A rögzített hosszúságú ablak mondatok közepén is vághat; a *szemantikus* darabolás ott vág, ahol a szomszédos mondatok hasonlósága hirtelen

lecsökken. Qu, Tu és Bao [40] szerint ennek előnye adatkészletfüggő és gyakran kisebb a vártnál, ezért a darabolást külön konfigurációkkal (**E5a**–**E5c**) vizsgáljuk (3.4.1. szakasz). Eredményeink szerint a szemantikus darabolás rövid, tartalom nélküli darabokat is létrehozhat, amelyekhez éppen a feladatleírás típusú lekérdezés áll a legközelebb.

Forráshivatkozás. A visszakeresés nem garantálja, hogy a válasz a visszakeresett szövegen alapul, ezért egyre több rendszer kéri, hogy a modell *hivatkozzon* a felhasznált részletre. Az ALCE benchmark [41] még a legjobb modelleknél is sok hiányos vagy pontatlan hivatkozást talált. Rashkin és munkatársai [42] szerint egy állítás akkor *tulajdonítható* egy forrásnak, ha egy átlagos olvasó a forrás alapján egyetértene vele. A javasolt módszer minden kérdéshez megköveteli a kulcsot igazoló darabok azonosítóját, és a bíró is ilyen olvasóközpontú definícióval dönt az alátámasztottságról.

Gráfalapú keresés és hosszú kontextus. A GraphRAG [43] nyelvi modellel fogalom- és kapcsolatgráfot épít, és ennek csoportjai alapján válaszol; ennek egyetlen dokumentumra korlátozott változatát az **E3** vizsgálja (3.4.7. szakasz). A RAG valódi alternatívája, hogy a teljes dokumentumot egyetlen promptban adjuk át, ahogy az oktatók a gyakorlatban teszik. A névleges kontextushossz viszont nem azonos a ténylegesen kihasználttal: Liu és munkatársai [6] szerint a modellek a bemenet közepén lévő információt rosszabbul használják, a RULER benchmark [44] szerint pedig a teljesítmény a hosszal folyamatosan romlik. Li és munkatársai [45] összevetésében elegendő erőforrás mellett a hosszú kontextus átlagosan jobb, a RAG viszont lényegesen olcsóbb, és a lekérdezések 63 %-ánál a kettő pontosan azonos előrejelzést ad. Mindebből két következtetés adódik a vizsgálatunkra nézve: egyrészt a teljes dokumentumot egyben kapó modell kérdései a szöveg egyes részeire tömörülhetnek (3. hipotézis), másrészt a hosszú kontextus a fogyasztói kártyák memóriakorlátja miatt helyben csak korlátozottan használható (3.3. szakasz). Erős modell mellett ugyanakkor a teljes dokumentumos megközelítés komoly alternatíva, ezért külön alapvonalként mérjük.

Mit old meg a visszakeresés, és mit nem? A RAG a **P4**-et kezeli a legközvetlenebbül: rövid kontextussal működik, ezért kis, helyi modell is használhatja, ami a **P3**-at is lehetővé teszi. A **P1**-et csak közvetve segíti, mert a promptba tett forrásból nem következik, hogy a modell arra támaszkodik. A **P2**-t a naiv RAG kifejezetten rontja, mert tartalom nélküli lekérdezéssel a dokumentum kis részét látja. A fejlett és moduláris változatokat jellemzően nagy modellel és kérdésmegválaszolásban értékelték, nem vizsgagenerálásban.

2.5. Feladatfelbontás és ellenőrzés

A dolgozat alapgondolata, hogy egy összetett feladatot rövid, jól körülhatárolt lépésekre bontva egy kisebb modell is megbízhatóbban teljesít. Wei és munkatársai [46] szerint a modell pontosabb, ha lépésenkénti gondolatmenetet ír (*chain-of-thought*); a *least-to-most* módszer [47] a problémát előbb részfeladatokra bontja, a *Plan-and-Solve* [48] pedig előbb tervet készíttet – ez a vizsgaterv

gondolatának közvetlen megfelelője. Ezek a felbontást a promptra bízzák, így a terv betartása ugyanúgy a modell utasításkövetésén múlik, mint a közvetlen megközelítésben. Wu, Terry és Cai [49] *MI-láncai* ezzel szemben a programban kötik össze az egymásra épülő modellhívásokat; felhasználói vizsgálatuk szerint a láncok jobb eredményt adtak, és *átláthatóbbak*, jobban *irányíthatók* voltak, mert minden köztes lépés látható és módosítható.

A javasolt módszer a második irányba tartozik: a szerkezeti döntéseket (hány kérdés, melyik témából, milyen szinten) a program hozza meg, a nyelvi modell csak jól körülhatárolt részfeladatot végez. Így minden lépés rövid kontextussal dolgozik (**P4**); a szerkezet kikényszerített tulajdonság (**P2**); a köztes eredmények visszakövethetők; és a lépések egyenként cserélhetők, ami az egytényezős kísérleti tervet lehetővé teszi. Az ár a több modellhívás és a hosszabb futási idő. A hivatkozott eredményeket többnyire nagy modellekkel, érvelési feladatokon mérték; kis modellen, vizsgagenerálásban az 5. és a 6. fejezet méri a hatást.

Ellenőrzés és önjavítás. A hallucináció elleni második stratégia a kimenet utólagos ellenőrzése. A Self-Refine [50] a modellel javíttatja saját kimenetét, a Chain-of-Verification [51] ellenőrző kérdéseket tesz fel a saját válaszáról, a FActScore [52] pedig atomi tényekre bontja a szöveget, és mindegyiket egy tudásforrással veti össze. A *természetes nyelvi következtetés* (*natural language inference*, NLI) annak eldöntése, hogy egy állítás következik-e egy szövegből; ilyen modellekkel összefoglalók tényszerűsége is ellenőrizhető [53]. Az alátámasztottság eldöntése pontosan ilyen feladat.

Az önellenőrzésnek azonban korlátai vannak. Huang és munkatársai [5] szerint *külső visszajelzés nélkül* az önjavítás érvelési feladatokban nem javít, sőt ronthat is; Snell és munkatársai [54] szerint viszont a futás közben elköltött többletszámítás bizonyos feladatokban helyettesítheti a nagyobb modellt. Együtt ez azt sugallja, hogy az ellenőrzés akkor hasznos, ha *külső* információt visz a folyamatba: determinisztikus szabályokat, a forrásszöveget vagy egy másik modell ítéletét. Az ellenőrzőnk ezért olcsó szabályokat (forma, hivatkozás, szivárgás, duplikátum) kombinál a forrással szembeni, nyelvi modellel végzett ítéletekkel, és a hibát visszajelzésként adja vissza a generátornak (3.4.6. szakasz).

A visszacsatolásnak saját veszélye is van. Goodhart törvénye Strathern megfogalmazásában: ha egy mérőszám céllá válik, megszűnik jó mérőszám lenni [55]. A generátor olyan megoldást is találhat, amely az ellenőrzést kielégíti, a valódi célt viszont nem; a pilotban ez a forrásmondat szinte szó szerinti bemásolása volt a törzsbe (*szivárgás*, 5.1. szakasz).

2.6. Kis nyelvi modellek helyi futtatása

A helyi futtatás feltétele, hogy a modell elférjen egy fogyasztói grafikus kártya memóriájában. Ma több nyílt modellcsalád ér el jó teljesítményt néhány milliárd paraméterrel, például a Qwen2.5 [56], a Llama 3.1 [57] és a Gemma 3 [58]. A pilotban és az előzetes vizsgálatban a Qwen2.5-7B, a fő vizsgálatban a Gemma 3 12B és a NYTK magyarra továbbtanított PULI-LlumiX 8B modellje [59] a generátor (2.8. szakasz). Természetes várakozás, hogy a magyarra hangolt modell magyar

tananyagból jobb kérdéseket ír; ezt közvetlenül teszteljük (6. fejezet).

A memóriaigény fő összetevője a súlyok mérete: egy 7 milliárd paraméteres modell 16 biten 14 GB-ot foglal. A *kvantálás* kevesebb biten tárolja a súlyokat; a GPTQ [60] 3–4 bitre tömörít, a helyi futtatás gyakorlati szabványa pedig a `llama.cpp` [61] GGUF formátuma, amelyre az Ollama [62] is épül; az általunk használt Q4_K_M változat kb. 4,8 bitet használ súlyonként. Átfogó kiértékelések szerint a 4 bites kvantálás általános feladatokon csak kis pontosságvesztést okoz [63]. A második összetevő a *kulcs–érték (KV) gyorsítótár*, amely a kontextus hosszával arányosan nő. Így egy 7–8B modell 8 GB-os, a Gemma 3 12B 12 GB-os kártyán futtatható (3.3. szakasz). A helyi futtatás tehát a **P3**-at és a **P4**-et egyszerre kezeli, de csak akkor, ha a módszer a kis modell rövidebb kontextusához és gyengébb utasításkövetéséhez igazodik.

2.7. A kiértékelés: nyelvi modell mint bíró és a mérés megbízhatósága

Az emberi értékelés drága és lassú, ezért elterjedt, hogy egy erős nyelvi modell pontozza a kimenetet (*LLM-as-a-judge*); a dolgozatban ezt a kérdéseket pontozó, független modellt *bírónak* nevezzük. Zheng és munkatársai [64] szerint egy erős bíró ítéletei közel annyira egyeznek az emberi preferenciákkal, mint az emberek egymással. Chiang és Lee [65] hasonló eredményre jutott úgy, hogy a modell ugyanazt az utasítást és értékelőlapot kapta, mint az emberi szakértők – ezt az elvet a rubrikánk is követi. A RAGAS [66] RAG-rendszerekhez javasol referencia nélküli, nyelvi modellel számolt hűségmutatókat. Ezek az egyezési eredmények főként párosított preferenciaítéletekre szólnak; a mi bírónk kérdésenként, forrásrészlethez mérve ítél, amire csak korlátozottan vihetők át.

A bírók torzításai jól dokumentáltak: a *pozíciós torzítás* [67], a *hossztorzítás* és az *önpreferencia*, vagyis a saját modellcsalád szövegeinek előnyben részesítése [68]. Ezért bírónk, a gpt-oss-120b [69] más modellcsaládba tartozik, mint bármelyik generátor (4.6. szakasz), ami az önpreferenciát csökkenti. A bíró csak akkor érvényes mérőeszköz, ha ítéletei egyeznek az emberi szakértőkével; ezt két értékelő bináris ítéleteire Cohen-κ-val [70], több értékelőre és ordinális skálára Krippendorff-α-val [71] mérik. Landis és Koch [72] szerint 0,20 alatt csekély, 0,21–0,40 között gyenge, 0,41–0,60 között közepes, 0,60 felett erős az egyezés; Krippendorff szerint $\alpha \geq 0{,}8$ megbízható, 0,667 és 0,8 között óvatos következtetésre elegendő (4.7. szakasz).

A kísérletek megbízhatósága. Bouthillier és munkatársai [73] szerint a véletlen tényezők okozta szórás gyakran összemérhető a közölt javulásokkal, így egyetlen futás alapján nem szabad módszerek között dönteni. Dror és munkatársai [74] szerint a nyelvtechnológiai cikkek jelentős része nem végez szignifikanciatesztet, vagy nem illőt használ; a 0 és 1 közé szorított, ferde mutatóknál a nemparaméteres próbák (például a Wilcoxon-próba) és a bootstrap a biztonságosabbak. Egy dokumentum tíz kérdése nem tíz független megfigyelés, ezért a dokumentumot tekintjük egységnek, és a sok összevetésből adódó véletlen „szignifikanciát” Holm-korrekcióval [75] szűrjük (4.8. szakasz). Veszélyt jelent az *adatszennyezés* is [76]: a nyilvános Wikipédia- és OpenStax-szövegek a tanítóadatban is szerepelhettek, így a bíró a kérdést emlékezetből is

megválaszolhatja.

Végül a mérés az oktatót is érinti. Parasuraman és Manzey [77] szerint a felhasználók hajlamosak túlságosan megbízni az automatikus jelzésekben (*automatizálási torzítás*): egy „ellenőrzöttnek” jelölt kérdést az oktató kevésbé figyelmesen néz át. A jelenséget az MI-rendelet is megnevezi az emberi felügyelet követelményei között [78]. Ezért az ellenőrző jelzéseit figyelmeztetésként, nem ítéletként kell az oktató elé tenni, amíg megbízhatóságukat mérések nem igazolják.

2.8. A magyar nyelv és a hazai előzmények

A magyar két szempontból jelent külön kihívást. Agglutináló nyelv, így egy szótőnek sok alakja van („immunrendszer”, „immunrendszert”, „immunrendszerben”), ami a lexikális keresést nehezíti és a tokenszámot növeli. Emellett kis erőforrású nyelv: a MEGA kiértékelés [79] szerint a generatív modellek teljesítménye a kisebb erőforrású nyelveken jelentősen elmarad az angoltól, ezért egy kis modell magyar szövegében nyelvtani hibákra is számítani kell.

Magyar nyelvi modellek. Az első széles körben használt magyar kódoló a huBERT [80] volt. A HUN-REN Nyelvtudományi Kutatóközpont (NYTK) PULI-családjának első tagjairól az MSZNY 2023-on számoltak be [81]: a BERT-Large több feladaton felülmúlta a huBERT-et, a 6,7 milliárd paraméteres GPT-3 típusú modellel pedig a szerzők az első magyar, néhány példás (*few-shot*) promptolási kísérleteket végezték; egy- és háromnyelvű GPT-modelljeiket ugyanabban az évben közölték [82]. A dolgozatban használt PULI-LlumiX 8B a Llama 3.1 magyar szövegeken folytatott további előtanításával készült [59]. A csoport 2025-ben Llama 3.1 és Qwen2.5 alapú, magyar utasításadatokon finomhangolt csevegő változatokat (ChatPULI) is leírt, amelyek mérésük szerint jobbak a korábbi PULI-modelleknél [83]. Mi az utólagos utasítás-hangolás nélküli változatot mértük, így a PULI-ra vonatkozó következtetésünk erre a változatra szól (6. fejezet).

Magyar benchmarkok és kérdés–válasz rendszerek. A magyar nyelvértési feladatok egységes mérésére a HuLU benchmark [84] szolgál. A MILQA [37, 85] magyar Wikipédia-cikkekre épülő, a SQuAD 2.0 elveit követő kérdés–válasz adatbázis, amelyet eldöntendő, többrészes és számolást igénylő kérdéstípusokkal bővítettek; adatforrásként mi is használjuk (4.2. szakasz). Erre épül a szegedi SHunQA nyíltkérdés-megválaszoló rendszer [86], amely a választ a forrásszövegben jelöli meg. Ezek a munkák kérdésmegválaszolással foglalkoznak, de két tanulságuk átvihető: magyar szövegen a lexikális keresés erős alapvonal, és a forrásban megjelölt válasz teszi ellenőrizhetővé a rendszert.

Hazai kérdésgenerálás és oktatási MI-használat. Magyar nyelvű vizsgakérdés-generálásról publikált, rendszerszintű kiértékelést nem találtunk. A legközelebbi előzmény a Szegedi Tudományegyetem 2024–2025-ös projektje, amely a helyben futtatható nyelvi modellek tananyagalapú magyar kérdésgenerálását vizsgálta, és nehézségként a modellek eltérő magyar nyelvi képességét és a kérdésekkel szembeni összetett elvárásokat nevezte meg [87]; eredményeiről publikációt nem

találtunk. Az igényt hazai felmérések is mutatják: egy 1027 hallgatós felmérésben a válaszadók kb. 87 %-a használt már MI-eszközt, az akadályok között pedig etikai (kb. 42 %) és adatvédelmi (kb. 30 %) aggályok is szerepeltek [88]; egy 1103 oktatót felölelő felmérés szerint az oktatók az MI-t főként rutinfeladatokra használják, a mélyebb pedagógiai felhasználás háttérbe szorul [89]. A vizsgakészítés ilyen mélyebb felhasználás, amelyhez megbízható és adatvédelmi szempontból vállalható eszköz kell.

2.9. Jogi keret: adatvédelem és MI-rendelet

A **P3** jogi hátterét két közvetlenül alkalmazandó uniós rendelet adja; az alábbi áttekintés mérnöki olvasat, nem jogi tanácsadás.

Adatvédelem. Az általános adatvédelmi rendelet (GDPR) [7] 5. cikke szerint személyes adat csak meghatározott célra, a cél eléréséhez szükséges mértékben (*adattakarékosság*) és ideig (*korlátozott tárolhatóság*) kezelhető, a 25. cikk pedig ezt beépített és alapértelmezett adatvédelemként a rendszer tervezésére is kiterjeszti. A felhőben futó csevegőasszisztens ezért problémás: ha az oktató a jegyzetét saját fiókkal tölti fel, az intézmény és a szolgáltató között nincs a 28. cikk szerinti adatfeldolgozói szerződés, a szolgáltató címzett lesz, és ha a tartalmat saját céljára (például modellfejlesztésre) is felhasználja, abban a körben maga is adatkezelő [90]. A tananyagban szereplő harmadik személyek adatai így tudtuk nélkül kerülnek új, esetleg harmadik országbeli adatkezeléshez, a modellbe került adat pedig később akár szó szerint is visszanyerhető [91]. A hazai felügyeleti hatóság, a NAIH [92] is arra figyelmeztet, hogy csevegőrobotba ne töltsünk fel személyes adatot [93], a szervezet tudta nélküli MI-használatot („árnyék-MI”) pedig az adatok feletti kontroll elvesztésének kockázataként elemzi [94]. A helyi futtatás és a feldolgozás utáni törlés ezt a kockázatot a forrásnál szünteti meg.

Az MI-rendelet. Az (EU) 2024/1689 rendelet [78] a kötelezettségeket a felhasználás kockázatához köti: megkülönböztet tiltott gyakorlatokat (5. cikk, például az érzelemfelismerést oktatási intézményben), magas kockázatú rendszereket (6. cikk, I. és III. melléklet) kockázatkezelési, dokumentációs és emberi felügyeleti követelményekkel, átláthatósági kötelezettséggel járó rendszereket (50. cikk) és minimális kockázatú rendszereket. A III. melléklet 3. pontja az oktatásban négy felhasználást minősít magas kockázatúnak:

(1) a felvétel eldöntését,

(2) a tanulási eredmények értékelését (akkor is, ha az eredmény a tanulási folyamatot irányítja),

(3) a képzési szint felmérését, valamint

(4) a tiltott vizsgaviselkedés megfigyelését.

A 6. cikk (3) bekezdése szerint egy ilyen rendszer mégsem magas kockázatú, ha nem jelent jelentős kockázatot, például mert csak egy értékelés *előkészítő feladatát* látja el – kivéve, ha természetes személyek profilalkotását végzi. Az 50. cikk szerint a felhasználót tájékoztatni kell, ha MI-rendszerrel érintkezik, a generált szöveget pedig géppel olvashatóan MI-generáltként kell

jelölni. Az átláthatósági kötelezettségek 2026. augusztus 2-ától alkalmazandók, a III. melléklet szerinti magas kockázatú kötelezettségeket pedig a 2026-os „digitális omnibusz” módosítás 2026. augusztus 2-áról 2027. december 2-ára halasztotta [95].

A javasolt módszer besorolása. A tanár által ellenőrzött, csak kötelező oktatói jóváhagyás után felhasználható kérdésgenerálás nem tartozik a III. melléklet 3. pontjába: nem értékel tanulási eredményt, hanem egy emberi döntés, a vizsga összeállításának alapanyagát adja; ha egy szigorú értelmezés mégis az értékelés részének tekintené, előkészítő feladatként a 6. cikk (3) bekezdése alá esne, mert profilalkotást nem végez. A hallgatói válaszok automatikus pontozása viszont a 3. pont b) alpontja szerint magas kockázatú felhasználás lenne, ezért ilyen funkciót nem vizsgálunk. A kötelező oktatói jóváhagyás egyben az automatizálási torzítás elleni védelem, amelyet az UNESCO oktatási útmutatója [96] is elvár; a tervezési elveket a 3.1. szakasz foglalja össze.

2.10. Összegzés és a kutatási rés

A 2.1. táblázat a tárgyalt megközelítéseket a **P1**–**P4** problémák szerint veti össze. A korai rendszerek helyben futnak, de sem a helyességet, sem a szerkezetet nem ellenőrzik; a csevegő modell egyik problémát sem kezeli; a naiv RAG forráshoz köti a generálást, de a feladatleírásból készült lekérdezéssel a dokumentum kis részét látja; az önjavító, a hivatkozó és a gráfalapú módszerek egy-egy problémát részben kezelnek, de nagy modellt feltételeznek. A javasolt módszer sorában a helyesség mérése csak részben teljesül: a bíró az oktatói értékeléssel csak sorrendben egyezik, és az ellenőrző kérdésenkénti megbízhatósága korlátozottnak bizonyult (5. fejezet).

2.1. táblázat. A kérdésgenerálási megközelítések összevetése a **P1**–**P4** problémák szempontjából (✓: kezeli, ∘: részben, –: nem kezeli). A táblázat azt mutatja, hogy egy megközelítés foglalkozik-e az adott szemponttal, nem azt, hogy milyen jól.

Megközelítés	Kulcs ellenőrzése	Szerkezet, lefedettség	Helyi futás	Kis modell	Forrás-hivatkozás	Helyesség mérése
Szabály- vagy sablonalapú [14, 15]	∘	–	✓	✓	∘	–
Neurális seq2seq [18]	–	–	✓	✓	–	–
Dokumentum → csevegő LLM (status quo)	–	–	–	–	–	–
LLM-alapú kérdésgenerálás [20, 21]	–	∘	–	–	–	∘
Naiv RAG [31]	–	–	∘	∘	∘	–
Továbbtanított kis modell [24]	–	–	✓	✓	–	∘
Feladatfelbontó promptolás [47, 48]	–	∘	–	–	–	–
Önjavítás / CoVe [50, 51]	∘	–	–	–	–	–
Hivatkozó generálás [41]	∘	–	–	–	✓	✓
GraphRAG [43]	–	∘	–	–	∘	–
Mimir (jelen munka)	✓	✓	✓	✓	✓	∘

Az összevetésből három hiányosság rajzolódik ki:

(i) Tudomásunk szerint nincs olyan nyílt rendszer, amely a kérdésgenerálást explicit tervvel, kérdésenkénti forráshivatkozással és ellenőrzéssel, fogyasztói GPU-n (8–12 GB) futó kis modellel végezné.

(ii) A kiértékelések ritkán mérik a kulcs helyességét és a vizsga lefedettségét, és hiányoznak az egytényezős kísérleti tervek, amelyek a komponensek hatását egyenként választják szét.

(iii) A magyar nyelvű vizsgakérdés-generálás kiértékelése feltáratlan: a hazai nyelvtechnológia erős modelleket és kérdés–válasz adatbázisokat épített, de publikált kérdésgenerálási kiértékelést nem találtunk.

Az első hiányosságra a 3., a másodikra a 4., a harmadikra – a rendelkezésre álló adatok korlátai között – az 5. és a 6. fejezet ad választ.

A fejezet tanulsága. A szakirodalom mind a négy problémára kínál részmegoldást, de egyik megközelítés sem kezeli egyszerre mindet: a nagy modellek a nyelvi minőséget megoldották, a **P1**-et csak statisztikailag javítják, a **P2**-t nem vizsgálják; a visszakeresés és a helyi futtatás a **P3**-at és a **P4**-et kezeli, de a naiv változat a **P2**-t rontja; a feladatfelbontást és a forráshoz mért ellenőrzést eddig főként nagy modellekkel vizsgálták. A jogi keret a helyi, emberi jóváhagyással működő megoldás felé mutat.

3. A javasolt generálási módszer

Ebből a fejezetből az olvasó megtudja, milyen elvekből indul ki a javasolt módszer (3.1–3.2. szakasz), mekkora GPU-memóriát igényel a helyi futtatás (3.3. szakasz), és lépésenként hogyan készül el egy vizsga: a darabolástól a vizsgaterven, a kérdéshelyenkénti keresésen és a forráshoz kötött generáláson át az ellenőrző láncig (3.4. szakasz). A módszert kutatási prototípusként, a nyílt kiértékelő keretrendszerben megvalósítva írjuk le; a részleteket az A. függelék, a paraméterek alapértékeit az E. függelék tartalmazza.

3.1. Tervezési elvek

A bevezetés **P1**–**P4** problémáiból és az MI-rendelet emberi felügyeletre vonatkozó elvárásából [78] öt elv következik.

(1) *Ellenőrizhetőség* (**P1**): minden kérdés a kulcsot igazoló forrásrészletekre hivatkozik, és a kulcs alátámasztottságát, valamint a kérdés egyértelműségét a módszer maga is ellenőrzi; ami az ellenőrzésen nem jut át, megjelölve kerül az oktató elé.

(2) *Kontrollált szerkezet* (**P2**): a darabszámot, a típusokat és a Bloom-szinteket egy explicit vizsgaterv rögzíti, a fogalmak kiválasztása a dokumentum lefedését követi.

(3) *Helyi futtatás és adatvédelem* (**P3**): a generátor helyben fut, a feldolgozott tartalom nem őrződik meg.

(4) *Megvalósíthatóság fogyasztói hardveren* (**P4**): rövid, 8 192 tokenes kontextusba férő hívások, 4 bitre kvantált modell 8–12 GiB-os GPU-n.

(5) *Emberi felügyelet*: a kérdések csak oktatói jóváhagyás után használhatók.

3.2. Helyi futtatás és adatkezelés

A (3) elv az adattakarékosság és a korlátozott tárolhatóság GDPR-elvén [7] alapul, az (5) pedig az MI-rendelet emberi felügyeletre és átláthatóságra vonatkozó követelményein [78] (a jogi hátteret a 2.9. szakasz foglalja össze). A módszer ezért minden nyelvimodell-hívást helyben, fogyasztói GPU-n futó modellel végez (a kiértékelés bírója és a szerveres összehasonlító konfigurációk csak a mérés részei, 4. fejezet); a feltöltött dokumentum, a darabok, a beágyazások és a promptok csak a vizsga elkészítéséig, memóriában léteznek, utána törlődnek (*zéró megőrzés*), és a naplóba tartalom helyett legfeljebb kriptográfiai ujjlenyomat kerül. A kész vizsga vázlat: az oktató átnézi, és csak jóváhagyás után használható (3.4.8. szakasz). Ezek az elvek a tanár által ellenőrzött kérdésgenerálást tartják az MI-rendelet szerinti magas kockázatú oktatási alkalmazásokon kívül, ahová a diákválaszok automatikus pontozása már tartozna.

3.3. A GPU-memória becslése

A negyedik tervezési elv gyakorlati megvalósíthatósága azon múlik, hogy a generátormodell az asztali operációs rendszer mellett is elfér-e egy fogyasztói videokártya memóriájában. A memóriaméretet a továbbiakban bináris egységekben adjuk meg (1 GiB = 2^{30} bájt); a kereskedelmi forgalomban „8 GB-os” és „12 GB-os” jelöléssel árusított kártyák ténylegesen 8, illetve 12 GiB memóriával rendelkeznek. A futtatás teljes memóriaigénye három összetevőből tevődik össze: a kvantált modellsúlyok méretéből, a kontextushosszal arányosan növekvő KV-gyorsítótárból, valamint a futtatókörnyezet fix többletfoglalásából (a pontos összefüggést az A.1. egyenlet és az A.1. táblázat részletezi az A.1. függelékben). Az általunk alkalmazott Q4_K_M kvantálás súlyonként átlagosan 4,8 bitet használ, amivel a súlyok tárigényét a 16 bites lebegőpontos ábrázolás nagyjából harmadára szorítja le.

A javasolt módszerben használt 8 192 tokenes kontextusablak mellett a három vizsgált helyi generátormodell memóriaigénye a következőképpen alakul:

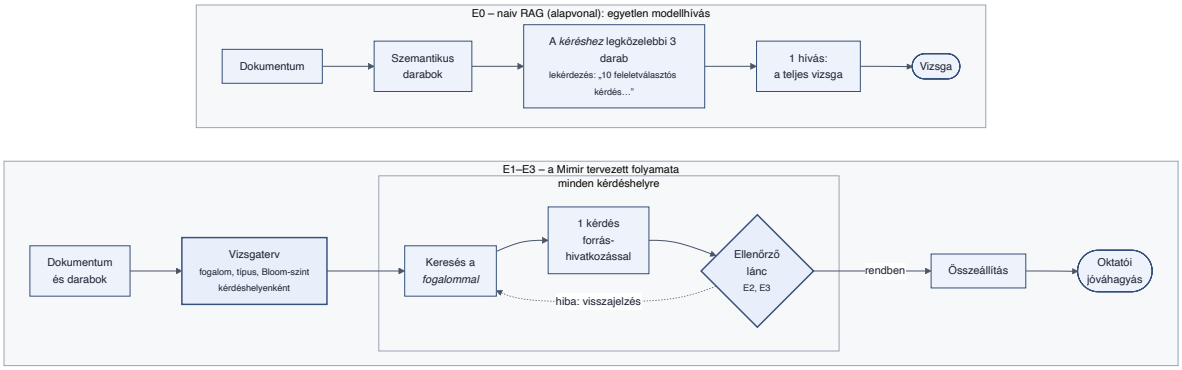
- **Qwen2.5-7B:** a modell becsült teljes memóriaigénye kb. 5,4 GiB;
- **PULI-LlumiX 8B:** a Llama-3.1-8B architektúráját öröklő modell becsült igénye kb. 6,1 GiB;
- **Gemma 3 12B:** a ténylegesen mért foglalás kb. 7,8 GiB (mivel a modell rétegeinek többsége csak egy rövid csúszóablakra figyel, az általános képlet ennél az architektúránál túlbecsüli a gyorsítótár méretét).

Mindebből két jól elkülönülő fogyasztói hardverszint adódik: a 7–8 milliárd paraméteres modellek 4 bites kvantálással biztonságosan elférnek egy 8 GiB-os kártyán, míg a 12 milliárd paraméteres modell az asztali környezet memóriafoglalásával együtt már 12 GiB-os GPU-t igényel. A kontextusablak növelése szintén jelentős többletköltséggel jár, hiszen 32 768 tokennél már a Qwen2.5-7B KV-gyorsítótára is önmagában 1,75 GiB-ot foglalna le. A helyi teljes dokumentumos alapvonal (**B-doc-L**) ezért legfeljebb 16 384 tokenes kontextussal és 30 000 karakterre csonkolt bemenettel fut, míg a javasolt tervezésvezérelt módszer modellhívásai a teljes folyamat során rövidek maradnak. A kísérletek során ténylegesen mért memóriafoglalási adatokat a 6.4. szakasz ismerteti.

3.4. A generálási módszer áttekintése

A 3.1. ábra a két összehasonlított generálási folyamatot mutatja. A *naiv RAG* (**E0**) a felhasználói kéréshez leginkább hasonló három darabot keresi vissza, és egyetlen hívásban kéri a teljes vizsgát; ez a legegyszerűbb visszakereséses megoldás és a legolcsóbb ésszerű alapvonal. A *tervezett folyamat* (**E1**–**E3**) először explicit vizsgatervet készít, majd a terv minden pontjára (a továbbiakban: *kérdéshelyére*) külön keresést, egyetlen kérdés generálását és – az ellenőrző változatokban – ellenőrzést végez. A lényeg a feladat felbontása: a naiv alapvonalban a modell egy hívásban dönt a kérdések számáról, témájáról, nehézségéről és disztraktorairól (rossz válaszlehetőségeiről), a tervezett folyamatban a szerkezeti döntéseket determinisztikus program

hozza meg, a modell pedig egy-egy rövid kérdést ír, csak a releváns kontextus alapján.



3.1. ábra. A naiv RAG és a Mimir tervezett generálási folyamata. A terv a vizsga szerkezetét még az első kérdés megírása előtt rögzíti, és minden kérdést a saját, hivatkozott kontextusával szemben ellenőriz.

A módszer modellfüggetlen: minden nyelvimodell-hívás OpenAI-kompatibilis felületen megy át, a generátor egy konfigurációs kulccsal cserélhető. A vizsgálatokban a Qwen2.5-7B [56] (pilot és előzetes vizsgálat), valamint a NYTK magyarra továbbtanított, Llama-3.1 alapú PULI-LlumiX 8B [59] és a Gemma 3 12B [58] (fő vizsgálat) volt a generátor. Mindhárom 4 bites (Q4_K_M, kb. 4,8 bit/súly) kvantálással fut az Ollamán [62], $T = 0{,}2$ hőmérséklettel és 8 192 tokenes kontextussal (a **B-doc-L** 16 384 tokennel); a fő vizsgálatban a válasz legfeljebb 4 096 token.

3.4.1. Szemantikus darabolás

A szöveget mondatokra bontjuk, és minden mondathoz 768 dimenziós vektort rendelünk a multilingual/E5-base [35] kódolóval: a mondat tokenvektorainak átlagát vesszük hosszabb szövegablakban, így a reprezentáció a szomszédos mondatok jelentését is figyelembe veszi. A szöveget ott vágjuk el, ahol két szomszédos mondat koszinusz-távolsága meghaladja a vágási küszöböt (alapértelmezésben a távolságok 85. percentilisét, vagyis a legnagyobb 15 %-ba eső értékeknél vágunk). A célméret (1 000 karakter) túllépése után a küszöb arányosan csökken; ez a *puha korlát* mondat közepén soha nem vág (a képlet: A.2. függelék).

A csonkolt kódoló hibája. A kódoló legfeljebb 512 tokenes bemenetet fogad. Az eredeti implementáció a teljes dokumentumot egy menetben, csonkolva kódolta, így az 512. token után kezdődő mondatok nullvektort kaptak, és hosszabb dokumentumon a vágás már nem a tartalomtól, csak a darab hosszától függött. A javított kódoló mondathatáron vágott, legfeljebb 510 tokenes ablakokban dolgozik (rövid szövegen az eredmény azonos). Az **E5a** a régi kódolót szándékosan megtartja, hogy a hiba hatása mérhető legyen.

3.4.2. Indexelés és az alapvonalak

A darabokat ugyanazzal az E5 kódolóval beágyazzuk, és memóriában futó Qdrant [97] vektortárba töltjük, amely minden új dokumentum előtt kiürül; a *sűrű keresés* a lekérdezéshez koszinusz-hasonlóság szerint legközelebbi k darabot adja vissza. Az **E0** lekérdezése a felhasználói kérés

szövege („Készíts pontosan 10 darab vizsgakérdést, típus: feleletválasztós. . . ”), kontextusa a három leghasonlóbb darab, promptja a Mimir kiinduló, v1.0-s naiv promptja (C. függelék). A *teljes dokumentumos prompt* (**B-doc-L** helyben, **B-doc-S** a szerveren) ugyanezt a promptot használja a teljes dokumentummal (helyben legfeljebb 30 000, a szerveren 80 000 karakter; a levágott rész arányát rögzítjük).

3.4.3. A vizsgaterv

Fogalomtervezés. A tervező egyetlen hívásban a dokumentum *áttekintését* kapja: minden darab azonosítóját ($C_0, C_1, \dots$) és elejét, összesen legfeljebb 12 000 karakterben (darabonként legalább 120 karaktert). A modell így folytonos szöveg helyett azonosítókkal tagolt felsorolást lát, ami a „lost in the middle” jelenség [6] ellen hat. A tervező $n+3$ fogalmat ad vissza (n a kért kérdésszám), mindegyikhez egymondatos leírást (mit kell kérdezni), az alátámasztó darabok azonosítóit és egy fontossági értéket (1: részlet, 2: fontos, 3: központi). Értelmezhetetlen válasznál darabonként egy álfogalom lép a helyükre, így a terv mindig létrejön.

Bloom-szintek és fogalomválasztás. A kért nehézséghez egy Bloom-szint-eloszlás tartozik [11], amelyet a legnagyobb maradék módszerével [98] alakítunk egész darabszámokká (A.2. táblázat, A.2. függelék). Az összeg mindig pontosan n, így a nehézség nem kérés a promptban, hanem a terv szerkezeti tulajdonsága. A kérdéshelyekhez egy *mohó* eljárás választ fogalmat: mindig azt, amely még le nem fedett darabot érint, ezen belül a legfontosabbat; ha minden darab le van fedve, a fontosság dönt. Ha a tervező legalább n fogalmat javasolt, a kérdések így nem tömörülhetnek a dokumentum egyetlen részére; kevesebb fogalomnál a fogalmakat más Bloom-szinttel újra felhasználjuk, a ki nem választottak alkotják a *tartaléklistát*.

3.4.4. Kérdéshelyenkénti keresés

Minden kérdéshely saját kontextust kap: a lekérdezés a fogalom neve és leírása, a kontextus a fogalomhoz a tervező által rendelt első két darab, kiegészítve a keresés $k = 3$ találatával (ismétlés nélkül), legfeljebb 6 000 karakterig. A lényegi különbség a naiv RAG-hoz képest, hogy a lekérdezés itt tartalmi fogalom („immunológiai memória: hogyan alakul ki”), nem feladatleírás („10 kérdés, könnyű”). A *hibrid* változat (**E2h**) a sűrű rangsort egy előtagtövesített BM25-rangsorral egyesíti reciprok rangfúzióval (A.2. függelék).

3.4.5. Forráshoz kötött kérdésgenerálás

A generátor egyetlen kérdést ír a kérdéshely terve szerint. A prompt (C. függelék) négy fő elemből épül fel:

– megadja a fogalmat, a kérdezendő tartalmat, a típusszabályt (négy válasz, egy helyes), a Bloom-szint magyar leírását, a nehézséget és a nyelvet;
– megismétli a naiv prompt szabályait (zéró hallucináció, meta-hivatkozás tilalma);

– felsorolja a már elfogadott kérdéseket az ismétlődés elkerülésére;
– megköveteli a forráshivatkozást, amelyben a modell megnevezi a kulcsot igazoló darabok azonosítóit.

Így minden kérdés saját, ellenőrizhető forrásrészlethez kötődik.

3.4.6. Az ellenőrző lánc

Az ellenőrzések a legolcsóbbtól a legdrágábbig futnak (3.1. táblázat; a visszacsatolás algoritmusa: A.2. függelék): ha egy szabályalapú ellenőrzés hibát talál, a nyelvi modellt igénylő ellenőrzések el sem indulnak. A modellalapú ellenőrzések forrását a kérdésben megjelölt darabok adják.

3.1. táblázat. Az ellenőrző lánc lépései végrehajtási sorrendben, a hiba esetén adott visszajelzéssel.

Ellenőrzés	LLM-hívás	Visszajelzés hiba esetén
Forma	–	feleletválasztós kérdés: 4 válasz, ebből 1 helyes
Meta-hivatkozás	–	fogalmazd meg „a szöveg szerint” jellegű hivatkozás nélkül
Szivárgás és kérdésforma *(a pilot után)*	–	a törzs ne tartalmazza a választ, és legyen valódi kérdés
Hivatkozás	–	hivatkozz a kontextus legalább egy darabjára
Alátámasztottság és disztraktorok	1	a kulcsot a részlet nem igazolja / egy disztraktor igaz lehet / kétértelmű
Vak megoldás	1	egy független megoldó más választ jelölt meg
Duplikátum	–	túl hasonló egy már elfogadott kérdéshez

A *szivárgási szabály* akkor jelez, ha a legalább háromszavas kulcs szavainak legalább 80 %-a a törzsben (a kérdés szövegében) is szerepel, a *kérdésforma-szabály* akkor, ha a törzs sem kérdőjelre, sem kettőspontra nem végződik; mindkettőt a pilot hibamódja (5.1. szakasz) motiválta. Az *alátámasztottsági* hívás azt kérdezi, igazolja-e a forrás a kulcsot, hamis-e minden disztraktor és kétértelmű-e a kérdés; a *vak megoldásban* a modell a kulcs ismerete nélkül, összekevert válaszokkal dönt. *Duplikátum* a legalább 0,9 koszinusz-hasonlóságú kérdés. Az ellenőrzést maga a generátor végzi, az **E2x**-ben egy másik modell (Llama-3.1-8B [57]).

A hibák listája visszajelzésként a következő kísérlet promptjába kerül ($r = 1$ újrapróbálkozás, majd egy tartalékfogalom); ha a kulcs nem igazolt, a keresés két darabbal bővül. Ha így sem sikerül, a legjobb kísérlet *nem ellenőrzöttként* megjelölve marad meg, hogy az oktató lássa; hibás formánál egy *javító* hívás pótolja a hiányzó disztraktorokat (A.1. algoritmus, A.2. függelék). Az **E1** csak a formát, a meta-hivatkozást és a duplikátumot vizsgálja. A technikai hiba miatt elmaradt ellenőrzés a kérdést nem tartja fel, de naplózzuk.

Költség. Az egyhívásos konfigurációk (**E0**, **E5a**–**E5c**, **B-doc**) egyetlen hívással dolgoznak; ezzel szemben az **E1** legalább $1+n$ (tervezés és kérdésenként egy generálás), az **E2** pedig legalább $1+3n$ hívást igényel (kérdésenként generálás, alátámasztottsági ellenőrzés és vak megoldás). Tíz kérdésnél ez 11, illetve 31 hívás, ha minden kérdés elsőre átmegy; minden elutasítás további két-három hívással jár.

3.4.7. Munkamenet-hatókörű fogalomgráf

Az **E3** a tervezőhívást egy fogalomgráffal váltja ki: kötegenként kinyeri a fogalmakat, a rövid tényeket és a fogalmak közötti kapcsolatokat, a fogalmakat centralitás szerint rendezi, és ez a lista lép a tervező helyébe; disztraktor-ötletként a generátor a fogalom testvérfogalmait kapja (A.2. függelék). A gráf csak a vizsga élettartamáig létezik, a memóriában.

3.4.8. Összeállítás és emberi felügyelet

Az elfogadott kérdéseket Bloom-szint szerint rendezzük, és mindegyikhez rögzítjük a hivatkozott darabokat, a tervezett fogalmat és az *ellenőrzött* jelzőt. Az eredmény nem kész vizsga, hanem vázlat: az oktató minden kérdést a hivatkozott forrásrészlet mellett lát, szerkesztheti, cserélheti vagy törölheti, és a vizsga csak az ő jóváhagyásával használható. A nem ellenőrzöttként megjelölt kérdések így oda kerülnek, ahol a döntést meg kell hozni: az oktatóhoz.

A fejezet tanulsága. A javasolt módszer a vizsgakészítést rövid, egyenként ellenőrizhető lépésekre bontja: a szerkezetet (darabszám, Bloom-szint, lefedés) determinisztikus terv rögzíti, minden kérdés saját, tartalmi lekérdezéssel keresett kontextusból és forráshivatkozással készül, a kulcsot pedig olcsó szabályok és két modellhívás ellenőrzi. Mindez 8–12 GiB-os GPU-n, helyben futtatható. Hogy a lépések közül melyik mennyit ér, és mennyibe kerül, azt a következő fejezetek mérik.

4. Kísérleti módszertan

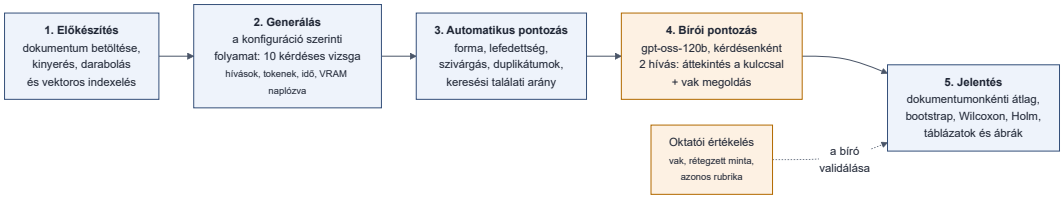
Ebből a fejezetből az olvasó megtudja, milyen eszközzel, dokumentumokon, konfigurációkkal, mutatókkal és statisztikai eljárásokkal mértük a módszereket és a modelleket, és milyen szabályok szerint vethetők össze a három vizsgálat eredményei. A kérdésgenerálás kiértékelése az irodalomban többnyire szóegyezésre és kis, nem vak emberi értékelésre támaszkodik, és ritkán ellenőrzi a kulcs helyességét (2. fejezet). A mérés eszköze ezért egy saját fejlesztésű, nyílt forráskódú kiértékelő keretrendszer, amely a dolgozat önálló hozzájárulása. A keretrendszert hat fő tulajdonság jellemzi:

– az *egyténye zős konfigurációk*, amelyekkel a komponensek hatása szétválasztható;
– a *forrásalapú mutatók*, amelyek a kulcs helyességét a forrásszöveghez mérik;
– a kérdéseket pontozó, a generátoroktól független nyelvi modell, a *bíró*, amelynek megbízhatóságát külön is ellenőrizzük;
– a *dokumentumszintű statisztika*;
– a *folytatható futás* a több napig tartó vizsgálatokhoz; valamint
– a *bírói gyorsítótár*, amellyel az újrapontozás determinisztikus, és nem igényel új bírói hívást.

A mutatók és az eljárások részletes definícióit az A. függelék tartalmazza.

4.1. A tesztelés menete

A kiértékelés alapegysége a *teszt*: egy *konfiguráció* (a generálási folyamat egy rögzített beállítása, rövid jele például **E0** vagy **E2**) egy dokumentumon, egy véletlenmaggal egy tízkérdéses feleletválasztós vizsgát állít elő, amelyet automatikus mutatókkal és a bíróval pontozunk (4.1. ábra). Az előkészítés (szövegkinyerés, darabolás, vektoros indexelés) és a konfiguráció szerinti generálás egyaránt a keretrendszerben fut. Minden modellhívás szakaszát, tokenszámát és idejét rögzítjük, a GPU-memóriát egy háttérszál mintavételezi.



4.1. ábra. Egy teszt lépései: előkészítés és indexelés, generálás a konfiguráció szerint, automatikus mutatók, bírói pontozás és összesítés.

A reprodukálhatóságot négy mechanizmus biztosítja:

(1) minden futás rögzíti a teljes konfigurációt, a kód és az adatkészlet verzióját, valamint a hardver adatait;
(2) a bírói gyorsítótár kulcsa a bírómodell, a promptverzió, a gondolkodási szint és a teljes

prompt kivonata, így újrapontozáskor ugyanarra a kérdésre ugyanaz az ítélet jön;
(3) egy megszakított futás folytatásakor csak a hiányzó vagy sikertelen vizsgák futnak újra;
(4) 43 automatikus teszt fedi le a keretrendszert, köztük ál-nyelvi modellel a teljes folyamatot.

4.2. Adatkészlet

Az `eval-v1` adatkészlet 39 dokumentumból és összesen 326 referenciakérdésből áll (A.3. táblázat, A.3. függelék):

– 3 saját, rövid magyar oktatási szöveg (kávé, immunrendszer, játékelmélet) kézzel írt referenciakérdésekkel,
– 12 OpenStax-tankönyvrészlet az EduQG [23] szakértői kérdéseivel, valamint
– 24 magyar Wikipédia-cikk a MILQA [37] szövegértési kérdéseivel.

A fő vizsgálat ebből 30-at használt: mind a 24 MILQA-cikket, a 3 saját szöveget és 3 OpenStax-részletet (`en-economics-short-01`, `en-humanities-medium-02`, `en-law-long-03`), összesen 27 magyar és 3 angol dokumentumot, hosszúság szerint 12 rövid, 9 közepes és 9 hosszú dokumentummal. A szűkítés oka a futásidő volt; az elsődleges cél a magyar nyelvű kiértékelés, az angol részletek a nyelvi összevetést szolgálják. A referenciakérdések *nem* célok, hiszen egy jó vizsgakérdésnek nem kell hozzájuk hasonlítania; a keresés pontosságát és a tematikus egyezést mérjük velük.

4.3. A kísérleti konfigurációk

A kísérleti terv *egytényezős*: minden konfiguráció egy referenciakonfigurációhoz képest pontosan egy tényezőben tér el, így a kettő különbsége az adott tényezőnek tulajdonítható. A 4.1. táblázat a 14 konfigurációt három csoportban foglalja össze.

4.1. táblázat. A kísérleti konfigurációk. Ref.: amelytől a konfiguráció egyetlen tényezőben eltér; Magok: dokumentumonkénti ismétlések száma az előzetes és a fő vizsgálatban (a pilotban mindenhol 3); Vizsg.: P = pilot, Ev = előzetes vizsgálat, F = fő vizsgálat.

Jel	Mit változtat (és módszertani leírása)	Ref.	Magok	Vizsg.
Alapvonalak				
B-doc-L	teljes dokumentum egy promptban, helyi modell (≤ 30 000 kar., 3.4.2. szakasz)	–	3	Ev, F
B-doc-S	ugyanez a szervermodellel (≤ 80 000 kar., 3.4.2. szakasz)	–	3	Ev
E0	naiv RAG: a kéréshez legközelebbi 3 darab, a vizsga egy hívásban (3.4.2. szakasz)	–	3	P, Ev, F
A módszer lépései				
E1	vizsgaterv, kérdéshelyenkénti keresés és generálás, ellenőrzés nélkül (3.4.3–3.4.5. szakasz)	**E0**	1	P, Ev, F
E2	**E1** + ellenőrző lánc visszacsatolással, a teljes módszer (3.4.6. szakasz)	**E1**	1	P, Ev, F
E3	**E2** + fogalomgráf (3.4.7. szakasz)	**E2**	1	P, Ev, F
Kiegészítő ablációk				
E2f	**E2** vak megoldási próba nélkül (3.4.6. szakasz)	**E2**	1	P, Ev, F
E2h	**E2** hibrid (BM25 + sűrű) kereséssel (3.4.4. szakasz)	**E2**	1	P, Ev, F
E2x	**E2**, az ellenőrzést egy másik modell (Llama-3.1-8B) végzi (3.4.6. szakasz)	**E2**	1	Ev, F
E4	**E0** a szervermodellel (3.4.2. szakasz)	**E0**	3	P, Ev
E4b	**E2** a szervermodellel (3.4.6. szakasz)	**E2**	1	Ev
E5a	**E0** a régi, 512 tokenre csonkolt kódolóval (3.4.1. szakasz)	**E0**	3	P, Ev, F
E5b	**E0**, vágási küszöb: átlag + 1,5 szórás (3.4.1. szakasz)	**E0**	3	P, Ev, F
E5c	**E0** rögzített, 800 karakteres darabokkal (3.4.1. szakasz)	**E0**	3	P, Ev, F

A három konfigurációcsoport szerepe a kísérleti tervben a következő:

– *Alapvonalak:* Azt modellezik, amit egy oktató a Mimir nélkül tenne. A **B-doc-S** a mai gyakorlatnak felel meg (a jegyzet feltöltése egy csevegőasszisztensbe), a **B-doc-L** ugyanezt valósítja meg helyi modellel és 16 384 tokenes kontextussal, míg az **E0** a Mimir kiinduló, naiv változata.

– *A módszer fő lépései:* Az egymásra épülő konfigurációk a javasolt folyamat fő összetevőinek hatását választják szét: az **E1**–**E0** különbség a tervezés (1. és 3. hipotézis), az **E2**–**E1** az ellenőrzés (2. hipotézis; az **E2**-ben az ellenőrzést a kérdést író modell végzi), az **E3**–**E2** pedig a fogalomgráf hatását méri.

– *Kiegészítő ablációk:* Az **E2f** a vak megoldási próba, az **E2h** a hibrid keresés, az **E2x** pedig a

külön ellenőrző modell hatását vizsgálja (a PULI-LlumiX esetében az ellenőrző a generátor alapmodellje, tehát nem független család). Az **E4** és az **E4b** a 4. hipotézist, az **E5a**–**E5c** pedig a darabolás hatását vizsgálja (régi kódoló: 3.4.1. szakasz; rögzített darabolás [40]).

A tervezett konfigurációk egy maggal futnak, mert egy vizsga perceket igényel, és a variancia fő forrása a dokumentum; az olcsó egyhívásos konfigurációk zaját három mag csökkenti. A tervben szereplő, kérdésenként külön hívással futó naiv RAG kontrollváltozat (**E0s**) egyik vizsgálatban sem futott. A többszörös összehasonlításból eredő torzítás elkerülésére hat elsődleges páros összevetést rögzítettünk előre, amelyekre Holm-korrekciót alkalmazunk (minden további összevetés leíró jellegű):

(1) **E1**–**E0**: a tervezés hatása,
(2) **E2**–**E1**: az ellenőrző lánc hatása,
(3) **E2**–**E0**: a teljes módszer hatása a naiv RAG-hoz képest,
(4) **E2**–**B-doc-L**: a teljes módszer a teljes dokumentumos prompttal szemben,
(5) **E2x**–**E2**: a független ellenőrző modell hatása,
(6) **E3**–**E2**: a fogalomgráf hatása.

4.4. A három vizsgálat

A kísérleteket három lépcsőben futtattuk (4.2. táblázat). A *pilot* a mérési láncot próbálta ki; egy dokumentumon hipotézist eldönteni elvileg sem lehet. Az *előzetes vizsgálat* a pilot után javított folyamattal (szivárgási szabályok, javító hívás, $r = 1$, a bíró a kérdés forrásdarabjait kapja), a *fő vizsgálat* ugyanezzel, 30 dokumentumon és két helyi generátorral futott.

Az előzetes vizsgálatban az **E4** és az **E4b** hat angol dokumentumon futott (ebből három közös), a többi konfiguráció a közös hat dokumentumon. A PULI-LlumiX-nél azért kevesebb a pontozott kérdés, mert gyakran tíznél kevesebb kérdést adott vissza. A 20 GiB-os kártyán a modell, a kvantálás és a kontextus ugyanaz, mint egy fogyasztói kártyán, így ez a minőséget nem befolyásolja, a memóriamérés pedig a modell saját foglalását adja.

Két összevetési szabály. A vizsgálatok eltérő dokumentumokon, generátorokkal és részben eltérő implementációval futottak, ezért az eredményeket két szabály szerint vetjük össze.

(1) *Összevetés csak azonos dokumentumokon.* Két konfigurációt, két modellt vagy két vizsgálatot csak ugyanazon a dokumentumhalmazon hasonlítunk össze, mert a variancia fő forrása a dokumentum (4.8. szakasz). Egy vizsgálaton belül ez a közös dokumentumokon teljesül. A három vizsgálat között az összevetés a *hat közös dokumentumon* megengedett (a három saját magyar szöveg és a fő vizsgálat három OpenStax-részlete), amelyen az előzetes vizsgálat Qwen2.5-7B-je és a fő vizsgálat két modellje egyaránt futott; ilyenkor ezt mindig jelezzük. A pilot az akkori, javítás előtti folyamatot méri, ezért vele számszerű összevetést nem végzünk.
(2) *A futásidő relatív szorzó.* A futásidőt azzal mérjük, hogy ugyanazon a GPU-n egy

4.2. táblázat. A három vizsgálat fő paraméterei és beállításai.

Paraméter	Pilot	Előzetes vizsgálat	Fő vizsgálat
Időpont (2026)	szept. 23.	szept. 27–28.	okt. 7. – nov. 1.
Dokumentumok	1 (`hu-coffee`, 1 702 kar.)	9 (3 saját, 6 angol; konf.-ként 6)	30 (24 MILQA, 3 saját, 3 OpenStax)
Konfigurációk	10 (9 helyi + **E4**)	14 (11 helyi + 3 szerveres)	11 helyi (mindkét modellel)
Generátormodell	Qwen2.5-7B (**E4**: szerver)	Qwen2.5-7B; szerver (**B-doc-S**, **E4**, **E4b**)	PULI-LlumiX 8B; Gemma 3 12B
Ismétlések száma	3 mag (mindenhol)	3 mag (egyhívásos) / 1 mag (tervezett)	3 mag (egyhívásos) / 1 mag (tervezett)
Pontozott kérdések	300 (100 % bírált)	1 670 (100 % bírált)	PULI: 2 935; Gemma: 6 212*
Újrapróbálkozás (r)	2	1	1
Szivárgásszűrés, javítás	nincs	van	van
Bíró forrása	teljes dokumentum	forrásdarabok (**B-doc**: első 24 000 kar.)	forrásdarabok (**B-doc**: első 24 000 kar.)
GPU	RTX 3070 Ti (8 GiB)	RTX A4500 (20 GiB)	RTX A4500 (20 GiB)

Jelmagyarázat és megjegyzések: A *pontozott kérdések* a generált vizsgákból kiértékelésre került kérdések számát jelölik, zárójelben a bírói áttekintő ítélettel rendelkező kérdések arányával. *A fő vizsgálatban a bírói áttekintő ítélet a kérdések 29–65 %-ánál (a PULI egyhívásos konfigurációinál 70–100 %-ánál) áll rendelkezésre; a részletes megoszlást és az érzékenységvizsgálatot az 5.9. szakasz ismerteti.

konfiguráció hányszor lassabb a referenciánál (például az **E2** az **E0**-nál). Mivel a módszerek egymáshoz mért aránya a lényeg, a GPU típusa ezt érdemben nem befolyásolja; az abszolút perceket csak mellékesen közöljük. A pilot RTX 3070 Ti-n, az előzetes és a fő vizsgálat RTX A4500-on futott, ezért a szorzókat is mindig egy vizsgálaton belül számoljuk (5.8. szakasz).

4.5. Mutatók

Minden ráta 0 és 1 (0 és 100 %) közötti, és a szivárgás, a nem kérdő törzs és a duplikátumok kivételével a nagyobb érték a jobb. A tartalmi mutatók a bíró ítéletén alapulnak:

- **Alátámasztottság (G):** azon kérdések aránya, amelyeknél a forrás igazolja a megjelölt kulcsot (a bírónak az igazoló mondatot szó szerint idéznie kell).
- **Vak megoldhatóság (A):** azon kérdések aránya, amelyeket a bíró a kulcs ismerete nélkül, összekevert válaszokkal, csak a forrás alapján helyesen old meg – ez a kulcs helyességét és a kérdés egyértelműségét együtt méri.
- **Disztraktor-validitás (V):** kérdésenként azon disztraktorok átlagos aránya, amelyek a forrás szerint hamisak *és* témába vágók.
- **Formai megfelelés (F):** vizsgaszintű igen/nem érték – a vizsga pontosan a kért számú kérdést tartalmazza, és minden kérdésnek pontosan négy válasza és egy kulcsa van.

A négyet egy *minőségi indexbe* foglaljuk:

$$Q = \frac{F + G + A + V}{4}. \tag{4.1}$$

A Q szándékosan egyszerű, súlyozatlan átlag, amelyet vizsgánként számolunk; a sikertelen vizsga (értelmezhetetlen modellválasz) Q-ja 0, a technikai (szolgáltatás-) hibák kimaradnak. Egyetlen hibás formájú vagy hiányzó kérdés így a Q-t 0,25-tel csökkenti; ezt vállaljuk, mert egy hiányos vagy hibás kulcsú vizsga nem használható változtatás nélkül. A komponenseket külön is közöljük.

A bíró emellett négy szempontot 1–5 skálán pontoz (*helyesség*, *érthetőség*, *disztraktorok*, *szintillesztés*), és igen/nem ítéletet ad (*felhasználnám*: bekerülne-e egy valódi dolgozatba legfeljebb apró javítással). A rubrika (D. függelék) a bíró és az oktatók számára azonos, ami a bíró validálásának (5. hipotézis) előfeltétele. A *lefedettség* (A.2. egyenlet) a kérdésekhez legközelebbi különböző darabok aránya a dokumentum darabjai között (a **P2** probléma mérőszáma); mivel tíz kérdésnél legfeljebb $10/K$ (K a darabszám), csak azonos dokumentumon, konfigurációk között hasonlítható, és szerkezeti mutatóként a Q-ba nem számít bele. A *szivárgást* és a *nem kérdő törzset* ugyanazzal a szabállyal mérjük, mint az ellenőrző (3.4.6. szakasz; vö. 5.1. szakasz). A duplikátumráta, a meta-hivatkozás, a keresési találati arány (recall@3), a tematikus hasonlóság és a költségmutatók definíciója az A.3. függelékben található.

4.6. A bíró

A bíró a gpt-oss-120b [69] modell az egyetemi GenAI-szerveren, nulla hőmérséklettel és alacsony („low”) gondolkodási szinttel. Más modellcsaládba tartozik, mint bármelyik generátor (Qwen, Llama/PULI, Gemma), ami az önpreferencia torzításának [68] kockázatát csökkenti. Kérdésenként két hívást végez: az *áttekintő* hívás látja a kulcsot (alátámasztottság szó szerinti idézettel, disztraktoronkénti ítélet, rubrikapontok, megvalósult Bloom-szint, „felhasználnám”), a *vak* hívás nem, és permutált válaszokkal kell megoldania a kérdést.

Forrásként a bíró a kérdéshez tartozó darabokat kapja (a tervezett konfigurációknál a kérdéshely kontextusát, az **E0**-nál a visszakeresett darabokat), a megosztott szerver futásideje miatt nem a teljes dokumentumot; így a dokumentum más részeiben lévő ellentmondást nem látja. A teljes dokumentumos konfigurációknál a dokumentum első 24 000 karakterét kapja, ezért ott az alátámasztottság alsó becslés. A fő vizsgálatban a bíró szervere a kérések egy részére hibával válaszolt; a hiányzó áttekintő ítéletek aránya forrásonként és modellenként eltér (4.2. táblázat), a bírón alapuló mutatók csak az ítélettel rendelkező kérdésekre számolódnak, a hatást és egy érzékenységvizsgálatot az 5.9. szakasz mutatja be.

4.7. Oktatói értékelés

A bíró csak akkor érvényes mérőeszköz, ha ítéletei az emberi szakértőkével egyeznek (5. hipotézis). Az oktatói értékelés vak értékelőlapjait a keretrendszer állítja elő és dolgozza fel. A hat közös dokumentumon a három generátor **B-doc-L** és **E2** konfigurációjából 10–10 (összesen 60) vakon értékelt kérdést és 12 közös kalibrációs kérdést öt oktató pontozott a bíróéval azonos rubrika és forrásrészlet alapján; az egyezést Krippendorff-α-val [71], Spearman-korrelációval és Cohen-κ-val mérjük (részletek: A.3. függelék). Az eredményeket az 5.10. szakasz közli.

4.8. Statisztikai elemzés

Az elemzés egysége a dokumentum. Egy vizsga tíz kérdése nem független: ugyanabból a dokumentumból, egy futáson belül készül, így független megfigyelésként kezelve a próbák a valósnál biztosabbnak mutatnák az eredményt. Ezért minden mutatót előbb dokumentumon belül átlagolunk (a kérdésekre és a magokra); a konfigurációnkénti érték a dokumentumonkénti átlagok átlaga. Bizonytalanságát *bootstrap*-módszerrel [99] becsüljük: a dokumentumokból 10 000-szer húzunk visszatevéssel, és a kapott átlagok középső 95 %-a adja a 95 %-os konfidenciaintervallumot.

Páros összehasonlítás és többszörös tesztelés. Két konfigurációt a páros Wilcoxon-féle előjeles rangpróbával [100] vetünk össze, amely a dokumentumonkénti különbségek rangjaival dolgozik, és nem feltételez normális eloszlást (ez a plafonhoz közeli rátáknál lényeges); a hatás nagysága a rangbiszeriális korreláció [101] (A.3. egyenlet, A.3. függelék), amely +1, ha az új konfiguráció minden dokumentumon jobb, és -1, ha mindenütt rosszabb. A hat előre rögzített összehasonlítás p-értékeit Holm módszerével [75] korrigáljuk (a legkisebbet 6-tal, a következőt 5-tel stb. szorozva; szignifikáns, ami korrekció után 0,05 alatt marad, és minden nála kisebb is). A Wilcoxon-próba legkisebb elérhető p-értéke hat dokumentumnál 0,031, korrekció után 0,19 (levezetés: A.3. függelék): a pilot ezért csak leíró, az előzetes vizsgálatban egyetlen összevetés sem lehet korrekció után szignifikáns, a fő vizsgálat 30 dokumentumán viszont a szignifikancia elérhető.

Egyezés és az ellenőrző mint osztályozó. Két igen/nem ítéletsor (például az ellenőrzőé és a bíróé) egyezését Cohen-κ-val [70] mérjük (A.4. egyenlet; $\kappa = 0$ a véletlen szintje, $\kappa = 1$ a teljes egyezés, az értelmezés Landis és Koch [72] skáláját követi). Az ellenőrző minden kérdést *átengedett* vagy *megjelölt* kategóriába sorol; a bíró alátámasztottsági ítéletét referenciának tekintve pontosságot és felidézést számolunk (A.5. egyenlet). Hasznos ellenőrzőtől mindkettő magas értéke és $\kappa \gg 0$ várható; $\kappa \approx 0$ esetén a jelzése az oktatónak nem hordoz információt.

A fejezet tanulsága. Az egytényezős konfigurációk, a forráshoz mért mutatók, a független, de maga is ellenőrzött bíró és a dokumentumot egységnek tekintő statisztika együtt teszik lehetővé, hogy egy különbséget egyetlen tényezőnek tulajdonítsunk, és lássuk, mikor nem szignifikáns; a két összevetési szabály a vizsgálatok eltérő dokumentumaiból és hardveréből adódó torzítást

zárja ki. A következő két fejezet ezzel értékeli a módszer lépéseit (5. fejezet) és a modelleket (6. fejezet).

5. Eredmények: a módszer komponensei

Ez a fejezet azt mutatja meg, hogy a generálási módszer egyes lépései – a vizsgaterv, az ellenőrző lánc, a darabolás és a keresés – mennyit javítanak a kérdések minőségén, és mennyibe kerülnek: melyik hatás szignifikáns, miért törékeny a naiv RAG és mi javítja, hányszor drágább a tervezett folyamat, és mennyire megbízható maga a mérés. A generátormodellek összevetése a 6. fejezetben, az értelmezés a 7. fejezetben következik. A részletes táblázatok kiegészítő adatait a B. függelék tartalmazza.

5.1. A pilot tanulságai

A pilot a mérési láncot próbálta ki egyetlen rövid magyar szövegen, a Qwen2.5-7B modellel és tíz konfigurációval (egy dokumentumon semmilyen különbség nem lehet szignifikáns, 4.8. szakasz; részletek: B.1. függelékszakasz). Három tanulsága alakította a módszert:

(1) A mérés több ponton *csendesen*, felfelé torzított (hiányos végső kérdések, sikertelen hívásoknál visszaadott tartalékvizsga, valamint a tartalomtól függetlenül vágó kódoló; 3.4.1. szakasz); mindhárom hibát javítottuk, a kódoló hatását az **E5a** méri.

(2) Egy új hibamódot, a *válaszszivárgást* találtuk: egyes ellenőrzött „kérdések" egy forrásmondatot másoltak a törzsbe és a kulcsba is, a bíró mégis jónak pontozta őket. Értelmezésünk szerint az ellenőrző visszacsatolása a kis modellt a forrás szó szerinti átvétele felé tolta – a Goodhart-törvény [55] példája –, ezért a szivárgást és a nem kérdő törzset azóta az ellenőrző lánc szabályként elutasítja, és mutatóként is mérjük.

(3) A futásról futásra jelentkező *zaj* két azonos kontextust kapó konfiguráció között 0,07 volt, mert a GPU-n végzett következtetés rögzített maggal sem bitre reprodukálható; ezért futott a fő vizsgálat 30 dokumentumon.

5.2. Az előzetes vizsgálat: a módszer egy 7B modellel

Az előzetes vizsgálat a javított folyamattal, a Qwen2.5-7B modellel futott hat dokumentumon, mind a 11 helyi konfigurációval (B.1. táblázat, B.2. függelékszakasz; a szerveres konfigurációk a 6.2. szakaszban). A tervezett és ellenőrzött folyamat (**E2**, 0,96) itt is jobb volt a naiv RAG-nál (0,64) és a teljes dokumentumos promptnál (0,83), és a legrobusztusabb is. A naiv RAG az angol szövegeken omlott össze, a darabolás javítása viszont nagyrészt helyrehozta (5.5. szakasz). Hat dokumentumon Holm-korrekció után egyetlen összevetés sem lehet szignifikáns, ezért a fő vizsgálat 30 dokumentumon és két másik helyi modellel futott.

5.3. A fő vizsgálat: összesített eredmények

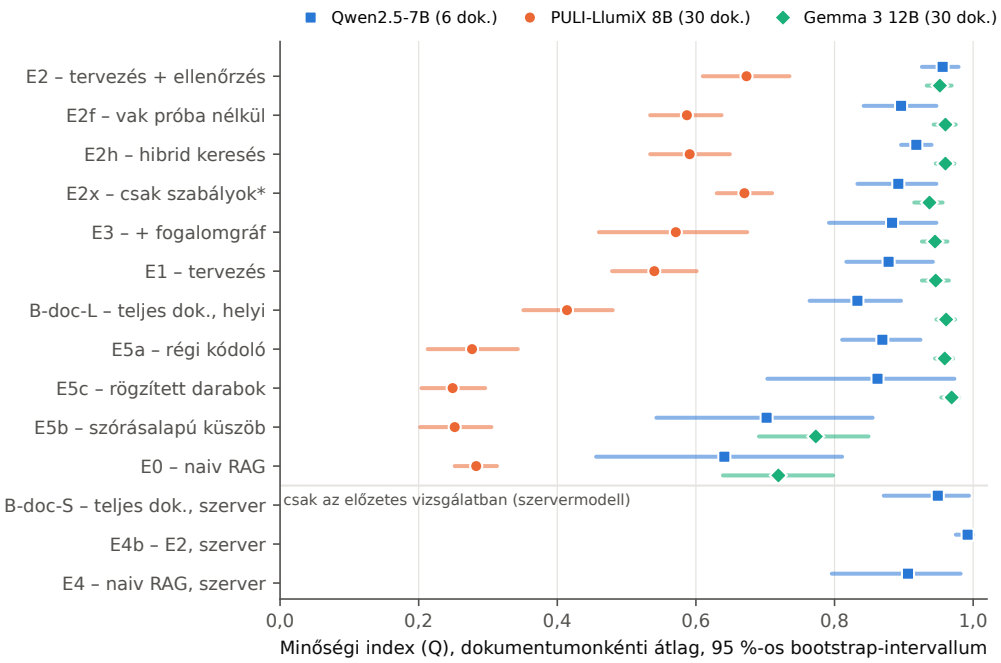
A fő vizsgálat 30 dokumentumon (24 magyar Wikipédia-cikk, három saját magyar és három angol OpenStax-szöveg) futtatta a 11 helyi konfigurációt mindkét modellel. A PULI-LlumiX 8B 2 935, a Gemma 3 12B 6 212 kérdést írt; a különbség oka, hogy a PULI az egyhívásos konfigurációkban a kért tíz kérdés töredékét adta vissza (6.3. szakasz). Az 5.1. táblázat a konfigurációnkénti eredményeket, az 5.1. ábra a minőségi indexet mindhárom helyi modellre mutatja.

5.1. táblázat. A fő vizsgálat összesített eredményei modellenként és konfigurációnként (30 dokumentum).

	PULI-LlumiX 8B						Gemma 3 12B							
Konfig.	*Q*	95 % KI	*F*	*G*	*A*	*V*	*Q*	95 % KI	*F*	*G*	*A*	*V*	Perc	Hívás
Alapvonalak														
B-doc-L	0,41	0,35–0,48	3	48	**82**	32	0,96	0,95–0,97	**100**	93	96	95	0,6	1
E0	0,28	0,25–0,31	1	27	79	9	0,72	0,64–0,80	**100**	46	87	57	0,6	1
A javasolt módszer lépései														
E1	0,54	0,48–0,60	47	58	62	49	0,95	0,93–0,96	**100**	88	97	93	2,9	14
E2	**0,67**	0,61–0,73	87	52	62	**66**	0,95	0,93–0,97	**100**	86	**99**	**96**	4,9	43
E3	0,57	0,46–0,67	80	**67**	51	60	0,94	0,93–0,96	**100**	92	96	90	6,1	56
Kiegészítő ablációk														
E2f	0,59	0,53–0,64	80	47	52	55	0,96	0,94–0,97	**100**	91	97	**96**	3,9	28
E2h	0,59	0,53–0,65	77	47	53	59	0,96	0,95–0,97	**100**	92	97	95	4,6	42
E2x*	**0,67**	0,63–0,71	**93**	48	62	64	0,94	0,92–0,96	**100**	87	94	94	7,4	15
*Darabolási változatok (az **E0** módosításai)*														
E5a	0,28	0,21–0,34	6	41	72	32	0,96	0,94–0,97	98	**96**	97	93	0,6	1
E5b	0,25	0,20–0,30	4	29	76	18	0,77	0,69–0,85	**100**	56	86	69	0,6	1
E5c	0,25	0,20–0,30	3	28	76	22	**0,97**	0,95–0,98	**100**	**96**	96	95	0,6	1

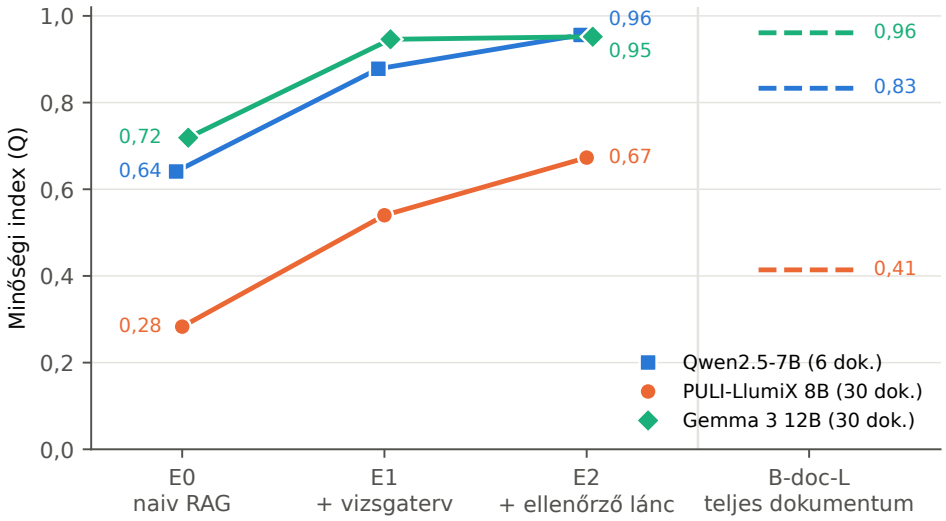
Jelmagyarázat: *Q*: összesített minőségi index; **95 % KI**: 95 %-os bootstrap-konfidenciaintervallum; *F*: formai megfelelés (%); *G*: forrás-alátámasztottság (%); *A*: vak megoldhatóság (%); *V*: disztraktor-validitás (%). **Perc**, **Hívás**: kizárólag a Gemma 3 12B medián futási ideje (RTX A4500 GPU-n) és modellhívásainak száma vizsgánként (mindhárom modell relatív költségét az 5.4. táblázat közli). A **félkövér** értékek modellenként az adott oszlop legjobb eredményét, a **zöld kiemelés** a legmagasabb minőségi indexet (*Q*) jelöli. *Az **E2x**-ben a második modell ellenőrző hívásai hibával tértek vissza, így csak a szabályalapú ellenőrzés futott.

A két modell két egészen különböző képet ad. A **PULI-LlumiX** egyhívásos konfigurációi szinte teljesen elbuknak (formai megfelelés 1–6 %, $Q \leq 0{,}41$), és a módszer lépései fokozatosan javítanak: a naiv RAG-hoz képest a tervezés 0,28-ról 0,54-re, az ellenőrzés 0,67-re emeli a minőségi indexet, a teljes dokumentumos promptnál (0,41) is jóval jobb eredménnyel. A **Gemma 3 12B** viszont szinte minden konfigurációban 0,94–0,97 között teljesít: a teljes dokumentumos prompt (0,96) és a rögzített darabolású naiv RAG (**E5c**, 0,97) legalább olyan jó, mint a tervezett folyamat (0,95). Ennél a modellnél csak a szemantikus darabolású naiv változatok maradnak el (**E0**: 0,72, **E5b**: 0,77). Az 5.2. ábra a három helyi modell lépésenkénti útját mutatja: a vizsgaterv minden modellnél nagyot lép előre a (szemantikus darabolású) naiv RAG-hoz képest,



5.1. ábra. A minőségi index konfigurációnként és generátormodellenként, 95 %-os bootstrap-intervallummal. A Qwen2.5-7B az előzetes vizsgálat hat dokumentumán, a másik két modell a fő vizsgálat 30 dokumentumán futott, ezért a modellek az ábrán nem közvetlenül összevethetők; az azonos dokumentumokon végzett összevetést a 6.1. szakasz közli. A szerveres konfigurációk csak az előzetes vizsgálatban futottak.

az ellenőrzés a gyengébb modelleknél ad hozzá, a teljes dokumentumos prompt pedig annál jobb, minél erősebb a modell.



5.2. ábra. A minőségi index a módszer lépései szerint (naiv RAG → vizsgaterv → ellenőrző lánc) és a teljes dokumentumos prompt (szaggatott vonal) a három helyi modellel (Qwen2.5-7B: hat, a másik kettő: 30 dokumentum). Minél gyengébb a modell, annál nagyobb a módszer haszna.

5.4. A komponensek hatása

Az 5.2. táblázat az előre rögzített hat páros összehasonlítást mutatja a fő vizsgálat két modelljére; a Qwen2.5-7B (hat dokumentum) értékeit a szövegben közöljük.

5.2. táblázat. Az előre rögzített hat páros összehasonlítás statisztikai próbái (fő vizsgálat, 30 dokumentum).

	PULI-LlumiX 8B				**Gemma 3 12B**			
Összevetés	Δ	r_{rb}	J/R	$\tilde{p}$	Δ	r_{rb}	J/R	$\tilde{p}$
Tervezés (**E1**–**E0**)	**+0,26**	0,97	27/2	**< 0,001**	**+0,23**	0,76	22/7	**0,002**
Ellenőrzés (**E2**–**E1**)	+0,13	0,48	19/10	0,066	+0,01	0,12	15/13	1,00
Teljes módszer (**E2**–**E0**)	**+0,39**	1,00	29/1	**< 0,001**	**+0,23**	0,82	23/6	**< 0,001**
Módszer vs. teljes dok. (**E2**–**B-doc-L**)	**+0,26**	0,83	24/5	**< 0,001**	−0,01	−0,04	16/13	1,00
Csak szabályok (**E2x**–**E2**)	0,00	0,01	14/16	0,975	−0,02	−0,12	14/15	1,00
Fogalomgráf (**E3**–**E2**)	−0,10	−0,18	15/15	0,775	−0,01	−0,20	9/16	1,00

Jelmagyarázat: Páros Wilcoxon-próbák a dokumentumonkénti minőségi indexen (Q). Δ: az elsőként megjelölt (új) és a második (referencia) konfiguráció átlagos Q-különbsége; r_{rb}: rangbiszeriális korreláció (hatásméret); **J/R**: hány dokumentumon javított (J), illetve rontott (R) az új konfiguráció (a 30-ból); $\tilde{p}$: a hat előre rögzített összevetésre Holm-eljárással korrigált p-érték. A **zöld kiemelés** és a félkövér szedés a statisztikailag szignifikáns ($\tilde{p} < 0{,}05$) hatásokat jelöli.

Tervezés. A vizsgaterv mindkét modellnél nagy és Holm-korrekció után is szignifikáns javulást hozott a naiv RAG-hoz képest; a Qwennél ugyanez +0,24 volt (négy javult, kettő romlott, $p = 0{,}22$). A referencia azonban a szemantikus darabolású **E0**, és az **E1** több tényezőben is eltér tőle (vizsgaterv, kérdéshelyenkénti lekérdezés, kérdésenkénti generálás); e kitétel következményét az 5.5. és a 7.1. szakasz tárgyalja.

Ellenőrzés. Az ellenőrző lánc hatása a modelltől függ, és Holm-korrekció után egyik modellnél sem szignifikáns: a Qwennél öt dokumentumon javított és egyen sem rontott (+0,08, $\tilde{p} = 0{,}19$), a PULI-nál korrigálatlanul $p = 0{,}022$, a Gemmánál a hatás gyakorlatilag nulla. A PULI-nál a javulás főként a formából (F: 47 %→87 %) és a disztraktorokból (V: 49 %→66 %) ered; az alátámasztottság a fő vizsgálatban mindkét modellnél kissé csökkent (PULI: 58 %→52 %, Gemma: 88 %→86 %), a Qwennél nőtt (80 %→90 %).

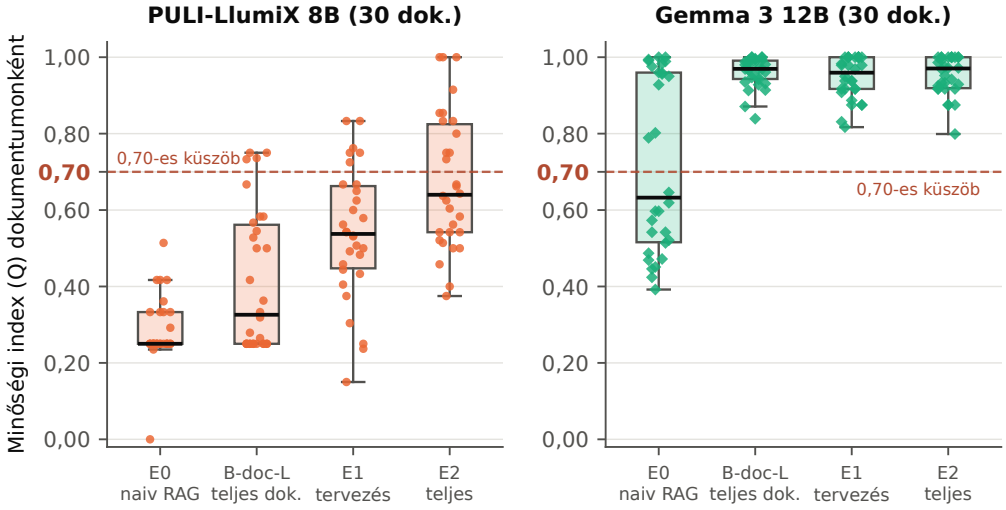
Vak próba. A vak megoldási próba elhagyása (**E2f**) a PULI-nál rontott (−0,09, 21 dokumentumon rosszabb, korrigálatlan $p = 0{,}014$), a Qwennél is (−0,06, egy javult, négy romlott, $p = 0{,}13$), a Gemmánál nem (+0,01, $p = 0{,}48$); az összevetés leíró jellegű.

Ellenőrző modell (E2x). A második modell (Llama-3.1-8B) ellenőrző hívásai mindkét vizsgálatban hibával tértek vissza (88, illetve 394 és 405 kihagyott ellenőrzés), így az **E2x** a „csak szabályalapú ellenőrzés” változatot mérte; a független ellenőrző kérdése nyitott maradt. Ez a PULI-nál és a Gemmánál nem tért el érdemben a teljes **E2**-től, a Qwennél rosszabb volt (0,89 vs. 0,96; egy javult, öt romlott, $\tilde{p} = 0{,}25$): a PULI-nál a lánc hasznát értelmezésünk szerint főként a szabályok adják.

Fogalomgráf és hibrid keresés. A fogalomgráf (**E3**) egyik modellnél sem érte meg a többletköltségét (a Qwennél −0,07, egy javult, öt romlott), miközben a vizsgánkénti hívásszám 55–80 lett a 43–61 helyett (5.4. táblázat). A hibrid keresés (**E2h**) sem javított: a PULI-nál −0,08 (korrigálatlan $p = 0{,}061$), a Qwennél −0,04, a Gemmánál +0,01.

5.5. Darabolás és robusztusság

A robusztusság azt méri, mekkora a kudarc esélye egy új dokumentumon (5.3. ábra). A Gemmával a tervezett konfigurációk, a teljes dokumentumos prompt és az **E5a**, **E5c** egyetlen dokumentumon sem estek 0,79 alá (a leggyengébb dokumentum az **E2**-nél 0,799, az **E2x**-nél 0,798, a többinél 0,80–0,88), a naiv RAG viszont 16 dokumentumon 0,70 alatt maradt, a leggyengébben 0,39-en; az **E5b** 11 dokumentumon maradt 0,70 alatt.



5.3. ábra. A minőségi index dokumentumonkénti eloszlása a fő vizsgálatban (pontok: egy-egy dokumentum; doboz: interkvartilis tartomány, vastag vonal: medián). A pontozott vonal a 0,70-es szint.

A naiv RAG törékenységének oka. A hiba nem a keresésben van: a referenciakérdésekkel végzett próbában az igazoló mondatot tartalmazó darab a fő vizsgálatban a kérdések 86 %-ánál (az előzetes vizsgálatban 93 %-ánál) az első három találat között volt, és ez az arány a rögzített darabolással sem változott érdemben (Gemma **E5c**: 86 %). A hiba a *lekérdezésben* van, amely nem tartalmi kérdés, hanem egy feladatleírás („10 feleletválasztós kérdés, könnyű nehézség”). A Wikipédia-cikkek és az OpenStax-szövegek rövid szerkezeti sorokat (címeket, „Link to Learning”-dobozokat) tartalmaznak, amelyeket a szemantikus darabolás minimális darabméret nélkül önálló darabbá vág, és a tartalom nélküli lekérdezés éppen ezekhez a tartalom nélküli darabokhoz áll a legközelebb. A Gemma ilyenkor magáról a feladatról kérdez: egy, a sclerosis multiplexről szóló cikkből például ezt írta: „Mi a nehézségi szint a vizsgának? [sic!]”, kulcsa: „Kezdő (könnyű).” A rögzített, 800 karakteres darabolás (**E5c**) ilyen darabot nem hoz létre. Valószínűleg ugyanez magyarázza, hogy a „hibás” régi kódoló (**E5a**) is javít: hosszabb dokumentumon az 512. token után már csak a darab hossza szerint vág (3.4.1. szakasz). A magasabb vágási küszöb (**E5b**) a

rövid darabokat nem szünteti meg, és csak kicsit javít.

5.3. táblázat. A darabolási változatok hatása a naiv RAG (**E0**) minőségi indexére.

	Qwen2.5-7B (6 dok.)			**PULI-LlumiX 8B** (30 dok.)			**Gemma 3 12B** (30 dok.)		
Változat	Δ	J/R	*p*	Δ	J/R	*p*	Δ	J/R	*p*
E5a (régi kódoló)	+0,23	5/1	0,16	−0,01	15/14	0,74	**+0,24**	23/5	**< 0,001**
E5b (magasabb küszöb)	+0,06	5/1	0,22	−0,03	6/12	0,20	+0,05	18/12	0,15
E5c (rögzített, 800 kar.)	+0,22	4/2	0,22	−0,03	9/17	0,22	**+0,25**	23/7	**< 0,001**

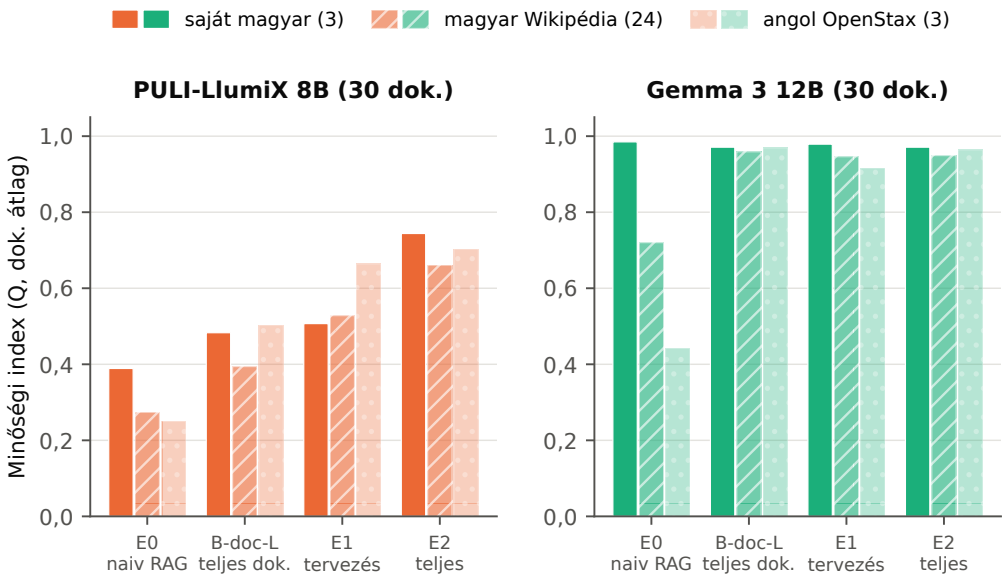
Jelmagyarázat: Az **E5a**–**E5c** darabolási változatok és az alapértelmezett szemantikus darabolású naiv RAG (**E0**) páros Wilcoxon-összevetése. Δ: a minőségi index (Q) változása az **E0**-hoz képest; **J/R**: a javult, illetve romlott dokumentumok száma; p: korrigálatlan p-érték (leíró jellegű összevetések, nem tartoznak az előre rögzített hat hipotézis közé). A **zöld kiemelés** a $p < 0{,}001$ szintű javulást jelöli; az abszolút Q-értékeket az 5.1. és a B.1. táblázat közli.

A három modell. A darabolás javítása a modell képességeitől függően eltérő hatású (5.3. táblázat):

– **Gemma 3 12B:** *Kiemelendő eredmény, hogy a Gemmánál a rögzített darabolású naiv RAG (**E5c**) a legjobb konfiguráció (*0,97*), és egyben a leggyorsabb is* (ideje az **E0**-éval azonos, az **E2** viszont 8,5-szer annyi ideig fut; 5.4. táblázat), továbbá egyetlen dokumentumon sem maradt 0,70 alatt. Az **E2**-től (0,95) és a teljes dokumentumos prompttól (0,96) való különbsége azonban kicsi, a konfidenciaintervallumok átfednek, és ezt az összevetést nem teszteltük.
– **Qwen2.5-7B:** A régi kódoló (**E5a**) és a rögzített darabolás (**E5c**) az **E0** 0,64-es értékéhez képest 0,87-et, illetve 0,86-ot ért el, hat dokumentumon nem szignifikánsan; az **E5c** itt nem is robusztus (leggyengébb dokumentuma 0,50, a törzsek 44 %-a nem kérdés), és mindkét változat elmarad az **E2**-től (0,96).
– **PULI-LlumiX 8B:** A darabolás nem segít (nem szignifikáns): a darabolási változatok formai megfelelése 3–6 %, a szűk keresztmetszet a formátumkövetés (6.3. szakasz; az érzékenységvizsgálatban a különbség kissé nagyobb, 5.9. szakasz).

A „vizsgaterv javít a naiv RAG-hoz képest” állítás tehát a szemantikus darabolású, három darabot visszakereső **E0**-ra igaz. Hogy a tervezett folyamat *nem függ* a darabolástól, azt nem mértük, mert az **E5a**–**E5c** csak az **E0**-t változtatta; elvárásunk szerint a függés kicsi, mert a tervezett folyamat kérdéshelyenként tartalmi lekérdezéssel keres, de ennek ellenőrzése (az **E2** rögzített darabolással) további munka.

Az 5.4. ábra ugyanezt forrásonként mutatja: a Gemma naiv RAG-ja a három rövid saját szövegen kiváló (0,99), a Wikipédia-cikkeken 0,72-re, az angol tankönyvi szövegeken 0,44-re esik, miközben a többi bemutatott konfiguráció minden forráson 0,91 felett marad (a legalacsonyabb az **E1** az angol szövegeken, 0,916). Az angol részhalmaz mindössze három dokumentum, ezért nyelvi összevetésre nem elegendő.



5.4. ábra. A minőségi index dokumentumforrásonként a fő vizsgálat négy fő konfigurációjában. Zárójelben a dokumentumok száma.

5.6. Az ellenőrző működése

Az **E2** ellenőrző láncának részletes mutatóit a B.2. táblázat (B.3. függelékszakasz) közli; az ellenőrzőt bináris osztályozóként is értékeltük, a bíró alátámasztottsági ítéletéhez képest (4.8. szakasz). A leggyakoribb elutasítási ok minden modellnél a *duplikátum*: tíz egymástól eltérő kérdés megírása egy rövid szövegből a kis modellek számára nehéz. Az ellenőrző terhelése a modell gyengeségét tükrözi: a kérdéshelyek első kísérletre a Gemmánál 70 %-ban, a Qwennél 23 %-ban, a PULI-nál 5 %-ban mentek át, így a Gemmánál a láncnak alig van mit javítania. Az ellenőrző kérdésenkénti ítélete a végső vizsgákon egyik modellnél sem egyezik a bíróéval a véletlennél érdemben jobban (κ = 0,00–0,08), mert az ellenőrző az elutasított kérdéseket már futás közben újrageneráltatta, így a végső vizsgában csak a minden próbálkozáson elbukott kérdéshelyek maradnak megjelölve (előszűrt minta); ennek értelmezését a 7.5. szakasz adja.

5.7. Lefedettség, kognitív szint és felhasználhatóság

A részletes, modellenkénti értékeket a B.4. függelékszakasz közli; itt a Gemma alapján összegzünk. A tervezett folyamat több darabot fed le, mint a naiv RAG (24 %→43 %), de nem többet, mint a teljes dokumentumos prompt (43 %): a kérdések egy szakaszra tömörülése a naiv RAG sajátja. A vizsgaterv a kérdések 43–45 %-át tervezte magasabb rendű Bloom-szintre, de a bíró szerint ebből a Gemmánál csak 7–11 %, a PULI-nál 0–2 % valósult meg: a kiosztás a *kért* szintet garantálja, a megvalósultat nem. A bíró „felhasználnám” ítélete a Gemma tervezett konfigurációiban 85–88 %, a naiv RAG-nál 42 %, a PULI **E2**-ben 29 %; a tervezett folyamat jellemzően hosszabb, összefüggést kérdező törzset ír.

5.8. Költség: relatív szorzók

A futási időt relatív szorzóként közöljük: egy konfiguráció medián vizsgaideje hányszorosa *ugyanazon modell* naiv RAG-jának (**E0**) ugyanazon a kártyán (5.4. táblázat). Mivel mindkét oldalon ugyanaz a modell, kvantálás és kontextus szerepel, a szorzót főként a hívások száma és hossza határozza meg, ezért a GPU típusa érdemben nem befolyásolja (csak az abszolút időt).

5.4. táblázat. A konfigurációk relatív futási ideje és modellhívásainak száma.

	Qwen2.5-7B		**PULI-LlumiX 8B**		**Gemma 3 12B**	
Konfiguráció	×**E0**	Hívás	×**E0**	Hívás	×**E0**	Hívás
Egyhívásos konfigurációk						
E0	1,0	1	1,0	1	1,0	1
B-doc-L	1,2	1	1,1	1	1,0	1
E5a	1,1	1	1,4	1	1,0	1
E5b	1,0	1	0,9	1	1,0	1
E5c	1,1	1	1,3	1	1,0	1
Tervezett folyamat						
E1	5,9	18	426†	24	5,0	14
E2	10,9	51	52,3	60,5	8,5	43
E2f	9,0	37	46,7	40	6,8	27,5
E2h	11,8	55	52,3	55,5	8,0	42
E2x*	23,9	20	76,2	33	12,8	14,5
E3	17,4	54,5	74,3	80	10,6	55,5
*Referencia: **E0** abszolút medián ideje (perc)*	0,32	–	0,23	–	0,58	–

Jelmagyarázat: ×**E0**: a konfiguráció medián vizsgaideje az azonos modell **E0** konfigurációjának hányszorosa (RTX A4500 GPU-n; Qwen2.5-7B: előzetes vizsgálat, 6 dokumentum; PULI-LlumiX 8B és Gemma 3 12B: fő vizsgálat, 30 dokumentum). **Hívás**: medián modellhívásszám vizsgánként. †Kiugró érték: a PULI **E1** futásában 103 modellhívás időtúllépéssel vagy hibával zárult, így a medián vizsgaidő 96 perc lett (6.3. szakasz). *Az **E2x**-ben a második modell sikertelen ellenőrző hívásai a hívásszámban nem, az időben feltehetően szerepelnek (5.4. szakasz).

A Gemmánál az egyhívásos konfigurációk – köztük a legjobb **E5c** – az **E0**-val azonos idő alatt futnak, az **E1** kb. ötször, az **E2** 8,5-ször, az **E3** 10,6-szor annyi ideig; a Qwennél a tervezett konfigurációk szorzója 6–17. A vak próba elhagyása (**E2f**) a Gemmánál az **E2** idejének kb. 80 %-ára csökkenti a költséget, minőségvesztés nélkül. A PULI szorzói azért kiugróak (47–76×), mert az **E0**-ja átlagosan csak 1,8 kérdést ír (6.4. szakasz). Abszolút értékben a tervezett folyamat a Gemmával vizsgánként 3–7 percig fut (5.1. táblázat).

5.9. A mérés megbízhatósága

Hiányzó bírói ítéletek. A fő vizsgálatban a bíró szervere a kérések egy részére hibával válaszolt (HTTP 400, újrapróbálás után is; az előzetes vizsgálatban ilyen hiba nem fordult elő). Az áttekintő ítélet a tervezett konfigurációkban a kérdések 29–52 %-ánál van meg (a PULI **E2**-

ben 85 kérdésnél), és a hiány *nem független a forrástól*: a Gemmánál az angol és a saját magyar szövegekből írt kérdések szinte mind kaptak ítéletet, a Wikipédia-kérdéseknek viszont csak 42–55 %-a, a dokumentum hossza szerint pedig nincs érdemi különbség; a PULI-nál a lefedettség minden forráson alacsony (B.3. táblázat, B.5. függelékszakasz). A szerver tehát a Wikipédia-kérdések egy részét elutasította; ennek oka nem ismert. Óvatos feltevésként felmerül egy szerveroldali tartalomszűrő, ezt azonban nem ellenőriztük. Ha egy vizsga minden bírói hívása sikertelen, a vizsgaszintű Q csak a formai megfelelésre (és a vak próbára) támaszkodik.

Érzékenységvizsgálat. A hiányzó ítéletek hatását úgy ellenőriztük, hogy az alátámasztottságot, a vak megoldhatóságot és a disztraktor-validitást a vizsgák helyett dokumentumonként, az összes bírált kérdésre összevonva számoltuk újra (Q_{pooled}):

(1) **Gemma 3 12B (minden konfiguráció) és PULI-LlumiX 8B (tervezett folyamat):** A minőségi index legfeljebb 0,01-es értékkel tér el az alapértelmezett számítástól, így a fő következtetések és összevetések teljesen érzéketlenek a hiányzó ítéletekre.

(2) **PULI-LlumiX 8B (egyhívásos konfigurációk):** Az eltérés – az **E0** kivételével (0,00) – 0,03–0,08 (**B-doc-L**: 0,03, **E5b**: 0,05, **E5a** és **E5c**: 0,08), ami a darabolási változatok egymás közti sorrendjét megfordítja (összevont számítással: **E5a** 0,36, **E5c** 0,33, **E5b** 0,30, **E0** 0,28). A darabolás hatása a PULI-nál ezért bizonytalan, de mindegyik egyhívásos változat 0,45 alatt marad, messze a tervezett folyamat (**E2**: 0,67) mögött.

A bíró vakfoltja. A teljes dokumentumos konfigurációknál a bíró a dokumentumnak csak az első 24 000 karakterét látja (4.6. szakasz), ezért ezek alátámasztottsága a hosszú dokumentumokon alsó becslés (példa: B.5. függelékszakasz).

5.10. Az oktatói értékelés

Öt oktató értékelte vakon ugyanazt a 72 kérdést (12 kalibrációs és 60 értékelendő; 4.7. szakasz): a hat közös dokumentumon (3 magyar, 3 angol) a három generátor teljes dokumentumos (**B-doc-L**) és teljes folyamatú (**E2**) konfigurációjából 10–10 kérdést. Négy oktató mind a 72 kérdést kitöltötte, egy 34-et, így a 60 értékelendő kérdésre 269 értékelés jutott (kérdésenként 4–5). Az elemzés a 60 értékelendő kérdésen történt; a kalibrációs kérdésekkel együtt az α-értékek legfeljebb 0,02-es értékkel térnek el.

Az oktatók egymás között. Krippendorff határát ($\alpha \geq 0{,}667$) csak a helyesség éri el (0,69; 5.5. táblázat); az érthetőség és a disztraktorok egyezése közepes, a szintillesztésé gyenge. A helyesség tehát a forrásrészlet alapján egyértelműen eldönthető, a többi szempont azonban az oktatók számára is részben szubjektív; a legkevésbé egyértelműnek a kért nehézség és a Bloom-szint megfeleltetése bizonyult. Az egyezés értékelőpáronként erősen szór (helyességen 0,27–0,95): három oktató egymással nagyon erősen egyezik (0,88–0,95), a másik kettő velük és egymással is gyengébben (0,27–0,64). Az oktatók szigora is eltér: a 60 kérdés 25–62 %-át használnák fel.

5.5. táblázat. Az oktatók egymás közötti és a bíróval való egyezése (60 kérdés, 5 oktató).

	Oktatók egymás közt		**Bíró és oktatók egyezése**		**Átlag / arány**	
Szempont	α_{okt}	95 % KI	ρ	α_{b} / κ	Oktatói átlag	Bírói átlag
Helyesség	**0,69**	0,58–0,79	**0,65**	**0,62**	3,71	4,10
Érthetőség	0,59	0,44–0,70	0,44	0,16	3,69	4,65
Disztraktorok	0,47	0,33–0,59	0,41	0,37	3,29	3,90
Szintillesztés	0,39	0,25–0,52	0,28	0,11	3,58	4,45
A négy szempont átlaga	–	–	0,63	–	3,57	4,28
Felhasználnám	0,45	0,31–0,58	–	κ = 0,46	45 %	70 %

Jelmagyarázat: α_{okt}: az oktatók egymás közötti Krippendorff-α együtthatója (az 1–5 skálás szempontoknál ordinális, a „Felhasználnám” sorban nominális); **95 % KI**: 95 %-os bootstrap-konfidenciaintervallum; ρ: a bíró pontszámának és az oktatói átlagnak a Spearman-korrelációja (minden szempontnál $p < 0{,}03$); α_{b}: a bíró és a kerekített oktatói medián Krippendorff-α-ja; κ: a „Felhasználnám” sorban a bíró és az oktatói többség Cohen-κ-ja. Az átlagok az 1–5 skálán értendők, a „Felhasználnám” sorban pedig az „igen” válaszok arányát (oktatóknál a többségi ítéletet) jelzik. A **zöld kiemelés** a Krippendorff-féle megbízhatósági határt ($\alpha \geq 0{,}667$) elérő egyezést jelöli.

A bíró és az oktatók. A bíró a kérdéseket az oktatókhoz hasonló *sorrendbe* állítja (helyességen ρ = 0,65, a négy szempont átlagán 0,63, $p < 0{,}001$), de a pontszámai abszolút értékben nem egyeznek: a bíró és az oktatói medián α-ja a helyességen 0,62 (95 % KI: 0,38–0,80), a többi szempontnál 0,11–0,37. A bíró egyetlen oktatóval átlagosan gyengébben egyezik, mint két oktató egymással (helyességen 0,53 és 0,64, érthetőségen 0,22 és 0,54). Az eltérés oka főként a *bíró engedékenysége*: minden szempontban magasabbra pontoz (+0,4–1,0 pont), és a hiba egyirányú. A bíró a kérdések 83 %-át ítélte alátámasztottnak, az oktatók többsége 67 %-ukat helyesnek (≥ 4; κ = 0,49); az oktatók szerint nem helyes 20 kérdésből a bíró 11-et alátámasztottnak tartott, fordítva csak egy eset fordult elő. A felhasználnám ítéletnél a bíró és az oktatói többség κ-ja (0,46) megegyezik két oktató átlagos κ-jával (0,45), de a bíró a kérdések 70 %-át használná fel, az oktatók 45 %-ukat: 16 kérdést csak a bíró, egyet pedig csak az oktatók fogadnának el. A két nyelven a bíró hasonlóan teljesít (a négy szempont átlagán ρ = 0,62 a magyar és 0,59 az angol kérdéseknél), az oktatók a magyar kérdéseket gyengébbnek látták (3,32 és 3,80).

Minőség konfigurációnként. Az oktatók szerint is a Gemma a legjobb és a PULI messze a leggyengébb generátor (5.6. táblázat); a hat konfiguráció sorrendje a bíróéval ρ = 0,77-tel egyezik. A bíró engedékenysége a gyenge modellnél a legnagyobb: a PULI kérdéseire 1,1–1,4 ponttal ad többet, mint az oktatók, a Gemmánál 0,4 ponttal. A teljes folyamat (**E2**) az oktatói átlagon mindhárom generátornál a teljes dokumentumos prompt fölött van (+0,08, +0,25, +0,24), ami iránya szerint megfelel a bírói mérésnek, de konfigurációnként tíz kérdésen egyik különbség sem szignifikáns (Mann–Whitney-próba, $p \geq 0{,}47$), és a PULI felhasználhatósági aránya **E2**-vel sem nőtt.

Következmény a mérésre. A bíró a konfigurációk és a modellek *rangsorolására* használható, abszolút minőségi szintként nem: a bírón alapuló arányok (alátámasztottság, felhasználnám)

5.6. táblázat. Az oktatók és a bíró szerinti minőség konfigurációnként (6 közös dokumentum).

		Oktatók			Bíró	
Generátor	Konfiguráció	Átlag	95 % KI	Felh.	Átlag	Felh.
Gemma 3 12B	**E2**	**4,26**	3,79–4,63	**78 %**	4,68	**90 %**
	B-doc-L	4,18	3,77–4,53	72 %	4,55	80 %
Qwen2.5-7B	**E2**	**4,07**	3,59–4,51	**63 %**	**4,73**	**90 %**
	B-doc-L	3,82	3,38–4,23	54 %	4,15	60 %
PULI-LlumiX 8B	**E2**	**2,67**	2,06–3,28	17 %	3,73	40 %
	B-doc-L	2,43	1,85–3,06	**20 %**	**3,83**	**60 %**

Jelmagyarázat: Értékelés 6 közös dokumentumon, konfigurációnként 10–10 kérdésen (összesen 60 kérdés). **Átlag**: a négy rubrikaszempont átlaga (1–5 skála); **95 % KI**: a kérdésekre vett 95 %-os bootstrap-konfidenciaintervallum; **Felh.**: a „Felhasználnám" kérdésre adott „igen" válaszok aránya (az oktatóknál a kérdésenkénti arányok átlaga). A **félkövér** értékek generátormodellenként a jobb konfigurációt, a **zöld kiemelés** a teljes összevetés legjobb eredményét jelöli.

felső becslések, és a gyenge modelleknél a legkevésbé pontosak. Az 5. hipotézis értékelését a 7.1. szakasz adja.

5.11. A fejezet tanulsága

– Egyedül a *vizsgaterv* hatása szignifikáns mindkét fő modellnél, a szemantikus darabolású naiv RAG-hoz mérve.
– A *naiv RAG törékenységét* a feladatleírás mint lekérdezés és a rövid szerkezeti darabok okozzák; rögzített darabolással (**E5c**) a Gemma naiv RAG-ja a legjobb és leggyorsabb konfiguráció.
– Az *ellenőrző lánc* a gyenge modelleknél ad hozzá, Holm-korrekció után egyiknél sem szignifikánsan; a fogalomgráf és a hibrid keresés nem érte meg a többletköltséget, a tervezett folyamat pedig ugyanazon a kártyán 5–17-szer annyi ideig fut, mint a naiv RAG.
– A *hiányzó bírói ítéletek* forrásfüggők, de a fő következtetéseket nem változtatják meg.
– Az *oktatói értékelés* a bíró rangsorát megerősíti ($\rho = 0{,}77$ a konfigurációk között), pontszámait azonban nem: a bíró engedékenyebb az oktatóknál, leginkább a gyenge modellnél.

6. Eredmények: a generátormodellek

Ez a fejezet a generátormodelleket veti össze: hogyan teljesít a három helyi modell azonos dokumentumokon, mennyire közelíti meg egy helyi modell a nagy szervermodellt, miért bukott el a magyarra továbbtanított PULI-LlumiX, és mekkora memóriát igényelnek a modellek. A modelleket kizárólag azonos dokumentumhalmazon hasonlítjuk össze, és mindenhol megnevezzük, melyiken.

6.1. A három helyi modell azonos dokumentumokon

Két ilyen halmaz van:

(a) Az előzetes vizsgálat hat dokumentumán (`en-economics-short-01`, `en-humanities-medium-02`, `en-law-long-03`, `hu-coffee`, `hu-gametheory`, `hu-immune`) a Qwen2.5-7B és a szervermodell futott; mivel ezek a fő vizsgálatban is szerepelnek, a PULI-LlumiX és a Gemma eredménye ezekre leszűkítve is számolható (6.1. táblázat).

(b) A fő vizsgálat 30 dokumentumán a PULI-LlumiX és a Gemma futott.

A három helyi modell erősorrendje minden vizsgált dokumentumhalmazon következetes:

– *A hat közös dokumentumon (3 magyar, 3 angol):* a sorrend minden konfigurációban Gemma > Qwen > PULI. A Qwen a PULI-nál nyolc konfigurációban mind a hat dokumentumon jobb ($p = 0{,}031$), az **E2**-ben és az **E2h**-ban pedig $p = 0{,}063$ mellett. A Gemma minőségi indexe mindenütt magasabb a Qwenénél, de mind a hat dokumentumon egyöntetű előnyt csak a teljes dokumentumos promptnál (0,83 vs. 0,97, a legnagyobb különbség) és az **E5a**-nál mutat ($p = 0{,}031$); a különbség az **E2**-nél a legkisebb (0,96 vs. 0,97, $p = 0{,}66$).

– *A három saját magyar szövegen:* a magyarra továbbtanított PULI a magyar szövegeken is a leggyengébb maradt (**E2**: Qwen 0,96, PULI 0,74, Gemma 0,97; **E0**: Qwen 0,88, PULI 0,39, Gemma 0,99).

– *A fő vizsgálat 30 dokumentumán:* a Gemma mind a tíz összevetett konfigurációban szignifikánsan felülmúlja a PULI-t (páros Wilcoxon-próba, korrigálatlanul $p \leq 5{,}3 \cdot 10^{-6}$; értékek: 5.1. táblázat). A különbség az **E2**-nél a legkisebb (0,67 vs. 0,95), az **E5c**-nél pedig a legnagyobb (0,25 vs. 0,97): a tervezett folyamat csökkenti a modellek közötti távolságot, de nem tünteti el.

6.2. A szervermodell és a helyi modellek

A szervermodell (az egyetemi GenAI-szerver nagy Qwen-modellje) csak az előzetes vizsgálatban futott; a helyi Qwen2.5-7B-vel való összevetését a 6.2. táblázat foglalja össze. Hat, illetve három dokumentumon ezek leíró jellegű eredmények (4.8. szakasz); a megosztott szerveren mért futási időket a helyiekkel nem vetjük össze (a szerver saját **E4b**/**E4** időszorzója kb. 9×).

Az összevetésből három fő tanulság adódik:

6.1. táblázat. A generátormodellek minőségi indexe (Q) a hat közös dokumentumon.

Konfiguráció	Helyi generátormodellek (Q)			Wilcoxon-p		
	Qwen2.5 7B	PULI-LlumiX 8B	Gemma 3 12B	Qwen–PULI	Qwen–Gemma	Szerver (Q, konfig.)
Alapvonalak						
B-doc-L	0,83	0,49	**0,97**	0,031	0,031	0,95 (**B-doc-S**)
E0	0,64	0,32	**0,71**	0,031	0,094	0,94[a] (**E4**)
A módszer lépései						
E1	0,88	0,59	**0,95**	0,031	0,22	–
E2	**0,96**	**0,72**	**0,97**	0,063	0,66	1,00[a] (**E4b**)
E3	0,88	0,44	**0,97**	0,031	0,22	–
Kiegészítő ablációk						
E2f	0,90	0,69	**0,98**	0,031	0,094	–
E2h	0,92	0,63	**0,96**	0,063	0,094	–
E2x	0,89	0,71	**0,96**	–	–	–
Darabolási változatok						
E5a	0,87	0,36	**0,97**	0,031	0,031	–
E5b	0,70	0,23	**0,76**	0,031	0,31	–
E5c	0,86	0,29	**0,97**	0,031	0,69	–

Jelmagyarázat: A hat közös dokumentum az előzetes vizsgálat dokumentumhalmaza (a PULI-LlumiX 8B és a Gemma 3 12B értéke a fő vizsgálat futásaiból, erre a hat dokumentumra leszűkítve). *Wilcoxon-p:* páros Wilcoxon-próba a hat dokumentumon, korrigálatlan, leíró jellegű (hat dokumentumon a legkisebb elérhető érték 0,031). *Szerver:* a szervermodell ugyanazzal a konfigurációval (**B-doc-S**, **E4**, **E4b**). [a]Csak a három közös angol dokumentumon. Kiemelés (**félkövér**): soronként a legjobb helyi modell (mindenütt a Gemma 3 12B), illetve oszloponként az adott helyi modell saját csúcsértéke.

6.2. táblázat. A helyi Qwen2.5-7B és a szervermodell összevetése az előzetes vizsgálatban.

Folyamat	Modell (konfig.)	Q (6 dok.)	Q (3 angol dok.)	Elsőre átment	„Felhasználnám”	Bloom-egyezés	Lefedettség
Teljes dok.	Qwen2.5-7B (**B-doc-L**)	0,83 (0,76–0,90)	–	–	68 %	–	45 %
	Szerver (**B-doc-S**)	0,95 (0,87–0,99)	–	–	–	–	–
Naiv RAG	Qwen2.5-7B (**E0**)	0,64 (0,46–0,81)	0,40	–	34 %	–	25 %
	Szerver (**E4**)	0,91 (0,80–0,98)[a]	0,94	–	–	–	9 %
Tervezett + ellenőrzött	Qwen2.5-7B (**E2**)	**0,96** (0,93–0,98)	**0,95**	23 %	80 %	35 %	44 %
	Szerver (**E4b**)	**0,99** (0,97–1,00)[a]	**1,00**	83 %	98 %	62 %	28 %

Jelmagyarázat: Q (6 dok.): minőségi index a hat dokumentumon (zárójelben a helyi modellnél a 95 %-os konfidenciaintervallum, a szervermodellnél a dokumentumonkénti terjedelem). [a]A szervermodell **E4** és **E4b** konfigurációja a saját hat angol dokumentumán futott; a helyi modellel való közvetlen összevetés a három közös angol dokumentumon lehetséges.

– *A helyi modell a módszerrel eléri a szerveres alapvonalakat:* a helyi Qwen2.5-7B a tervezett és ellenőrzött folyamattal (**E2**, $Q = 0{,}96$) a hat közös dokumentumon eléri a szervermodell teljes dokumentumos promptját (**B-doc-S**, 0,95), a három közös angol dokumentumon pedig a szervermodell naiv RAG-ját (0,95 vs. 0,94). Ugyanezzel a módszerrel azonban a szervermodell is tovább javul (**E4b**: 0,99, a három közös angol dokumentumon 1,00), így a „helyi modell eléri a szervermodellt” állítás kizárólag a szerveres alapvonalakra igaz.
– *A tervezett folyamatban a szervermodell a részmutatókon is fölényben van:* az **E4b**-ben a kérdéshelyek 83 %-a elsőre átment az ellenőrzésen (Qwen **E2**: 23 %), a bíró „felhasználnám” aránya 98 % (Qwen: 80 %), a tervezett és megvalósult Bloom-szint pedig az esetek 62 %-ában egyezett (Qwen: 35 %).
– *A naiv RAG hibáit a nagy szervermodell sem kerüli el:* az **E4** konfigurációban a kérdéspárok 49 %-a közel azonos volt, a dokumentum-lefedettség mindössze 9 %-ot ért el (**E4b**: 28 %), és a modell tartalmilag üres kérdéseket is írt („Hány szóból áll a »Link to Learning« cím?”), amelyeket a bíró 5/5-re pontozott – ugyanaz a rövid szerkezeti darab vitte félre, mint a helyi naiv RAG-ot (5.5. szakasz).

6.3. Miért bukik el a PULI-LlumiX?

A magyarra továbbtanított modelltől azt vártuk, hogy a magyar dokumentumokon jobb lesz a többnyelvű modelleknél; ehelyett a magyar szövegeken is a leggyengébb lett, és ennek oka az *utasításkövetés*. A modellkártya szerint a PULI-LlumiX-Llama-3.1 a Llama 3.1 8B *Instruct* modell magyar szövegeken folytatott további előtanítása, utólagos utasítás-hangolás nélkül (a kártya „base” modellnek nevezi) [59]; a vizsgálatban egy harmadik féltől származó, GGUF-kvantált változat futott (`hf.co/mradermacher/PULI-LlumiX-Llama-3.1-GGUF:Q4_K_M`).

Egyetlen hívásban a PULI a kért tíz kérdés helyett átlagosan 1,8-at (**E0**), illetve 5,6-ot (**B-doc-L**) adott vissza; az egyhívásos konfigurációk vizsgáinak 94–99 %-a formailag hibás volt, a darabolási változatok vizsgáinak 14–29 %-ában a válasz nem is volt értelmezhető JSON. A tervezett folyamat ezt részben megkerüli, mert hívásonként egy kérdést kér, de ott is konfigurációnként 128–620 modellválasz volt értelmezhetetlen (a Gemmánál és a Qwennél egy sem). Az ellenőrzés nélküli **E1** kérdéseinek 34 %-a szivárogtatja a kulcsot, 45 %-ának törzse nem kérdés, a kérdéspárok 62 %-a közel azonos, a törzsek átlagosan 252 karakteresek (a Gemma **E1**-ében 122): a modell jellemzően a forrás egy mondatát másolja be kérdésként és kulcsként is (5.1. szakasz). A *Nürnbergi per* című cikk esetén például a generált „kérdés” egy kijelentő forrásmondat volt, a négy válasz közül kettő ugyanezt a mondatot ismételte, a bíró helyességi pontszáma pedig 1/5 lett. Az ellenőrző lánc a szivárgást (34 %→12 %) és a nem kérdő törzseket (45 %→22 %) mérsékli, de a megvalósult Bloom-szint gyakorlatilag mindig az emlékezés marad, és a teljes módszerrel is 18 dokumentumon 0,70 alatt marad a minőségi index (a leggyengébben 0,38). Az **E1** futása instabil is volt: 103 modellhívás időtúllépéssel vagy hibával zárult, a medián vizsgaidő 96 perc lett (a Gemmánál 2,9 perc).

Fontos hangsúlyozni, hogy ez a megállapítás kizárólag a vizsgált modellváltozatra vonatkozik: a kudarcot nem maga a magyar nyelvű továbbtanítás okozta, hanem az, hogy a további előtanítást nem követte újabb utasításhangolás, így a modell nem tartotta be a strukturált kimeneti formátumot. Feltevésként a GGUF-fájlba ágyazott csevegési sablon (chat-sablon) is szerepet játszhatott; ezt nem vizsgáltuk, és a kvantálás hatását sem tudjuk elkülöníteni.

6.4. Memóriaigény és futási idő

A 6.3. táblázat a modellek mért memóriaigényét, a 6.1. ábra a minőséget a futási idő függvényében mutatja.

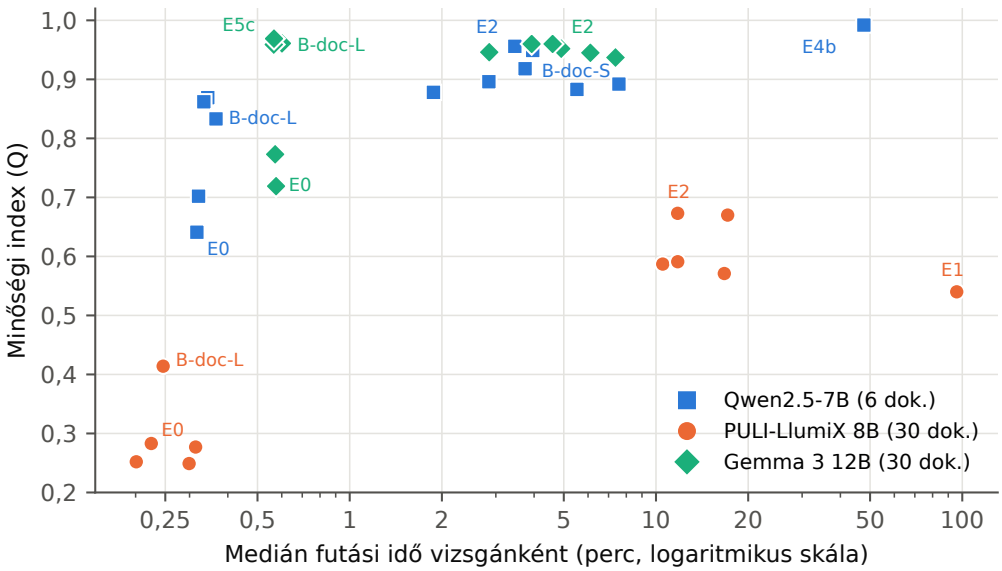
6.3. táblázat. A helyi generátormodellek memóriaigénye és relatív futási ideje.

Modell	Modell (GiB)	Teljes dok. (GiB)	Kártya	**E2/E0**
Qwen2.5-7B (Q4_K_M)	4,8	5,2	8 GB-os	10,9×
PULI-LlumiX 8B (Q4_K_M)	5,5	6,5	8 GB-os*	52,3×
Gemma 3 12B (Q4_K_M)	7,8	7,8	12 GB-os	8,5×

Jelmagyarázat: *Modell (GiB):* az Ollama által jelentett, mért foglalás 8 192 tokenes kontextusnál (a A.1. táblázat becslésével összevetendő). *Teljes dok. (GiB):* ugyanez a 16 384 tokenes **B-doc-L** konfigurációnál. *Kártya:* a szükséges fogyasztói GPU az asztali környezet 1,6–1,9 GiB-os foglalása mellett (a pilot mérése). ***E2/E0**:* a medián vizsgaidő modellen belüli szorzója ugyanazon a kártyán (5.4. táblázat). *A 16 384 tokenes teljes dokumentumos konfigurációhoz a 8 GB-os kártya várhatóan nem elég (lásd a szöveget).

Memória. A Qwen2.5-7B és a PULI-LlumiX 8B 8 192 tokenes kontextussal egy 8 GB-os fogyasztói kártyán is elfér (a pilot RTX 3070 Ti-ján a Qwennel a legrosszabb esetben is kb. 380 MiB tartalék maradt); a Gemma 3 12B foglalása az asztali környezettel együtt kb. 9,4–9,7 GiB, vagyis 12 GB-os kártyát igényel. A 16 384 tokenes konfigurációnál a Qwen foglalása 464 MiB-tal nőtt, nagyságrendben egyezően a (A.1) becslés 448 MiB-os KV-többletével; a PULI-é 1 024 MiB-tal, így az asztali környezettel együtt meghaladná egy 8 GB-os kártya kapacitását (fogyasztói kártyán ezt nem mértük). A Gemma foglalása gyakorlatilag nem nőtt (16 MiB), feltehetően a csúszóablakos helyi figyelemrétegek miatt [58]; ezt nem vizsgáltuk.

Futási idő. A szorzókat egy vizsgálaton belül értelmezzük (5.8. szakasz). A PULI 52,3×-os szorzója félrevezetően nagy, mert az **E0**-ja alig ír kérdést; a fő vizsgálaton belül, azonos dokumentumokon és kártyán a PULI **E0**-ja a Gemmáénak kb. 0,4-szerese, az **E2**-je viszont kb. 2,4-szerese, mert szinte minden kérdéshelyet újra kell próbálnia (2,0 kísérlet a Gemma 1,3-ával szemben, B.2. táblázat), és sok válasza értelmezhetetlen. A Qwen idejét a fő vizsgálat modelljeiével nem vetjük össze, mert más vizsgálatban, más dokumentumokon mértük. A mérések alapján két GPU-szint különíthető el: 8 GB-on a 7–8B modellek (a vizsgált feladatra ezek közül a Qwen2.5-7B alkalmas), 12 GB-on a Gemma 3 12B, amely minden konfigurációban a legjobb helyi eredményt adta.



6.1. ábra. Minőség és futási idő. Az egyhívásos konfigurációk gyorsak, de minőségük a modelltől és a darabolástól függően erősen ingadozik; a tervezett konfigurációk lassabbak, de minden modellnél a legjobbak között vannak. A Qwen2.5-7B az előzetes vizsgálat hat dokumentumán, a másik két helyi modell a fő vizsgálat 30 dokumentumán, a szervermodell (**B-doc-S**, **E4b**) pedig megosztott szerveren futott, ezért az abszolút időtengely modellen belül értelmezendő (a relatív időszorzókat az 5.4. táblázat adja).

6.5. Modellválasztási tanulság

A vizsgált feladatban az utasításkövetés fontosabb volt a nyelvi specializációnál: a többnyelvű Qwen2.5-7B a hat közös dokumentumon, a magyar szövegeken is, minden konfigurációban jobb volt a magyarra továbbtanított PULI-LlumiX 8B-nél. Minél erősebb a modell, annál kisebb a módszer haszna a minőségben: ugyanezen a hat dokumentumon az **E2**–**E0** különbség a PULI-nál 0,41, a Qwennél 0,32, a Gemmánál 0,26, az **E2**–**B-doc-L** különbség 0,23, 0,12, illetve nulla; az erős modellnél a módszer értéke ezért elsősorban az ellenőrizhetőség, a gyenge modellnél maga a használható vizsga. Mivel ezt a modellkártya nem mutatja meg, a modellt a célfeladaton mérve kell kiválasztani.

7. Az eredmények értékelése

Ebben a fejezetben az 5. és a 6. fejezet eredményeit értékeljük: mely hipotéziseket támasztják alá a mérések, hogyan viszonyulnak az irodalomhoz, mikor éri meg a módszer, és milyen konfiguráció ajánlható GPU-szintenként. A fejezetet a mérés tanulságai, az érvényesség korlátai és az etikai szempontok zárják.

7.1. A hipotézisek értékelése

7.1. táblázat. A dolgozat hipotéziseinek értékelése a kísérleti eredmények alapján.

Hipotézis	Bizonyíték	Értékelés
1. Tervezés	*Fő vizsgálat (30 dok.):* Q +0,26 (PULI, $\tilde{p} < 0{,}001$) és +0,23 (Gemma, $\tilde{p} = 0{,}002$); G: 27→58 %, ill. 46→88 %; lefedettség: 10→23 %, ill. 24→43 %; a forma nem romlott (a rögzített darabolású naiv RAG, az **E5c** a Gemmánál 0,97). *Előzetes vizsgálat (6 dok.):* Qwen Q +0,24 (nem szignifikáns).	**Támogatott** (a szemantikus darabolású **E0**-hoz képest)
2. Ellenőrzés	*Fő vizsgálat (30 dok.):* G csökkent (PULI: 58→52 %, Gemma: 88→86 %); Q +0,13 ($\tilde{p} = 0{,}066$), ill. +0,01 ($\tilde{p} = 1{,}00$). *Előzetes vizsgálat (6 dok., Qwen):* G: 80→90 %, A: 80→97 %, Q +0,08 (5 dok. javult, 0 romlott, $\tilde{p} = 0{,}19$). *Egyezés a bíróval:* κ = 0,00–0,08 minden modellnél.	**Nem támogatott** (a fő vizsgálatban; az előzetesben leíró szinten javult)
3. Lefedettség	*Fő vizsgálat (30 dok., Gemma):* teljes dok. 43 % vs. **E2** 43 %. *Előzetes vizsgálat (6 dok., Qwen):* teljes dok. 45 % vs. **E2** 44 %. A kérdések egyetlen szakaszra tömörülése a naiv RAG sajátja (10–25 %).	**Nem támogatott** (a teljes dok. lefedettsége nem alacsonyabb)
4. Helyi vs. szerver	*Előzetes vizsgálat (3 közös angol dok.):* Qwen **E2** 0,95 vs. szerver **E4** 0,94. *Előzetes vizsgálat (6 közös dok.):* Qwen **E2** 0,96 vs. szerver **B-doc-S** 0,95 (Gemma **E2**: 0,97, PULI **E2**: 0,72); a szervermodell a saját módszerünkkel (**E4b**) 0,99. Memóriaigény: 4,8–7,8 GiB.	**Támogatott** (leíró szinten, a szerveres alapvonalhoz mérve)
5. Mérés	*Oktatói egyezés (5 oktató, 60 kérdés):* bíró–oktatói medián α = 0,62 (helyesség, KI: 0,38–0,80; az oktatók egymás közt 0,69), a többi szempont 0,11–0,37; a bíró minden szempontban engedékenyebb. *Rangsor-korreláció:* ρ = 0,65 (helyesség), ρ = 0,77 (6 konfiguráció).	**Nem támogatott** (a küszöb nem teljesül, de a rangsor egyezik)

Jelmagyarázat: *Fő vizsgálat:* 30 dokumentumos mérés (PULI-LlumiX 8B és Gemma 3 12B); *Előzetes vizsgálat:* 6 dokumentumos mérés (Qwen2.5-7B és a szervermodell). Q: minőségi index; G: alátámasztottság; A: vak megoldhatóság; $\tilde{p}$: Holm-korrigált p-érték; KI: 95 %-os bootstrap-konfidenciaintervallum.

Megjegyzések a táblázathoz:

– **1. hip.:** Az **E1** és az **E0** több tényezőben különbözik (lekérdezés, kérdésenkénti generálás), ezért a javulást a vizsgaterv egészének tulajdonítjuk, nem egyetlen lépésének.

– **2. hip.:** A lánc a vizsga egészét javította (forma, szivárgás, nem kérdő törzsek; 5.6. szakasz), a kérdések tartalmi helyességét nem.
– **3. hip.:** A PULI teljes dokumentumos vizsgáinak alacsony lefedettsége a kevés kérdésből adódik, és tíz kérdésnél a hosszú dokumentumokon a felső korlát minden konfigurációt egyformán korlátoz.
– **4. hip.:** A hipotézis a szervermodell *naiv* változatához mér; a „helyi modell elérte a szervermodellt” állítás csak a szerveres teljes dokumentumos promptra igaz, a saját módszerünkkel futó szervermodellre nem.
– **5. hip.:** A 0,667-es küszöböt egyik szempont sem éri el; a helyességen a pontbecslés közel van hozzá, és az intervallum tartalmazza, ezért ott a hipotézist nem cáfoltnak, hanem nem igazoltnak tekintjük. Az eltérés nagy része egyirányú (a bíró engedékenyebb), a sorrend viszont egyezik, ezért a bíró ítéleteit – ahogy eddig is – relatív, a konfigurációk összevetésére szolgáló mérésként kezeljük, az abszolút arányokat (alátámasztottság, felhasználnám) felső becslésnek. A rangsort az oktatók is megerősítik: Gemma > Qwen > PULI, és az **E2** mindhárom generátornál a **B-doc-L** fölött van, bár tíz-tíz kérdésen nem szignifikánsan (5.10. szakasz).

7.2. Összevetés az irodalommal

Eredményeinket a 2. fejezetben tárgyalt munkákkal vetjük össze. A feladatok, a modellek és a mutatók eltérnek a mieinktől, ezért az összevetés irányt és nem pontos nagyságot jelez.

Önellenőrzés külső visszajelzés nélkül. A szakirodalom [5] szerint a nyelvi modellek külső támpont nélkül nem tudják megbízhatóan kijavítani saját hibáikat, sőt az önjavítás után a teljesítmény akár romolhat is. A mi ellenőrző láncunk kétféle ellenőrzést tartalmaz: determinisztikus szabályokat (forma, válaszszivárgás, kérdésforma, duplikátum) és a modell saját, forrásszövegre támaszkodó ítéletét. A mérések azt mutatták, hogy a modell önálló ítélete önmagában gyenge (a végső vizsgákon a véletlen szintjén, $\kappa = 0{,}00$–$0{,}08$ arányban egyezik a független bíróval): a gyenge PULI-nál és az erős Gemmánál az ellenőrző lánc hasznát gyakorlatilag teljes egészében a determinisztikus szabályok adják (a csak szabályalapú **E2x** ugyanannyit ért el, mint a teljes **E2**: a PULI-nál 0,67 vs. 0,67, a Gemmánál a különbség nem szignifikáns). Egyedül a közepes Qwen2.5-7B-nél javított érdemben a forrásszöveggel szembeni modellalapú ellenőrzés (0,89 → 0,96, öt dokumentumon javult, egyen romlott), amit azonban az **E2x** technikai hibája miatt még újra kell mérni (7.6. szakasz).

Darabolás. Qu, Tu és Bao [40] szerint a szemantikus darabolás többletköltségét a mért előnyök nem indokolják. Nálunk a rögzített, 800 karakteres darabolás (**E5c**) a Gemmánál (0,72 → 0,97, 23 dokumentumon jobb) és a Qwennél (0,64 → 0,86, leíró szinten) is jobb volt, mint a szemantikus **E0**; a PULI-nál egyik változat sem adott értékelhető vizsgát. Eredményünk a megállapítást egy mechanizmussal egészíti ki: a minimális darabméret nélküli szemantikus darabolás rövid, tartalom nélküli darabokat hoz létre, és a feladatleírás típusú lekérdezés éppen ezeket találja meg

(5.5. szakasz).

Lekérdezés-átírás. A HyDE [39] abból indul ki, hogy a lekérdezésnek a keresett szöveghez kell hasonlítania, ezért egy generált hipotetikus dokumentum beágyazásával keres. Eredményünk ezt támasztja alá: a kereső tartalmi kérdéssel jól működik (a referenciakérdések igazoló darabja a fő vizsgálat dokumentumain 86 %-ban az első három találat között volt), a naiv RAG kudarca tehát a feladatleírásból képzett lekérdezésből fakad. A vizsgaterv tartalmi fogalmai a lekérdezés-átírás egyszerű formájának tekinthetők; egy HyDE-szerű lekérdezés a naiv RAG-ban további kutatási irány.

Hosszú kontextus és RAG. Li és munkatársai [45] szerint elegendő erőforrás mellett a hosszú kontextus átlagosan jobb a RAG-nál, a RAG viszont jóval olcsóbb, a lekérdezések 63 %-án a kettő előrejelzése azonos, és kérdésenkénti útválasztással a költség csökkenthető. Nálunk ez modellfüggő: a Gemma teljes dokumentumos promptja (0,96) versenyképes a tervezett folyamattal és a jól darabolt naiv RAG-gal, a gyengébb modelleknél viszont elmarad (Qwen 0,83, PULI 0,41).

A hosszú bemenet egyenetlen használata. Liu és munkatársai [6] eredménye alapján azt vártuk, hogy a teljes dokumentumot kapó modell kérdései a dokumentum egyes részeire tömörülnek (3. hipotézis); a lefedettségben ez nem jelent meg. A Gemma teljes dokumentumos promptja a hosszú dokumentumokon leíró szinten valamivel gyengébb (0,94), mint a rövideken (0,98), a hossz növelésével romló teljesítménynek megfelelően [44], de a különbség kicsi.

Hibás kulcsok a generált kérdésekben. Doughty és munkatársai [21] szerint a GPT-4 kérdéseinek 81,7 %-a minden szempontnak megfelelt, de 4,9 %-ukban több helyes válasz volt (az oktatói kérdéseknél 1,1 %), 4,0 %-ukban pedig egy disztraktor elárulta a kulcsot (0,9 %); Wang és munkatársai [20] a GPT-3 kérdéseinek egy részét az emberiekkel összemérhetőnek találták. Méréseink hasonló képet adnak: a Gemma tervezett konfigurációiban a bíró a kérdések 85–88 %-át használná fel, a Qwen **E2** kérdéseinek 80 %-át, a szervermodell **E4b** kérdéseinek 98 %-át, és még a legjobb helyi konfigurációk kérdéseinek is 4–14 %-a nem alátámasztott. A mutatók és a tárgyterületek eltérnek, de a következtetés azonos: oktatói átnézés nélkül hibás kérdések kerülnének a vizsgába.

A bíró érvényessége. Zheng és munkatársai [64] szerint egy erős bíró több mint 80 %-ban egyezik az emberi preferenciákkal, nagyjából annyira, mint az emberek egymással, de pozíciós, hossz- és önpreferencia-torzítása van; Chiang és Lee [65] az emberi szakértőkével azonos utasítással kapott hasonló egyezést. Ezek páros preferenciákra és más feladatokra vonatkoznak, így nem vihetők át a mi forrásalapú rubrikánkra, és vizsgálataink több bírói vakfoltot is feltártak (7.5. szakasz). A más modellcsaládba tartozó bíró az önpreferenciát csökkenti [68]. Az oktatói értékelés részben megerősíti ezeket az eredményeket: a felhasználnám ítéletben a bíró annyira egyezik az oktatói többséggel ($\kappa = 0{,}46$), mint két oktató egymással (0,45), a rubrikapontokban viszont gyengébben, és szisztematikusan engedékenyebb (5.10. szakasz).

7.3. Mikor éri meg a módszer?

A módszer haszna a modell képességétől függ (5.2. ábra):

– **Gyenge formátumkövető modellnél** (PULI-LlumiX 8B) csak a feladatfelbontás ad értékelhető vizsgát, de a modellt ez sem teszi alkalmassá.
– **Közepes modellnél** (Qwen2.5-7B) éri meg a legjobban: a többlethívások árán a szerveres teljes dokumentumos prompt szintjét éri el, összhangban azzal, hogy a futás közbeni többletszámítás a nagyobb modellt részben helyettesítheti [54].
– **Erős modellnél** (Gemma 3 12B) átlagos minőségben nem ad hozzá, értéke a kérdésenkénti forrás (**P1**) és a terv (**P2**).

A szintenkénti számokat a 7.2. táblázat adja.

7.4. Gyakorlati következmények

A 7.2. táblázat GPU-szintenként a legjobb minőségű, a leggyorsabb és a legrobusztusabb (a leggyengébb dokumentumon is legjobb) konfigurációt, valamint a mérésekből következő ajánlást mutatja.

7.2. táblázat. Ajánlott konfigurációk GPU-szintenként.

Szempont	Konfig.	Q	Min.	Idő	Megjegyzés
8 GB: Qwen2.5-7B					
Legjobb minőség	**E2**	0,96	0,89	≈ 11×	a szerveres teljes dokumentumos prompt (0,95) szintje; kérdésenkénti forrás
Leggyorsabb	**E5c**	0,86	0,50	≈ 1×	a saját magyar szövegeken 0,77, a törzsek 44 %-a nem kérdés
Legrobusztusabb	**E2**	0,96	0,89	≈ 11×	azonos a legjobb minőségűvel; a következő az **E2h** (0,88)
Ajánlott	**E2**	**0,96**	**0,89**	≈ 11×	tervezés és ellenőrzés
12 GB: Gemma 3 12B					
Legjobb minőség	**E5c**	0,97	0,81	≈ 1×	a **B-doc-L**, **E2f**, **E2h**, **E5a** (0,96) a konfidenciaintervallumon belül; nincs kérdésenkénti forrás és terv
Leggyorsabb	**E5c**	0,97	0,81	≈ 1×	az **E0**, **E5a** és **B-doc-L** is ≈ 1×
Legrobusztusabb	**E2h**	0,96	0,88	≈ 8×	a tervezett konfigurációk minimuma 0,80–0,88, egy-egy dokumentumon múlik; a hibrid keresés más modelleknél rontott
Ajánlott	**E1–E2**	**0,95**	**0,80–0,82**	≈ 5–8,5×	tervezett folyamat; ha forrás és terv nem kell, **E5c**

Jelmagyarázat: Q: minőségi index; *Min.:* a leggyengébb dokumentum Q-ja; *Idő:* a medián futási idő szorzója az azonos modellel futó **E0**-hoz képest. A 8 GB-os szint a hat dokumentumos előzetes, a 12 GB-os a 30 dokumentumos fő vizsgálat adatai. A szintén 8 GB-on futó PULI-LlumiX 8B egyik szempontból sem ajánlott (legjobb **E2**: 0,67, a leggyengébb dokumentumon 0,38, 18 dokumentum 0,70 alatt).

A 8 GB-os szinten a tervezett és ellenőrzött folyamat egyszerre a legjobb és a legrobusztusabb;

a 12 GB-os szinten a győztesek minősége a konfidenciaintervallumokon belül azonos.

A komponensekről. A mérések alapján az egyes építőelemek mérlege a következő:

– **Megéri:**
  - a *vizsgaterv* (kikényszeríti a darabszámot, a típust és a Bloom-kiosztást: a PULI egy hívásban átlagosan 1,8 kérdést adott a kért tíz helyett, a tervvel 9,9-et),
  - a *kérdésenkénti forráshivatkozás* (ez teszi ellenőrizhetővé a kérdéseket),
  - a *szabályalapú ellenőrzés* (olcsó, és a lánc hasznának nagy részét adja), valamint
  - a *rögzített darabolás* a naiv RAG-ban is (a Gemmánál a 0,70 alatti dokumentumok száma 16-ról nullára csökkent).
– **Nem éri meg:** a *fogalomgráf* (**E3**: Gemma −0,01, PULI −0,10, Qwen −0,07, a Gemmánál ≈ 10,6×) és a *hibrid keresés* (**E2h**: Gemma +0,01, nem szignifikáns; PULI −0,08, Qwen −0,04).
– **Az ellenőrző modellalapú ítélete** kérdésenkénti döntésre nem alkalmas, legfeljebb figyelmeztetésként, mert az „ellenőrzött” címke az automatizálási torzítás [77] miatt az átnézést gyengítené.
– **Utasításkövetés vs. nyelvi specializáció:** az utasításkövetés fontosabbnak bizonyult a magyar nyelvi specializációnál; ezt a PULI-LlumiX 8B esetére szűkítve állítjuk (6. fejezet).
– **Adaptív ellenőrzés (további irány):** az elsőre elfogadott kérdéshelyek arányától (Gemma 70 %, Qwen 23 %, PULI 5 %) függően érdemes futtatni a modellalapú lépéseket.

7.5. Mit tanultunk az ellenőrzésről és a mérésről?

Az ellenőrző lánc szűrőként és „második esélyként” működik, nem osztályozóként: jelzései egyenként zajosak, de az elutasított kérdés helyére írt új kérdés átlagosan jobb. A mérés több ponton csendben torzított volna, miközben hihető számokat adott:

– a sikertelen hívásoknál visszaadott tartalékvizsga és a hiányos végső kérdések,
– az 512 tokenre csonkolt kódoló (3.4.1. szakasz),
– a válaszszivárgás és a tartalmilag üres kérdések magas bírói pontszáma (5.1. szakasz),
– a bíró 24 000 karakteres forrásablaka a teljes dokumentumos konfigurációknál, valamint
– a hibával visszatérő második ellenőrző modell (**E2x**) hívásai.

A nyers kimenetek kézi átolvasása ezért nem hagyható el. A bírói ítéletek forrásfüggően hiányoznak: a Wikipédia-cikkek kérdései kisebb arányban kaptak ítéletet (a Gemma **E2**-ben összesen 52 %, a PULI **E2**-ben 29 %). Ez a következtetéseket nem fordítja meg (5.9. szakasz), de a forrásonkénti összevetéseket gyengíti.

7.6. Az érvényességet veszélyeztető tényezők

Belső. Az **E1** és az **E0** több tényezőben különbözik, az ellenőrzés a kérdések hosszát is megváltoztatja, és a tervezett konfigurációk egy maggal futottak, így a dokumentumonkénti értékekben futási zaj is van. A vizsgálatok közötti összevetés minden esetben azonos dokumentumokon, a hat közös dokumentumon történt. Az **E2x** a tervezettől eltérő konfigurációt mért (csak a szabályok futottak).

Konstrukciós. A formai megfelelés vizsgaszintű, ezért minden komponenst külön is közlünk. A tartalmi mutatók egyetlen bíróra épülnek, amely csak a kérdés saját forrását látja, ítéletei forrásfüggően hiányoznak (5.9. szakasz), és az oktatókkal csak sorrendben egyezik, abszolút szintben nem (5.10. szakasz). Az oktatói referencia is korlátos (60 kérdés és öt oktató), ráadásul a helyességen kívül az oktatók egymás közötti egyezése is csak közepes vagy gyenge.

Külső. A 30 dokumentumból 24 magyar Wikipédia-cikk, az angol részhalmaz három dokumentum; a szervermodell csak a hat dokumentumon futott; csak feleletválasztós kérdéseket értékeltünk; a nyílt dokumentumok a tanítóadatban is szerepelhettek [76]. A futási időt ugyanazon a GPU-n mért relatív szorzóként értelmezzük.

Következtetési. A 30 dokumentum a nagy hatások kimutatására elegendő, a kicsikére (például az ellenőrzés hatására a Gemmánál) nem; a hat dokumentumos vizsgálat következtetései leíró jellegűek.

7.7. Etikai és jogi szempontok

Az ajánlott konfigurációk fogyasztói GPU-n, helyben futnak, így a tananyag nem kerül külső szolgáltatóhoz (3.2. szakasz). A módszer kérdést generál, és nem értékeli a hallgatókat; minden kérdés oktatói jóváhagyást igényel, amit a kérdésenkénti forráshivatkozás ellenőrizhetővé tesz – ez megfelel az emberi felügyelet követelményének (2.9. szakasz) [78].

Tanulság. A vizsgaterv minden vizsgált modellnél javított a szemantikus darabolású naiv RAG-hoz képest, az ellenőrző lánc haszna és a teljes dokumentumos prompt versenyképessége viszont a modelltől függ. Erős modellnél a módszer értéke az ellenőrizhetőség és a kontroll, nem az átlagos minőség. Az oktatók a modellek és a konfigurációk sorrendjét megerősítették, de a bírónál szigorúbbak: a Gemma 3 12B kérdéseinek 72–78 %-át használnák fel, a PULI-LlumiX 8B-éinek 17–20 %-át.

8. Összefoglalás és további munka

Ez a fejezet a kutatási kérdésekre adott válaszokat foglalja össze, és kijelöli a további munkát.

8.1. Összefoglalás

A vizsgakérdés-generálás négy problémájából indultunk ki (**P1**–**P4**), és azt vizsgáltuk, hogy a feladat ellenőrizhető lépésekre bontása lehetővé teszi-e megbízható vizsga előállítását fogyasztói GPU-n futó kis modellekkel. A javasolt Mimir módszert kutatási prototípusként, saját, nyílt kiértékelő keretrendszerben valósítottuk meg, és 14 konfigurációval, három vizsgálatban, legfeljebb 30 dokumentumon és három helyi modellen mértük.

RQ1. A vizsgaterv a szemantikus darabolású naiv RAG-hoz (**E0**) képest a fő vizsgálat mindkét modelljénél szignifikánsan javított (+0,26 és +0,23, Holm-korrekció után is), és a lefedettséget is növelte (5.3. szakasz). A rögzített méretű darabolású naiv RAG (**E5c**) azonban az erős Gemma 3 12B-nél önmagában is elég volt (0,97), a gyenge PULI-LlumiX 8B-nél nem (5.5. szakasz). A teljes dokumentumos prompttal szemben az előny a PULI-nál nagy (0,41 → 0,67), a Qwen2.5-7B-nél a hat dokumentumon leíró jellegű (0,83 → 0,96), a Gemmánál nincs (0,96 és 0,95), és a teljes dokumentumos prompt lefedettsége is azonos szintű volt (Gemma: 43 % vs. 43 %, Qwen: 45 % vs. 44 %). **Összességében a tervezett folyamat a szemantikus darabolású naiv RAG-hoz képest bizonyítottan javítja a minőséget és a lefedettséget (1. hipotézis: támogatott), a teljes dokumentumos prompt lefedettsége azonban erős modellnél nem marad el tőle (3. hipotézis: nem támogatott).**

RQ2. A legnagyobb hatású tényező a visszakeresés lekérdezése: a vizsgaterv kérdéshelyenként tartalmi lekérdezéssel keres, míg a naiv RAG minőségét a darabolás részletei erősen befolyásolták. Az ellenőrző lánc a gyengébb modelleknél javított a minőségi indexen (+0,08 és +0,13, ez utóbbi Holm-korrekció után nem szignifikáns), az erősnél nem; az alátámasztottság a fő vizsgálatban mindkét modellnél kissé csökkent, az ellenőrző modellalapú ítélete pedig a bíróéval csak a véletlen szintjén egyezik (κ = 0,00–0,08), így a lánc hasznának nagy részét a determinisztikus szabályok adják. A fogalomgráf és a hibrid keresés egyik modellnél sem javított érdemben, a teljes ellenőrzött folyamat pedig ugyanazon a GPU-n a naiv RAG futásidejének nagyjából 8,5-szeresét igényli (Gemma 3 12B, 5. fejezet). **Összességében a komponensek közül a vizsgaterv, a kérdésenkénti forráshivatkozás, a szabályalapú szűrés és a rögzített darabolás vált be, míg a fogalomgráf, a hibrid keresés és az önmagában álló modellalapú ellenőrzés nem érte meg a többletköltséget (2. hipotézis: a fő vizsgálatban nem támogatott).**

RQ3. A 8 GB-os kártyán futó Qwen2.5-7B a módszerrel a hat közös dokumentumon a szervermodell teljes dokumentumos promptjának minőségét (0,96 vs. 0,95), a három közös angol dokumentumon pedig a szerveres naiv RAG-ét (0,95 vs. 0,94) érte el; a módszerrel futó szerver-

modell (0,99) ennél is jobb volt, így az egyezés a szerveres alapvonalakra vonatkozik. A 12 GB-os szinten a Gemma 3 12B a tervezett konfigurációkkal és a rögzített darabolású naiv RAG-gal is hasonlóan magas minőséget adott (0,95–0,97). Ezzel szemben a vizsgált, magyarra továbbtanított, de utólagos utasításhangolás nélküli PULI-LlumiX 8B az utasítás- és formátumkövetésen bukott el (6. fejezet). **Összességében egy jól megválasztott, 8–12 GB-os fogyasztói GPU-n futó helyi modell a javasolt módszerrel eléri a szervermodell teljes dokumentumos alapvonalának minőségét (4. hipotézis: támogatott), de a modellválasztás kritikus, mert az utasításkövetés fontosabb a nyelvi specializációnál.**

Mérési tanulságok és következmények. A vizsgálatok feltárták a válaszszivárgást (5.1. szakasz), a csendes tartalékágakat és a forrásfüggően hiányzó bírói ítéleteket (5.9. szakasz): egy nyelvi modellekre épülő rendszer kiértékelésében minden tartalékágat láthatóvá kell tenni, és a nyers kimeneteket kézzel is át kell olvasni. Öt oktató 60 kérdésen végzett vak értékelése (5.10. szakasz) szerint a bíró a kérdéseket és a konfigurációkat az oktatókhoz hasonló sorrendbe állítja (helyességen $\rho = 0{,}65$, a hat konfiguráción $\rho = 0{,}77$), de engedékenyebb náluk, és a Krippendorff-$\alpha \geq$ $\geq 0{,}667$ küszöböt egyik szempont sem éri el (helyességen $\alpha = 0{,}62$). A mérések alapján ajánlott konfiguráció (7. fejezet) a vizsgaterv kérdésenkénti forráshivatkozással, szabályalapú ellenőrzéssel és rögzített vagy minimális méretű darabolással; a nyelvi modellel végzett ellenőrzés a modell erősségéhez igazítható. **Összességében a független nyelvi modell (bíró) az oktatói értékelések sorrendjét megbízhatóan reprodukálja ($\rho = 0{,}77$), de szisztematikusan engedékenyebb az oktatóknál, így a szigorú egyezési küszöböt nem éri el (5. hipotézis: nem támogatott; a bíró relatív rangsorolásra alkalmas).**

8.2. További munka

- **A bíró kalibrálása:** nagyobb oktatói mintán (konfigurációnként több kérdéssel) a bíró engedékenységének korrigálása, és pontosabb rubrika a szintillesztéshez, amelyben az oktatók egymással is alig egyeztek.
- **A hiányzó mérések pótlása:** a sikertelen bírói hívások újrapontozása, a független ellenőrző (**E2x**) újramérése, és a szervermodell futtatása a fő vizsgálat 30 dokumentumán.
- **A darabolás hatása a tervezett folyamatra:** a darabolási változatokat (**E5a**–**E5c**) csak a naiv RAG-gal mértük, ezért a tervezett folyamat darabolásfüggését még mérni kell.
- **Adaptív és jobb ellenőrzés:** a modellalapú ellenőrző lépések adaptív futtatása az első kísérletek sikerarányától függően, valamint természetes nyelvi következtetésre tanított osztályozó [53] alkalmazása a kérdésenkénti jelzéshez.
- **Tanórai kipróbálás:** a generált vizsgák tételelemzése (nehézség, megkülönböztető erő, nem működő disztraktorok [10]) valós hallgatói válaszokon.

A kód nyílt forráskódú (MIT-licenc), a konfigurációk és a vizsgálatok nyers kimenetei a tárolóban rendelkezésre állnak.

Irodalomjegyzék

[1] T. M. Haladyna, S. M. Downing és M. C. Rodriguez. „A Review of Multiple-Choice Item-Writing Guidelines for Classroom Assessment”. *Applied Measurement in Education* 15.3 (2002), 309–333. old.

[2] M. J. Gierl, O. Bulut, Q. Guo és X. Zhang. „Developing, Analyzing, and Using Distractors for Multiple-Choice Tests in Education: A Comprehensive Review”. *Review of Educational Research* 87.6 (2017), 1082–1116. old.

[3] G. Kurdi, J. Leo, B. Parsia, U. Sattler és S. Al-Emari. „A Systematic Review of Automatic Question Generation for Educational Purposes”. *International Journal of Artificial Intelligence in Education* 30.1 (2020), 121–204. old. DOI: 10.1007/s40593-019-00186-y.

[4] Z. Ji, N. Lee, R. Frieske és tsai. „Survey of Hallucination in Natural Language Generation”. *ACM Computing Surveys* 55.12 (2023), 1–38. old.

[5] J. Huang, X. Chen, S. Mishra és tsai. „Large Language Models Cannot Self-Correct Reasoning Yet”. *International Conference on Learning Representations (ICLR)*. 2024.

[6] N. F. Liu, K. Lin, J. Hewitt és tsai. „Lost in the Middle: How Language Models Use Long Contexts”. *Transactions of the Association for Computational Linguistics* 12 (2024), 157–173. old.

[7] Európai Parlament és a Tanács. *Az Európai Parlament és a Tanács (EU) 2016/679 rendelete (általános adatvédelmi rendelet)*. Az Európai Unió Hivatalos Lapja, L 119. 2016.

[8] S. M. Downing. „The Effects of Violating Standard Item Writing Principles on Tests and Students: The Consequences of Using Flawed Test Items on Achievement Examinations in Medical Education”. *Advances in Health Sciences Education* 10.2 (2005), 133–143. old. DOI: 10.1007/s10459-004-4019-5.

[9] M. C. Rodriguez. „Three Options Are Optimal for Multiple-Choice Items: A Meta-Analysis of 80 Years of Research”. *Educational Measurement: Issues and Practice* 24.2 (2005), 3–13. old. DOI: 10.1111/j.1745-3992.2005.00006.x.

[10] M. Tarrant, J. Ware és A. M. Mohammed. „An Assessment of Functioning and Non-Functioning Distractors in Multiple-Choice Questions: A Descriptive Analysis”. *BMC Medical Education* 9 (2009), 40. old. DOI: 10.1186/1472-6920-9-40.

[11] L. W. Anderson és D. R. Krathwohl, szerk. *A Taxonomy for Learning, Teaching, and Assessing: A Revision of Bloom's Taxonomy of Educational Objectives*. New York: Longman, 2001.

[12] D. Scully. „Constructing Multiple-Choice Items to Measure Higher-Order Thinking”. *Practical Assessment, Research, and Evaluation* 22.4 (2017).

[13] B. Csapó és G. Molnár. „Online Diagnostic Assessment in Support of Personalized Teaching and Learning: The eDia System”. *Frontiers in Psychology* 10 (2019), 1522. old. DOI: 10.3389/fpsyg.2019.01522.

[14] R. Mitkov és L. A. Ha. „Computer-Aided Generation of Multiple-Choice Tests”. *Proceedings of the HLT-NAACL 03 Workshop on Building Educational Applications Using Natural Language Processing*. 2003, 17–22. old.

[15] M. Heilman és N. A. Smith. „Good Question! Statistical Ranking for Question Generation”. *Human Language Technologies: The 2010 Annual Conference of the North American Chapter of the Association for Computational Linguistics*. 2010, 609–617. old.

[16] J. Alshboul és E. Baksa-Varga. „A Hybrid Approach for Automatic Question Generation from Program Codes”. *International Journal of Advanced Computer Science and Applications* 15.1 (2024), 10–17. old.

[17] P. Rajpurkar, J. Zhang, K. Lopyrev és P. Liang. „SQuAD: 100,000+ Questions for Machine Comprehension of Text”. *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing*. 2016, 2383–2392. old.

[18] X. Du, J. Shao és C. Cardie. „Learning to Ask: Neural Question Generation for Reading Comprehension”. *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics*. 2017, 1342–1352. old.

[19] E. Alhazmi, Q. Z. Sheng, W. E. Zhang, M. Zaib és A. Alhazmi. „Distractor Generation in Multiple-Choice Tasks: A Survey of Methods, Datasets, and Evaluation”. *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. 2024, 14437–14458. old.

[20] Z. Wang, J. Valdez, D. Basu Mallick és R. G. Baraniuk. „Towards Human-Like Educational Question Generation with Large Language Models”. *Artificial Intelligence in Education (AIED 2022)*. 13355. köt. Lecture Notes in Computer Science. Springer, 2022, 153–166. old.

[21] J. Doughty, Z. Wan, A. Bompelli, J. Qayum, T. Wang, J. Zhang és tsai. „A Comparative Study of AI-Generated (GPT-4) and Human-crafted MCQs in Programming Education”. *Proceedings of the 26th Australasian Computing Education Conference*. 2024, 114–123. old.

[22] S. K. Bitew, J. Deleu, C. Develder és T. Demeester. *Distractor Generation for Multiple-Choice Questions with Predictive Prompting and Large Language Models*. arXiv:2307.16338. 2023.

[23] A. Hadifar, S. K. Bitew, J. Deleu, C. Develder és T. Demeester. „EduQG: A Multi-Format Multiple-Choice Dataset for the Educational Domain”. *IEEE Access* 11 (2023), 20885–20896. old.

[24] F. Fawzi, S. Amini és S. Bulathwela. „Small Generative Language Models for Educational Question Generation”. *NeurIPS 2023 Workshop on Generative AI for Education (GAIED)*. 2023.

[25] N. Mulla és P. Gharpure. „Automatic Question Generation: A Review of Methodologies, Datasets, Evaluation Metrics, and Applications”. *Progress in Artificial Intelligence* 12.1 (2023), 1–32. old.

[26] A. Vaswani, N. Shazeer, N. Parmar és tsai. „Attention Is All You Need”. *Advances in Neural Information Processing Systems*. 30. köt. 2017.

[27] J. Devlin, M.-W. Chang, K. Lee és K. Toutanova. „BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”. *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics*. 2019, 4171–4186. old.

[28] T. B. Brown, B. Mann, N. Ryder, M. Subbiah, J. Kaplan, P. Dhariwal és tsai. „Language Models are Few-Shot Learners”. *Advances in Neural Information Processing Systems*. 33. köt. 2020, 1877–1901. old.

[29] L. Ouyang, J. Wu, X. Jiang, D. Almeida, C. L. Wainwright, P. Mishkin és tsai. „Training Language Models to Follow Instructions with Human Feedback”. *Advances in Neural Information Processing Systems*. 35. köt. 2022.

[30] B. T. Willard és R. Louf. *Efficient Guided Generation for Large Language Models*. arXiv:2307.09702. 2023.

[31] P. Lewis, E. Perez, A. Piktus és tsai. „Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks”. *Advances in Neural Information Processing Systems*. 33. köt. 2020, 9459–9474. old.

[32] Y. Gao, Y. Xiong, X. Gao és tsai. *Retrieval-Augmented Generation for Large Language Models: A Survey*. 2023. arXiv: 2312.10997.

[33] S. Robertson és H. Zaragoza. „The Probabilistic Relevance Framework: BM25 and Beyond”. *Foundations and Trends in Information Retrieval* 3.4 (2009), 333–389. old.

[34] V. Karpukhin, B. Oğuz, S. Min és tsai. „Dense Passage Retrieval for Open-Domain Question Answering”. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. 2020, 6769–6781. old.

[35] L. Wang, N. Yang, X. Huang, L. Yang, R. Majumder és F. Wei. *Multilingual E5 Text Embeddings: A Technical Report*. 2024. arXiv: 2402.05672.

[36] N. Thakur, N. Reimers, A. Rücklé, A. Srivastava és I. Gurevych. „BEIR: A Heterogeneous Benchmark for Zero-shot Evaluation of Information Retrieval Models”. *Thirty-fifth Conference on Neural Information Processing Systems Datasets and Benchmarks Track*. 2021.

[37] A. Novák, B. Novák, D. Zombori, G. Szabó, Z. Szántó és R. Farkas. „A Question Answering Benchmark Database for Hungarian”. *Proceedings of the 17th Linguistic Annotation Workshop (LAW-XVII)*. 2023, 188–198. old.

[38] G. V. Cormack, C. L. A. Clarke és S. Buettcher. „Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods”. *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval*. 2009, 758–759. old.

[39] L. Gao, X. Ma, J. Lin és J. Callan. „Precise Zero-Shot Dense Retrieval without Relevance Labels”. *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics*. 2023, 1762–1777. old.

[40] R. Qu, R. Tu és F. Bao. *Is Semantic Chunking Worth the Computational Cost?* 2024. arXiv: 2410.13070.

[41] T. Gao, H. Yen, J. Yu és D. Chen. „Enabling Large Language Models to Generate Text with Citations”. *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. 2023, 6465–6488. old.

[42] H. Rashkin, V. Nikolaev, M. Lamm, L. Aroyo, M. Collins, D. Das és tsai. „Measuring Attribution in Natural Language Generation Models”. *Computational Linguistics* 49.4 (2023), 777–840. old.

[43] D. Edge, H. Trinh, N. Cheng és tsai. *From Local to Global: A Graph RAG Approach to Query-Focused Summarization*. 2024. arXiv: 2404.16130.

[44] C.-P. Hsieh, S. Sun, S. Kriman és tsai. „RULER: What’s the Real Context Size of Your Long-Context Language Models?”: *Conference on Language Modeling (COLM)*. 2024.

[45] Z. Li, C. Li, M. Zhang, Q. Mei és M. Bendersky. „Retrieval Augmented Generation or Long-Context LLMs? A Comprehensive Study and Hybrid Approach”. *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing: Industry Track*. 2024.

[46] J. Wei, X. Wang, D. Schuurmans és tsai. „Chain-of-Thought Prompting Elicits Reasoning in Large Language Models”. *Advances in Neural Information Processing Systems*. 35. köt. 2022.

[47] D. Zhou, N. Schärli, L. Hou, J. Wei, N. Scales, X. Wang és tsai. „Least-to-Most Prompting Enables Complex Reasoning in Large Language Models”. *International Conference on Learning Representations (ICLR)*. 2023.

[48] L. Wang, W. Xu, Y. Lan és tsai. „Plan-and-Solve Prompting: Improving Zero-Shot Chain-of-Thought Reasoning by Large Language Models”. *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics*. 2023, 2609–2634. old.

[49] T. Wu, M. Terry és C. J. Cai. „AI Chains: Transparent and Controllable Human-AI Interaction by Chaining Large Language Model Prompts”. *Proceedings of the 2022 CHI Conference on Human Factors in Computing Systems*. 2022.

[50] A. Madaan, N. Tandon, P. Gupta, S. Hallinan, L. Gao, S. Wiegreffe és tsai. „Self-Refine: Iterative Refinement with Self-Feedback”. *Advances in Neural Information Processing Systems*. 36. köt. 2023.

[51] S. Dhuliawala, M. Komeili, J. Xu és tsai. „Chain-of-Verification Reduces Hallucination in Large Language Models”. *Findings of the Association for Computational Linguistics: ACL 2024*. 2024.

[52] S. Min, K. Krishna, X. Lyu és tsai. „FActScore: Fine-grained Atomic Evaluation of Factual Precision in Long Form Text Generation”. *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. 2023, 12076–12100. old.

[53] P. Laban, T. Schnabel, P. N. Bennett és M. A. Hearst. „SummaC: Re-Visiting NLI-based Models for Inconsistency Detection in Summarization”. *Transactions of the Association for Computational Linguistics* 10 (2022), 163–177. old.

[54] C. Snell, J. Lee, K. Xu és A. Kumar. „Scaling LLM Test-Time Compute Optimally Can be More Effective than Scaling Parameters for Reasoning”. *International Conference on Learning Representations (ICLR)*. 2025.

[55] M. Strathern. „‘Improving Ratings’: Audit in the British University System”. *European Review* 5.3 (1997), 305–321. old.

[56] Qwen Team. *Qwen2.5 Technical Report*. 2024. arXiv: 2412.15115.

[57] A. Grattafiori és tsai. *The Llama 3 Herd of Models*. 2024. arXiv: 2407.21783.

[58] Gemma Team. *Gemma 3 Technical Report*. 2025. arXiv: 2503.19786.

[59] NYTK – HUN-REN Nyelvtudományi Kutatóközpont. *PULI-LlumiX-Llama-3.1: magyar–angol nyelvi modell (8B), a Llama 3.1 továbbtanításával*. https://huggingface.co/NYTK/PULI-LlumiX-Llama-3.1. Modellkártya. 2024.

[60] E. Frantar, S. Ashkboos, T. Hoefler és D. Alistarh. „GPTQ: Accurate Post-Training Quantization for Generative Pre-trained Transformers”. *International Conference on Learning Representations (ICLR)*. 2023.

[61] G. Gerganov és tsai. *llama.cpp: LLM inference in C/C++*. `https://github.com/ggml-org/llama.cpp`. Szoftver, GGUF formátum és K-kvantálás. 2023.

[62] Ollama. *Ollama: Get up and running with large language models locally*. `https://github.com/ollama/ollama`. Szoftver. 2024.

[63] S. Li, X. Ning, L. Wang és tsai. „Evaluating Quantized Large Language Models”. *Proceedings of the 41st International Conference on Machine Learning (ICML)*. 235. köt. PMLR. 2024, 28480–28524. old.

[64] L. Zheng, W.-L. Chiang, Y. Sheng, S. Zhuang, Z. Wu, Y. Zhuang és tsai. „Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena”. *Advances in Neural Information Processing Systems (Datasets and Benchmarks Track)*. 36. köt. 2023.

[65] C.-H. Chiang és H.-y. Lee. „Can Large Language Models Be an Alternative to Human Evaluations?”: *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics*. 2023, 15607–15631. old.

[66] S. Es, J. James, L. Espinosa-Anke és S. Schockaert. „RAGAs: Automated Evaluation of Retrieval Augmented Generation”. *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations*. 2024, 150–158. old.

[67] P. Wang, L. Li, L. Chen és tsai. „Large Language Models are not Fair Evaluators”. *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics*. 2024, 9440–9450. old.

[68] A. Panickssery, S. R. Bowman és S. Feng. „LLM Evaluators Recognize and Favor Their Own Generations”. *Advances in Neural Information Processing Systems*. 37. köt. 2024.

[69] OpenAI. *gpt-oss-120b & gpt-oss-20b Model Card*. 2025. arXiv: `2508.10925`.

[70] J. Cohen. „A Coefficient of Agreement for Nominal Scales”. *Educational and Psychological Measurement* 20.1 (1960), 37–46. old.

[71] K. Krippendorff. *Content Analysis: An Introduction to Its Methodology*. 2. kiad. Thousand Oaks, CA: Sage, 2004.

[72] J. R. Landis és G. G. Koch. „The Measurement of Observer Agreement for Categorical Data”. *Biometrics* 33.1 (1977), 159–174. old.

[73] X. Bouthillier, P. Delaunay, M. Bronzi, A. Trofimov, B. Nichyporuk, J. Szeto és tsai. „Accounting for Variance in Machine Learning Benchmarks”. *Proceedings of Machine Learning and Systems (MLSys)*. 2021.

[74] R. Dror, G. Baumer, S. Shlomov és R. Reichart. „The Hitchhiker’s Guide to Testing Statistical Significance in Natural Language Processing”. *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics*. 2018, 1383–1392. old.

[75] S. Holm. „A Simple Sequentially Rejective Multiple Test Procedure”. *Scandinavian Journal of Statistics* 6.2 (1979), 65–70. old.

[76] O. Sainz, J. A. Campos, I. García-Ferrero, J. Etxaniz, O. Lopez de Lacalle és E. Agirre. „NLP Evaluation in Trouble: On the Need to Measure LLM Data Contamination for each Benchmark”. *Findings of the Association for Computational Linguistics: EMNLP 2023*. 2023.

[77] R. Parasuraman és D. H. Manzey. „Complacency and Bias in Human Use of Automation: An Attentional Integration”. *Human Factors* 52.3 (2010), 381–410. old.

[78] Európai Parlament és a Tanács. *Az Európai Parlament és a Tanács (EU) 2024/1689 rendelete a mesterséges intelligenciára vonatkozó harmonizált szabályok megállapításáról (mesterséges intelligenciáról szóló rendelet)*. Az Európai Unió Hivatalos Lapja, L sorozat. 2024.

[79] K. Ahuja, H. Diddee, R. Hada, M. Ochieng, K. Ramesh, P. Jain és tsai. „MEGA: Multilingual Evaluation of Generative AI". *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. 2023.

[80] D. M. Nemeskey. „Introducing huBERT". *XVII. Magyar Számítógépes Nyelvészeti Konferencia (MSZNY 2021)*. Szeged, 2021, 3–14. old.

[81] Z. G. Yang, R. Dodé, G. Ferenczi és tsai. „Jönnek a nagyok! BERT-Large, GPT-2 és GPT-3 nyelvmodellek magyar nyelvre". *XIX. Magyar Számítógépes Nyelvészeti Konferencia (MSZNY 2023)*. Szeged, 2023, 247–262. old.

[82] Z. G. Yang, L. J. Laki, T. Váradi és G. Prószéky. „Mono- and Multilingual GPT-3 Models for Hungarian". *Text, Speech, and Dialogue (TSD 2023)*. 14102. köt. Lecture Notes in Computer Science. Cham: Springer, 2023, 94–104. old. DOI: 10.1007/978-3-031-40498-6_9.

[83] Z. G. Yang, Á. Bánfi, R. Dodé, G. Ferenczi, F. Földesi, P. Hatvani és tsai. „ChatPULI: Enhancement to the First Hungarian Conversational Model". *Annales Mathematicae et Informaticae* 61 (2025), 261–274. old. DOI: 10.33039/ami.2025.10.010.

[84] N. Ligeti-Nagy, G. Ferenczi, E. Héja és tsai. „HuLU: Hungarian Language Understanding Benchmark Kit". *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*. 2024, 8360–8371. old.

[85] A. Novák és B. Novák. „MILQA kérdés-válasz benchmark adatbázis". *XIX. Magyar Számítógépes Nyelvészeti Konferencia (MSZNY 2023)*. Szeged, 2023, 203–216. old.

[86] P. Berkecz, T. Zombori, G. Banga és tsai. „SHunQA: egy nyíltkérdés-megválaszoló rendszer". *XX. Magyar Számítógépes Nyelvészeti Konferencia (MSZNY 2024)*. Szeged, 2024, 73–84. old.

[87] Szegedi Tudományegyetem és Z. Szántó. *Kérdés generálás tananyag alapon (kutatási projekt a HUN-REN Cloud infrastruktúráján, 2024. november – 2025. február)*. https://science-cloud.hu/projektek/kerdes-generalas-tananyag-alapon. Projektoldal, letöltve: 2026. november 6. 2025.

[88] Z. Rajki, J. T. Nagy és I. Dringó-Horváth. „A mesterséges intelligencia a felsőoktatásban: hallgatói hozzáférés, attitűd és felhasználási gyakorlat". *Iskolakultúra* 34.7 (2024), 3–22. old. DOI: 10.14232/iskkult.2024.7.3.

[89] J. T. Nagy, Z. Rajki és I. Dringó-Horváth. „Mesterséges intelligencia a felsőoktatásban: oktatói hozzáférés, attitűd és felhasználási gyakorlat". *Iskolakultúra* 35.7 (2025), 3–20. old. DOI: 10.14232/iskkult.2025.7.3.

[90] Európai Adatvédelmi Testület (EDPB). *Guidelines 07/2020 on the Concepts of Controller and Processor in the GDPR (Version 2.0)*. https://www.edpb.europa.eu/our-work-tools/our-documents/guidelines/guidelines-072020-concepts-controller-and-processor-gdpr_en. Elfogadva: 2021. július 7. 2021.

[91] N. Carlini, F. Tramèr, E. Wallace, M. Jagielski, A. Herbert-Voss, K. Lee és tsai. „Extracting Training Data from Large Language Models”. *30th USENIX Security Symposium*. 2021, 2633–2650. old.

[92] Országgyűlés. *2011. évi CXII. törvény az információs önrendelkezési jogról és az információszabadságról (Infotv.)* Nemzeti Jogszabálytár, `https://njt.jog.gov.hu/jogszabaly/2011-112-00-00`. 2011.

[93] Nemzeti Adatvédelmi és Információszabadság Hatóság (NAIH). *Figyelemfelhívás az MI használatának kockázataira a beadványok készítésénél*. `https://www.naih.hu/`. A hatóság honlapján közzétett, dátum nélküli közlemény; letöltve: 2026. november 6. 2026.

[94] Nemzeti Adatvédelmi és Információszabadság Hatóság (NAIH). *Jelentés magyarországi bankok MI használatáról*. `https://www.naih.hu/hirek/802-jelentes-magyarorszagi-bankok-mi-hasznalatarol`. Közzétéve: 2025. december 22.; angol változata: Report on the Processing of Personal Data by Artificial Intelligence (AI) Systems Used by Banks in Hungary. 2025.

[95] Európai Parlament és a Tanács. *Az Európai Parlament és a Tanács (EU) 2026/1744 rendelete (2026. július 8.) az (EU) 2024/1689, az (EU) 2018/1139 és az (EU) 2023/1230 rendeletnek a mesterséges intelligenciára vonatkozó harmonizált szabályok végrehajtásának egyszerűsítése tekintetében történő módosításáról (a mesterséges intelligenciáról szóló digitális omnibusz csomag)*. Az Európai Unió Hivatalos Lapja, L sorozat, 2026.7.24., `https://eur-lex.europa.eu/eli/reg/2026/1744/oj`. 2026.

[96] F. Miao és W. Holmes. *Guidance for Generative AI in Education and Research*. Paris: UNESCO, 2023.

[97] Qdrant. *Qdrant: Vector Similarity Search Engine*. `https://github.com/qdrant/qdrant`. Szoftver. 2024.

[98] M. L. Balinski és H. P. Young. *Fair Representation: Meeting the Ideal of One Man, One Vote*. 2. kiad. Washington, D.C.: Brookings Institution Press, 2001.

[99] B. Efron és R. J. Tibshirani. *An Introduction to the Bootstrap*. New York: Chapman & Hall, 1993.

[100] F. Wilcoxon. „Individual Comparisons by Ranking Methods”. *Biometrics Bulletin* 1.6 (1945), 80–83. old.

[101] D. S. Kerby. „The Simple Difference Formula: An Approach to Teaching Nonparametric Correlation”. *Comprehensive Psychology* 3 (2014).

Ábrák jegyzéke

3.1. A naiv RAG és a Mimir tervezett generálási folyamata. 17

4.1. Egy teszt lépései. 21

5.1. A minőségi index konfigurációnként és generátormodellenként. 31
5.2. A minőségi index a módszer lépései szerint a három helyi modellel. 31
5.3. A minőségi index dokumentumonkénti eloszlása a fő vizsgálatban. 33
5.4. A minőségi index dokumentumforrásonként a fő vizsgálat négy fő konfigurációjában. 35

6.1. Minőség és futási idő. 44

Táblázatok jegyzéke

2.1. A kérdésgenerálási megközelítések összevetése a **P1**–**P4** problémák szempontjából. 13

3.1. Az ellenőrző lánc lépései végrehajtási sorrendben, a hiba esetén adott visszajelzéssel. 19

4.1. A kísérleti konfigurációk. 23
4.2. A három vizsgálat fő paraméterei és beállításai. 25

5.1. A fő vizsgálat összesített eredményei modellenként és konfigurációnként (30 dokumentum). 30
5.2. Az előre rögzített hat páros összehasonlítás statisztikai próbái (fő vizsgálat, 30 dokumentum). 32
5.3. A darabolási változatok hatása a naiv RAG (**E0**) minőségi indexére. 34
5.4. A konfigurációk relatív futási ideje és modellhívásainak száma. 36
5.5. Az oktatók egymás közötti és a bíróval való egyezése (60 kérdés, 5 oktató). . . 38
5.6. Az oktatók és a bíró szerinti minőség konfigurációnként (6 közös dokumentum). 39

6.1. A generátormodellek minőségi indexe (Q) a hat közös dokumentumon. 41
6.2. A helyi Qwen2.5-7B és a szervermodell összevetése az előzetes vizsgálatban. . 41
6.3. A helyi generátormodellek memóriaigénye és relatív futási ideje. 43

7.1. A dolgozat hipotéziseinek értékelése a kísérleti eredmények alapján. 45
7.2. Ajánlott konfigurációk GPU-szintenként. 48

A.1. Becsült GPU-memóriaigény (8 192 tokenes kontextus, Q4_K_M kvantálás). . . 62
A.2. A nehézségi szintekhez rendelt Bloom-eloszlások és egy tízkérdéses vizsga kiosztása. 63
A.3. Az `eval-v1` adatkészlet és a fő vizsgálatban használt része. 64

B.1. Az előzetes vizsgálat helyi konfigurációinak eredményei (Qwen2.5-7B, 6 dokumentum). 67
B.2. Az **E2** ellenőrző láncának működése modellenként. 67
B.3. A bírói ítélettel rendelkező kérdések forrásonként. 68

E.1. A generálási folyamat paraméterei. 71

A. A módszer és a kiértékelés részletei

Ez a függelék a 3. és a 4. fejezet részleteit tartalmazza; a paraméterek alapértékeit az E. függelék foglalja össze.

A.1. A GPU-memória becslése

A szövegelőállítás közbeni memóriaigény

$$M = W + \mathrm{ctx} \cdot m_{kv} + M_0, \tag{A.1}$$

ahol W a kvantált súlyok mérete, ctx a kontextus hossza tokenben, M_0 a futtatókörnyezet többletigénye, $m_{kv} = 2 \cdot L \cdot H_{kv} \cdot d_h \cdot 2$ bájt pedig a KV-gyorsítótár tokenenkénti mérete (L réteg, H_{kv} kulcs–érték fej, d_h elemű vektorok, 2 bájt/elem). A Qwen2.5-7B-re [56] ($L = 28$, $H_{kv} = 4$, $d_h = 128$) $m_{kv} = 56\,\mathrm{KiB}$, így a gyorsítótár 8 192 tokennél 448 MiB, 16 384 tokennél 896 MiB, 32 768 tokennél 1,75 GiB (A.1. táblázat). A PULI-LlumiX 8B [59] a Llama-3.1-8B architektúráját örökli. A Gemma 3 12B rétegeinek többsége csak egy rövid, helyi ablakra (*sliding window*) figyel, és csak minden hatodik réteg lát a teljes kontextusra, ezért nála a képlet túlbecsül, és a mért értéket használjuk.

A.1. táblázat. Becsült GPU-memóriaigény 8 192 tokenes kontextusnál, Q4_K_M kvantálással (kb. 4,8 bit/súly) és $M_0 \approx 0{,}56\,\mathrm{GiB}$ többlettel. A súlyok a GGUF-fájlok GiB-ra átszámított mérete, m_{kv} a publikált architektúrákból számolt érték; a Gemma 3 12B sorában az Ollama által mért foglalás áll.

Modell	L/H_{kv}	Súlyok	m_{kv}	Összesen	Kártya
Qwen2.5-3B	36/2	1,8 GiB	36 KiB	2,6 GiB	8 GiB
Qwen2.5-7B	28/4	4,4 GiB	56 KiB	5,4 GiB	8 GiB
Llama-3.1-8B [57] (= PULI-LlumiX 8B)	32/8	4,6 GiB	128 KiB	6,1 GiB	8 GiB
Gemma 3 12B [58]	48/8	7,5 GiB	($\leq$ 384 KiB)	$\approx$ 7,8 GiB (mért)	12 GiB
Qwen2.5-14B	48/8	8,4 GiB	192 KiB	10,4 GiB	12 GiB

A.2. A generálási módszer részletei

Bloom-kiosztás. A nehézségi szinthez tartozó eloszlást (A.2. táblázat) *legnagyobb maradék módszerrel* (Hamilton-módszer [98]) alakítjuk egész darabszámokká: közepes nehézségnél $n = 7$ kérdésre a (2,8; 2,8; 1,4) szorzatok egészrészei (2,2,1), a két maradék hely a két legnagyobb törtrészű szinthez kerül, így a kiosztás (3,3,1). A szinteket véletlenszerűen rendeljük a kérdéshelyekhez, a kész vizsgát a könnyebbtől a nehezebb felé rendezzük.

Darabolás. A vágási küszöb a szomszédos mondatok $\delta_i = 1 - \cos(\mathbf{v}_i, \mathbf{v}_{i+1})$ távolságainak 85. percentilise (az **E5b**-ben az átlag + 1,5 szórás), amely a célméret (1 000 karakter) túllépése

A.2. táblázat. A nehézségi szintekhez rendelt Bloom-eloszlások és egy tízkérdéses vizsga kiosztása.

Nehézség	Emlékezés	Megértés	Alkalmazás	Elemzés	Értékelés	Kiosztás ($n = 10$)
Könnyű	0,5	0,5	–	–	–	(5, 5, 0, 0, 0)
Közepes	–	0,4	0,4	0,2	–	(0, 4, 4, 2, 0)
Nehéz	–	–	0,3	0,4	0,3	(0, 0, 3, 4, 3)

után $\tau/(\ell/1\,000)$-re csökken (ℓ az aktuális darab hossza karakterben).

Hibrid keresés. Az **E2h** a hat karakterre csonkolt szavakon számolt BM25-rangsort [33] és a sűrű rangsort reciprok rangfúzióval [38] egyesíti: egy darab pontszáma $1/(60 + \text{rang}_{\text{sűrű}}) + 1/(60 + \text{rang}_{\text{BM25}})$.

Fogalomgráf. Az **E3** legfeljebb 3 000 karakteres kötegenként kinyeri a fogalmakat, tényeket és kapcsolatokat, a 0,92-nél hasonlóbb nevű fogalmakat összevonja, és a fogalmakat a kapcsolatok + $\frac{1}{2}\cdot$ darabok + $\frac{1}{2}\cdot$ tények centralitás szerint rendezi; disztraktor-ötletként az azonos szülőjű testvérfogalmakat adja át.

Egy kérdéshely kitöltése. Az A.1. algoritmus az **E2** egy kérdéshelyét tölti ki (vö. 3.4.6. szakasz). Ha egy tartalékfogalommal sem sikerül, a *legjobb* kísérlet (formailag helyes, szivárgásmentes, legkevesebb hibájú) marad meg *nem ellenőrzöttként* megjelölve.

Algoritmus A.1: Egy kérdéshely kitöltése visszacsatolással (**E2**).

Bemenet: kérdéshely s (fogalom, típus, Bloom-szint); elfogadott kérdések $\mathcal{A}$; $k = 3$; $r = 1$
Kimenet: kérdés q és az *ellenőrzött* jelző

$q^* \leftarrow \emptyset$;
minden *fogalom* $c \in \big(s.\textit{fogalom},\ \textit{az első tartalékfogalom}\big)$ **elemre**
  $h \leftarrow \emptyset$; $k' \leftarrow k$;
  ciklus $t = 0, \ldots, r$ **:**
    $K \leftarrow \textsc{Kontextus}(c, k')$; // ≤ 6 000 karakter
    $q \leftarrow \textsc{Generál}(s, c, K, \mathcal{A}, h)$; // h: az előző hibák
    $h \leftarrow \textsc{Ellenőriz}(q, K) \cup \textsc{Duplikátum}(q, \mathcal{A})$;
    ha $h = \emptyset$ **akkor visszatér** $(q,$ igaz$)$;
    $q^* \leftarrow$ a jobb q^* és q közül;
    ha *a kulcs nem igazolt* **akkor** $k' \leftarrow k' + 2$;
ha q^* *formája hibás* **akkor** $q^* \leftarrow \textsc{Javít}(q^*)$;
visszatér $(q^*,$ hamis$)$;

A.3. A mérés részletei

Adatkészlet. Minden referenciakérdéshez rendelkezésre áll a forrásszakasz és a választ igazoló mondat; az importált forrásokból csak azokat a kérdéseket tartottuk meg, amelyek igazoló mondata szó szerint szerepel a dokumentumban (A.3. táblázat).

Oktatói értékelés. A hat közös dokumentumon (3 magyar, 3 angol) futott hat konfigurációból (Qwen2.5-7B, PULI-LlumiX 8B és Gemma 3 12B; **B-doc-L** és **E2**) futásonként 10 értékelendő

A.3. táblázat. Az `eval-v1` adatkészlet és a fő vizsgálatban használt része. R/K/H: rövid (≤ 6 000), közepes (6 000–25 000) és hosszú (25 000–90 000 karakteres) dokumentumok.

		`eval-v1`			Fő vizsgálat		
Forrás	Nyelv	Dok.	R/K/H	Ref. kérdés	Dok.	R/K/H	Licenc
Saját oktatási szövegek	magyar	3	3/0/0	12	3	3/0/0	saját
OpenStax, EduQG	angol	12	4/4/4	74	3	1/1/1	CC BY 4.0
Wikipédia, MILQA	magyar	24	8/8/8	240	24	8/8/8	CC BY-SA 4.0
Összesen		39	15/12/12	326	30	12/9/9	

és 2 kalibrációs kérdést mintavételezünk (előbb minden dokumentumból egyet, rögzített maggal, csak a bíró által pontozott kérdések közül). A 72 kérdés minden értékelőnél azonos; több, eltérő kérdéssorrendű lapváltozat készült, amelyeket összesen öt oktató töltött ki. A lapok vakok: a konfiguráció neve nem szerepel, az értékelendő kérdések sorrendje lapváltozatonként véletlen, a forrásrészlet és a rubrika a bíróéval azonos. Az oktatók egymás közötti egyezését Krippendorff-α-val [71] mérjük (a hiányzó értékeléseket az α kezeli). A bíró és az oktatók egyezését a bíró pontszáma és az oktatói átlag Spearman-korrelációjával, a bíró pontszáma és a kerekített oktatói medián α-jával, a bíró „alátámasztott” ítéletének és az oktatói többség helyesség ≥ 4 ítéletének, valamint a két felhasználnám ítéletnek az egyezését Cohen-κ-val mérjük. A 95 %-os intervallumok a kérdésekre vett bootstrapből (2 000 minta) származnak.

Mutatók. A *lefedettség*

$$\text{Lef} = \frac{\text{a kérdésekhez (törzs és kulcs) legközelebbi különböző darabok száma}}{K}, \tag{A.2}$$

ahol K a dokumentum darabjainak száma; tíz kérdésnél legfeljebb $10/K$. A további mutatók definíciója:

– *Szivárgás:* a legalább háromszavas kulcs szavainak legalább 80 %-a a törzsben is szerepel.
– *Nem kérdés:* a törzs sem kérdőjelre, sem kettőspontra nem végződik.
– *Duplikátumráta:* a 0,9-nél nagyobb koszinusz-hasonlóságú kérdéspárok aránya.
– *Meta-hivatkozás:* az „a szöveg szerint” jellegű fordulatok aránya.
– *Recall@3:* a referenciakérdéssel futtatott keresés első három találata között szerepel-e az igazoló mondatot tartalmazó darab.
– *Tematikus hasonlóság:* a referenciakérdések mekkora részéhez van közeli generált kérdés.
– *Költségmutatók:* a szakaszonkénti futási idő, a hívások és tokenek száma, valamint a GPU-memória alapszintje és csúcsa.

Statisztika. A hatásnagyság a rangbiszeriális korreláció [101]

$$r_{rb} = \frac{W^+ - W^-}{W^+ + W^-}, \tag{A.3}$$

ahol W^+ és W^- a pozitív, illetve negatív különbségek rangösszege. D dokumentumnál a Wilcoxon-próba [100] legkisebb kétoldali p-értéke $2 \cdot 2^{-D}$ (hatnál 0,031, ötnél 0,0625), Holm-korrekció [75] után hat összehasonlításnál hatszorosa, 0,19. Két igen/nem ítéletsor egyezése Cohen-κ-val [70]

$$\kappa = \frac{p_o - p_e}{1 - p_e}, \tag{A.4}$$

ahol p_o a megfigyelt, p_e a véletlenül várható egyezési arány (értelmezés: Landis és Koch [72]). A bíró alátámasztottsági ítéletét referenciának tekintve az ellenőrzőre

$$\text{pontosság} = \frac{\text{átengedett és alátámasztott}}{\text{átengedett}}, \qquad \text{felidézés} = \frac{\text{átengedett és alátámasztott}}{\text{alátámasztott}}. \tag{A.5}$$

B. Kiegészítő eredmények

Ez a függelék az 5. fejezet részletes táblázatait és számait tartalmazza.

B.1. A pilot részletei

A pilot a `hu-coffee` szövegen (1 702 karakter, négy darab) tíz konfigurációval, konfigurációnként három vizsgával, összesen 300 kérdéssel futott. Ha egy kérdéshely minden kísérlete elbukott, a megtartott kérdésnek néha csak két-három válasza volt, ami a vizsga Q-ját 0,25-tel csökkentette (javítás: a kiválasztás a formát is figyeli, egy javító hívás pótolja a disztraktorokat); sikertelen hívásoknál egy egykérdéses tartalékvizsga került a kimenetbe, a kódoló pedig a hosszabb szövegeket a tartalomtól függetlenül vágta (3.4.1. szakasz). Szivárgásra példa az **E3** egy „kérdése”, amely szó szerint egy forrásmondat volt („. . . Európába pedig a 17. században jutott el a velencei kereskedők révén.”), kulcsa ugyanez volt, disztraktorai pedig ugyanezt a mondatot ismételték a 16., 18. és 15. századdal; az **E3** kérdéseinek 20 %-a szivárgott, 47 %-uk nem volt kérdés, a bíró mégis többnyire 5-ös helyességet adott. Az azonos kontextust kapó **E0** és **E5a** 0,83, illetve 0,90 minőségi indexet ért el, ezért egy dokumentumon a 0,07-nél kisebb különbségek zajnak tekintendők.

B.2. Az előzetes vizsgálat helyi konfigurációi

Az **E2** a legrobusztusabb (leggyengébb dokumentuma is 0,89), az ellenőrzés az **E1**-hez képest öt dokumentumon javított, egyen sem rontott (+0,08), a kiegészítő ablációk mind elmaradtak az **E2**-től, a naiv RAG pedig az angol szövegeken omlott össze (0,40; a magyarokon 0,88). Az **E2**–**E0** (hat javulás) és az **E2**–**E1** (öt javulás, romlás nélkül) korrigálatlanul $p = 0{,}031$, Holm-korrekció után egyik sem szignifikáns (a legkisebb elérhető korrigált érték 0,19).

B.3. Az ellenőrző lánc részletei

A Qwen ellenőrzője pontos, de szigorú (a jó kérdések közel felét is megjelöli), a Gemmáé szinte mindent átenged; a PULI mutatói mindössze 85 bírált kérdésen alapulnak. A többi ellenőrzött konfigurációban a κ legfeljebb 0,22 (Qwen **E2h**).

B.4. Lefedettség, kognitív szint és felhasználhatóság

A *lefedettség* az **E0**-ról az **E2**-re a Qwennél 25 %→44 %, a PULI-nál 10 %→21 %, a Gemmánál 24 %→43 %. A teljes dokumentumos promptnál a lefedettség a Gemmánál 43 %, a Qwennél 45 % (tíz kérdésnél a felső korlát $10/K$).

B.1. táblázat. Az előzetes vizsgálat helyi konfigurációinak eredményei (Qwen2.5-7B, 6 dokumentum).

Konfiguráció	Q	95 % KI	F	G	A	V	Lef.	Min.
Alapvonalak								
B-doc-L (teljes dok.)	0,83	0,76–0,90	83	79	86	85	45	0,71
E0 (naiv RAG)	0,64	0,46–0,81	**100**	43	62	52	25	0,34
A javasolt módszer lépései								
E1 (tervezés)	0,88	0,82–0,94	**100**	80	80	91	46	0,76
E2 (tervezés + ellenőrzés)	**0,96**	0,93–0,98	**100**	**90**	**97**	**96**	44	**0,89**
E3 (+ fogalomgráf)	0,88	0,79–0,95	**100**	83	87	83	40	0,68
Kiegészítő ablációk								
E2f (vak próba nélkül)	0,90	0,84–0,95	**100**	78	88	92	44	0,81
E2h (hibrid keresés)	0,92	0,90–0,94	**100**	82	92	94	42	0,88
E2x (csak szabályok)*	0,89	0,83–0,95	**100**	78	83	95	42	0,77
Darabolási változatok								
E5a (régi kódoló)	0,87	0,81–0,92	**100**	74	84	90	36	0,76
E5b (magasabb küszöb)	0,70	0,54–0,86	**100**	39	78	63	35	0,45
E5c (rögzített darabolás)	0,86	0,70–0,97	**100**	82	82	81	**51**	0,50

Jelmagyarázat: Az egyhívásos konfigurációk három, a tervezettek egy véletlen maggal futottak (a futási időket az 5.4. táblázat, a szerveres konfigurációkat a 6.2. szakasz közli). Q: minőségi index; **95 % KI**: 95 %-os bootstrap-konfidenciaintervallum; F, G, A, V: formai megfelelés, forrás-alátámasztottság, vak megoldhatóság és disztraktor-validitás (%); **Lef.**: dokumentum-lefedettség (%); **Min.**: a leggyengébb dokumentum Q-ja. A **félkövér** értékek oszloponként a legjobb eredményt, a **zöld kiemelés** a legmagasabb átlagos és dokumentumszintű minimum Q-t jelöli. *Az **E2x**-ben a második modell ellenőrző hívásai hibával tértek vissza (5.4. szakasz).

B.2. táblázat. Az **E2** ellenőrző láncának működése modellenként.

Modell	n	Első kísérlet	Kísérlet/ kérdéshely	Átengedett	Pontosság	Felidézés	κ	Leggyakoribb elutasítási okok
Qwen2.5-7B	60	23 %	1,8	52 %	0,94	0,54	0,08	duplikátum, igaz lehet egy disztraktor, nem kérdés
PULI-LlumiX 8B	85	5 %	2,0	19 %	0,56	0,21	0,05	duplikátum, forma, nem kérdés, vak eltérés, szivárgás
Gemma 3 12B	157	70 %	1,3	95 %	0,88	0,95	0,00	duplikátum, vak eltérés

Jelmagyarázat: n: bírói ítélettel rendelkező kérdések száma (5.9. szakasz); **Első kísérlet**: az első próbálkozásra elfogadott kérdéshelyek aránya; **Átengedett**: a végső vizsgában ellenőrzöttként elfogadott kérdések aránya; **Pontosság**, **Felidézés**, κ: az ellenőrző mint bináris osztályozó mutatói és Cohen-κ-ja a bíró alátámasztottsági ítéletéhez képest (4.8. szakasz). Az elutasítási okok az összes kísérletre vonatkoznak.

A vizsgaterv a kérdések 43–45 %-át a fő vizsgálatban, illetve 27 %-át az előzetes vizsgálatban tervezte *magasabb rendű Bloom-szintre*. A bíró szerint ebből a Gemmánál 7–11 %, a Qwennél 5–13 %, a PULI-nál 0–2 % valósult meg, a tervezett és a megvalósult szint pedig a Gemmánál 12–20 %-ban, a PULI-nál 6–10 %-ban, a Qwennél 33–45 %-ban egyezett.

A *„felhasználnám”* ítélet aránya (csak a bírált kérdéseken) a Gemmánál a tervezett konfigurációkban 85–88 %, a teljes dokumentumos promptnál 83 %, az **E5c**-nél 80 %, a naiv RAG-nál 42 %; a Qwennél **E2** 80 %, **B-doc-L** 68 %, **E0** 34 %; a PULI-nál legfeljebb 38 % (**E5a**, vizsgánként átlagosan 2,3 kérdéssel), az **E2**-ben 29 %. A Gemma törzsei a tervezett konfigurációkban átlagosan 122–125 karakteresek (**E3**: 106), a teljes dokumentumos kérdéseknél 63, a naiv RAG-nál 54.

B.5. A bírói ítéletek lefedettsége

B.3. táblázat. A bírói ítélettel rendelkező kérdések forrásonként (ítélettel rendelkező / összes kérdés) három jellemző konfigurációban.

Konfiguráció	Angol (3 dok.)	Saját magyar (3 dok.)	Wikipédia (24 dok.)	Összesen
Gemma **E2**	30/30 (100 %)	26/30 (87 %)	101/240 (42 %)	157/300 (52 %)
Gemma **E0**	90/90 (100 %)	90/90 (100 %)	394/720 (55 %)	574/900 (64 %)
PULI **E2**	9/30 (30 %)	5/30 (17 %)	71/238 (30 %)	85/298 (29 %)

Az áttekintő ítélet a fő vizsgálat tervezett konfigurációinál a kérdések 44–52 %-ánál (Gemma), illetve 29–48 %-ánál (PULI), az egyhívásosaknál 47–65 %-ánál, illetve 70–100 %-ánál van meg (az előzetes vizsgálatban mindenütt 100 %); konfigurációnként 85 (PULI **E2**) és 574 (Gemma **E0**) közötti, a tervezetteknél pedig 85–138 (PULI), illetve 132–157 (Gemma) kérdés kapott ítéletet. Hossz szerint nincs érdemi különbség (Gemma **E2**, Wikipédia- és angol dokumentumok: rövid 46/90, közepes 42/90, hosszú 43/90). Ennek három következménye van:

(1) a Wikipédia-dokumentumok G, A, V értéke kevesebb kérdésen alapul;

(2) tartalomfüggő elutasítás esetén e mutatók a bírált részhalmazra érvényesek;

(3) ha egy vizsga minden bírói hívása sikertelen, a Q csak a formára (és a vak próbára) támaszkodik, amit az érzékenységvizsgálat ellenőriz (5.9. szakasz).

A teljes dokumentumos konfigurációknál a bíró a dokumentum első 24 000 karakterét látja (4.6. szakasz): a 68 000 karakteres jogi szövegen ezért a szervermodell egy helyes kérdését („What is the access economy?”) alá nem támasztottnak ítélte, mert a fogalom a 38 603. karakternél áll.

C. A generátor promptja

Az alábbi kódblokk a generátor promptjának lényegi sorait közli; a kihagyásokat [. . .] jelöli, a kapcsos zárójelben álló részek helyére a program illeszti be az aktuális értéket. A prompt megismétli a naiv RAG-prompt szabályait, így az **E0** és az **E1**–**E3** konfigurációk szerkezetben, nem szabályokban különböznek. A naiv RAG (**E0**) és a teljes dokumentumos prompt (**B-doc**) ugyanezeket a szabályokat egyetlen hívásban kapja: a kontextus a három legközelebbi darab, illetve a teljes dokumentum, a feladat pedig „Készíts pontosan 10 darab vizsgakérdést [. . .]”. A tervező, a javító hívás, az ellenőrző és a fogalomgráf promptja angol nyelvű.

```
[generator] Te egy kiemelkedő tudású oktatásmódszertani szakértő [...] vagy. Kizárólag
↪  érvényes JSON
formátumban válaszolj! Készíts PONTOSAN EGY vizsgakérdést az alábbi terv szerint.
TERV: - Fogalom: {concept}   - Mit kérdezzen: {description}
- Kérdéstípus: feleletválasztós ("mcq"): pontosan 4 válasz, ebből pontosan 1 helyes és 3
↪  hihető,
  de a kontextus szerint egyértelműen helytelen disztraktor; [...]
- Bloom-szint: {pl. Megértés (magyarázat, összehasonlítás, saját szavakkal)}
- Vizsga nehézsége: {difficulty}   - Nyelv: [...] {magyar} nyelven írd.
KÖTELEZŐ SZABÁLYOK:
1. ZÉRÓ HALLUCINÁCIÓ: KIZÁRÓLAG a KONTEXTUS alapján dolgozz. [...]
2. HIVATKOZÁS: a "citations" mezőbe írd azoknak a részleteknek az azonosítóját (pl. "C3"),
   amelyek igazolják a helyes választ.
3. NO LATEX. [...]  4. META-REFERENCIA TILALOM: [...]  5. NE ISMÉTELD a már elkészült
↪  kérdéseket: {existing}
[AZ ELŐZŐ PRÓBÁLKOZÁS HIBÁS VOLT, JAVÍTSD: {feedback}]            (csak újrapróbálkozáskor)
KONTEXTUS: [C3] ... [C1] ...
KIMENETI FORMÁTUM: {"type": "mcq", "text": "A kérdés szövege?", "answers": [...],
↪  "citations": ["C0"],
 "bloom": "understand", "explanation": "egy mondat: miért ez a helyes válasz"}
```

D. A bíró és az oktatók rubrikája

A rubrika szövege a bíró és az oktatói értékelőlap számára azonos (a bíró az angol, az oktatók a magyar változatot kapják).

Helyesség

A megjelölt válasz a forrás szerint helyes, és más opció nem helyes. 1 = hibás kulcs vagy két helyes opció; 3 = helyes, de pontatlan; 5 = teljesen helyes, egyértelmű.

Érthetőség

A kérdés önmagában érthető, nyelvtanilag helyes, egyértelmű, nem hivatkozik „a szövegre” vagy a dokumentum szerkezetére. 1 = zavaros; 3 = nehezen érthető; 5 = vizsgakész megfogalmazás.

Disztraktorok

A rossz válaszok a forrás szerint egyértelműen rosszak, de egy felkészületlen diák számára hihetők (azonos téma, hasonló hossz és forma). 1 = abszurd vagy szintén helyes; 3 = részben hihető; 5 = mind hihető és rossz. Kifejtős kérdésnél üresen marad.

Szintillesztés

A kognitív szint megfelel a kért nehézségnek (könnyű: felidézés/megértés; közepes: alkalmazás/megértés; nehéz: elemzés/értékelés). 1 = egyértelműen rossz szint; 3 = határeset; 5 = illik.

Felhasználnám

Beraknád ezt a kérdést egy valódi dolgozatba legfeljebb apró javítással? (igen/nem)

A bíró áttekintő hívása ezen felül kéri a kulcsot igazoló mondat szó szerinti idézését, disztraktoronként azt, hogy a forrás szerint rossz-e, és a témához tartozik-e, a kérdés Bloom-szintjét és egy-két mondatos indoklást.

E. A generálási folyamat paraméterei

E.1. táblázat. A generálási folyamat paraméterei és alapértékei az előzetes és a fő vizsgálatban.

Paraméter	Alapérték	Megjegyzés
darabolás	percentilis, 85	célméret 1 000 karakter, puha korlát; **E5b**: átlag + 1,5 szórás; **E5c**: rögzített 800 karakter
visszakeresett darabok (k)	3	**E0**: a teljes vizsgához; tervezett folyamat: kérdéshelyenként
keresés módja	sűrű	**E2h**: BM25 + sűrű, RRF ($c = 60$), 6 karakteres előtagtövesítés
áttekintés kerete	12 000 karakter	a tervező ennyit lát; darabonként legalább 120 karakter
fogalmak száma	$n + 3$	3 tartalékfogalom
kérdéshely-kontextus kerete	6 000 karakter	+ 2 darab, ha a kulcs nem igazolt
újrapróbálkozás (r)	1	pilot: 2; utána 1 tartalékfogalom
ellenőrző lánc	**E1**: ki; **E2**, **E3**: be	vak megoldás: be (**E2f**: ki)
szivárgási szabályok, javító hívás	be	a pilot után bevezetve
duplikátumküszöb	0,9	koszinusz-hasonlóság (E5-beágyazás)
fogalomgráf (**E3**)	3 000 karakteres köteg	összevonás 0,92 hasonlóság felett
teljes dokumentum (**B-doc**)	30 000 / 80 000 karakter	helyi / szerver; helyben 16 384 tokenes kontextus
generátor	Q4_K_M, $T = 0{,}2$	8 192 tokenes kontextus; legfeljebb 4 096 tokenes válasz (fő vizsgálat)
bíró	gpt-oss-120b, $T = 0$	„low” gondolkodás; forrás legfeljebb 24 000 karakter