ÓBUDAI EGYETEM

[Kar neve, pl. Neumann János Informatikai Kar]
[Intézet neve]

TUDOMÁNYOS DIÁKKÖRI DOLGOZAT

Vizsgakérdés-generálás helyben futtatható nyelvi modellekkel

A MIMIR *tervezésvezérelt, forráshivatkozásos RAG-módszere és kísérleti kiértékelése*

Szerzők:

[Szerző 1 neve]
[szak, évfolyam]

[Szerző 2 neve]
[szak, évfolyam]

Konzulens:

[Konzulens neve]
[beosztás, intézet]

Budapest, 2026

64. Tudományos Diákköri Konferencia – 2026. őszi félév

Tartalmi összefoglaló

A vizsgakérdések írása lassú, hibalehetőségekkel teli szakmai munka: a kérdésnek egyértelműnek kell lennie, a megadott helyes válasznak a tananyagból kell következnie, feleletválasztós kérdésnél pedig a rossz válaszoknak (disztraktoroknak) hihetőnek, de igazolhatóan hibásnak kell lenniük. A nagy nyelvi modellek (LLM) megjelenésével a legelterjedtebb gyakorlat az lett, hogy az oktató feltölti a jegyzetét egy felhőben futó csevegő asszisztensbe, és „tíz vizsgakérdést" kér. Ez kényelmes, de négy lényeges hiányossága van: (P1) semmi sem ellenőrzi, hogy a megjelölt helyes válasz valóban következik-e a dokumentumból; (P2) a kérdések száma, típusa és nehézsége csak kérés, és a kérdések a tananyag néhány részére tömörülhetnek; (P3) a tananyag egy harmadik félhez kerül; (P4) a módszer nagy, távoli modellekre támaszkodik.

Dolgozatunkban bemutatjuk a MIMIR rendszert, amely az egyetlen promptot explicit, ellenőrizhető *módszerrel* váltja fel, és fogyasztói GPU-n futtatható nyelvi modellekkel működik. A rendszer feleletválasztós, igaz–hamis és kifejtős kérdéseket egyaránt előállít. A módszer lépései: a dokumentum szemantikus darabolása; egy vizsgaterv, amely a kérdésekhez előre kiosztja a típusokat, a témákat és a kognitív (Bloom-) szinteket; kérdésenkénti keresés a dokumentumban; egyenként generált, a forrásrészletekre hivatkozó kérdések; valamint egy ellenőrző lánc (formai és szivárgási szabályok, a válasz forrással való alátámasztottsága, a disztraktorok hamissága, „vak" megoldási próba), amely hiba esetén visszajelzéssel újrapróbálkozik. A rendszer a feltöltött tartalmat csak a feladat idejére tárolja.

A módszert egy nyílt kiértékelő keretrendszerrel vizsgáltuk: tizennégy, egyszerre egy tényezőt változtató kísérleti kar, 39 magyar és angol dokumentumból álló adatkészlet, a generátoroktól eltérő modellcsaládba tartozó nyelvi modell mint bíró, és dokumentumszintű statisztika. Egy egydokumentumos pilot három, a mérést felfelé torzító hibát tárt fel, köztük egy új hibamódot: az ellenőrző visszacsatolása a helyes választ a kérdés szövegébe szivárogtatta. A javított rendszerrel, feleletválasztós kérdéseken végzett fő vizsgálatban (14 kar, kilenc dokumentum, 1 670 kérdés) a helyi modellel futó, tervezett és ellenőrzött csővezeték érte el a legmagasabb minőségi indexet (0,96), szemben a naiv visszakereséses megoldás (0,64), a teljes dokumentumot egy promptban kapó helyi modell (0,83) és a teljes dokumentumot kapó nagy szervermodell (0,95) értékével, és mind a hat dokumentumon legalább 0,89-et ért el. A tervezés 0,24-dal, az ellenőrzés mind a hat dokumentumon 0,08-dal javított; a modell 5–5,6 GB GPU-memóriát foglalt, így 8 GB-os kártyán is fut. Az ellenőrző kérdésenkénti ítélete a bíróéval csak gyengén egyezett, a kis modell a kért kognitív szintet csak a kérdések harmadánál valósította meg, a kis minta miatt pedig a különbségek statisztikailag nem szignifikánsak. A teljes adatkészleten végzett futás és a bíró oktatói validálása a következő lépés.

Kulcsszavak: automatikus kérdésgenerálás, visszakereséssel kiegészített generálás (RAG), kis nyelvi modellek, ellenőrzés, nyelvi modell mint bíró, adatvédelem, oktatástechnológia, magyar nyelv

Tartalomjegyzék

Tartalmi összefoglaló ii

Tartalomjegyzék iii

Rövidítések és jelölések vi

1. Bevezetés 1
1.1. Motiváció . . . 1
1.2. Problémafelvetés . . . 1
1.3. Kutatási kérdések és hipotézisek . . . 2
1.4. Hozzájárulások . . . 3
1.5. A dolgozat felépítése . . . 3

2. Szakirodalmi áttekintés 5
2.1. A feleletválasztós kérdés mint mérőeszköz . . . 5
2.1.1. A jó kérdés ismérvei . . . 5
2.1.2. Kognitív szintek: Bloom taxonómiája . . . 6
2.1.3. Tételelemzés: nehézség és megkülönböztető erő . . . 6
2.2. Az automatikus kérdésgenerálás fejlődése . . . 7
2.2.1. Szabály- és sablonalapú rendszerek . . . 7
2.2.2. Neurális rendszerek és adatkészletek . . . 7
2.2.3. Disztraktorgenerálás . . . 8
2.2.4. A kiértékelés problémája . . . 8
2.3. A nagy nyelvi modellek alapjai . . . 8
2.4. Nagy nyelvi modellek a kérdésgenerálásban . . . 10
2.5. Feladatfelbontás és többlépéses csővezetékek . . . 11
2.6. Hallucináció . . . 12
2.7. Visszakereséssel kiegészített generálás . . . 13
2.7.1. Az alapelv és változatai . . . 13
2.7.2. Lexikális és sűrű keresés . . . 13
2.7.3. Darabolás . . . 14
2.7.4. Forráshivatkozás . . . 15
2.7.5. Gráfalapú visszakeresés . . . 15
2.8. Hosszú kontextus: a visszakeresés alternatívája? . . . 15
2.9. Ellenőrzés és önjavítás . . . 16
2.10. Kis nyelvi modellek és kvantálás . . . 17
2.11. Nyelvi modell mint bíró . . . 18
2.12. A kísérleti kiértékelés megbízhatósága . . . 18
2.13. Adatvédelem és szabályozási környezet . . . 19
2.14. Magyar nyelvi erőforrások . . . 20
2.15. Összegzés és a kutatási rés . . . 20

3. A MIMIR rendszer és generálási módszere **22**
3.1. Tervezési célok . . . 22
3.2. Mikroszolgáltatás-architektúra . . . 22
3.3. Adatvédelem: zéró adatmegőrzés . . . 23
3.4. A GPU-memória becslése . . . 24
3.5. A generálási módszer áttekintése . . . 25
3.6. Szemantikus darabolás . . . 26
3.7. Indexelés és az alapvonalak . . . 27
3.8. A vizsgaterv . . . 27
3.9. Slotonkénti keresés . . . 28
3.10. Forráshoz kötött kérdésgenerálás . . . 29
3.11. Az ellenőrző lánc . . . 29
3.11.1. Ellenőrzések a költség szerinti sorrendben . . . 29
3.11.2. Slotkitöltés visszacsatolással . . . 30
3.12. Munkamenet-hatókörű fogalomgráf . . . 31
3.13. Összeállítás és emberi felügyelet . . . 31

4. Kiértékelési módszertan **32**
4.1. A tesztelés menete . . . 32
4.2. Adatkészlet . . . 33
4.3. A kísérleti karok (tesztkonfigurációk) . . . 33
4.4. A két vizsgálat . . . 35
4.5. Mutatók . . . 36
4.5.1. Tartalmi mutatók . . . 37
4.5.2. Automatikus mutatók . . . 37
4.5.3. Költségmutatók . . . 38
4.6. A bíró . . . 38
4.7. Oktatói értékelés . . . 39
4.8. Statisztikai elemzés . . . 39

5. Eredmények **41**
5.1. A pilot vizsgálat . . . 41
5.2. A fő vizsgálat . . . 43
5.2.1. Beállítások és dokumentumok . . . 43
5.2.2. Összesített eredmények . . . 44
5.2.3. Dokumentumonkénti bontás . . . 45
5.2.4. A tervezés és az ellenőrzés hatása . . . 46
5.2.5. Mi történik az ellenőrző láncban? . . . 48
5.2.6. Az ellenőrző mint osztályozó . . . 48
5.2.7. Válaszszivárgás és nem kérdő törzsek . . . 49
5.2.8. Darabolás és a naiv RAG törékenysége . . . 50
5.2.9. A teljes dokumentumos alapvonal és a lefedettség . . . 50
5.2.10. Szervermodell és helyi modell . . . 51
5.2.11. A bíró rubrikapontjai és a kérdések jellege . . . 52
5.2.12. Magyar és angol dokumentumok . . . 53
5.2.13. Erőforrásigény és költség . . . 53
5.2.14. Példák . . . 54

6. Az eredmények értékelése **56**
6.1. A hipotézisek értékelése . . . 56
6.2. Miért módszer, és nem prompt? . . . 57
6.3. Mit tanultunk az ellenőrzésről? . . . 58
6.4. A mérés mint kutatási eredmény . . . 59
6.5. Gyakorlati ajánlás . . . 59
6.6. Az érvényességet veszélyeztető tényezők . . . 60
6.7. Etikai és jogi megfontolások . . . 61

7. Összefoglalás és további munka **62**
7.1. Összefoglalás . . . 62
7.2. További munka . . . 63

Irodalomjegyzék **65**

Ábrajegyzék **75**

Táblázatjegyzék **76**

A Promptok **78**
A.1. A naiv alapvonal (E0) és a teljes dokumentumos alapvonal promptja . . . 78
A.2. A tervező promptja . . . 78
A.3. A generátor promptja . . . 79
A.4. Az ellenőrző promptjai . . . 79
A.5. A fogalomgráf promptja (E3) . . . 80

B A bíró és az oktatók rubrikája **81**

C Konfigurációk és reprodukálás **82**
C.1. Példakonfigurációk . . . 82
C.2. A reprodukálás lépései . . . 82
C.3. A fő vizsgálat futtatási terve . . . 83
C.4. A közölt számok forrásai . . . 84

Rövidítések és jelölések

Rövidítések

AQG	*Automatic Question Generation*, automatikus kérdésgenerálás
BM25	*Best Matching 25*, szógyakoriságon alapuló lexikális rangsoroló függvény
CI	*Confidence Interval*, konfidenciaintervallum
E5	többnyelvű szövegbeágyazó modellcsalád (itt: multilingual-E5-base)
GGUF	a `llama.cpp` kvantált modellformátuma
GQA	*Grouped-Query Attention*, csoportosított lekérdezésű figyelem
GPU	*Graphics Processing Unit*, grafikus feldolgozóegység
GDPR	az EU 2016/679 általános adatvédelmi rendelete
KV	*key–value*, kulcs–érték gyorsítótár a szövegelőállítás közben
LLM	*Large Language Model*, nagy nyelvi modell
MCQ	*Multiple-Choice Question*, feleletválasztós kérdés
NLI	*Natural Language Inference*, természetes nyelvi következtetés
Q4_K_M	4 bites, csoportos K-kvantálás közepes változata (`llama.cpp`)
RAG	*Retrieval-Augmented Generation*, visszakereséssel kiegészített generálás
RQ	*Research Question*, kutatási kérdés
RRF	*Reciprocal Rank Fusion*, reciprok rangfúzió
VRAM	a GPU dedikált memóriája

Fontosabb fogalmak

darab (*chunk*)	a dokumentum egy összefüggő, néhány mondatos részlete, a keresés egysége
kulcs	a feleletválasztós kérdés megjelölt helyes válasza
disztraktor	a feleletválasztós kérdés helytelen, de hihető válaszlehetősége
vizsgaterv (*blueprint*)	a vizsga előre rögzített szerkezete: slotonként fogalom, típus és Bloom-szint
slot	a vizsgaterv egy pontja, amelyből egy kérdés készül
kar	a kísérlet egy konfigurációja, amely a referenciakarától egy tényezőben tér el
bíró	a kérdéseket értékelő, a generátoroktól független nagy nyelvi modell
szivárgás	a kulcs szövege (szinte) szó szerint szerepel a kérdés törzsében

Jelölések

n	a vizsga kérdéseinek száma (a vizsgálatokban $n = 10$)
k	a slotonként visszakeresett darabok száma

r	a slotonkénti újrapróbálkozások legnagyobb száma
δ_i	két szomszédos mondat szemantikus távolsága, $1 - \cos(\mathbf{v}_i, \mathbf{v}_{i+1})$
τ	a darabolás vágási küszöbe
F, G, A, V	formai megfelelés, alátámasztottság, vak megoldhatóság, disztraktor-validitás
Q	minőségi index, $(F+G+A+V)/4$
Lef	lefedettség: a kérdésekhez legközelebbi különböző darabok aránya
W, m_{kv}, M_0	a súlyok mérete, a KV-gyorsítótár tokenenkénti mérete, a futtatókörnyezet többlete
κ	Cohen-féle egyezési együttható
α	Krippendorff-féle megbízhatósági együttható
r_{rb}	páros rangbiszeriális hatásméret
$p, \tilde{p}$	korrigálatlan és Holm-korrigált p-érték

1. Bevezetés

1.1. Motiváció

A felsőoktatásban és a középiskolában a feleletválasztós kérdés (*multiple-choice question*, MCQ) a tudásmérés egyik legszélesebb körben használt eszköze: gépi úton javítható, nagy létszámú kurzusokon is skálázható, és jól illeszkedik a tanulásmenedzsment-rendszerek (pl. Moodle) kvízmoduljaihoz. Előállítása azonban drága. A pszichometriai szakirodalom szerint egy jó kérdés törzse önmagában is érthető és egyértelmű, pontosan egy válaszlehetősége helyes a tananyag szerint, a disztraktorok pedig azonos témájúak, formailag hasonlóak és egy felkészületlen hallgató számára hihetők, ám igazolhatóan hibásak [1, 2]. Egy tapasztalt oktató egy-egy ilyen kérdésen perceket, egy teljes vizsgán órákat dolgozik, és a disztraktorok megírása a munka legnehezebb része.

A nagy nyelvi modellek (*large language model*, LLM) megjelenése [3] gyökeresen átalakította ezt a munkafolyamatot. Az oktatástechnológiai irodalom egyszerre hangsúlyozza a lehetőségeket és a kockázatokat [4]: a modellek képesek kérdéseket és disztraktorokat fogalmazni [5, 6], ugyanakkor hajlamosak folyékony, de a forrás által nem alátámasztott állításokat generálni [7]. A gyakorlatban a legelterjedtebb használati mód a legegyszerűbb: az oktató feltölti az előadásjegyzetét egy felhőben futó csevegő asszisztensbe, és „tíz feleletválasztós kérdést” kér. Ezt a munkafolyamatot a továbbiakban *status quo*-nak vagy *közvetlen megközelítésnek* nevezzük.

1.2. Problémafelvetés

A közvetlen megközelítés kényelmes, de az iskolai alkalmazás szempontjából négy, egymástól független gyengesége van. Ezek adják dolgozatunk kiindulópontját.

(P1) **A helyesség nincs ellenőrizve.** Semmi sem garantálja, hogy a megjelölt kulcsot a dokumentum alátámasztja, és hogy a disztraktorok valóban hamisak. Az LLM-ek hihető, de alá nem támasztott állításokat állítanak elő [7]; az önellenőrzés ezt csökkentheti, de nem szünteti meg [8–10].

(P2) **A szerkezet és a lefedettség nincs kontrollálva.** A kért darabszám, típus és nehézség csak kérés a promptban. A hosszú bemenetet a modellek egyenetlenül használják: a kontextus elejére és végére jobban figyelnek, mint a közepére [11], a névleges kontextushossznál jóval rövidebb az a hossz, amelyen még megbízhatóan dolgoznak [12]. Ennek következménye, hogy a kérdések a dokumentum néhány szakaszára tömörülnek.

(P3) **Adatvédelem.** A tananyag személyes adatot (pl. esettanulmányban szereplő neveket, hallgatói munkákat) is tartalmazhat; a felhőszolgáltatás az adatkezelés címzettjévé válik [13], az intézmény pedig elveszíti a kontrollt a tartalom sorsa felett.

(P4) **Függés a nagy, távoli modellektől.** A teljes dokumentum egyetlen promptban hosszú

kontextust és nagy modellt igényel. Az iskola által saját hardveren futtatható kis modellek (néhány milliárd paraméter, 8 GB videomemória) kontextusa és memóriája korlátos.

Fontos látni, hogy a négy probléma nem oldható meg egyszerűen „jobb prompttal”. A P1 és a P2 a *módszer* hiányából fakad: ha a vizsga szerkezete, a kérdések forrása és az ellenőrzés nem explicit lépések, akkor nem is mérhetők és nem is kényszeríthetők ki. A P3 és a P4 pedig egymást erősítik: a helyi futtatás megoldaná az adatvédelmi problémát, de a helyben futtatható kis modellek éppen a hosszú kontextusú, egylépéses feladatban a leggyengébbek. Kutatásunk alapgondolata ezért az, hogy a feladatot rövid, jól specifikált, egyenként ellenőrizhető lépésekre bontva egy kis, helyben futó modell is képes lehet megbízható vizsgát előállítani, és ez a felbontás egyben a P1 és P2 problémát is kezeli.

1.3. Kutatási kérdések és hipotézisek

A fenti problémák alapján három kutatási kérdést fogalmaztunk meg.

RQ1 A strukturált generálás – tervezés, kérdésenkénti forráshoz kötés és ellenőrzés – érvényesebb és jobban lefedő vizsgát eredményez-e, mint ha a modellnek a dokumentumot (vagy annak visszakeresett részleteit) egyetlen promptban adjuk át?

RQ2 Mennyivel járul hozzá a minőséghez az egyes komponens (tervező, ellenőrző, fogalomgráf, hibrid visszakeresés, darabolási stratégia), és mennyibe kerül futási időben, modellhívásban és tokenben?

RQ3 Mennyire közelíti meg egy 8 GB-os fogyasztói GPU-n futó, 4 bitre kvantált 7B modell egy nagy, szerveren futó modell teljesítményét?

A kutatási kérdésekhez a következő hipotéziseket rendeljük. Értékelésüket a pilot és a fő vizsgálat alapján a 6.1. szakasz adja.

1. Hipotézis (Tervezés)**.** Azonos generátormodell mellett a vizsgaterv (E1) a naiv RAG alapvonalhoz (E0) képest növeli a kérdések alátámasztottságát és a vizsga darablefedettségét, a formai megfelelés romlása nélkül.

2. Hipotézis (Ellenőrzés)**.** Az ellenőrző lánc (E2) a tervezéshez (E1) képest tovább növeli az alátámasztottságot és a vak megoldhatóságot; az ellenőrző ítélete pozitívan egyezik a független bíró ítéletével ($\kappa > 0$).

3. Hipotézis (Lefedettség)**.** A teljes dokumentumot egyetlen promptban kapó alapvonal (B-doc) lefedettsége – modellmérettől függetlenül – alacsonyabb, mint a tervezett változatoké.

4. Hipotézis (Helyi vs. szerver)**.** A helyi 7B modell a tervezett és ellenőrzött csővezetékben a szervermodell naiv változatának minőségi indexét megközelíti (különbség $< 0{,}1$), miközben a GPU-memóriaigénye 8 GB alatt marad.

5. Hipotézis (Mérés)**.** A generátoroktól eltérő modellcsaládba tartozó LLM-bíró ítéletei az oktatói értékelésekkel legalább elfogadható megbízhatósággal egyeznek (Krippendorff-$\alpha \geq$ $\geq 0{,}667$).

1.4. Hozzájárulások

Dolgozatunk négy, egymásra épülő hozzájárulást tartalmaz.

(1) **A MIMIR generálási módszere** (3. fejezet): ablakozott mondatbeágyazáson alapuló szemantikus darabolás; lefedettségvezérelt vizsgaterv, amely a Bloom-szinteket a legnagyobb maradék elvén osztja ki; slotonkénti sűrű vagy hibrid keresés; forrásrészletekre hivatkozó, egyenkénti kérdésgenerálás; a legolcsóbbtól a legdrágábbig rendezett ellenőrző lánc visszacsatolással és tartalékfogalmakkal; valamint egy munkamenet-hatókörű fogalomgráf.

(2) **Adatvédelmet biztosító helyi architektúra** (3. fejezet): lazán csatolt mikroszolgáltatások, zéró adatmegőrzés, ujjlenyomat-alapú audit, valamint a GPU-memóriaigény egyszerű becslése, amelyet két vizsgálatban mért értékekkel ellenőrzünk.

(3) **Kiértékelési módszertan és nyílt keretrendszer** (4. fejezet): tizennégy egytényezős kísérleti kar, kétnyelvű adatkészlet referenciakérdésekkel, forrásalapú mutatók, a generátoroktól eltérő modellcsaládba tartozó LLM-bíró, oktatói értékelési protokoll és dokumentumszintű statisztika.

(4) **Empirikus eredmények** (5. és 6. fejezet): egy pilot vizsgálat, amely három, a mérést felfelé torzító hibát – köztük a válaszszivárgást mint új hibamódot – és a futásról futásra jelentkező zajt tárta fel, valamint egy 14 karos, kilenc dokumentumos fő vizsgálat, amely szerint a helyi 7B modellel futó tervezett és ellenőrzött csővezeték a közös dokumentumokon a naiv RAG-ot (0,64) és a teljes dokumentumos promptot (0,83) is felülmúlta (0,96), elérte a teljes dokumentumot kapó szervermodellt (0,95), és mind a hat dokumentumon egyenletesen jól teljesített.

1.5. A dolgozat felépítése

A dolgozat a TDK-dolgozatok szokásos felépítését követi: a szakirodalmi áttekintés, a módszertan és az eredmények kiértékelése nagyjából azonos terjedelmű. A 2. fejezet áttekinti a feleletválasztós kérdés tesztelméleti hátterét, az automatikus kérdésgenerálás fejlődését, a nagy nyelvi modelleket, a visszakereséssel kiegészített generálást, az ellenőrzést, a kis modelleket és a nyelvi modellel végzett kiértékelést, és azonosítja a kutatási rést. A 3. fejezet a rendszer architektúráját, adatvédelmi megoldásait és generálási módszerét, a 4. fejezet a kiértékelési módszertant – a kísérleti karokat, a mutatókat, a bírót és a statisztikai elemzést – mutatja be. Az 5. fejezet a pilot és a fő vizsgálat eredményeit közli, a 6. fejezet ezeket a hipotézisek szempontjából értékeli, és tárgyalja az érvényességet veszélyeztető tényezőket. A 7. fejezet az összefoglalást és a további

munkát tartalmazza. A függelék a promptokat, a rubrikát, a konfigurációkat és a reprodukálás lépéseit közli.

2. Szakirodalmi áttekintés

Ebben a fejezetben azokat a kutatási területeket tekintjük át, amelyekre a MIMIR módszere és kiértékelése épül. A fejezet a „mit akarunk előállítani” kérdéstől halad a „hogyan” és a „hogyan mérjük” kérdése felé. Először a feleletválasztós kérdés tesztelméleti követelményeit és a kognitív szintek leírására szolgáló Bloom-taxonómiát mutatjuk be (2.1. szakasz), majd az automatikus kérdésgenerálás fejlődését a szabályalapú rendszerektől a nagy nyelvi modellekig (2.2–2.4. szakasz). A feladatfelbontásról szóló rész (2.5. szakasz) a dolgozat központi gondolatának irodalmi hátterét adja. Ezután a nyelvi modellek legfontosabb gyengeségét, a hallucinációt, és az ellene kidolgozott technikákat tárgyaljuk: a visszakereséssel kiegészített generálást, a hosszú kontextus kérdését és az ellenőrzést (2.6–2.9. szakasz). A helyi futtatás feltételeit a kis modellekről és a kvantálásról szóló rész (2.10. szakasz), a mérés kérdését a nyelvi modellel végzett kiértékelésről szóló rész (2.11. szakasz) és a kísérleti kiértékelés megbízhatóságáról szóló rész (2.12. szakasz) tárgyalja. A fejezetet az adatvédelmi és szabályozási környezet, a magyar nyelvi erőforrások áttekintése és a kutatási rés megfogalmazása zárja.

2.1. A feleletválasztós kérdés mint mérőeszköz

2.1.1. A jó kérdés ismérvei

A feleletválasztós kérdés (*multiple-choice question*, MCQ) három részből áll: a *törzsből* (a kérdés vagy a befejezendő állítás), a *kulcsból* (a helyes válasz) és a *disztraktorokból* (a helytelen, de hihető válaszlehetőségek). A formátum népszerűségét az adja, hogy gépi úton, gyorsan és objektíven javítható, és rövid idő alatt a tananyag nagy részét lefedheti. Ennek ára, hogy a jó kérdés megírása nehéz: a hibás kérdés nem egyszerűen „kevésbé jó”, hanem rossz irányba torzítja a mérést.

A kérdésírás szabályait Haladyna, Downing és Rodriguez [1] foglalta össze 31 irányelvben, amelyeket a tankönyvek és a mérésmódszertani szakirodalom elemzéséből vezettek le. Az irányelvek négy csoportba sorolhatók. A *tartalmi* irányelvek szerint egy kérdés egyetlen, fontos tanulási célt mérjen, és ne apró, lényegtelen részletre kérdezzen. A *formai* irányelvek a törzs világosságát írják elő: a törzs önmagában is érthető legyen, tartalmazza a lényeges információt, és kerülje a tagadást. A *disztraktorokra* vonatkozó irányelvek szerint a helytelen opciók legyenek hihetők, egymást kölcsönösen kizárók, a kulccsal azonos hosszúságúak és nyelvtani formájúak, és ne adjanak nyelvi „árulkodó jelet” (például a kulcs ne legyen feltűnően hosszabb vagy pontosabb a többinél). Végül kerülni kell a „mindegyik fenti” és „egyik sem” típusú opciókat, mert ezek a találgatást segítik.

Hogy ezek az irányelvek nem csupán esztétikai kérdések, azt Downing [14] egy orvosi vizsgán végzett vizsgálata mutatta meg. A szabálysértő kérdések – például a nem egyértelmű törzs vagy az árulkodó opció – miatt a vizsgán a hallgatók 10–15 %-a került a „nem felelt

meg” kategóriába, akik a hibás kérdések nélkül átmentek volna; a rossz kérdés tehát valódi következményekkel járt. Ez a megállapítás közvetlen motivációt ad munkánk számára: ha egy gépi rendszer kérdéseket generál, nem elég, hogy a kérdések „jónak tűnjenek”, a szabályok betartását mérni és ellenőrizni kell.

A disztraktorok számáról Rodriguez [15] nyolcvan év kutatásait összegző metaanalízise azt találta, hogy a három opció (egy kulcs és két disztraktor) a legtöbb esetben elegendő, mert a negyedik és ötödik opció ritkán „működik”. Tarrant, Ware és Mohammed [16] ápolóképzési vizsgák elemzésével hasonló eredményre jutott: a disztraktorok jelentős része *nem funkcionáló*, vagyis a hallgatók kevesebb mint 5 %-a választja. Gierl és munkatársai [2] áttekintése szerint a nem funkcionáló disztraktor gyakorlatilag csökkenti az opciók számát, és így növeli a találgatással elérhető pontszámot. A MIMIR a Moodle-ban megszokott négyopciós formátumot követi, de a fenti eredmények alapján a disztraktorok *minőségét* – hogy hamisak és témába vágók-e – külön mutatóként mérjük (4.5. szakasz).

2.1.2. Kognitív szintek: Bloom taxonómiája

A kérdések nehézségének leírására a legelterjedtebb keret Bloom taxonómiája [17]. Anderson és Krathwohl átdolgozott változata [18, 19] hat, egymásra épülő kognitív szintet különít el: *emlékezés* (tények felidézése), *megértés* (magyarázat, összehasonlítás saját szavakkal), *alkalmazás* (ismert eljárás használata új helyzetben), *elemzés* (részek és összefüggések felismerése), *értékelés* (döntés, ítélet kritériumok alapján) és *alkotás* (új egész létrehozása). A feleletválasztós formátum az első öt szint mérésére alkalmas, az alkotás jellemzően nyitott feladatot igényel.

Scully [20] kimutatta, hogy a feleletválasztós kérdések is mérhetnek magasabb rendű gondolkodást, ha a törzs új helyzetet ír le, és a hallgatónak a tanult elvet kell alkalmaznia rá; a gyakorlatban azonban a kérdések nagy többsége az emlékezés szintjén marad, mert ezeket a legkönnyebb megírni. Ugyanez a jelenség a gépi kérdésgenerálásban is megfigyelhető: ha a modell maga dönti el, milyen kérdést ír, jellemzően tényfelidéző kérdést választ. A MIMIR ezért a kért nehézséghez előre rögzített Bloom-szint-eloszlást rendel (3.8. szakasz), és ezt a vizsgatervben kérdésenként kiosztja. Eredményeink (5.2.11. szakasz) azt mutatják, hogy a kért szint és a megvalósult szint ennek ellenére gyakran eltér.

2.1.3. Tételelemzés: nehézség és megkülönböztető erő

A klasszikus tesztelmélet [21] a kérdéseket (itemeket) a vizsga megírása *után*, a hallgatók válaszai alapján is értékeli. A két legegyszerűbb mutató a nehézségi és a diszkriminációs index. A *nehézségi index* a kérdésre helyesen válaszolók aránya:

$$p = \frac{\text{helyes válaszok száma}}{\text{a válaszolók száma}}, \tag{2.1}$$

vagyis a nagyobb érték *könnyebb* kérdést jelent; a jól mérő kérdések jellemzően a 0,3–0,8 tartományba esnek. A *diszkriminációs index* azt méri, mennyire különbözteti meg a kérdés a

jobban és a gyengébben teljesítő hallgatókat. A legegyszerűbb változatában a hallgatókat a teljes pontszámuk szerint sorba rendezzük, és a felső és az alsó csoport (például a legjobb és a leggyengébb 27 %) nehézségi indexének különbségét vesszük:

$$D = p_{\text{felső}} - p_{\text{alsó}}. \tag{2.2}$$

Ha D közel nulla vagy negatív, a kérdést a jól felkészült hallgatók sem oldják meg jobban, ami gyakran hibás kulcsra vagy kétértelmű törzsre utal. A disztraktorok elemzése ugyanezen az elven működik: egy jó disztraktort az alsó csoport gyakrabban választ, mint a felső [2, 16].

Ezek a mutatók valós hallgatói válaszokat igényelnek, ezért a vizsga *előállításakor* nem állnak rendelkezésre. Egy generáló rendszer csak olyan, a válaszoktól független jellemzőket ellenőrizhet, amelyek a rossz tételelemzési eredmények tipikus okai: hogy a kulcs helyes-e, hogy a disztraktorok valóban hamisak-e, és hogy a kérdés egyértelmű-e. A MIMIR ellenőrző lánca és kiértékelése pontosan ezeket a jellemzőket méri; a generált vizsgák tételelemzése valós hallgatói válaszokon a további munka része (7. fejezet).

2.2. Az automatikus kérdésgenerálás fejlődése

Az automatikus kérdésgenerálás (*automatic question generation*, AQG) több évtizedes kutatási terület. Kurdi és munkatársai [5] szisztematikus irodalmi áttekintése 93 oktatási célú rendszert elemzett, Zhang és munkatársai [22] pedig a természetes nyelvi szövegből történő kérdésgenerálás módszereit tekintették át. Mindkét áttekintés három generációt különít el, amelyeket az alábbiakban röviden bemutatunk.

2.2.1. Szabály- és sablonalapú rendszerek

Az első generáció rendszerei nyelvészeti szabályokra épülnek. A szöveget szintaktikailag elemzik, megkeresik a „kérdezhető” mondatrészeket (például egy főnévi csoportot vagy egy évszámot), és transzformációs szabályokkal kérdő mondattá alakítják. Mitkov és Ha rendszere [23] a szöveg fontos főnévi csoportjait választja kulcsnak, és a WordNet lexikai adatbázisban hozzájuk közel álló fogalmakat ajánlja disztraktornak. Heilman és Smith [24] a *túlgenerálás és rangsorolás* elvét vezette be: a szabályok sok jelölt kérdést állítanak elő, amelyek közül egy statisztikai modell választja ki a legjobbakat. A szabályalapú rendszerek előnye, hogy átláthatók és a kulcs mindig a szövegből származik; hátrányuk, hogy a kérdések merevek, többnyire a mondatok egyszerű átfogalmazásai, és minden nyelvhez külön szabályrendszer kell.

2.2.2. Neurális rendszerek és adatkészletek

A második generációt a neurális hálózatok és a nagy, kézzel annotált adatkészletek tették lehetővé. A SQuAD [25] több mint százezer, Wikipédia-bekezdésekhez írt kérdés–válasz párt tartalmaz, a RACE [26] kínai középiskolai angol nyelvvizsgák feleletválasztós olvasásértési feladataiból áll,

a SciQ [27] pedig természettudományos feleletválasztós kérdéseket gyűjtött közösségi munkával. Ezeken az adatkészleteken Du és munkatársai [28] figyelemmechanizmusos kódoló–dekódoló hálózattal tanítottak kérdésgenerálást: a modell a bekezdést és a kiválasztott választ kapja bemenetként, és a kérdést szóról szóra állítja elő. A neurális modellek kérdései folyékonyabbak a szabályalapúakénál, de a tanítóadat stílusát követik, és nem garantálják, hogy a kérdés a forrásból megválaszolható.

2.2.3. Disztraktorgenerálás

A disztraktorok előállítása külön kutatási irány. Liang és munkatársai [29] rangsorolási feladatként fogalmazták meg: egy jelöltkészletből (például a szöveg többi fogalmából) egy tanult modell választja ki azokat, amelyek a kulcshoz hasonlók, de nem azonosak vele. Gao és munkatársai [30] a RACE adatkészleten neurális modellel generáltak disztraktorokat, amelyek a bekezdéshez és a kérdéshez is illeszkednek. Alhazmi és munkatársai [6] legújabb áttekintése a módszereket három csoportba sorolja: tudásbázis-alapú (hasonló fogalmak ontológiából), korpuszalapú (szóbeágyazásokban közeli szavak) és generatív (neurális vagy nyelvi modelles) módszerekre. Megállapításuk szerint a generatív módszerek adják a legtermészetesebb disztraktorokat, de gyakori hibájuk, hogy egy disztraktor valójában szintén helyes, vagy nyilvánvalóan abszurd. Ez a két hibatípus pontosan az, amelyet a MIMIR ellenőrző lánca és a bíró disztraktoronként vizsgál.

2.2.4. A kiértékelés problémája

Az áttekintések visszatérő megállapítása, hogy a kérdésgenerálás gyenge pontja a kiértékelés. Mulla és Gharpure [31] szerint a rendszerek jelentős részét a gépi fordításból átvett, referenciaátfedésen alapuló metrikákkal (BLEU [32], ROUGE [33]) mérik. Ezek azt számolják, hány szó vagy szósorozat egyezik a generált és egy ember által írt referenciakérdés között. Egy vizsgakérdés azonban akkor is kiváló lehet, ha egyetlen szava sem egyezik a referenciával, és akkor is használhatatlan, ha a kulcsa hibás. Kurdi és munkatársai [5] azt is kimutatták, hogy a humán értékelések jellemzően kis mintán, nem vakon történnek, és ritkán ellenőrzik a kulcs helyességét. Munkánkban ezért a referenciakérdéseket nem célként használjuk, hanem csak a visszakeresés pontosságának és a tematikus hasonlóságnak a mérésére; a helyességet a forrással szembeni ítéletekkel mérjük (4. fejezet).

2.3. A nagy nyelvi modellek alapjai

A harmadik generációt a nagy nyelvi modellek (LLM) jelentik. Ezek alapja a transzformer architektúra [34], amely a szöveget *tokenekre* (szavakra vagy szódarabokra) bontja, és egy *figyelemmechanizmus* segítségével minden token reprezentációját a többi token függvényében számolja ki. A transzformernek két fő felhasználási módja alakult ki. A *kódoló* modellek (például a BERT [35]) a teljes szöveget egyszerre látják, és a szöveg jelentését egy vektorban (*beágyazás-*

ban) foglalják össze; ezeket osztályozásra és keresésre használják. A *dekódoló* vagy generatív modellek (például a GPT-család [3]) a szöveget balról jobbra, tokenenként állítják elő: minden lépésben megbecsülik, melyik token következik a legnagyobb valószínűséggel. A MIMIR mindkét típust használja: kódoló modellt a darabolásra és a keresésre, generatív modellt a kérdések megírására.

Tokenek és beágyazások. A modellek a szöveget nem betűnként vagy szavanként, hanem *szódarabokra* bontva dolgozzák fel; a szótárat egy statisztikai eljárás (például a byte-pair encoding [36]) úgy építi fel, hogy a gyakori szavak egy tokent, a ritkák több tokent kapjanak. A magyar szavak a hosszú toldalékok miatt átlagosan több tokenre bomlanak, mint az angolok, így ugyanaz a szöveg magyarul több tokent foglal a kontextusban. Minden tokenhez a modell egy d dimenziós vektort rendel, és egy kódoló modell egy teljes mondathoz vagy bekezdéshez is egyetlen vektort (*beágyazást*) tud rendelni. Két szöveg jelentésbeli hasonlóságát a beágyazásaik által bezárt szög koszinuszával mérjük:

$$\cos(\mathbf{u},\mathbf{v}) = \frac{\mathbf{u}\cdot\mathbf{v}}{\|\mathbf{u}\|\,\|\mathbf{v}\|}, \tag{2.3}$$

amelynek értéke 1, ha a két vektor azonos irányú, és annál kisebb, minél jobban eltér a két szöveg jelentése. A dolgozatban a darabolás, a keresés, a duplikátumszűrés és a lefedettség mérése is erre a mértékre épül.

A figyelemmechanizmus. A transzformer központi lépése a *figyelem*: minden token reprezentációja a többi token reprezentációinak súlyozott átlaga, ahol a súly azt fejezi ki, mennyire „releváns” a másik token az adott helyen. Vaswani és munkatársai [34] jelölésével, ha Q, K és V a tokenekből számolt lekérdezés-, kulcs- és értékmátrix, akkor

$$\text{Figyelem}(Q,K,V) = \text{softmax}\left(\frac{QK^{\mathsf{T}}}{\sqrt{d}}\right)V, \tag{2.4}$$

ahol a softmax függvény a hasonlóságokat nemnegatív, egyre összegződő súlyokká alakítja. A számítás költsége a kontextus hosszával négyzetesen nő, és a már feldolgozott tokenek kulcs- és értékvektorait a szövegelőállítás során tárolni kell (KV-gyorsítótár, 2.10. szakasz) – ez az oka annak, hogy a hosszú kontextus drága, és egy kis kártyán korlátozott.

Szövegelőállítás és hőmérséklet. A generatív modell minden lépésben egy valószínűségeloszlást számol a következő tokenre, és ebből választ. A választás „merészségét” a *hőmérséklet* (T) szabályozza: ha a modell a j-edik tokenhez z_j pontszámot rendel, a választás valószínűsége

$$P(j) = \frac{e^{z_j/T}}{\sum_i e^{z_i/T}}. \tag{2.5}$$

Kis T mellett a legvalószínűbb token szinte mindig győz (determinisztikusabb, „óvatos” szöveg), nagy T mellett a ritkább tokenek is esélyt kapnak (változatosabb, de hibára hajlamosabb szöveg).

Holtzman és munkatársai [37] megmutatták, hogy a túl determinisztikus választás ismétlődő, a túl véletlenszerű pedig összefüggéstelen szöveghez vezet. A MIMIR generátora $T = 0{,}2$-vel, a bíró $T = 0$-val fut, hogy a kimenetek a lehető legstabilabbak legyenek; a pilot azonban megmutatta, hogy a GPU-n végzett számítás miatt még így sem bitre azonosak (5.1. szakasz).

Strukturált kimenet. Egy vizsgagenerátornak gépileg feldolgozható kimenetet – a mi esetünkben JSON-objektumot – kell előállítania. A modellek ezt az utasítás alapján többnyire betartják, de egy kis modell időnként hibás vagy hiányos JSON-t ír. Erre két megoldás terjedt el: a kimenet utólagos ellenőrzése és szükség esetén újrakérése, illetve a *korlátozott dekódolás*, amely a szövegelőállítás közben csak a formátumnak megfelelő tokeneket engedi meg [38]. A MIMIR az előbbit alkalmazza: az értelmezhetetlen választ egyszer újrakéri, és a formai hibát az ellenőrző lánc első lépése szűri.

Brown és munkatársai [3] megmutatták, hogy egy elég nagy generatív modell finomhangolás nélkül, néhány példa vagy csupán egy utasítás alapján is képes új feladatok megoldására. Kaplan és munkatársai [39] szerint a modellek hibája a paraméterszám, az adatmennyiség és a számítási kapacitás növelésével egyenletesen, hatványfüggvény szerint csökken; Hoffmann és munkatársai [40] pontosították, hogy adott számítási keret mellett a modellméretet és a tanítóadat mennyiségét együtt érdemes növelni. Ezek az eredmények magyarázzák a „minél nagyobb, annál jobb” tendenciát, és egyben azt is, miért korlátozottabb egy néhány milliárd paraméteres helyi modell.

A csevegő asszisztensek használhatóságát az *utasításkövetésre* történő hangolás adta. Ouyang és munkatársai [41] emberi visszajelzéssel tanították a modellt arra, hogy a felhasználó szándékát kövesse; az így kapott modellek kisebb méret mellett is hasznosabb válaszokat adtak. A modellek viselkedése a *prompttal* (a bemeneti utasítással) is jelentősen befolyásolható. Wei és munkatársai [42] szerint ha a modellt lépésenkénti gondolatmenet leírására kérjük (*chain-of-thought*), összetett feladatokban pontosabban válaszol; Wang és munkatársai [43] pedig azt mutatták meg, hogy több, egymástól független gondolatmenet többségi szavazása tovább javítja a pontosságot. Ezek a technikák közös gondolatra épülnek: ha egy feladatot kisebb, jól körülhatárolt lépésekre bontunk, a modell megbízhatóbban teljesít. A MIMIR ezt az elvet a vizsgagenerálás egészére alkalmazza: a vizsgát nem egy hívásban kérjük, hanem tervezésre, kérdésenkénti generálásra és ellenőrzésre bontjuk.

2.4. Nagy nyelvi modellek a kérdésgenerálásban

A nagy nyelvi modellek megjelenése után gyorsan nőtt azoknak a vizsgálatoknak a száma, amelyek oktatási kérdések generálására használják őket. Wang és munkatársai [44] GPT-3-mal generáltak tankönyvi kérdéseket, és emberi értékelés szerint a kérdések egy része az emberek által írtakkal összemérhető volt. Elkins és munkatársai [45] oktatókkal értékeltették a nyelvi modellel generált kérdéseket: a kérdések többségét jó minőségűnek és hasznosnak ítélték. Doughty és munkatársai [46] programozási kurzusokon hasonlították össze a GPT-4-gyel és az oktatók

által írt feleletválasztós kérdéseket; a gépi kérdések többsége jól megfogalmazott volt egyértelmű helyes válasszal, kisebb részükben azonban a kulcs vagy egy disztraktor hibásnak bizonyult, ami emberi átnézés nélkül a vizsgába került volna. Bitew és munkatársai [47] a disztraktorgenerálásban értek el jó eredményt úgy, hogy a promptba hasonló, már jóváhagyott kérdéseket tettek példaként. A dolgozatunkban használt EduQG adatkészlet [48] ugyanennek a kutatócsoportnak a munkája: OpenStax-tankönyvekhez írt, szakértők által ellenőrzött feleletválasztós kérdéseket tartalmaz.

A kis modellek oldaláról Fawzi és munkatársai [49, 50] kimutatták, hogy egy néhány száz millió paraméteres modell oktatási szövegeken végzett további előtanítással és finomhangolással a nagy modellekhez mérhető kérdéseket írhat. Jaldi és munkatársai [51] kis, helyben futtatható modelleket hasonlítottak össze nagy modellekkel Bloom-szintekhez igazított értékelési feladatok tervezésében.

Az oktatástechnológiai irodalom a lehetőségek mellett a kockázatokat is hangsúlyozza. Kasneci és munkatársai [4] áttekintése szerint a nyelvi modellek jelentősen csökkenthetik az oktatók adminisztratív terheit, de a kimenet pontosságát ellenőrizni kell, és tisztázni kell az adatok kezelését. Az UNESCO generatív MI-ről szóló oktatási útmutatója [52] hasonlóan emberi felügyeletet, átláthatóságot és az adatvédelem biztosítását várja el. A felsorolt vizsgálatok közös vonása, hogy a kérdések minőségét utólag, emberi értékeléssel mérik; arra, hogy a generálás *folyamata* hogyan biztosíthatja a helyességet és a lefedettséget, kevesebb figyelem jut. Ez az a pont, ahol a MIMIR hozzájárulni kíván.

A kérdések nehézségének szabályozása a nyelvi modellek előtt is kutatott terület volt: Gao és munkatársai [53] olyan neurális modellt tanítottak, amely a kért nehézségi szintnek megfelelő olvasásértési kérdést generál, és a nehézséget azzal közelítették, hogy egy kérdésmegoldó modell meg tudja-e válaszolni a kérdést. Ez a gondolat – a nehézséget vagy a helyességet egy *második* modell viselkedésével mérni – a MIMIR vak megoldási próbájában is megjelenik.

2.5. Feladatfelbontás és többlépéses csővezetékek

A dolgozat központi gondolata, hogy egy összetett feladatot rövid, jól specifikált lépésekre bontva egy kisebb modell is megbízhatóbban teljesít. Ez a gondolat a nyelvi modellek irodalmában több formában is megjelent.

Felbontás a promptban. A gondolatmenet-alapú promptolás [42] után több munka explicit felbontást javasolt. A *least-to-most* módszer [54] először részfeladatokra bontja a problémát, majd a részfeladatokat egymás után, az előzők eredményét felhasználva oldja meg; a modell így olyan feladatokat is megold, amelyek a promptban látott példáknál bonyolultabbak. A *Plan-and-Solve* módszer [55] arra kéri a modellt, hogy előbb készítsen tervet, és csak utána hajtsa végre – ez a vizsgaterv gondolatának közvetlen megfelelője. A *Decomposed Prompting* [56] a részfeladatokat külön, szakosított promptokra (vagy akár nem nyelvi modelles programokra) osztja ki, a *Tree of Thoughts* [57] pedig több lehetséges lépést is kipróbál, és értékeli őket, mielőtt

továbblép.

Felbontás a programban. Egy másik irány a felbontást nem a promptra, hanem a programra bízza. Wu, Terry és Cai [58] *MI-láncoknak* nevezték azokat a rendszereket, amelyekben több, egymásra épülő nyelvimodell-hívás eredményét a program köti össze. Felhasználói vizsgálatuk szerint a láncok nemcsak jobb eredményt adtak, hanem *átláthatóbbak* és jobban *irányíthatók* is voltak, mert a felhasználó minden köztes lépést láthatott és módosíthatott. A ReAct [59] a modell érvelését külső eszközök (például keresés) hívásával váltakoztatja, a DSPy [60] pedig a többlépéses csővezetékeket deklaratív programként írja le, és a promptokat automatikusan optimalizálja.

Kapcsolat a vizsgagenerálással. A MIMIR tervezett csővezetéke a második irányba tartozik: a szerkezeti döntéseket (hány kérdés, milyen témából, milyen szinten) a program hozza meg, a nyelvi modell csak a jól körülhatárolt részfeladatokat végzi (fogalmak javaslása, egy kérdés megírása, egy ítélet). A felbontásnak a vizsgagenerálásban három előnye van, amelyek a fenti munkákban is megjelennek: (i) minden lépés rövid kontextussal dolgozik, ami egy kis modell számára kedvező; (ii) minden köztes eredmény (terv, hivatkozott darab, ellenőrzési ítélet) látható, így az oktató és a kiértékelés is visszakövetheti; (iii) a lépések egyenként cserélhetők és mérhetők, ami lehetővé teszi az egytényezős kísérleti tervet. A felbontás ára a több modellhívás és a hosszabb futási idő, amelyet a kiértékelésnek a minőségi nyereséggel együtt kell mérnie.

2.6. Hallucináció

A nyelvi modellek legfontosabb gyengesége a *hallucináció*: folyékony, magabiztos, de a forrással vagy a valósággal ellentétes szöveg előállítása. Ji és munkatársai [7] két típust különítenek el. Az *intrinzikus* hallucináció ellentmond a forrásnak (például a forrás szerint a kávé a 17. században jutott el Európába, a modell a 9. századot írja), az *extrinzikus* hallucináció pedig olyan állítás, amely a forrásból sem nem igazolható, sem nem cáfolható. Maynez és munkatársai [61] összefoglaló-generálásban mutatták ki, hogy a modellek kimenetének jelentős része tartalmaz a forrásban nem szereplő állítást, és hogy a hagyományos átfedésalapú metrikák ezt nem veszik észre. Huang és munkatársai [62] újabb áttekintése a hallucináció okait az adatokban (hibás vagy elavult tanítóadat), a tanításban és a következtetésben (a valószínű, de hamis folytatás kiválasztása) keresi.

A kérdésgenerálásban mindkét típus előfordul, és mindkettő súlyos: ha a kulcs ellentmond a forrásnak, a jól felkészült hallgató veszít pontot; ha a kulcs a forrásban nem szerepel, a kérdés a tananyag alapján nem válaszolható meg. Ezért dolgozatunkban a kérdés *alátámasztottságát* – vagyis hogy a forrás igazolja-e a kulcsot – tekintjük a legfontosabb minőségi mutatónak. A hallucináció csökkentésére az irodalom két fő irányt javasol: a modell kiegészítését külső tudásforrással (visszakeresés) és a kimenet utólagos ellenőrzését. A következő szakaszok ezeket mutatják be.

2.7. Visszakereséssel kiegészített generálás

2.7.1. Az alapelv és változatai

A visszakereséssel kiegészített generálás (*retrieval-augmented generation*, RAG) alapgondolata, hogy a modell ne csak a paramétereiben tárolt tudásra támaszkodjon, hanem a válasz előtt keressen releváns szövegrészleteket egy külső gyűjteményből, és ezek alapján válaszoljon. A gondolat több párhuzamos munkában jelent meg: a REALM [63] már az előtanítás során megtanította a modellt a keresésre, Lewis és munkatársai [64] egy sűrű keresőt és egy generatív modellt kapcsoltak össze, és a RAG elnevezés is tőlük származik. Izacard és Grave [65] megmutatták, hogy a generátor sok visszakeresett részletet is képes együtt feldolgozni, Borgeaud és munkatársai [66] pedig azt, hogy egy visszakeresést használó kisebb modell nyelvmodellezésben felveheti a versenyt egy nagyságrenddel nagyobb modellel. Shuster és munkatársai [67] párbeszédes rendszerekben közvetlenül mérték, hogy a visszakeresés csökkenti a hallucinációt.

Gao és munkatársai [68] áttekintése a RAG három paradigmáját különíti el. A *naiv RAG* egyetlen keresést és egyetlen generálást végez: a kérdéshez legjobban hasonló néhány részletet a promptba másolja. A *fejlett RAG* a keresés előtt és után is optimalizál (például átírja a lekérdezést, vagy újrarangsorolja a találatokat). A *moduláris RAG* pedig a keresési, generálási és ellenőrzési lépéseket tetszőleges sorrendben kombinálja. Ilyen moduláris rendszer például a Self-RAG [69], amelyben a modell maga dönti el, mikor keressen, és saját kimenetét is értékeli. A MIMIR tervezett csővezetéke ebben a terminológiában moduláris RAG: a keresés a terv minden pontjára külön fut, és az ellenőrzés eredménye visszahat a keresésre.

2.7.2. Lexikális és sűrű keresés

A keresés két alapvető módszere a lexikális és a sűrű keresés. A *lexikális* keresés a klasszikus információkeresés [70] eszköztárára épül: a dokumentumokat szavaik alapján indexeli, és azokat a részleteket rangsorolja előre, amelyekben a lekérdezés szavai gyakran, de a gyűjtemény egészében ritkán fordulnak elő. Legismertebb képviselője a BM25 [71], amely a szógyakoriság hatását telíti (a tizedik előfordulás már alig számít többet a kilencediknél), és a hosszú részleteket normalizálja. A lexikális keresés gyors, nem igényel tanítást, és jól kezeli a ritka szakkifejezéseket és tulajdonneveket, de nem ismeri fel a szinonimákat és az átfogalmazásokat.

A *sűrű* keresés a szövegeket egy közös vektortérbe képezi, ahol a hasonló jelentésű szövegek közel kerülnek egymáshoz; két szöveg hasonlóságát a vektoraik által bezárt szög koszinuszával mérjük. A DPR [72] kérdés–bekezdés párokon tanított két kódolóval mutatta meg, hogy ez a módszer a nyílt kérdésmegválaszolásban felülmúlja a BM25-öt. A Sentence-BERT [73] mondatbeágyazásokat tanított sziámi hálózattal; az E5 modellcsalád [74] nagy, gyengén felügyelt szövegpárgyűjteményen, kontrasztív tanítással készült, többnyelvű változata [75] a magyart is támogatja, ezért ezt használjuk. A ColBERT [76] a pontosabb illesztés érdekében tokenenkénti vektorokat tárol, Nogueira és Cho [77] pedig egy második, lassabb, de pontosabb modellel

rangsorolták újra a találatokat. A keresők összehasonlítására a BEIR [78] és az MTEB [79] benchmark szolgál; mindkettő egyik fontos tanulsága, hogy egyik módszer sem a legjobb minden adatkészleten, és a BM25 meglepően erős alapvonal marad.

Mivel a két módszer hibái eltérők, gyakori a *hibrid* keresés, amely mindkét rangsort felhasználja. Az eredmények egyesítésének egyszerű és robusztus módja a reciprok rangfúzió (RRF) [80]: minden részlet annál több pontot kap, minél előrébb áll az egyes rangsorokban, és a pontokat összeadjuk. Az RRF csak a rangokat használja, így nem kell a két módszer eltérő skálájú pontszámait egymáshoz igazítani. A MIMIR egyik kísérleti kara (E2h) ezt a hibrid keresést vizsgálja.

Lekérdezés-átírás. A keresés minősége nemcsak a keresőn, hanem a *lekérdezésen* is múlik. Ha a lekérdezés rövid, általános vagy más stílusú, mint a keresett szöveg, a sűrű keresés is rossz találatokat adhat. Erre az irodalom a lekérdezés átírását javasolja: a HyDE módszer [81] egy nyelvi modellel előbb egy „hipotetikus” választ ír a kérdésre, és ennek a beágyazásával keres, mert az jobban hasonlít a keresett dokumentumokra, mint maga a kérdés; a Query2doc [82] hasonló módon bővíti ki a lekérdezést; Ma és munkatársai [83] pedig egy külön, kisebb modellt tanítottak a lekérdezések átírására. A vizsgagenerálás szempontjából ez kulcsfontosságú megfigyelés: a naiv RAG lekérdezése egy *feladatleírás* („tíz feleletválasztós kérdés, könnyű”), amely tartalmilag semmit sem mond a keresett szövegről. A MIMIR tervezett csővezetéke ezt a problémát a tervező által javasolt tartalmi fogalmakkal kerüli meg, amelyek lényegében átírt, tartalmi lekérdezések; eredményeink (5.2.8. szakasz) azt mutatják, hogy ez a különbség a naiv RAG egyik legnagyobb hibaforrását szünteti meg.

2.7.3. Darabolás

A keresés egysége a *darab* (*chunk*): a dokumentumot rövidebb részletekre kell bontani, mert a keresők és a generátorok is korlátozott hosszúságú bemenetet kezelnek. A legegyszerűbb módszer a rögzített hosszúságú ablak, amely azonban mondatok és gondolatmenetek közepén is vághat. A *szemantikus* darabolás a szomszédos mondatok beágyazásait hasonlítja össze, és ott vág, ahol a hasonlóság hirtelen lecsökken, vagyis ahol valószínűleg témaváltás van. Qu, Tu és Bao [84] szisztematikusan vizsgálták, megéri-e a szemantikus darabolás többletköltsége, és azt találták, hogy az előnye adatkészletfüggő és gyakran kisebb a vártnál. Chen és munkatársai [85] szerint a keresés egységének megválasztása (mondat, bekezdés vagy atomi állítás) önmagában is jelentősen befolyásolja az eredményt. E munkák alapján a darabolási stratégiát mi is külön kísérleti karokkal (E5a–c) vizsgáljuk, ahelyett hogy eleve jobbnak tekintenénk a szemantikus változatot. Eredményeink (5.2.8. szakasz) meg is erősítik, hogy a darabolás részletei a naiv RAG minőségét drámaian befolyásolhatják.

2.7.4. Forráshivatkozás

A visszakeresés önmagában nem garantálja, hogy a válasz a visszakeresett szövegen alapul; a modell figyelmen kívül is hagyhatja azt. Ezért egyre több rendszer kéri, hogy a modell *hivatkozzon* arra a részletre, amelyből a válaszát vette. Gao és munkatársai ALCE benchmarkja [86] azt méri, hogy a hivatkozások ténylegesen alátámasztják-e az állításokat, és azt találta, hogy a legjobb modellek hivatkozásainak is jelentős része hiányos vagy pontatlan. Rashkin és munkatársai [87] keretet adtak annak eldöntésére, mikor tekinthető egy állítás egy forrásnak „tulajdoníthatónak”: akkor, ha egy átlagos olvasó a forrás alapján egyetértene vele. A MIMIR minden kérdéshez megköveteli a kulcsot igazoló darabok azonosítóját, és a bíró is ehhez hasonló, olvasóközpontú definícióval dönt az alátámasztottságról.

2.7.5. Gráfalapú visszakeresés

Edge és munkatársai GraphRAG módszere [88] a dokumentumgyűjteményből nyelvi modellel fogalom- és kapcsolatgráfot épít, a gráfot csoportokra bontja, és a csoportok összefoglalóival válaszol a gyűjtemény egészére vonatkozó kérdésekre. A módszer erőssége, hogy a fogalmak közötti kapcsolatokat explicitté teszi; hátránya, hogy drága, mert a teljes szöveget többször fel kell dolgozni. A vizsgagenerálás szempontjából a gráf két helyen lehet hasznos: a fontos fogalmak kiválasztásában és a disztraktorok javaslásában, hiszen egy fogalom „testvérei” (az azonos kategóriába tartozó fogalmak) természetes disztraktorjelöltek. A MIMIR ennek egy könnyített, egyetlen dokumentumra korlátozott változatát vizsgálja (E3).

2.8. Hosszú kontextus: a visszakeresés alternatívája?

A RAG alternatívája az, hogy a teljes dokumentumot egyetlen promptban adjuk át a modellnek – ez felel meg az oktatók napi gyakorlatának. A modellek kontextusablaka az utóbbi években gyorsan nőtt, amit többek között az elforgatott pozíciókódolás (RoPE) [89] és a hatékonyabb figyelmi mechanizmusok tettek lehetővé; ma már több százezer token is elfér egy nagy modell bemenetében.

A névleges kontextushossz azonban nem azonos a ténylegesen kihasznált hosszal. Liu és munkatársai [11] kimutatták, hogy a modellek a kontextus elején és végén lévő információt jobban használják, mint a közepén lévőt („elveszve a közepén”, *lost in the middle*). Hsieh és munkatársai RULER benchmarkja [12] szerint a legtöbb modell „tényleges” kontextushossza jóval rövidebb a névlegesnél, és a teljesítmény a hossz növelésével folyamatosan romlik. Xu és munkatársai [90] összevetése szerint egy rövid, 4 000 tokenes kontextusú, de visszakeresést használó modell sok feladatban felveheti a versenyt egy 16 000 tokenes kontextusú modellel, és a kettő kombinációja a legjobb. Li és munkatársai [91] hasonló összevetésben azt találták, hogy elegendő erőforrás esetén a hosszú kontextus átlagosan jobb, a RAG viszont nagyságrenddel olcsóbb, és a kérdések jelentős részén azonos eredményt ad.

Vizsgagenerálásra vetítve ezekből két várakozás következik. Egyrészt a teljes dokumentumot kapó modell kérdései várhatóan a dokumentum elejére és végére tömörülnek, ami a lefedettség mérésével közvetlenül tesztelhető (3. hipotézis). Másrészt egy 8 GB-os kártyán futó kis modell számára a hosszú kontextus nem is járható út: a kontextus növelésével a memóriaigény is nő (3.4. szakasz), így a helyi futtatás szempontjából a rövid, célzott hívások jelentik a megoldást.

2.9. Ellenőrzés és önjavítás

A hallucináció elleni második stratégia a kimenet utólagos ellenőrzése. Ennek legegyszerűbb formája az *önjavítás*: a modell értékeli és javítja a saját kimenetét. A Self-Refine [8] ezt iteratívan végzi (generálás, visszajelzés, javítás, ismétlés), a Chain-of-Verification (CoVe) [9] pedig ellenőrző kérdéseket fogalmaz meg a saját válaszáról, ezekre egymástól függetlenül válaszol, és az eltérések alapján módosítja az eredeti választ. A SelfCheckGPT [92] több mintavételezett válasz összevetésével becsli a hallucinációt: ha a modell ugyanarra a kérdésre többször eltérő tényt állít, az valószínűleg kitalált. A FActScore [93] a szöveget atomi tényekre bontja, és mindegyiket külön ellenőrzi egy tudásforrással szemben; a módszer jól mutatja, hogy a hosszú szöveg helyességét érdemes kis, egyenként eldönthető kérdésekre bontani.

Az ellenőrzés egy másik ága a *természetes nyelvi következtetés* (*natural language inference*, NLI). Az NLI-feladatban egy modellnek azt kell eldöntenie, hogy egy állítás következik-e egy szövegből, ellentmond-e neki, vagy egyik sem. A feladathoz nagy adatkészletek készültek (SNLI [94], MultiNLI [95]), és az így tanított modelleket sikerrel alkalmazták összefoglalók tényszerűségének ellenőrzésére (SummaC [96]). Honovich és munkatársai TRUE benchmarkja [97] szerint a tényszerűség-ellenőrzésben a nagy NLI-modellek és a nyelvi modellel végzett ítéletek a legmegbízhatóbbak. Az alátámasztottság eldöntése a kérdésgenerálásban pontosan ilyen NLI-feladat: következik-e a forrásból, hogy a megjelölt kulcs a kérdés helyes válasza?

Az önellenőrzésnek azonban korlátai vannak. Huang és munkatársai [10] kimutatták, hogy *külső visszajelzés nélkül* a modellek önjavítása érvelési feladatokban nem javít, sőt ronthat is: a modell gyakran a helyes választ is „kijavítja”. Snell és munkatársai [98] ugyanakkor azt mutatták meg, hogy a következtetési időben elköltött többletszámítás (több minta, ellenőrzés, újrapróbálkozás) bizonyos feladatokban helyettesítheti a nagyobb modellt – ez adja az elméleti alapját annak, hogy egy kis modell ellenőrző lánccal megközelítheti egy nagy modell minőségét. A két eredmény együtt azt sugallja, hogy az ellenőrzés akkor hasznos, ha külső, független információt visz a folyamatba: determinisztikus szabályokat, a forrásszöveget, vagy egy másik modell ítéletét.

Az ellenőrzés tervezésekor egy további veszélyre is figyelni kell. Ha egy rendszert arra optimalizálunk, hogy egy mérőszámon jól teljesítsen, a rendszer olyan megoldásokat is találhat, amelyek a mérőszámot javítják, a valódi célt viszont nem. Ezt a jelenséget Goodhart-törvényként ismerjük, Strathern megfogalmazásában: ha egy mérőszám céllá válik, megszűnik jó mérőszám lenni [99]. A pilot vizsgálatunk egy ilyen jelenséget tárt fel (5.1. szakasz): az ellenőrzésen

való átjutás legolcsóbb módja a modell számára a forrásmondat szó szerinti bemásolása volt a kérdésbe.

A MIMIR ellenőrző lánca a fenti irányok metszetében helyezkedik el: olcsó, determinisztikus szabályokat (forma, hivatkozás, szivárgás, duplikátum) kombinál a forrással szembeni, nyelvi modellel végzett ítéletekkel (alátámasztottság, disztraktorok, vak megoldás), és a hibát visszajelzésként adja vissza a generátornak.

2.10. Kis nyelvi modellek és kvantálás

A helyi futtatás feltétele, hogy a modell elférjen egy fogyasztói grafikus kártya memóriájában. Az utóbbi években több olyan modellcsalád jelent meg, amely néhány milliárd paraméterrel is jó teljesítményt ér el: a Mistral 7B [100], a Phi-3 [101], a Qwen2.5 [102] és a Llama 3.1 [103]. Ezek közös jellemzője, hogy a kisebb méretet több és jobb minőségű tanítóadattal ellensúlyozzák, összhangban a skálázási törvényekkel [40]. Dolgozatunkban a Qwen2.5-7B-t használjuk generátorként, mert többnyelvű és jól követi a JSON-formátumú kimenetre vonatkozó utasításokat.

A kis modellek létrehozásának egyik fontos eszköze a *tudásdesztilláció* [104]: egy nagy „tanár” modell kimeneteit egy kisebb „diák” modell tanulja meg utánozni, így a diák a tanár tudásának jelentős részét kisebb méretben őrzi meg. A DistilBERT [105] például a BERT méretének 60 %-ával a teljesítményének nagy részét megtartotta. A desztilláció és a finomhangolás azonban tanítóadatot, számítási kapacitást és szakértelmet igényel, ami egy iskola vagy egy oktató számára ritkán áll rendelkezésre. A MIMIR ezért egy kész, általános célú kis modellt használ változtatás nélkül, és a minőséget a köré épített csővezetékkel igyekszik javítani – a két megközelítés egymást kiegészítheti.

A memóriaigény fő összetevője a modell súlyainak mérete. Egy 7 milliárd paraméteres modell 16 bites ábrázolásban paraméterenként 2 bájtot, összesen 14 GB-ot foglal, ami nem fér el egy 8 GB-os kártyán. A *kvantálás* a súlyokat kevesebb biten tárolja. Az LLM.int8() [106] 8 bites, a GPTQ [107] és az AWQ [108] 3–4 bites, tanítás utáni kvantálást vezetett be; a QLoRA [109] azt is megmutatta, hogy kvantált modellek finomhangolhatók. A helyi futtatás de facto szabványa a `llama.cpp` projekt [110] GGUF formátuma és csoportos, úgynevezett K-kvantálása (például a Q4_K_M változat, amely átlagosan kb. 4,5–5 bitet használ súlyonként); erre épül az általunk használt Ollama futtatókörnyezet [111]. Átfogó kiértékelések szerint a 4 bites súlykvantálás általános feladatokon csak kis pontosságvesztést okoz [112–114].

A memóriaigény második összetevője a *kulcs–érték (KV) gyorsítótár*, amelyben a modell a már feldolgozott tokenekhez tartozó köztes eredményeket tárolja, hogy ne kelljen őket újra kiszámolni. Ennek mérete a kontextus hosszával arányosan nő, így hosszú bemenetnél jelentős lehet. A csoportosított lekérdezésű figyelem (GQA) [115] a tárolt fejek számának csökkentésével ezt mérsékli, a PagedAttention [116] pedig a memória töredezettségét szünteti meg. A helyi futtatás energiaigényét fogyasztói hardveren Zähl és Hennig mérte [117]. A memóriaigény számszerű becslését a mi rendszerünkre a 3.4. szakasz adja meg.

2.11. Nyelvi modell mint bíró

A generált szövegek emberi értékelése drága és lassú, ezért egyre elterjedtebb, hogy egy erős nyelvi modell végzi az értékelést (*LLM-as-a-judge*). Zheng és munkatársai [118] szerint a GPT-4 bíró ítéletei közel akkora mértékben egyeznek az emberi preferenciákkal, mint az emberek ítéletei egymással. Chiang és Lee [119] szövegek minőségének értékelésében hasonló eredményre jutott úgy, hogy a nyelvi modell szó szerint ugyanazt az utasítást és értékelőlapot kapta, mint az emberi szakértők – ezt az elvet a mi rubrikánk is követi. A G-Eval [120] gondolatmenet-alapú, űrlapszerű értékeléssel tovább javította az emberi egyezést. A RAG-rendszerek referenciamentes kiértékelésére a RAGAS [121] nyelvi modellel számolt hűség- és relevanciamutatókat javasol.

A bírók torzításai ugyanakkor jól dokumentáltak. A *pozíciós torzítás* azt jelenti, hogy a bíró az első vagy a második helyen álló választ részesíti előnyben [122]; a *hossztorzítás*, hogy a hosszabb válaszokat jobbnak ítéli; az *önpreferencia* pedig azt, hogy a modellek felismerik és előnyben részesítik a saját generálásaikat [123]. Ezekből két tervezési döntésünk következik: a bíró más modellcsaládba tartozik, mint bármelyik generátor (gpt-oss [124] a Qwen- és Llama-generátorokkal szemben), és a vak megoldási próbában a válaszlehetőségek sorrendjét véletlenszerűen összekeverjük.

A bíró csak akkor tekinthető érvényes mérőeszköznek, ha ítéletei egyeznek az emberi szakértőkével. Az egyezés mérésére a tartalomelemzésben és a nyelvtechnológiában bevett mutatók szolgálnak [125]. Két értékelő bináris ítéleteire Cohen-κ-t [126], több értékelő és ordinális skála esetén Krippendorff-α-t [127] használnak; mindkettő azt méri, mennyivel nagyobb az egyezés a véletlenül várhatónál. A κ értelmezésére Landis és Koch [128] skálája terjedt el: 0,20 alatt csekély, 0,21–0,40 között gyenge, 0,41–0,60 között közepes, 0,60 felett erős egyezés. Krippendorff ajánlása szerint $\alpha \geq 0{,}8$ megbízható, 0,667 és 0,8 között óvatos következtetésre elegendő.

2.12. A kísérleti kiértékelés megbízhatósága

A gépi tanulási és nyelvtechnológiai kísérletek eredményei gyakran kisebb különbségeken múlnak, mint amekkora a mérés bizonytalansága. Bouthillier és munkatársai [129] kimutatták, hogy a benchmarkeredményekben a véletlen tényezők (inicializálás, adatsorrend, hardver) okozta szórás gyakran összemérhető a közölt javulásokkal, ezért egyetlen futás alapján nem szabad két módszer között dönteni. Nyelvi modelleknél ehhez a szövegelőállítás véletlenszerűsége és a GPU-n végzett lebegőpontos műveletek nem determinisztikus sorrendje is hozzájárul: ugyanaz a bemenet két futásban eltérő kimenetet adhat.

A különbségek megítélésére a statisztikai próbák szolgálnak. Dror és munkatársai [130] áttekintése szerint a nyelvtechnológiai cikkek jelentős része nem végez szignifikanciatesztet, vagy a mérési adatok eloszlásához nem illő próbát használ; a 0 és 1 közé szorított, gyakran ferde eloszlású mutatóknál a nemparaméteres próbák (például a Wilcoxon-próba) és a bootstrap

módszer a biztonságosabbak. A bootstrapet a gépi fordítás kiértékelésében Koehn [131] tette általánossá: a tesztkészletből visszatevéssel sokszor újramintavételezünk, és megnézzük, a minták hány százalékában marad meg a különbség. Fontos szempont az is, hogy mi a mérés *egysége*: ha egy dokumentumból tíz kérdés készül, a tíz kérdés nem tíz független megfigyelés. Ha sok összevetést végzünk, a véletlenül „szignifikáns" eredmények számát a többszörös összehasonlítás korrekciója (például Holm módszere [132]) tartja kordában.

Egy további veszély az *adatszennyezés*: a nagy modellek tanítóadata a nyilvános weboldalak jelentős részét tartalmazza, így egy Wikipédia-cikkre vagy egy nyílt tankönyvre épülő kiértékelésben a modell a választ a saját emlékezetéből is tudhatja [133]. Ez a mi kiértékelésünkben két helyen számít: a nyílt licencű dokumentumok (OpenStax, Wikipédia) a modellek tanítóadatában is szerepelhettek, és a bíró a vak megoldási próbában a forrás nélkül, általános tudásból is helyesen válaszolhat. Ezért a vak megoldhatóságot mindig az alátámasztottsággal együtt értelmezzük.

Végül a mérés az emberi felhasználót is érinti. Parasuraman és Manzey [134] az automatizálás hatásait vizsgálva kimutatták, hogy a felhasználók hajlamosak túlságosan megbízni az automatikus rendszerek jelzéseiben (*automatizálási torzítás*): ha egy rendszer egy kérdést „ellenőrzöttnek" jelöl, az oktató kevésbé figyelmesen nézi át. Egy ellenőrző jelzésének ezért csak akkor szabad ítéletként megjelennie, ha a megbízhatóságát mérésekkel igazoltuk – ez a szempont a 5.2.6. szakasz eredményeinek értelmezésében központi szerepet kap.

2.13. Adatvédelem és szabályozási környezet

A tananyag felhőszolgáltatónak való átadása nem csupán elméleti kockázat. A GDPR [13] értelmében, ha a tananyag személyes adatot tartalmaz (például esettanulmányban szereplő neveket vagy hallgatói munkákat), a szolgáltató adatkezelővé vagy adatfeldolgozóvá válik, és az átadáshoz jogalap, szerződés és – harmadik országba történő továbbításnál – további garanciák kellenek. Az adatminimalizálás és a tárolás korlátozásának elve szerint csak a feltétlenül szükséges adat kezelhető, a szükséges ideig. A nyelvi modellek esetében ehhez egy technikai kockázat is társul: Carlini és munkatársai [135] kimutatták, hogy a tanítóadat egyes részletei – köztük személyes adatok – a kész modellből szó szerint visszanyerhetők, vagyis ha a feltöltött tartalom a szolgáltató tanítóadatába kerül, később más felhasználókhoz is eljuthat.

Az EU mesterséges intelligenciáról szóló rendelete (AI Act) [136] az oktatásban használt MI-rendszerek egy részét – például a tanulási eredmények értékelésére szolgálókat – magas kockázatúnak minősíti, és emberi felügyeletet, átláthatóságot, valamint a mesterséges intelligenciával készült tartalom jelölését várja el. Az UNESCO útmutatója [52] ugyanezeket az elveket fogalmazza meg oktatáspolitikai szinten. A MIMIR tervezési céljai (3.1. szakasz) közvetlenül ezekből a követelményekből következnek: helyi futtatás, zéró adatmegőrzés, kötelező oktatói jóváhagyás és az MI-közreműködés jelölése.

2.14. Magyar nyelvi erőforrások

A magyar nyelv két szempontból jelent külön kihívást. Egyrészt agglutináló (toldalékoló) nyelv: egy szótőnek sok ragozott alakja van („immunrendszer”, „immunrendszert”, „immunrendszerben”), ami a szavak egyezésén alapuló lexikális keresést megnehezíti, és amit a morfológiai elemzők – például a magyarlanc [137] – kezelnek. Másrészt a magyar a nagy nyelvi modellek tanítóadatában kis arányban szerepel, ezért a többnyelvű modellek magyar teljesítménye elmarad az angoltól. Ahuja és munkatársai MEGA kiértékelése [138] több tucat nyelven mérte a generatív modelleket, és azt találta, hogy a teljesítmény a kisebb erőforrású nyelveken – különösen a nem latin írásúakon – jelentősen elmarad az angoltól. Egy 7B modell magyar szövegében ezért nyelvtani hibákra és pontatlan megfogalmazásokra is számítani kell, amit a kiértékelésnek külön is mérnie kell (érthetőségi pontszám). A magyar nyelvtechnológiai közösség saját modelleket (például a huBERT kódolót [139]) és kiértékelési kereteket is létrehozott: a HuLU benchmark [140] a magyar nyelvértési feladatok egységes kiértékelését teszi lehetővé, a MILQA [141] pedig magyar Wikipédia-cikkekre épülő kérdés–válasz adatbázis, amelyet a referenciakérdések egyik forrásaként használunk. Tudomásunk szerint magyar nyelvű vizsgakérdés-generálásra még nem publikáltak rendszerszintű, szisztematikus kiértékelést.

2.15. Összegzés és a kutatási rés

A 2.1. táblázat a tárgyalt megközelítéseket a bevezetésben megfogalmazott négy probléma (P1–P4) szempontjából veti össze. A szabályalapú és a neurális rendszerek helyben futtathatók, de a kérdések minőségét és a vizsga szerkezetét nem ellenőrzik. A csevegő nyelvi modell a legjobb minőségű szöveget adja, de egyik problémát sem kezeli: nincs ellenőrzés, a szerkezet csak kérés, a tananyag a szolgáltatóhoz kerül, és nagy modellt igényel. A naiv RAG forráshoz köti a generálást, de egyetlen kereséssel a dokumentum kis részét látja. Az önjavító és gráfalapú módszerek egy-egy problémát részben kezelnek, de nagy modellt feltételeznek.

Az összevetésből három hiányosság rajzolódik ki. (i) Nincs olyan nyílt rendszer, amely a kérdésgenerálást explicit tervvel, forráshivatkozással és ellenőrzéssel, fogyasztói GPU-n futó kis modellel végezné. (ii) A kiértékelések ritkán mérik a kulcs helyességét és a vizsga lefedettségét, és hiányoznak azok a kísérleti tervek, amelyek a komponensek hatását egyenként választják szét. (iii) A magyar nyelvű vizsgagenerálás kiértékelése feltáratlan. Az első hiányosságra a 3., a másodikra a 4., a harmadikra – a rendelkezésre álló adatok korlátai között – az 5. fejezet ad választ.

2.1. táblázat. A kérdésgenerálási megközelítések összevetése a P1–P4 problémák szempontjából (✓: megoldott, ○: részben, –: nem kezelt).

Megközelítés	Kulcs ellenőrzése	Szerkezet, lefedettség	Helyi futás	Kis modell	Forrás-hivatkozás	Helyesség mérése
Szabály/sablon alapú [23, 24]	○	–	✓	✓	○	–
Neurális seq2seq [28]	–	–	✓	✓	–	–
Dokumentum → csevegő LLM (status quo)	–	–	–	–	–	–
LLM-alapú kérdésgenerálás [44, 46]	–	○	–	–	–	○
Naiv RAG [64]	–	–	○	○	○	–
Finomhangolt kis modell [49, 50]	–	–	✓	✓	–	○
Feladatfelbontó promptolás [54, 55]	–	○	–	–	–	–
Önjavítás / CoVe [8, 9]	○	–	–	–	–	–
Hivatkozó generálás [86]	○	–	–	–	✓	✓
GraphRAG [88]	–	○	–	–	○	–
MIMIR (jelen munka)	✓	✓	✓	✓	✓	✓

3. A MIMIR rendszer és generálási módszere

Ez a fejezet a dolgozat módszertani magja. Először a rendszer tervezési céljait, felépítését és adatvédelmi megoldásait mutatjuk be (3.1–3.4. szakasz), majd lépésenként ismertetjük a generálási módszert: a darabolást, a vizsgatervet, a keresést, a kérdések generálását, az ellenőrző láncot és a fogalomgráfot (3.5–3.13. szakasz). A leírás a kiértékelő keretrendszer implementációját követi (`tests/eval/mimir_eval/blueprint`).

3.1. Tervezési célok

A bevezetésben megfogalmazott P1–P4 problémákból és az AI Act emberi felügyeletre vonatkozó elvárásából [136] öt tervezési célt vezettünk le. A 3.1. táblázat ezeket a közvetlen megközelítéssel (dokumentum feltöltése egy csevegő asszisztensbe) veti össze.

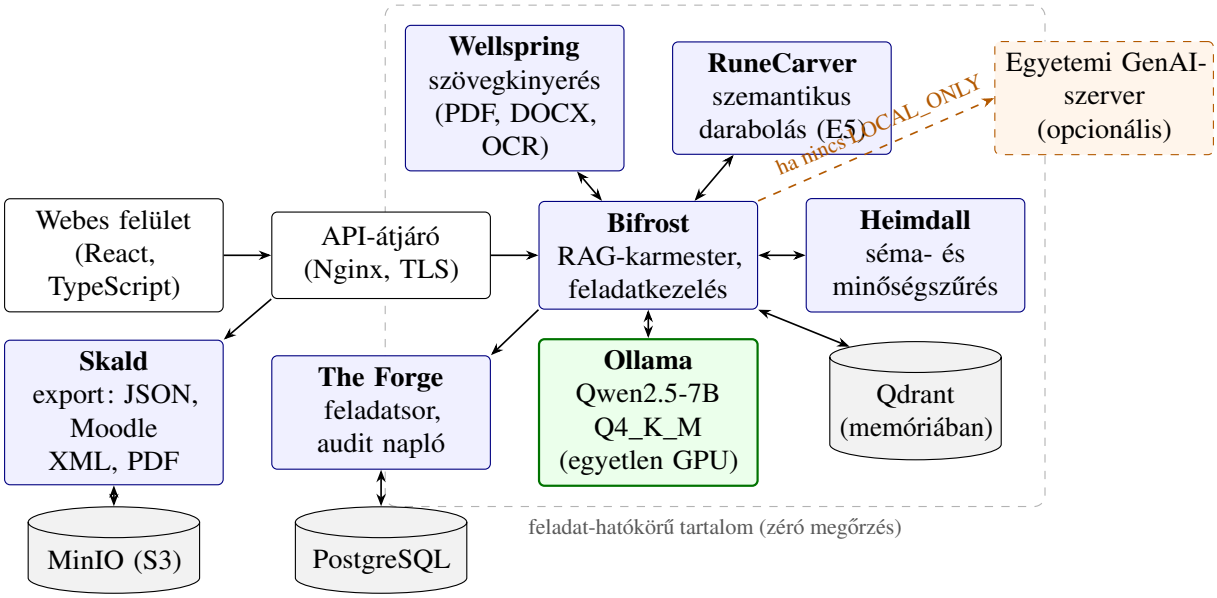
3.1. táblázat. Tervezési célok: a dokumentum csevegő LLM-nek való átadása és a MIMIR összevetése.

Cél	Dokumentum → csevegő LLM	MIMIR
G1 Ellenőrizhető	A kulcs nincs ellenőrizve, nincs forráshivatkozás	Minden kérdés a forrásrészletekre hivatkozik; alátámasztottsági és vak megoldási ellenőrzés; az ellenőrzésen át nem jutott kérdés megjelölve
G2 Kontrollált	Darabszám, típus, nehézség csak kérés	A terv rögzíti a darabszámot, a típusokat és a Bloom-szinteket; lefedettségvezérelt fogalomválasztás
G3 Adatvédő	Az anyag a szolgáltatóhoz kerül	Helyi modell; a tartalom a feladat végén törlődik; kapcsolható, kizárólag helyi mód
G4 Megvalósítható	Hosszú kontextus, nagy modell	Rövid hívások 8 192 tokenes kontextusban; 7B modell 8 GB-os kártyán
G5 Felügyelt	A kimenet változtatás nélkül használható	Kötelező oktatói jóváhagyás szerkesztőben, a hivatkozott forrással; MI-közreműködés jelölése az exportban

3.2. Mikroszolgáltatás-architektúra

A rendszer lazán csatolt, konténerizált szolgáltatásokból áll, amelyeket egy Nginx-alapú API-átjáró fog össze (3.1. ábra). A szolgáltatások az északi mitológia tudással kapcsolatos alakjairól kapták nevüket. A *Wellspring* a szöveget nyeri ki PDF-ből, DOCX-ből és szövegfájlból (olvashatatlan PDF-oldalnál helyi módban Tesseract OCR-rel); a *RuneCarver* a mondatokra bontást, a mondatbeágyazást és a darabolást végzi (3.6. szakasz); a *Bifrost* a generálás karmestere (feladatkezelés, indexelés, keresés, promptépítés, modellválasztás); a *Heimdall* a modellválaszok

formáját szűri; a *The Forge* a feladatsort és az audit naplót kezeli; a *Skald* pedig JSON, Moodle XML és PDF formátumba exportál. Minden szolgáltatás FastAPI-alapú Python-alkalmazás egységes, verziózott felülettel, így a kiértékelő keretrendszer pontosan ugyanazokat a végpontokat hívja, mint az éles webes felület.



3.1. ábra. A MIMIR szolgáltatásai és adatfolyama. A szaggatott keretben lévő komponensek a feltöltött tartalmat kizárólag a feladat élettartama alatt, memóriában tartják; a nyelvi modell az egyetlen GPU-t használó összetevő.

A generálás percekig tarthat, ezért a rendszer *aszinkron* módon működik: a generálási kérés azonnal egy feladatazonosítót ad vissza, az állapot (haladás, becsült hátralévő idő) pedig egy másik végponton kérdezhető le. A háttérmunkát a The Forge osztja ki a munkásoknak egy adatbázistáblán alapuló sorral, amely a PostgreSQL `FOR UPDATE SKIP LOCKED` zárolási záradékára [142] épül: minden munkás a legrégebbi, még senki által nem zárolt feladatot veszi ki, így egy feladatot pontosan egy munkás kap meg, külön üzenetközvetítő szoftver nélkül. Mivel a GPU egyszerre egyetlen modellt futtat, a generálási feladatok egymás után futnak; a párhuzamos munkások a CPU-igényes kinyerést és darabolást gyorsítják.

3.3. Adatvédelem: zéró adatmegőrzés

A G3 cél megvalósítása az adatminimalizálás és a tárolási korlátozás GDPR-elvein [13] alapul: a feltöltött tartalom csak addig létezik, amíg a feladathoz szükséges. A 3.2. táblázat a feldolgozás során keletkező adatfajták életciklusát összegzi.

Az audit napló a reprodukálhatóság és az elszámoltathatóság miatt fontos, ugyanakkor nem tartalmazhat tananyagot. Ezért a napló a feladat azonosítóját, a modell nevét, a promptverziót és a minőségi pontszámot tárolja, a kérésből, a promptból és a visszakeresett kontextusból pedig csak a SHA-256 *ujjlenyomatot* (kriptográfiai kivonatot) és a szöveg hosszát. Az ujjlenyomat alapján utólag igazolható, hogy két futás ugyanazzal a kontextussal dolgozott-e, a tartalom azonban nem

3.2. táblázat. Adatfajták életciklusa a MIMIR rendszerben.

Adat	Tárolás helye	Élettartam
Feltöltött fájl	memória	a szövegkinyerés végéig
Kinyert szöveg, darabok	memória	a feladat végéig
Beágyazások	Qdrant, memóriában	a következő dokumentum indexelése előtt törlődnek
Promptok, kontextus	memória	a modellhívás végéig
Generált vizsga (vázlat)	feladattár	60 perc, majd automatikus törlés
Jóváhagyott, mentett vizsga	MinIO	beállítható megőrzési idő, az oktató törölheti
Audit napló	PostgreSQL	csak metaadatok és ujjlenyomatok; megőrzési idő után törlés

állítható vissza belőle. A `LOCAL_ONLY` kapcsoló minden külső modellhívást letilt: ilyenkor a rendszer kizárólag a helyi modellt és a helyi OCR-t használja.

3.4. A GPU-memória becslése

A G4 cél kvantitatív kérdés: elfér-e a generátor egy 8 GB-os kártyán úgy, hogy mellette az asztali környezet is fut? A szövegelőállítás közbeni memóriaigény három tag összege:

$$M = W + \mathrm{ctx} \cdot m_{kv} + M_0, \tag{3.1}$$

ahol W a kvantált súlyok mérete, ctx a kontextus hossza tokenben, m_{kv} a KV-gyorsítótár tokenenkénti mérete, M_0 pedig a futtatókörnyezet többletigénye (számítási pufferek). A tokenenkénti gyorsítótár a modell felépítéséből számolható: minden rétegben (L réteg) minden kulcs–érték fejhez (H_{kv} fej) egy kulcs- és egy értékvektort kell tárolni, egyenként d_h elemmel és elemenként 2 bájttal. A Qwen2.5-7B modellre [102] ($L = 28$, $H_{kv} = 4$, $d_h = 128$):

$$m_{kv} = 2 \cdot 28 \cdot 4 \cdot 128 \cdot 2 \text{ bájt} = 57\,344 \text{ bájt} \approx 56 \text{ KiB}. \tag{3.2}$$

Így 8 192 tokenes kontextusnál a gyorsítótár kb. 448 MiB, 16 384 tokennél kb. 896 MiB. A 3.3. táblázat több lehetséges helyi generátorra mutatja a becslést.

A becslés szerint a 3–8 milliárd paraméteres modellek 4 bites kvantálással elférnek egy 8 GB-os kártyán, a 14B modell vagy a 8 bites 7B modell viszont már 12 GB-ot igényel. A becslést mindkét vizsgálatban mért értékekkel ellenőriztük (5.1. és 5.2.13. szakasz). A becslésből az is látszik, hogy a teljes dokumentumot egy promptban kapó helyi alapvonal számára a kontextus növelése nem ingyenes: 32 768 tokennél a gyorsítótár önmagában 1,75 GiB, ami a kártya kapacitását meghaladná, és a futtatókörnyezet a modell egy részét a lassú CPU-ra helyezné. Ezért a helyi teljes dokumentumos alapvonal 16 384 tokenes kontextussal és 30 000 karakterre

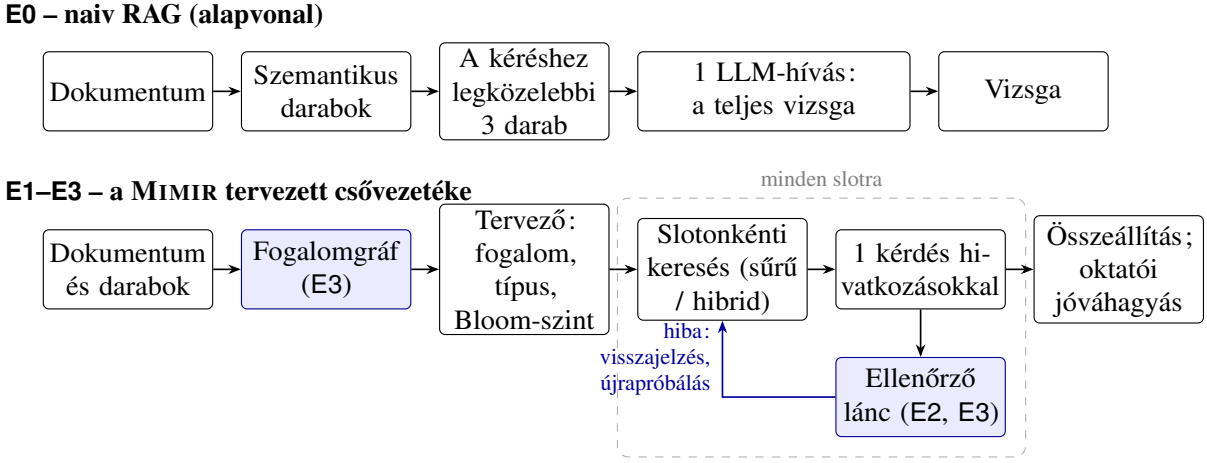
3.3. táblázat. Becsült GPU-memóriaigény 8 192 tokenes kontextusnál, $M_0 \approx 0{,}6$ GB futtatókörnyezeti többlettel. A súlyok a GGUF-fájlok mérete, a gyorsítótár a publikált architektúrákból számolt érték.

Modell	Kvantálás	L/H_{kv}	Súlyok	m_{kv}	Összesen	Kártya
Qwen2.5-3B	Q4_K_M	36/2	1,9 GB	36 KiB	2,8 GB	8 GB
Qwen2.5-7B	Q4_K_M	28/4	4,7 GB	56 KiB	5,8 GB	8 GB
Llama-3.1-8B [103]	Q4_K_M	32/8	4,9 GB	128 KiB	6,6 GB	8 GB
Qwen2.5-7B	Q8_0	28/4	8,1 GB	56 KiB	9,2 GB	12 GB
Qwen2.5-14B	Q4_K_M	48/8	9,0 GB	192 KiB	11,2 GB	12 GB

csonkolt dokumentummal fut. Ez az a korlát, amelyet egy kis helyi modell egyetlen promptban nem tud megkerülni, a tervezett csővezeték viszont igen, mert minden hívása rövid.

3.5. A generálási módszer áttekintése

A 3.2. ábra a két összehasonlított csővezetéket mutatja. A *naiv RAG* (E0) a felhasználói kéréshez legjobban hasonlító három darabot keresi vissza, és egyetlen hívásban kéri a teljes vizsgát; ez a rendszer eredeti (v1) működése és egyben a legolcsóbb ésszerű alapvonal. A *tervezett csővezeték* (E1–E3) először explicit vizsgatervet készít, majd a terv minden pontjára (a továbbiakban: *slotjára*) külön keresést, egyetlen kérdés generálását és – az ellenőrző változatokban – ellenőrzést végez.



3.2. ábra. A naiv RAG és a MIMIR tervezett csővezetéke. Kék: a kísérleti karokban ki- és bekapcsolt komponensek. A terv a vizsga szerkezetét még az első kérdés megírása előtt rögzíti, és minden kérdést a saját, hivatkozott kontextusával szemben ellenőriz.

A két megközelítés közötti lényegi különbség nem a modell, hanem a feladat felbontása. A naiv alapvonalban a modellnek egyetlen hívásban kell eldöntenie, hány kérdést, milyen témákról, milyen nehézségben és milyen disztraktorokkal ír. A tervezett csővezetékben a szerkezeti döntéseket (darabszám, típus, Bloom-szint, téma) determinisztikus program hozza meg, a modell feladata pedig egy-egy rövid, jól körülhatárolt kérdés megírására szűkül, amelyhez csak a releváns kontextust kapja meg. A csővezeték fontosabb paramétereit a 3.4. táblázat foglalja

össze.

3.4. táblázat. A tervezett csővezeték paraméterei és alapértékei a fő vizsgálatban.

Paraméter	Alapérték	Jelentés
visszakeresett darabok (k)	3	ennyi darabot keresünk slotonként
keresés módja	sűrű	sűrű (E5) vagy hibrid (BM25 + sűrű, E2h)
tartalékfogalmak	3	a tervező $n+3$ fogalmat javasol
újrapróbálkozás (r)	1 (pilot: 2)	slotonként, visszajelzéssel
ellenőrző lánc	ki/be	E1: ki; E2, E3: be
vak megoldási próba	be	E2f: ki
szivárgási szabályok	be	a pilot után bevezetve
javító hívás	be	a pilot után bevezetve
duplikátumküszöb	0,9	koszinusz-hasonlóság két kérdés között
áttekintés kerete	12 000 karakter	a tervező ennyit lát a dokumentumból
slotkontextus kerete	6 000 karakter	a generátor ennyit lát slotonként
generátor	Qwen2.5-7B	Q4_K_M kvantálás, hőmérséklet 0,2, 8 192 tokenes kontextus

3.6. Szemantikus darabolás

Mondatbeágyazás. A darabolás első lépése a mondatokra bontás (a mondatvégi írásjelek és sortörések mentén). Ezután minden mondathoz egy 768 dimenziós beágyazóvektort rendelünk a multilingual-E5-base [75] kódolóval. A kódoló nem az egyes mondatokat külön, hanem hosszabb szövegablakokat dolgoz fel, és egy mondat vektora az őt alkotó tokenek vektorainak átlaga. Előnye, hogy egy rövid, önmagában kétértelmű mondat vektora a szomszédos mondatok jelentését is tükrözi.

Vágási szabály. Két szomszédos mondat *szemantikus távolsága*

$$\delta_i = 1 - \cos\big(\mathbf{v}_i, \mathbf{v}_{i+1}\big), \tag{3.3}$$

ahol $\mathbf{v}_i$ az i-edik mondat vektora; a távolság 0, ha a két mondat jelentése azonos irányú, és annál nagyobb, minél jobban eltér. Az alapgondolat, hogy témaváltásnál a távolság nagy. A *vágási küszöb* (τ) alapértelmezésben a távolságok 85. percentilise, vagyis a legnagyobb 15 % szomszédos távolságnál vágunk; az E5b változatban a küszöb az átlag plusz 1,5 szórás. Hogy egy darab ne nőjön túl hosszúra, a küszöb a célméret (1 000 karakter) túllépése után arányosan csökken: egy kétszeres hosszúságú darab már fele akkora távolságnál is lezárul. Ez a „puha korlát” megakadályozza a túl hosszú darabokat anélkül, hogy a mondatok közepén vágna.

A csonkolt kódoló hibája. A kódoló legfeljebb 512 tokenes bemenetet fogad. Az eredeti implementáció a teljes dokumentumot egyetlen menetben, csonkolva kódolta, így minden mondat, amely az 512. token után kezdődött, nullvektort kapott. A nullvektor bármely mondattól

ugyanolyan távol van ($\delta = 1$), ezért hosszabb dokumentumon a küszöb is 1 lett, a vágás pedig a dokumentum nagy részén már nem a tartalomtól, hanem csak a darab hosszától függött. Becslésünk szerint a kiértékelő adatkészlet átlagos dokumentumának 68–71 %-a esett a határ után, így a hiba a hosszabb dokumentumokon végzett minden korábbi mérést érintette. A javított kódoló a mondatokat mondathatáron vágott, legfeljebb 510 tokenes ablakokba csoportosítja, és ablakonként futtatja a modellt. Az `E5a` kar a régi kódolót szándékosan megtartja, hogy a hiba hatása mérhető legyen. Rövid, 512 tokennél rövidebb szövegen a két kódoló azonos darabokat ad.

3.7. Indexelés és az alapvonalak

A darabokat a rendszer az E5 kódolóval beágyazza, és egy memóriában futó Qdrant [143] vektortárba tölti. A tár minden új dokumentum előtt kiürül, így mindig csak az aktuális feladat tartalmát tartalmazza. A *sűrű keresés* egy lekérdezésre azt a k darabot adja vissza, amelynek vektora a lekérdezés vektorához a legközelebb áll (a koszinusz-hasonlóság szerint).

Naiv RAG (`E0`). A lekérdezés a felhasználói kérés szövege (például „10 feleletválasztós kérdés, könnyű nehézség”), a kontextus a három leghasonlóbb darab. A prompt (A. függelék) a rendszer éles, v1.0-s promptja: szigorú szabályokat ír elő (csak a kontextusból dolgozzon, tartsa be a kért darabszámot és típust, egy helyes és három hihető disztraktort adjon, ne hivatkozzon „a szövegre”) és megadja a kimeneti JSON-formátumot. A generálás egyetlen hívás.

Teljes dokumentum (`B-doc-L`, `B-doc-S`). Ez a status quo modellje: ugyanaz a prompt, de a kontextus a teljes dokumentum. A helyi változat 16 384 tokenes kontextussal és 30 000 karakterre csonkolt dokumentummal, a szerverváltozat 80 000 karakterig fut; a levágott rész arányát vizsgánként rögzítjük.

3.8. A vizsgaterv

Fogalomtervezés. A tervező egyetlen hívásban a dokumentum *áttekintését* kapja meg: minden darab azonosítóját ($C_0, C_1, \ldots$) és a darab elejét, összesen legfeljebb 12 000 karakterben (darabonként legalább 120 karaktert). Így minden darab megjelenik a tervező bemenetében, és a modell nem egy hosszú, folytonos szöveget, hanem egy azonosítókkal tagolt, rövid felsorolást lát – ez a „lost in the middle” jelenség [11] ellen hat. A tervező $n+3$ fogalmat ad vissza (ahol n a kért kérdésszám), mindegyikhez egy rövid leírást (mit kell kérdezni), a fogalmat alátámasztó darabok azonosítóit és egy fontossági értéket (1: részlet, 2: fontos, 3: központi). Ha a tervező válasza értelmezhetetlen, a rendszer darabonként egy egyszerű álfogalomra esik vissza, így a terv mindig létrejön.

Bloom-szintek kiosztása. A kért nehézséghez egy Bloom-szint-eloszlás tartozik (3.5. táblázat). Az eloszlást a *legnagyobb maradék módszerével* alakítjuk egész darabszámokká, amelyet

a választási matematikából ismerünk (Hamilton-módszer [144]): minden szint először a kérdésszám és az arány szorzatának egészrészét kapja, a maradék helyeket pedig a legnagyobb törtrésszel rendelkező szintek kapják. Közepes nehézségnél (0,4 ; 0,4 ; 0,2 a megértés, alkalmazás és elemzés szintekre) $n = 10$ kérdésnél a kiosztás pontosan $(4,4,2)$; $n = 7$ kérdésnél a szorzatok $(2{,}8;\ 2{,}8;\ 1{,}4)$, az egészrészek $(2,2,1)$, a két maradék hely a két legnagyobb törtrészű szinthez kerül, így a kiosztás $(3,3,1)$. A módszer garantálja, hogy a darabszámok összege pontosan n, és egyik szint darabszáma sem tér el egynél többel az ideális értéktől. A nehézség így nem kérés a promptban, hanem a terv szerkezeti tulajdonsága. A szinteket véletlenszerűen rendeljük a fogalmakhoz, a kész vizsgát pedig a könnyebbtől a nehezebb felé rendezzük.

3.5. táblázat. A nehézségi szintekhez rendelt Bloom-eloszlások és egy 10 kérdéses vizsga kiosztása.

Nehézség	Emlékezés	Megértés	Alkalmazás	Elemzés	Értékelés	Kiosztás ($n = 10$)
Könnyű	0,5	0,5	–	–	–	(5, 5, 0, 0, 0)
Közepes	–	0,4	0,4	0,2	–	(0, 4, 4, 2, 0)
Nehéz	–	–	0,3	0,4	0,3	(0, 0, 3, 4, 3)

Lefedettségvezérelt fogalomválasztás. A slotokhoz a fogalmakat egy *mohó* eljárás választja ki: a fogalmakat fontosság szerint sorba rendezi, és minden lépésben azt választja, amely érint még le nem fedett darabot, és ezen belül a legfontosabb. Ha már minden darab le van fedve, a fontosság dönt. Ennek következménye, hogy ha a tervező legalább n fogalmat javasolt, a vizsga legalább annyi különböző darabra támaszkodik, ahány slot és lefedhető darab van (a kettő közül a kisebb); a kérdések tehát nem tömörülhetnek a dokumentum egyetlen részére. Ha kevesebb fogalom van, mint slot, a fogalmakat eltérő Bloom-szinttel újra felhasználjuk. A ki nem választott fogalmak alkotják a *tartaléklistát*.

3.9. Slotonkénti keresés

Minden slot saját kontextust kap. A lekérdezés a fogalom neve és leírása, a kontextus pedig a fogalomhoz a tervező által rendelt első két darab, kiegészítve a keresés $k = 3$ találatával (ismétlődés nélkül), legfeljebb 6 000 karakterig. Ez a keret a kis modell „kényelmi zónájában” tartja a bemenetet. Ha az ellenőrző azt jelzi, hogy a hivatkozott részlet nem igazolja a kulcsot, a következő kísérletben két további darabot keresünk. Fontos különbség a naiv RAG-hoz képest, hogy a lekérdezés itt egy tartalmi fogalom („immunológiai memória: hogyan alakul ki”), nem pedig egy feladatleírás („10 kérdés, könnyű”).

Hibrid keresés (E2h). A hibrid változat a sűrű rangsort egy lexikális BM25-rangsorral [71] egyesíti. A magyar ragozás miatt a szavakat egyszerű *előtagtövesítéssel* normalizáljuk: a hat karakternél hosszabb szavakat az első hat karakterükre vágjuk, így az „immunrendszer”, „immunrendszert”, „immunrendszerben” alakok közös kulcsot kapnak. A két rangsort a reciprok

rangfúzió [80] egyesíti: a c darab pontszáma

$$\mathrm{RRF}(c) = \frac{1}{60 + \mathrm{rang}_{\text{sűrű}}(c)} + \frac{1}{60 + \mathrm{rang}_{\mathrm{BM25}}(c)}, \tag{3.4}$$

ahol a rang az adott rangsorbeli helyezés (1-től számozva), a 60-as konstans pedig az irodalomban bevett érték, amely csökkenti az első helyek túlzott súlyát.

3.10. Forráshoz kötött kérdésgenerálás

A generátor egyetlen kérdést ír a slot terve szerint. A prompt (A. függelék) tartalmazza a fogalmat, a kérdezendő tartalmat, a típusszabályt (négy válasz, egy helyes, a válaszok hossza és formája hasonló), a Bloom-szint magyar leírását, a nehézséget és a nyelvet; megismétli az éles prompt szabályait; felsorolja a már elfogadott kérdéseket, hogy a modell ne ismételje őket; és megköveteli a `citations` mezőt, amelyben a modell megnevezi a kulcsot igazoló darabok azonosítóit. Ha az előző kísérlet hibás volt, a prompt a hibák listáját is tartalmazza („Az előző próbálkozás hibás volt, javítsd: …”). Az egyenkénti generálás két előnnyel jár: a modellnek egyszerre csak egy döntést kell hoznia, és minden kérdés saját, ellenőrizhető forrásrészlethez kötődik (G1).

3.11. Az ellenőrző lánc

3.11.1. Ellenőrzések a költség szerinti sorrendben

Az ellenőrzések a legolcsóbbtól a legdrágábbig futnak (3.6. táblázat): ha egy olcsó, szabályalapú ellenőrzés hibát talál, a drága, nyelvi modellt igénylő ellenőrzések el sem indulnak. A modellalapú ellenőrzések a kérdés által hivatkozott darabokat kapják forrásként.

3.6. táblázat. Az ellenőrző lánc lépései végrehajtási sorrendben, a hiba esetén adott visszajelzéssel.

Ellenőrzés	LLM-hívás	Visszajelzés hiba esetén
Forma	–	feleletválasztós kérdés: 4 válasz, ebből 1 helyes
Meta-hivatkozás	–	fogalmazd meg „a szöveg szerint” jellegű hivatkozás nélkül
Szivárgás és kérdésforma *(új)*	–	a törzs ne tartalmazza a választ, és legyen valódi kérdés
Hivatkozás	–	hivatkozz a kontextus legalább egy darabjára
Alátámasztottság és disztraktorok	1	a kulcsot a részlet nem igazolja / egy disztraktor igaz lehet / kétértelmű
Vak megoldás	1	egy független megoldó más választ jelölt meg
Duplikátum	–	túl hasonló egy már elfogadott kérdéshez

A *szivárgási szabály* akkor jelez, ha a legalább háromszavas kulcs szavainak legalább 80 %-a a törzsben is szerepel; a *kérdésforma-szabály* akkor, ha a törzs sem kérdőjelre, sem kettőspontra nem végződik. Mindkettőt a pilot vizsgálatban feltárt hibamód (5.1. szakasz) motiválta. Az

alátámasztottsági ellenőrzés egyetlen hívásban három kérdést tesz fel a modellnek: igazolja-e a forrás a megjelölt kulcsot; hamis-e minden disztraktor a forrás szerint; és kétértelmű-e a kérdés. A *vak megoldás* külön hívás, amelyben a modell a kulcs ismerete nélkül, összekevert sorrendben látja a válaszokat, és a forrás alapján választania kell; ha mást választ, mint a megjelölt kulcs, a kérdés vagy hibás, vagy kétértelmű. A *duplikátum* akkor áll fenn, ha a kérdés beágyazásának koszinusz-hasonlósága egy már elfogadott kérdéséhez legalább 0,9. Az E2x kar az ellenőrző hívásokat egy másik modellcsaládba tartozó modellel (Llama-3.1-8B [103]) végzi, hogy elválassza az önellenőrzés és az ellenőrzés általános hatását.

3.11.2. Slotkitöltés visszacsatolással

Egy slot kitöltése a következő lépésekből áll:

1. A generátor megírja a kérdést a slot kontextusával.
2. Az ellenőrző lánc (3.6. táblázat) megvizsgálja; ha nincs hiba, a kérdés *ellenőrzöttként* bekerül a vizsgába.
3. Ha hiba van, a hibák listája a következő kísérlet promptjába kerül, és a generátor újrapróbálkozik (legfeljebb r alkalommal). Ha a hiba „a kulcsot a részlet nem igazolja”, a keresés két további darabbal bővül.
4. Ha egyik kísérlet sem sikerül, a slot egy tartalékfogalommal újraindul (ismét legfeljebb $r+1$ kísérlettel).
5. Ha ez sem sikerül, a *legjobb* kísérlet marad meg *nem ellenőrzöttként* megjelölve, hogy az oktató a szerkesztőben lássa. A „legjobb” kiválasztása három szempont szerint, sorrendben történik: a formailag helyes kérdés mindig előnyt élvez; ezen belül a szivárgásmentes; végül a kevesebb hibát tartalmazó.
6. Ha a megmaradt feleletválasztós kérdés formája mégis hibás (például csak három válasza van), egyetlen *javító* hívás pótolja a hiányzó disztraktorokat a törzs és a kulcs megtartásával.

Az 5. és 6. lépés a pilot egyik hibájára adott válasz: ott egy-egy vizsgában hibás formájú végső kérdés maradt meg, ami a vizsga formai megfelelését nullára állította (5.1. szakasz).

Költség. A modellhívások száma a módszer fő költségtényezője. Az egyhívásos karok (E0, E5a–c, B-doc) egyetlen hívással dolgoznak. Az ellenőrzés nélküli E1 legalább $1+n$ hívást igényel (egy tervezés és kérdésenként egy generálás), az ellenőrzött E2 legalább $1+3n$ hívást (kérdésenként generálás, alátámasztottsági ellenőrzés és vak megoldás). Tíz kérdésnél ez 11, illetve 31 hívás akkor, ha minden kérdés elsőre átmegy; minden elutasítás további két-három hívással jár.

3.12. Munkamenet-hatókörű fogalomgráf

Az E3 kar a tervezőt egy fogalomgráffal egészíti ki. A gráfépítés a darabokat legfeljebb 3 000 karakteres kötegekbe csoportosítja, és kötegenként egyetlen hívásban kinyeri a fogalmakat (definícióval, szülőfogalommal és darabazonosítókkal), a rövid, atomi tényeket és a fogalmak közötti kapcsolatokat (például *része*, *fajtája*, *okozza*, *ellentéte*). Az azonos vagy nagyon hasonló nevű fogalmakat (névbeágyazásuk koszinusz-hasonlósága legalább 0,92) összevonjuk, ami a magyar ragozott alakokat (például „T-sejt”, „T-sejtek”) is egyesíti.

Egy fogalom fontosságát a gráfbeli *centralitása* adja, amely egyszerű pontszám:

$$\text{cent}(v) = \text{kapcsolatok száma} + \tfrac{1}{2} \cdot \text{darabok száma} + \tfrac{1}{2} \cdot \text{tények száma}. \tag{3.5}$$

A gráf három helyen gazdagítja a csővezetéket: (i) a tervező a centralitás szerint rendezett fogalomlistát kapja; (ii) a generátor disztraktor-ötletként a fogalom *testvérfogalmait* kapja (azokat, amelyeknek ugyanaz a szülőfogalmuk, például a „T-sejt” mellett a „B-sejtet”), amelyek ugyanabba a kategóriába tartoznak, ezért hihetők, de nem azonosak a kulccsal; (iii) a kontextus a szomszédos fogalmak két leggyakoribb darabjával bővül. A gráf csak a vizsga élettartamáig létezik a memóriában, a zéró megőrzéssel összhangban.

3.13. Összeállítás és emberi felügyelet

Az elfogadott kérdéseket a Bloom-szint szerint rendezzük, és minden kérdéshez rögzítjük a hivatkozott darabokat, a tervezett fogalmat és az *ellenőrzött* jelzőt. A vázlat egy szerkesztőbe kerül, ahol az oktató szerkesztheti, átrendezheti és törölheti a kérdéseket, módosíthatja a kulcsot, egyetlen kérdést újragenerálhat, és minden kérdés mellett megtekintheti a hivatkozott forrásrészletet. Jóváhagyás nélkül semmi sem exportálható, az exportált dokumentum pedig feltünteti, hogy a tartalom MI-rendszer közreműködésével készült, és melyik modellel (G5).

4. Kiértékelési módszertan

A 2. fejezetben láttuk, hogy a kérdésgenerálás kiértékelése jellemzően a referenciakérdésekkel való szóegyezésre és kis, nem vak emberi értékelésekre támaszkodik, és ritkán ellenőrzi a kulcs helyességét. Ebben a fejezetben olyan kiértékelési módszertant mutatunk be, amely (i) a forráshoz viszonyított helyességet méri, (ii) egytényezős kísérleti tervvel választja szét a komponensek hatását, (iii) a mérőeszközt (a bírót) is ellenőrzi, és (iv) a dokumentumot tekinti a statisztikai elemzés egységének. A módszertan minden eleme a nyílt forráskódú keretrendszerben (`tests/eval`) implementált.

4.1. A tesztelés menete

A kiértékelés alapegysége egy *teszt*: egy kísérleti kar (a csővezeték egy konfigurációja) egy dokumentumon, egy véletlenmaggal egy tízkérdéses, feleletválasztós vizsgát állít elő, amelyet ezután automatikus mutatókkal és egy független nyelvi modellel (a bíróval) pontozunk. Egy teszt lépései:

1. **Előkészítés.** A keretrendszer betölti a dokumentumot, és a futó szolgáltatásokon keresztül elvégzi a szövegkinyerést és a darabolást – pontosan úgy, ahogyan az éles rendszer.
2. **Generálás.** A kar konfigurációja szerinti csővezeték elkészíti a vizsgát. Minden modellhívásról rögzítjük a szakaszt (tervezés, generálás, ellenőrzés), a tokenszámot és az időt, a GPU-memóriát pedig egy háttérszál mintavételezi.
3. **Automatikus pontozás.** A program kiszámítja a bírót nem igénylő mutatókat (forma, lefedettség, szivárgás, duplikátumok, 4.5. szakasz).
4. **Bírói pontozás.** A bíró minden kérdést két hívásban értékel: egyszer a kulcs ismeretében (alátámasztottság, disztraktorok, rubrikapontok), egyszer vakon (megoldja-e a kérdést a forrás alapján).
5. **Jelentés.** A `report` lépés dokumentumonként, majd karonként összesíti az eredményeket, statisztikai próbákat végez, és elkészíti a dolgozat táblázatait és ábráit.

A reprodukálhatóságot négy mechanizmus biztosítja. (1) Minden futás rögzíti a teljes konfigurációt, a programkód verzióját, az adatkészlet verzióját és a hardvert (GPU típusa, memóriája). (2) A bíró válaszai gyorsítótárba kerülnek, így az újrapontozás determinisztikus. (3) A megszakított futások folytathatók: a már elkészült tesztek nem futnak újra. (4) A teljes folyamatot ál-szolgáltatásokkal és ál-nyelvi modellel futó automatikus tesztek (40 tesztfüggvény) fedik le, így a keretrendszer saját hibái is kiszűrhetők.

4.2. Adatkészlet

A kiértékelő adatkészlet (`eval-v1`) 39 dokumentumból áll, három forrásból (4.1. táblázat). A forrásokat az döntötte el, hogy minden referenciakérdéshez rendelkezésre álljon a forrásszakasz *és* a választ igazoló mondat, mert a keresési mutatók ezt igénylik.

4.1. táblázat. Az `eval-v1` kiértékelő adatkészlet. R/K/H: rövid ($\leq 6\,000$), közepes (6 000–25 000) és hosszú (25 000–90 000 karakteres) dokumentumok száma.

Forrás	Nyelv	Dok.	R/K/H	Medián kar.	Ref. kérdés	Licenc
Saját oktatási szövegek	magyar	3	3/0/0	1 923	12	saját
OpenStax, EduQG [48]	angol	12	4/4/4	16 752	74	CC BY 4.0
Wikipédia, MILQA [141]	magyar	24	8/8/8	8 072	240	CC BY-SA 4.0
Összesen		39	15/12/12	7 919	326	

Saját szövegek. Három rövid magyar oktatási szöveg (a kávé története és feldolgozása; az immunrendszer; a játékelmélet alapjai) könnyű, közepes és nehéz vizsgaszinttel, dokumentumonként négy kézzel írt referenciakérdéssel.

EduQG. Az EduQG [48] OpenStax-tankönyvekhez írt, szakértői feleletválasztós kérdéseket tartalmaz. Tárgyterületenként (élettudományok, társadalomtudományok, jog, közgazdaságtan) egy rövid, egy közepes és egy hosszú, összefüggő tankönyvi részletet választottunk, és csak azokat a kérdéseket tartottuk meg, amelyek igazoló mondata szó szerint szerepel a részletben.

MILQA. A MILQA [141] magyar Wikipédia-cikkekre épülő szövegértési adatbázis. A dokumentumok a cikkek aktuális változatából készültek; referenciakérdésként azokat tartottuk meg, amelyek igazoló mondata a cikkben is megtalálható.

A referenciakérdéseket *nem* használjuk célként, hiszen egy jó vizsgakérdésnek nem kell egy referenciakérdéshez hasonlítania. Arra szolgálnak, hogy igazoló mondataik alapján mérjük a keresés pontosságát, és hogy lássuk, a generált kérdések érintik-e a szakértő által fontosnak tartott tényeket.

4.3. A kísérleti karok (tesztkonfigurációk)

A kísérleti terv *egytényezős*: minden kar egy referenciakarhoz képest pontosan egy tényezőben tér el, így a két kar közötti különbség az adott tényezőnek tulajdonítható. A karok öt csoportba sorolhatók. Minden helyi kar a Qwen2.5-7B-Instruct modellt használja Q4_K_M kvantálással és 0,2-es hőmérséklettel; a szerverkarok az egyetemi GenAI-szerver nagy, szintén Qwen-családba tartozó modelljét. A 4.2. táblázat a karok összefoglalását, a lenti leírás a részleteket adja.

A) Alapvonalak. Ezek a karok azt modellezik, amit egy oktató a MIMIR nélkül tenne, és ezekhez mérjük a módszert.

4.2. táblázat. A kísérleti karok. Ref.: a referenciakar, amelytől a kar egyetlen tényezőben eltér; Magok: dokumentumonkénti ismétlések száma.

Kar	Mit csinál	Ref.	Magok
A) Alapvonalak			
B-doc-L	teljes dokumentum egy promptban, helyi 7B modell (status quo, helyben)	–	3
B-doc-S	teljes dokumentum egy promptban, szervermodell (status quo)	–	3
E0	naiv RAG: 3 darab, a teljes vizsga egy hívásban	–	3
B) A módszer felépítése lépésenként			
E1	vizsgaterv: tervező, slotonkénti keresés, kérdésenként egy hívás	E0	1
E2	E1 + ellenőrző lánc visszacsatolással (a teljes módszer)	E1	1
E3	E2 + fogalomgráf	E2	1
C) Az ellenőrző lánc változatai			
E2f	E2 vak megoldási próba nélkül	E2	1
E2h	E2 hibrid (BM25 + sűrű) kereséssel	E2	1
E2x	E2 más modellcsaládba tartozó ellenőrzővel (Llama-3.1-8B)	E2	1
D) Modellméret			
E4	E0 a szervermodellel	E0	3
E4b	E2 a szervermodellel	E2	1
E) Darabolás			
E5a	E0 a régi, 512 tokenre csonkolt kódolóval	E0	3
E5b	E0 szórásalapú vágási küszöbbel	E0	3
E5c	E0 rögzített, 800 karakteres darabokkal	E0	3

– B-doc-S – *a mai gyakorlat*. A teljes dokumentum (80 000 karakterig) és az éles prompt egyetlen hívásban kerül a nagy szervermodellhez, amely egyszerre adja vissza a tíz kérdést. Ez felel meg annak, amikor az oktató a jegyzetét egy csevegő asszisztensbe tölti fel. *Kérdés:* mennyire jó a status quo, és mennyire tömörülnek a kérdései?

– B-doc-L – *a mai gyakorlat helyben*. Ugyanez a helyi 7B modellel, 16 384 tokenes kontextussal és 30 000 karakterre csonkolt dokumentummal. *Kérdés:* mit ad egy kis modell, ha a feladatot nem bontjuk fel?

– E0 – *naiv RAG*. A dokumentumot darabolja, a kéréshez leghasonlóbb három darabot adja át, és egy hívásban kéri a vizsgát; ez volt a rendszer eredeti működése. *Kérdés:* mit ad a legegyszerűbb visszakereséses megoldás?

B) A módszer felépítése lépésenként. Ezek a karok a MIMIR komponenseit egyenként kapcsolják be, így a hozzájárulásuk külön mérhető.

– E1 – *tervezés*. Vizsgaterv (fogalmak, Bloom-szintek), slotonkénti keresés és kérdésenkénti generálás, ellenőrzés nélkül (csak a duplikátum- és formaszűrés fut). Az E0-hoz képest a különbség a tervezés. *Kérdés:* javítja-e a terv a helyességet és a lefedettséget (1. hipotézis)?

– E2 – *tervezés és ellenőrzés*, a teljes módszer. Az E1-hez képest bekapcsolja a 3.6. táblázat

ellenőrző láncát; az ellenőrzést ugyanaz a Qwen-modell végzi, amely a kérdést írta. *Kérdés:* mennyit ad hozzá az ellenőrzés, és mennyire egyezik az ítélete a bíróéval (2. hipotézis)?

– E3 – *fogalomgráf*. Az E2 kiegészítése a 3.12. szakasz gráfjával (tervezői bemenet, disztraktor-ötletek, bővített kontextus). *Kérdés:* megéri-e a gráfépítés többletköltsége?

C) Az ellenőrző lánc változatai. Ezek a karok az E2 egy-egy elemét változtatják meg.

– E2f – *vak próba nélkül*. Kikapcsolja a vak megoldási ellenőrzést (gyorsabb, olcsóbb). *Kérdés:* szükséges-e a lánc legdrágább eleme?

– E2h – *hibrid keresés*. A sűrű keresést BM25 + sűrű, RRF-fel egyesített keresésre cseréli. *Kérdés:* segít-e a lexikális keresés, különösen a szakkifejezéseknél?

– E2x – *független ellenőrző*. Az ellenőrző hívásokat egy másik modellcsaládba tartozó modell (Llama-3.1-8B) végzi. *Kérdés:* az önellenőrzés vagy általában az ellenőrzés hat-e, és jobb-e egy a generátortól független ellenőrző?

D) Modellméret. Ezek a karok a helyi modellt a nagy szervermodellre cserélik.

– E4 – *naiv RAG a szervermodellel*. *Kérdés:* mennyit ad önmagában a nagyobb modell (4. hipotézis)?

– E4b – *a teljes módszer a szervermodellel*. *Kérdés:* modellfüggetlen-e a módszer, vagyis nagy modellel is javít-e?

E) Darabolás. Ezek a karok az E0 darabolását változtatják meg, a többi beállítás azonos.

– E5a – *régi kódoló*: a 3.6. szakaszban leírt hibás, 512 tokenre csonkolt kódolás. *Kérdés:* mekkora volt a hiba hatása?

– E5b – *szórásalapú küszöb*: a percentilis helyett az átlag $+1{,}5$ szórás a vágási küszöb. *Kérdés:* érzékeny-e az eredmény a küszöbválasztásra?

– E5c – *rögzített darabok*: 800 karakteres, a tartalomtól független ablakok. *Kérdés:* megéri-e egyáltalán a szemantikus darabolás [84]?

A tervezett karok (E1–E3, E4b) dokumentumonként egy véletlenmaggal futnak, mert egy vizsga 2–8 percet igényel, és a variancia elsődleges forrása a dokumentum, nem a mag; az egyhívásos karok három maggal futnak, mert olcsók, és egyetlen futásuk zaja jelentős (5.1. szakasz). A tervben szereplő további kontrollkar (E0s: az E0 az éles végponton keresztül) nem futott le, ezért a dolgozat 14 karral dolgozik. A tervezett páros összehasonlítások: E1–E0 (tervezés, RQ1–2), E2–E1 (ellenőrzés, RQ2), E2x–E2 és E3–E2 (az ellenőrző és a gráf, RQ2), E1–B-doc-L (módszer vs. status quo, RQ1) és E4–E0 (modellméret, RQ3); a többi kar leíró összevetést szolgál.

4.4. A két vizsgálat

A kísérleteket két lépcsőben futtattuk (4.3. táblázat).

Pilot vizsgálat (2026. szeptember 23.). Célja nem a hipotézisek eldöntése volt – egyetlen dokumentumon ez a 4.8. szakasz szerint elvileg sem lehetséges –, hanem (i) a teljes mérési lánc kipróbálása, (ii) a komponensek hatásának és költségének előzetes becslése, és (iii) a fő vizsgálat tervének megalapozása. Egyetlen rövid magyar dokumentumon (`hu-coffee`) futott tíz karral, karonként három ismétléssel.

Fő vizsgálat (2026. szeptember 27–28.). A pilot tapasztalatai alapján javított csővezetékkel futott: bekerültek a szivárgási szabályok és a javító hívás, az újrapróbálkozások száma $r = 1$-re csökkent, a bíró pedig a teljes dokumentum helyett a kérdés saját forrásdarabjait kapta. A tervezett 39 dokumentumból időkorlát miatt karonként hat dokumentum készült el (kilenc különböző dokumentum, 5.2.1. szakasz).

4.3. táblázat. A pilot és a fő vizsgálat beállításai.

	Pilot	Fő vizsgálat
Dokumentumok	1 (magyar, 1 702 karakter)	9 (3 magyar, 6 angol; karonként 6)
Karok	10	14
Ismétlés	3 mag minden karon	3 mag (egyhívásos karok), 1 mag (tervezett karok)
Kérdések	300	1 670
Újrapróbálkozás (r)	2	1
Szivárgási szabály, javító hívás	nincs	van
Bíró forrása	a teljes dokumentum	a kérdés forrásdarabjai (teljes dokumentumos karoknál a dokumentum első 24 000 karaktere)
Helyi GPU	GeForce RTX 3070 Ti (8 GB), asztali PC	RTX A4500 (20 GB), egyetemi munkaállomás

A két vizsgálat csővezetéke tehát eltér, így eredményeik nem közvetlenül összevethetők: a pilot az akkori, a fő vizsgálat a javított implementációt méri. A fő vizsgálat egy 20 GB-os munkaállomás-kártyán futott, hogy a hosszú futás ne foglalja le az asztali gépet; a modell, a kvantálás és a kontextushossz azonos volt, így a minőségi eredményekre ez nincs hatással, a memóriamérés pedig a modell tényleges foglalását méri (5.2.13. szakasz). A futásidők csak azonos hardveren hasonlíthatók össze.

4.5. Mutatók

A mutatók három csoportba sorolhatók: a bírót nem igénylő *automatikus* mutatók, a bíró ítéletein alapuló *tartalmi* mutatók és a *költség*mutatók. Minden ráta 0 és 1 (0 és 100 %) közötti, és – a szivárgás és a duplikátumok kivételével – a nagyobb érték a jobb.

4.5.1. Tartalmi mutatók

Alátámasztottság (G)

Azon kérdések aránya, amelyeknél a bíró szerint a forrás igazolja a megjelölt kulcsot. A bírónak a kulcsot igazoló mondatot szó szerint idéznie kell.

Vak megoldhatóság (A)

Azon kérdések aránya, amelyeket a bíró a kulcs ismerete nélkül, összekevert sorrendű válaszokkal, csak a forrás alapján helyesen old meg. Ez a kulcs helyességének és a kérdés egyértelműségének együttes mércéje: ha a kulcs hibás, vagy két válasz is védhető, a megoldó várhatóan mást választ.

Disztraktor-validitás (V)

A kérdésenkénti azon disztraktorok aránya, amelyek a forrás szerint hamisak *és* témába vágók, a kérdésekre átlagolva.

Formai megfelelés (F)

Vizsgaszintű igen/nem érték: a vizsga pontosan a kért számú kérdést tartalmazza, és minden feleletválasztós kérdésnek pontosan négy válasza és pontosan egy kulcsa van.

Minőségi index. A négy mutatót egyetlen számmá foglaljuk össze:

$$Q = \frac{F + G + A + V}{4}. \tag{4.1}$$

A Q szándékosan egyszerű, súlyozatlan átlag. Következménye, hogy a formai megfelelés súlya egyenlő a tartalmi mutatókéval: egyetlen hibás formájú kérdés egy tízkérdéses vizsgában a Q-t 0,25-tel csökkenti. Ezt tudatosan vállaljuk, mert egy hibás formájú kérdés a gyakorlatban használhatatlanná teszi a vizsgát (a hiányzó vagy kettős kulcs miatt nem javítható), de minden komponenst külön is közlünk.

Rubrika. A bíró emellett négy szempontot 1–5 skálán pontoz, és egy igen/nem ítéletet ad (B. függelék): *helyesség* (1: hibás kulcs vagy két helyes opció, 5: teljesen helyes és egyértelmű), *érthetőség* (1: zavaros, 5: vizsgakész megfogalmazás), *disztraktorok* (1: abszurd vagy szintén helyes, 5: mind hihető és hibás), *szintillesztés* (1: egyértelműen rossz Bloom-szint, 5: illik a kért nehézséghez), valamint *felhasználnám* (bekerülne-e egy valódi dolgozatba legfeljebb apró javítással). A rubrika szó szerint azonos a bíró és az oktatók számára, ami a bíró validálásának (5. hipotézis) előfeltétele.

4.5.2. Automatikus mutatók

Lefedettség. Azt méri, mennyire oszlik el a vizsga a tananyagon (a P2 probléma közvetlen mérőszáma). Minden kérdéshez (a törzs és a kulcs együtt) megkeressük azt a darabot, amelynek

beágyazása hozzá a legközelebb áll, és megszámoljuk, hány különböző darab került így elő:

$$\text{Lef} = \frac{\text{a kérdésekhez legközelebbi különböző darabok száma}}{\text{a dokumentum darabjainak száma}}. \tag{4.2}$$

Egy tízkérdéses vizsga egy négydarabos dokumentumon elvben 100 %-os, egy százdarabos dokumentumon legfeljebb 10 %-os lefedettséget érhet el. A lefedettség szerkezeti, nem minőségi mutató, ezért a Q indexbe nem számít bele.

Válaszszivárgás és nem kérdő törzs. A kérdés *szivárogtatja a kulcsot*, ha a legalább háromszavas kulcs szavainak legalább 80 %-a a törzsben is szerepel; a háromszavas alsó korlát kizárja, hogy egy egyszavas tulajdonnév (például „Arabica”) téves jelzést adjon. A törzs *nem kérdés*, ha sem kérdőjelre, sem kettőspontra nem végződik. Mindkettőt a pilotban feltárt hibamód motiválta (5.1. szakasz).

További mutatók. A *duplikátumráta* azon kérdéspárok aránya, amelyek koszinusz-hasonlósága meghaladja a 0,9-et; a *meta-hivatkozás* aránya azoké, amelyek „a szöveg szerint” jellegű fordulatot tartalmaznak. A *keresési találati arány* (recall@3) azt méri, hogy a referenciakérdésekre futtatott keresés első három találata között szerepel-e az igazoló mondatot tartalmazó darab.

4.5.3. Költségmutatók

Vizsgánként rögzítjük a futási időt (szakaszonként is), a nyelvimodell-hívások számát szakaszonként, a felhasznált tokenek számát, az értelmezhetetlen válaszok számát, a GPU-memória alapszintjét és csúcsát, valamint azt, hogy a modell teljes egészében a GPU-n futott-e.

4.6. A bíró

A bíró a gpt-oss-120b [124] modell az egyetemi GenAI-szerveren, nulla hőmérséklettel (determinisztikus válaszokkal), alacsony gondolkodási szinttel. A választás elsődleges szempontja, hogy más modellcsaládba tartozzon, mint bármelyik generátor (Qwen, Llama), így az önpreferencia torzítása [123] nem lép fel. Kérdésenként két hívást végez:

1. **Áttekintés** (látja a kulcsot): igazolja-e a forrás a kulcsot, egy szó szerinti igazoló mondat idézésével; minden disztraktorra, hogy a forrás szerint hamis-e és témába vágó-e; a négy rubrikapontszám; a kérdés megvalósult Bloom-szintje; és a „felhasználnám”-ítélet, rövid indoklással.
2. **Vak megoldás** (nem látja a kulcsot): a forrás alapján válaszolnia kell a kérdésre, véletlenül permutált opciókkal.

A fő vizsgálatban a bíró forrásként a kérdéshez tartozó darabokat kapja, nem a teljes dokumentumot. Ezt a futási idő indokolja: a bíró egy hívása a megosztott szerveren kb. 14 másodperc, és ez a mérés szűk keresztmetszete. A választás korlátja, hogy a bíró a dokumentum más részeiben lévő ellentmondást nem láthatja. A teljes dokumentumos karoknál, ahol a kérdésekhez

nem tartozik forrásdarab, a bíró a dokumentum elejét kapja, legfeljebb 24 000 karaktert; ennek következményét az 5.2.9. szakasz tárgyalja.

4.7. Oktatói értékelés

A bíró csak akkor tekinthető érvényes mérőeszköznek, ha ítéletei az emberi szakértőkével egyeznek (5. hipotézis). Ennek ellenőrzésére a következő protokollt dolgoztuk ki: három oktató vakon értékel egy rétegzett mintát a négy fő karból (B-doc-S, E0, E1, E2), karonként 15 kérdést, azaz oktatónként 60 kérdést, valamint 10 közös kalibrációs kérdést. A lapok nem tartalmazzák a kar nevét, a kérdések sorrendje véletlen, a rubrika azonos a bíróéval. Az oktatók egymás közötti egyezését Krippendorff-α-val, a bíró és az oktatók egyezését szempontonként Spearman-féle rangkorrelációval és Krippendorff-α-val, a bináris ítéletekre Cohen-κ-val mérjük. Az értékelőlapok exportálását és visszaolvasását a keretrendszer automatizálja; a dolgozat lezárásáig az oktatói értékelés nem készült el, így ez a mérés a további munka része (7. fejezet).

4.8. Statisztikai elemzés

Az elemzés egysége a dokumentum. Egy vizsga tíz kérdése nem független egymástól: ugyanabból a dokumentumból, ugyanazon a futáson belül készül. Ha a kérdéseket független megfigyelésnek tekintenénk, a próbák a valósnál sokkal biztosabbnak mutatnák az eredményt. Ezért minden mutatót először dokumentumon belül átlagolunk (a kérdésekre és a magokra), és a statisztikai következtetés egysége a *dokumentum*. A karonkénti értékek a dokumentumonkénti átlagok átlagai.

Konfidenciaintervallum. A karonkénti átlag bizonytalanságát *bootstrap* módszerrel [145] becsüljük: a dokumentumokból 10 000-szer húzunk visszatevéssel ugyanannyi dokumentumot, mindegyik mintán kiszámoljuk az átlagot, és a kapott átlagok középső 95 %-a adja a 95 %-os konfidenciaintervallumot. Szűk intervallum azt jelenti, hogy a kar a dokumentumok között egyenletesen teljesít.

Páros összehasonlítás. Két kar összevetésére a páros Wilcoxon-féle előjeles rangpróbát [146] használjuk. A próba minden dokumentumra kiszámítja a két kar különbségét, a különbségeket abszolút értékük szerint rangsorolja, és azt vizsgálja, hogy a pozitív és a negatív különbségek rangösszege egyensúlyban van-e. Nem feltételez normális eloszlást, ami a 0 és 1 közé szorított, gyakran a plafonhoz közeli rátáknál lényeges. A hatás nagyságát a rangbiszeriális korrelációval [147] adjuk meg:

$$r_{rb} = \frac{W^+ - W^-}{W^+ + W^-}, \tag{4.3}$$

ahol W^+ a pozitív, W^- a negatív különbségek rangösszege. Értéke -1 és $+1$ közé esik: $+1$, ha az új kar minden dokumentumon jobb, -1, ha minden dokumentumon rosszabb, 0, ha kiegyenlített.

A minimális mintaméret. Ha egy összevetésben csak D dokumentum van, a Wilcoxon-próba legkisebb elérhető (kétoldali) p-értéke $2 \cdot 2^{-D}$, és ezt akkor kapjuk, ha minden különbség azonos előjelű. Öt dokumentumnál ez 0,0625, hatnál 0,031. Hat dokumentumnál kevesebből tehát $p < 0{,}05$ *elvileg sem* érhető el, ezért az egyetlen dokumentumos pilot eredményei kizárólag leíró jellegűek, a fő vizsgálat hat dokumentuma pedig éppen a legkisebb olyan szám, amelyen egy összevetés egyáltalán szignifikáns lehet.

Többszörös összehasonlítás. Ha sok összevetést végzünk, a véletlen „szignifikáns" eredmények esélye nő. Ezt Holm módszerével [132] kezeljük: a p-értékeket növekvő sorrendbe rakjuk, a legkisebbet az összevetések számával (M), a másodikat $M-1$-gyel stb. szorozzuk, és egy összevetést csak akkor tekintünk szignifikánsnak, ha a korrigált értéke (és minden nála kisebbé) 0,05 alatt van. Hat összevetésnél például a legkisebb, 0,031-es p-érték korrigált értéke $6 \cdot 0{,}031 = 0{,}19$.

Egyezési mutatók. Két értékelő (vagy az ellenőrző és a bíró) igen/nem ítéleteinek egyezését Cohen-κ-val [126] mérjük:

$$\kappa = \frac{p_o - p_e}{1 - p_e}, \tag{4.4}$$

ahol p_o a megfigyelt egyezési arány, p_e pedig a véletlenül várható egyezés (amely a két értékelő „igen" és „nem" arányaiból számolható). $\kappa = 0$ azt jelenti, hogy az egyezés nem jobb a véletlennél, $\kappa = 1$ a teljes egyezést. Az értelmezés Landis és Koch [128] skáláját követi (2.11. szakasz).

Az ellenőrző mint osztályozó. Az ellenőrző lánc minden kérdést *átengedett* vagy *megjelölt* kategóriába sorol, vagyis bináris osztályozó. A bíró alátámasztottsági ítéletét referenciának tekintve két mutatóval jellemezzük:

$$\text{pontosság} = \frac{\text{átengedett és alátámasztott}}{\text{átengedett}}, \qquad \text{felidézés} = \frac{\text{átengedett és alátámasztott}}{\text{alátámasztott}}. \tag{4.5}$$

A pontosság azt mondja meg, mennyire bízhatunk egy átengedett kérdésben; a felidézés azt, hogy a jó kérdések közül mennyit enged át az ellenőrző. Egy hasznos ellenőrzőtől mindkettő magas értéke és $\kappa \gg 0$ várható; $\kappa \approx 0$ azt jelenti, hogy a jelzése az oktató számára nem hordoz információt.

5. Eredmények

Ebben a fejezetben a két vizsgálat (4.4. szakasz) eredményeit közöljük. A pilot eredményeit röviden, a fő vizsgálat tervét meghatározó tanulságokra összpontosítva mutatjuk be (5.1. szakasz); a fejezet nagyobb része a fő vizsgálattal foglalkozik (5.2. szakasz). Minden közölt szám a nyers adatokból, a keretrendszer `report` lépésével vagy a nyers kimenetek közvetlen feldolgozásával készült (pilot: `tests/eval/results_pilot`, fő vizsgálat: `tests/eval/results`); a megfeleltetést a C. függelék adja meg. Az eredmények értelmezését és a hipotézisek értékelését a 6. fejezet tartalmazza.

5.1. A pilot vizsgálat

A pilot a `hu-coffee` dokumentumon futott: egy 1 702 karakteres magyar oktatási szöveg a kávé eredetéről, fajtáiról, termesztéséről és feldolgozásáról, könnyű vizsgaszinttel. A szemantikus darabolás négy darabot adott. Minden kar három vizsgát generált, vizsgánként tíz feleletválasztós kérdéssel, így karonként 30, összesen 300 kérdés készült. Az 5.1. táblázat a karonkénti fő mutatókat mutatja.

5.1. táblázat. A pilot fő eredményei: egy magyar dokumentum, 3 mag, karonként 30 kérdés. Ráták %-ban. Q: minőségi index; Form.: formai megfelelés; Alát.: alátámasztottság; Vak: vak megoldhatóság; Diszt.: disztraktor-validitás; Lef.: lefedettség; Sziv.: kulcs a törzsben; Hívás: átlagos modellhívás vizsgánként; Perc: medián futási idő vizsgánként (RTX 3070 Ti).

Kar	Q	Form.	Alát.	Vak	Diszt.	Lef.	Sziv.	Hívás	Perc
E0	0,83	100	67	85	80	50	0	1	0,3
E1	0,88	100	73	93	87	58	0	23	3,0
E2	0,76	67	73	77	89	58	3	75	6,2
E2f	0,73	67	53	82	90	58	7	59	5,3
E2h	0,76	67	67	79	93	67	10	76	6,7
E3	0,85	67	87	100	87	50	20	101	8,0
E4	**0,99**	100	100	100	97	**25**	0	1	6,6
E5a	0,90	100	80	86	93	50	0	1	0,3
E5b	0,90	100	80	90	91	56	0	1	0,3
E5c	0,81	100	60	79	83	67	0	1	0,3

A pilot egyetlen dokumentuma miatt az eredmények kizárólag leíró jellegűek. Öt megfigyelés határozta meg a fő vizsgálat tervét.

1. A tervezés kis mértékben javított. A vizsgaterv (E1) a naiv alapvonalhoz képest azonos formai megfelelés mellett minden tartalmi mutatón jobb volt (alátámasztottság $+6$, vak megoldhatóság $+8$, disztraktor-validitás $+7$, lefedettség $+8$ százalékpont), 23-szoros hívásszámért és 9-szeres futási időért. A különbség ($+0{,}05$) azonban a futásról futásra jelentkező zaj nagyság-

rendjébe esik (5. pont). Egy négydarabos szövegen a naiv RAG a három visszakeresett darabbal a dokumentum nagy részét látja, így ez a tervezés számára a legkedvezőtlenebb helyzet.

2. A formai hiba és a tartalékkérdés. Az ellenőrző karok mindegyikében a három vizsgából egyben előfordult, hogy egy slot minden kísérlete elbukott, és a megtartott végső kérdésnek csak két vagy három válaszlehetősége volt. Ez a vizsga formai megfelelését nullára, a minőségi indexét 0,25-tel csökkentette; az ellenőrző karok alacsony Q értéke nagyrészt ebből ered. A hiba nem a módszer elvi korlátja, hanem implementációs hiányosság volt: a végső kérdés kiválasztása csak a hibák számát nézte, a formát nem. A javítás a 3.11. szakaszban leírt kiválasztási sorrend és a javító hívás.

3. Az önellenőrzés a bíróval véletlenszerűen egyezett. A formai hibától függetlenül az ellenőrzés a tartalmi mutatókon sem javított. Ha az ellenőrzőt osztályozóként értékeljük (5.2. táblázat), az általa *átengedett* kérdéseket a bíró *ritkábban* (66 %) ítélte alátámasztottnak, mint a *megjelölteket* (75 %), és a κ együttható minden karon $-0{,}14$ és $0{,}07$ között volt, vagyis az ellenőrző ítélete a véletlen szintjén egyezett a bíróéval. Ez összhangban van azzal, hogy külső visszajelzés nélkül a modellek önjavítása nem javít [10].

5.2. táblázat. A 7B ellenőrző mint osztályozó a pilotban, a bíró alátámasztottsági ítéletéhez képest. Átengedett: az ellenőrzésen átjutott kérdések aránya (%).

Kar	n	Átengedett	Pontosság	Felidézés	κ
E2	30	57	0,71	0,55	−0,07
E2f	30	67	0,50	0,62	−0,09
E2h	30	60	0,61	0,55	−0,14
E3	30	40	0,92	0,42	0,07

4. Válaszszivárgás: egy új hibamód. A kérdések kézi átolvasása olyan hibát tárt fel, amelyet sem az automatikus mutatók, sem a bíró nem büntetett: egyes ellenőrzött kérdések egy forrásmondatot másolnak a törzsbe, és ugyanazt a mondatot ismétlik meg kulcsként, a disztraktorok pedig ugyanennek a mondatnak egy-egy szóban eltérő változatai. Az E3 egyik „kérdése” például a forrás mondata volt: „A kávéfogyasztás szokása Etiópiából hamar átterjedt a szomszédos Jemenbe, majd az arab világba, Európába pedig a 17. században jutott el a velencei kereskedők révén.” A kulcs ugyanez a mondat volt, a disztraktorok pedig ugyanez a 16., 18., illetve 15. századdal. Ugyanebben a vizsgálatban a naiv alapvonal egyik kérdésének kulcsa (9. század) egyszerűen hibás volt: a forrás szerint a kávé a 17. században jutott el Velencébe, a 9. század az etióp legenda ideje. A szivárgás kizárólag az ellenőrző karokban fordult elő, és ott volt a legerősebb, ahol a legtöbb újrapróbálkozás történt: az E3 kar kérdéseinek 20 %-a szivárgott, és 47 %-uk törzse nem is kérdés volt. A bíró a szivárgó kérdések többségének 5-ös helyességi pontot adott, ami érthető: a kulcs valóban alátámasztott (szó szerint a forrásból származik), és a kérdés vakon is megoldható (a válasz a kérdésben van). A szivárgás tehát *egyszerre* torzította felfelé az alátámasztottságot, a vak megoldhatóságot és a bírói pontszámot – ez magyarázza,

hogy a pilotban éppen az E3 kar érte el a legmagasabb helyi alátámasztottságot (87 %) és vak megoldhatóságot (100 %). Értelmezésünk szerint az ellenőrző visszacsatolási hurka a kis modellt a forrásszöveg szó szerinti átvétele felé tolta, mert ez a legolcsóbb módja annak, hogy egy alátámasztottsági ellenőrzésen átjusson – a Goodhart-törvény [99] tankönyvi példája. A fő vizsgálatban ezért a szivárgást és a nem kérdő törzset az ellenőrző lánc szabályként elutasítja, és mindkettőt mutatóként is mérjük.

5. A futásról futásra jelentkező zaj. Az E0 és az E5a kar a pilotban azonos darabokat, azonos visszakeresett kontextust és azonos magokat kapott (512 tokennél rövidebb szövegen a régi és az új kódoló ugyanazt adja), mégis 0,83, illetve 0,90 minőségi indexet ért el. Ez egy természetes kontrollkísérlet: a teljes mérési láncot változatlanul hagyva, csak az ismétlés miatt 0,07-es eltérés adódott. Az ok az, hogy a GPU-n végzett következtetés alacsony hőmérsékleten és rögzített maggal sem bitre reprodukálható. Egyetlen dokumentumon tehát a 0,07-nél kisebb különbségek zajnak tekintendők; a pilot szinte minden helyi karpárjának különbsége ebbe a sávba esik. A zaj csökkentésének hatékony módja nem a magok, hanem a dokumentumok számának növelése, ezért a fő vizsgálat több dokumentumon, dokumentumszintű statisztikával fut.

Erőforrásigény. A pilot a helyi karokat egy asztali PC 8 GB-os kártyáján (RTX 3070 Ti) futtatta, 16 384 tokenes kontextussal. Az asztali környezet a kártyából 1 612–1 931 MiB-ot foglalt, a generálás alatti csúcs 7 022–7 808 MiB volt, vagyis a modell és a futtatókörnyezet 5 400–5 950 MiB-ot foglalt. Ez a (3.1) becslés alapján várt $4{,}7\,\mathrm{GB} + 0{,}9\,\mathrm{GiB} + M_0$ értékkel összhangban van, és a legrosszabb esetben is ≈380 MiB tartalékot hagyott.

A korábbi mérések hibái. A keretrendszer építése és a pilot összesen három olyan hibát tárt fel, amely a mérést felfelé torzította volna. (1) Ha minden modellhívás sikertelen volt, a háttérrendszer egy beégetett, egykérdéses *tartalékvizsgát* adott vissza hibaüzenet helyett; egy korábbi tesztfutás így három „sikeresen generált” vizsgát jelentett, holott mindhárom ez a tartalék volt. (2) A *csonkolt kódoló* (3.6. szakasz) a hosszabb dokumentumok nagy részét a tartalomtól függetlenül darabolta. (3) A *válaszszivárgás* a tartalmi mutatókat és a bírót is félrevezette. Mindhárom hibát javítottuk, illetve külön mérjük (E5a, szivárgási mutatók).

5.2. A fő vizsgálat

5.2.1. Beállítások és dokumentumok

A fő vizsgálat 2026. szeptember 27–28-án futott a javított csővezetékkel (4.3. táblázat), 14 karral. A helyi karok egy egyetemi munkaállomás NVIDIA RTX A4500 kártyáján (20 GB) futottak, a szerverkarok és a bíró az egyetemi GenAI-szerveren. A futás időkorlát miatt nem a teljes, 39 dokumentumos adatkészleten, hanem karonként hat, összesen kilenc dokumentumon készült el (5.3. táblázat). Tizenkét kar – a helyi karok és a B-doc-S – ugyanazon a hat dokumentumon futott: a három saját, rövid magyar szövegen és az OpenStax-gyűjtemény egy rövid, egy közepes és egy hosszú angol szövegén. A két szerveres RAG-kar (E4, E4b) a szerverkarok rögzített

dokumentumlistájának első hat elemét kapta; ezek mind angol szövegek, és közülük csak három közös a többi karéval. A MILQA-ból származó magyar Wikipédia-cikkek egyike sem került sorra.

Ennek két következménye van: (i) az E4 és az E4b átlaga a többi karéval nem közvetlenül, csak a közös három dokumentumon vethető össze; (ii) a „magyar" részhalmaz három rövid saját szöveg, így a nyelv hatása a forrás és a hossz hatásával keveredik. Az egyhívásos karok dokumentumonként három maggal (18 vizsga, 180 kérdés), a tervezett karok egy maggal (6 vizsga, 60 kérdés) futottak; az E5c kar egy vizsgája sikertelen volt. Összesen 1 670 kérdés készült, mindegyiket a bíró értékelte.

5.3. táblázat. A fő vizsgálatban kiértékelt dokumentumok. Ref.: referenciakérdések száma; Darab: a szemantikus darabolás által előállított darabok száma.

Dokumentum	Nyelv, forrás	Karakter	Darab	Ref.	Karok
`hu-coffee`	magyar, saját	1 696	4	4	mind, kivéve E4, E4b
`hu-immune`	magyar, saját	1 923	4	4	mind, kivéve E4, E4b
`hu-gametheory`	magyar, saját	2 295	5	4	mind, kivéve E4, E4b
`en-economics-short-01`	angol, OpenStax	6 000	13	6	mind
`en-humanities-medium-02`	angol, OpenStax	24 937	–	6	mind
`en-law-long-03`	angol, OpenStax	68 063	100	7	mind
`en-lifesciences-short-04`	angol, OpenStax	5 843	–	4	csak E4, E4b
`en-economics-medium-05`	angol, OpenStax	16 661	–	8	csak E4, E4b
`en-humanities-long-06`	angol, OpenStax	61 045	–	10	csak E4, E4b

5.2.2. Összesített eredmények

Az 5.4. táblázat a karonkénti mutatókat mutatja. A rangsor csak az első tizenkét karra értelmezhető közvetlenül, mert az E4 és az E4b más dokumentumokon futott; a kiértékelő keretrendszer automatikus jelentése ennek ellenére az E4b-t emelte ki „győztesként", ami jól mutatja, hogy egy automatikus rangsor csak azonos dokumentumokon futott karok között értelmes.

Négy megfigyelés emelhető ki. *Először*, a közös hat dokumentumon a legjobb kar a helyi 7B modellel futó, tervezett és ellenőrzött csővezeték (E2, $Q = 0{,}96$), a legszűkebb konfidenciaintervallumok egyikével (0,93–0,98). *Másodszor*, a pilottal ellentétben a naiv alapvonal (E0, 0,64) a leggyengébb kar. *Harmadszor*, a pilotban megfigyelt formai hiba eltűnt: minden tervezett kar formai megfelelése 100 %, vagyis a javított tartalékkérdés és a javító hívás működik; formai hibát csak a teljes dokumentumos helyi alapvonal (B-doc-L, 83 %) mutatott, amelynél a kis modell egy hívásban nem mindig tartotta be a tíz kérdést és a négy opciót. *Negyedszer*, a tervezett karok lefedettsége (40–45 %) a teljes dokumentumos alapvonalakéval (45–47 %) azonos szinten van, a naiv RAG-é viszont lényegesen alacsonyabb (E0: 25 %, E4: 9 %).

5.4. táblázat. A fő vizsgálat eredményei. Q: minőségi index (a dokumentumonkénti átlagok átlaga) 95 %-os bootstrap-konfidenciaintervallummal; a ráták %-ban. Nell.: nem ellenőrzött kérdések száma vizsgánként; Hívás: átlagos modellhívás vizsgánként; Perc: medián futási idő vizsgánként (helyi karok: RTX A4500). A többi rövidítés az 5.1. táblázatéval azonos. Az első tizenkét kar ugyanazon a hat dokumentumon futott; az E4 és az E4b hat angol dokumentumon, amelyek közül három közös a többiekével.

Kar	Q	95 % CI	Form.	Alát.	Vak	Diszt.	Lef.	Sziv.	Nell.	Hívás	Perc
B-doc-L	0,83	0,76–0,90	83	79	86	85	45	1	–	1	0,4
B-doc-S	0,95	0,87–0,99	100	90	100	89	47	0	–	1	4,0
E0	0,64	0,46–0,81	100	43	62	52	25	0	–	1	0,3
E1	0,88	0,82–0,94	100	80	80	91	45	8	1,2	17	1,9
E2	**0,96**	0,93–0,98	100	90	97	96	44	3	4,8	51	3,5
E3	0,88	0,79–0,95	100	83	87	83	40	0	4,8	56	5,5
E2f	0,90	0,84–0,95	100	78	88	92	44	3	3,7	38	2,8
E2h	0,92	0,90–0,94	100	82	92	94	42	2	5,2	53	3,7
E2x[†]	0,89	0,83–0,95	100	78	83	95	42	2	2,5	19	7,6
E5a	0,87	0,81–0,92	100	74	84	90	36	2	–	1	0,3
E5b	0,70	0,54–0,85	100	39	78	63	35	1	–	1	0,3
E5c	0,86	0,70–0,97	100	82	82	81	51	2	–	1	0,3
Hat angol dokumentumon:											
E4	0,91	0,80–0,98	100	77	98	87	9	0	–	1	5,3
E4b	0,99	0,97–1,00	100	98	100	98	28	0	0,0	37	47,7

[†] Az E2x karban a Llama-ellenőrző hívásai hibával tértek vissza, így a kar ténylegesen csak a szabályalapú ellenőrzéseket futtatta (5.2.4. szakasz).

5.2.3. Dokumentumonkénti bontás

Az átlagok mögött a dokumentumok között nagy eltérések húzódnak meg. Az 5.5. táblázat a minőségi indexet dokumentumonként mutatja; ez a bontás magyarázza a fejezet legtöbb későbbi megállapítását.

A táblázatból három mintázat olvasható ki. (1) Az E2 az egyetlen kar, amely *mind a hat* dokumentumon legalább 0,89-et ért el; a legrosszabb dokumentuma jobb, mint a legtöbb kar átlaga. Az oktató szempontjából ez a legfontosabb tulajdonság: nem az átlag, hanem az számít, hogy egy új dokumentumon mekkora a kudarc esélye. (2) A két szemantikus darabolású naiv kar (E0, E5b) a magyar szövegeken jó (0,83–0,93), az angol szövegeken viszont mindhárom dokumentumon összeomlik (0,33–0,60); ennek okát az 5.2.8. szakasz elemzi. (3) A teljes dokumentumot kapó karok a leghosszabb, 68 063 karakteres jogi dokumentumon a leggyengébbek (B-doc-L: 0,71, B-doc-S: 0,76), miközben a tervezett karok ott is 0,87–0,98 között teljesítenek. A rövid szövegek egyes kiugróan gyenge értékei (E3: játékelmélet 0,68; E5c: immunrendszer 0,50) egyetlen dokumentumhoz kötődnek, és az adott vizsgák több rossz disztraktorából erednek; az E5c például a rögzített darabolással az immunrendszer-szöveget három darabra vágta, és a vizsgák disztraktorainak csak 16–26 %-a volt érvényes.

5.5. táblázat. Minőségi index dokumentumonként (fő vizsgálat; az egyhívásos karoknál a három mag átlaga). Min.: a kar leggyengébb dokumentuma. Félkövér: 0,70 alatti érték.

	Magyar (saját, rövid)			Angol (OpenStax)				
Kar	kávé	immun	játékelm.	közg. (R)	bölcs. (K)	jog (H)	Átlag	Min.
B-doc-L	0,96	0,87	0,85	0,86	0,75	0,71	0,83	0,71
B-doc-S	0,98	1,00	1,00	0,96	0,99	0,76	0,95	0,76
E0	0,89	0,88	0,89	**0,33**	**0,44**	**0,42**	0,64	0,33
E1	0,76	0,96	0,83	0,83	0,99	0,89	0,88	0,76
E2	0,96	0,97	0,97	0,95	1,00	0,89	**0,96**	**0,89**
E3	0,93	0,92	**0,68**	0,93	0,86	0,98	0,88	0,68
E2f	0,81	0,97	0,81	0,96	0,96	0,88	0,90	0,81
E2h	0,92	0,92	0,89	0,88	0,96	0,94	0,92	0,88
E2x	0,77	0,98	0,87	0,90	0,97	0,87	0,89	0,77
E5a	0,90	0,91	0,78	0,89	0,97	0,76	0,87	0,76
E5b	0,93	0,91	0,83	**0,48**	**0,45**	**0,60**	0,70	0,45
E5c	0,80	**0,50**	1,00	0,94	0,96	0,97	0,86	0,50

5.2.4. A tervezés és az ellenőrzés hatása

A komponensek lépésenkénti hozzájárulása ugyanazon a hat dokumentumon: tervezés $+0{,}24$ (E0→E1), ellenőrzés $+0{,}08$ (E1→E2), fogalomgráf $-0{,}07$ (E2→E3). Az 5.6. táblázat a tervezett páros összehasonlításokat mutatja.

5.6. táblázat. Páros Wilcoxon-próbák a dokumentumonkénti minőségi indexen (fő vizsgálat). n: a közös dokumentumok száma; r_{rb}: rangbiszeriális hatásméret ($r_{rb} > 0$: az új kar jobb); $\tilde{p}$: a hat összevetésre Holm-korrigált p-érték.

Összevetés	n	Ref. Q	Új Q	Δ	r_{rb}	p	$\tilde{p}$
E1 – B-doc-L	6	0,83	0,88	$+0{,}04$	0,24	0,688	0,875
E1 – E0	6	0,64	0,88	$+0{,}24$	0,62	0,219	0,875
E2 – E1	6	0,88	0,96	$+0{,}08$	1,00	0,031	0,188
E2x – E2	6	0,96	0,89	$-0{,}06$	$-0{,}90$	0,062	0,312
E3 – E2	6	0,96	0,88	$-0{,}07$	$-0{,}62$	0,219	0,875
E4 – E0	3	0,40	0,93	$+0{,}54$	1,00	0,250	0,875

Tervezés (E1 – E0). A vizsgaterv a naiv alapvonalhoz képest 0,64-ről 0,88-ra emelte a minőségi indexet, az alátámasztottságot 43-ról 80 %-ra, a vak megoldhatóságot 62-ről 80 %-ra, a disztraktor-validitást 52-ről 91 %-ra, a lefedettséget 25-ről 45 %-ra, változatlan (100 %-os) formai megfelelés mellett. A hatás nagy ($r_{rb} = 0{,}62$), de nem egyirányú: a három angol dokumentumon a javulás $0{,}40 \rightarrow 0{,}91$, a három rövid magyar szövegen viszont $0{,}88 \rightarrow 0{,}85$, azaz ott a tervezés nem javított (5.5. táblázat). Ez összhangban van a pilottal: egy négydarabos szövegen a naiv alapvonal a dokumentum nagy részét látja, így a tervezésnek kevés hozzáadnivalója marad. A különbség a Holm-korrekció után nem szignifikáns ($\tilde{p} = 0{,}875$). A tervezés ára 17 hívás és 1,9

perc vizsgánként (a naiv alapvonalnál 1 hívás és 20 másodperc).

Ellenőrzés (E2 – E1). A pilottal ellentétben az ellenőrző lánc a fő vizsgálatban javított: 0,88-ról 0,96-ra emelte a minőségi indexet, az alátámasztottságot 80-ról 90 %-ra, a vak megoldhatóságot 80-ról 97 %-ra, a disztraktor-validitást 91-ről 96 %-ra. A javulás mind a hat dokumentumon azonos irányú ($r_{rb} = 1{,}00$), a korrigálatlan $p = 0{,}031$ éppen a hat dokumentumnál elérhető minimum; a Holm-korrekció után $\tilde{p} = 0{,}188$, így a különbség formálisan nem szignifikáns, iránya azonban a vizsgált dokumentumokon egyértelmű. A javulás mindkét nyelven megjelent (magyar: 0,85 → 0,96, angol: 0,91 → 0,95), és a legnagyobb ott volt, ahol az E1 a leggyengébb (kávé: 0,76 → 0,96). Az ellenőrzés ára a háromszoros hívásszám (17 helyett 51) és 1,8-szoros futási idő (1,9 helyett 3,5 perc).

Szabályalapú és modellalapú ellenőrzés (E2x). Az E2x kar célja az volt, hogy a Qwen-generátort egy más modellcsaládba tartozó modell (Llama-3.1-8B) ellenőrizze. A nyers adatok utólagos elemzése szerint azonban a Llama-ellenőrző hívásai a futtató gépen hibával tértek vissza (vizsgánként 8–20 hiba), és a csővezeték – a tervezett hibakezelés szerint – ilyenkor nem blokkolja a kérdést, hanem a modellalapú ellenőrzést kihagyja. A karban így egyetlen alátámasztottsági vagy vak megoldási hívás sem futott (88 kihagyott ellenőrzés); a kérdéseket kizárólag a szabályalapú ellenőrzések (forma, meta-hivatkozás, szivárgás, kérdésforma, hivatkozás, duplikátum) szűrték. A sikertelen hívások a futási időt is megnövelték (7,6 perc, miközben a tényleges modellidő vizsgánként 1,2–2,4 perc volt). Az eredeti kérdés – jobb-e egy független ellenőrző – ezért ebből a futásból nem válaszolható meg. A kar ugyanakkor egy véletlen, de hasznos bontást ad: az E1 (csak duplikátumszűrés, 0,88), az E2x (szabályok, 0,89) és az E2 (szabályok és modellalapú ítéletek, 0,96) sorozata szerint az ellenőrzés hasznának nagyobb része a *modellalapú* ítéletekből ered (+0,06–0,07, öt dokumentumon azonos irányban, $r_{rb} = -0{,}90$), a szabályok önmagukban alig javítanak a minőségi indexen. A szabályok szerepe inkább védelmi: a szivárgó kérdések aránya az E1 8 %-áról az E2x 2 %-ára csökkent (5.2.7. szakasz).

A lánc további elemei. A vak megoldási próba nélküli változat (E2f) 0,90-et ért el, alátámasztottsága (78 %) és vak megoldhatósága (88 %) is elmarad az E2-étől: a vak próba tehát a lánc hasznos eleme, 38 helyett 51 hívásért. A hibrid keresés (E2h, 0,92) átlagosan nem javított a sűrű keresésen, de egyenletesebb volt (konfidenciaintervalluma a legszűkebb, 0,90–0,94), és az egyetlen hosszú dokumentumon (jog) az E2-nél jobb eredményt adott (0,94 vs. 0,89) – ez összhangban van azzal, hogy a lexikális keresés a hosszú, szakkifejezésekben gazdag szövegeken segíthet [78]. A fogalomgráf (E3) az E2-höz képest rontott (0,96 → 0,88, $r_{rb} = -0{,}62$), elsősorban a disztraktorokon (96 helyett 83 %), több hívásért (56) és hosszabb futási időért (5,5 perc). A pilotban az E3 kiugró alátámasztottságát a szivárgás okozta; a szivárgási szabályokkal ez az előny eltűnt. Feltételezésünk szerint a kis modell által kinyert gráf „testvérfogalmai” nem mindig valódi alternatívák, így a belőlük képzett disztraktorok egy része a forrás szerint szintén igaz vagy nem egyértelműen hamis.

5.2.5. Mi történik az ellenőrző láncban?

Az ellenőrzés hatásának megértéséhez a slotok naplóiból összesítettük, hogy az egyes kísérletek miért buktak el (5.7. táblázat).

5.7. táblázat. Az ellenőrző lánc működése a fő vizsgálatban (karonként 60 slot). Első kísérlet: az első próbálkozásra elfogadott slotok aránya; Kísérlet/slot: a generálási kísérletek átlagos száma; Átengedett: az ellenőrzöttként elfogadott kérdések aránya; a további oszlopok az egyes elutasítási okok előfordulásai az összes kísérletben (egy kísérlet több okból is elbukhat).

	Összesítés			Elutasítási okok (darab)					
Kar	Első kísérlet	Kísérlet/ slot	Átengedett	Diszt. igaz lehet	Vak eltérés	Szivárgás	Nem kérdés	Duplikátum	Egyéb
E1	62 %	1,6	88 %	–	–	–	–	43	6
E2	23 %	2,2	52 %	41	9	14	18	57	4
E2f	38 %	2,1	63 %	35	–	11	12	45	10
E2h	20 %	2,3	48 %	35	19	12	19	50	6
E2x	50 %	1,8	75 %	–	–	10	9	50	8
E3	27 %	2,1	52 %	29	21	8	9	45	16
E4b	83 %	1,3	100 %	1	–	3	1	10	3

A táblázat négy dolgot mutat meg. *Először*, a leggyakoribb elutasítási ok minden helyi karon a *duplikátum*: a rövid magyar szövegekből a kis modell nehezen ír tíz, egymástól eltérő kérdést, és gyakran ugyanazt a tényt kérdezi meg más szavakkal. *Másodszor*, a modellalapú ellenőrzés a helyi 7B modellel szinte kizárólag a *disztraktorokon* keresztül hat: az alátámasztottsági hívás a fő vizsgálatban egyetlen esetben sem jelezte, hogy a kulcs nem igazolt, vagy hogy a kérdés kétértelmű, viszont 41 esetben jelezte, hogy egy disztraktor igaz lehet. A kis modell tehát a „ez a helyes válasz” ítéletben megerősítésre hajlik, a „ez biztosan hamis” ítéletben viszont óvatosabb – és éppen ez a jelzés javítja a disztraktorokat (91 %→96 %). *Harmadszor*, a vak próba (9–21 eltérés) a második legfontosabb modellalapú jelzés, és elhagyása (E2f) mérhetően rontott. *Negyedszer*, a nagy szervermodell (E4b) kérdéseinek 83 %-a elsőre átment, és minden kérdése végül ellenőrzött lett; a helyi modellnél ez az arány 23 %, illetve 52 %, vagyis a kis modell a minőséget sok újrapróbálkozással „vásárolja meg”.

5.2.6. Az ellenőrző mint osztályozó

Az 5.8. táblázat a pilotbeli elemzést (5.2. táblázat) ismétli meg a fő vizsgálat adatain. Az ellenőrző karok (E2, E2x, E2f, E2h, E3, E4b) 360 kérdéséből 234-et engedett át az ellenőrző, 126-ot jelölt meg.

A pilothoz képest az irány megfordult: az átengedett kérdéseket a bíró gyakrabban ítélte alátámasztottnak (89 %), mint a megjelölteket (77 %), vakon is gyakrabban oldotta meg helyesen (93 vs. 87 %), és a „felhasználnám” arány is magasabb (85 vs. 68 %). Az E4b kar 60, mind átengedett kérdése nélkül az átengedett helyi kérdések 86 %-a alátámasztott (174-ből 150), a különbség tehát nem a szervermodell kérdéseiből ered. A helyi ellenőrzők κ együtthatója 0,02 és

5.8. táblázat. Az ellenőrző pontossága, felidézése és Cohen-κ együtthatója a bíró alátámasztottsági ítéletéhez képest, karonként (fő vizsgálat). † Csak szabályalapú ellenőrzés.

Kar	*n*	Átengedett (%)	Pontosság	Felidézés	κ
E2	60	52	0,94	0,54	0,08
E2x†	60	75	0,82	0,79	0,16
E2f	60	63	0,79	0,64	0,02
E2h	60	48	0,93	0,55	0,22
E3	60	52	0,87	0,54	0,08
E4b	60	100	0,98	1,00	0,00

0,22 közé esik, ami Landis és Koch skáláján [128] csekély vagy gyenge egyezés. Az ellenőrző *pontossága* magas (0,79–0,94: amit átenged, az többnyire jó), a *felidézése* alacsony (0,54–0,64: a jó kérdések közel felét is megjelöli). Az oktató szemszögéből ez azt jelenti, hogy a megjelölt kérdések háromnegyede valójában rendben van; a jelzés *figyelmeztetésként* hasznos, de nem szabad ítéletként bemutatni. Figyelemre méltó, hogy a csak szabályokat futtató E2x egyezése (0,16) nem rosszabb a modellalapú ellenőrzőkénél: a kérdésenkénti jelzés megbízhatóságát a modellalapú ítélet nem javította, a vizsga egészének minőségét viszont igen. Az E4b szervermodellje minden kérdést átengedett, és a bíró ezek 98 %-át alátámasztottnak ítélte; mivel egyik ítéletben sincs szórás, a κ itt nem informatív.

5.2.7. Válaszszivárgás és nem kérdő törzsek

5.9. táblázat. Válaszszivárgás és nem kérdő törzsek aránya karonként (fő vizsgálat, %; a 4.5. szakasz definíciói szerint). A ki nem írt karok (E4, E5a, E5b) értékei 0–2, illetve 0–11 %.

	B-doc-L	B-doc-S	E0	E1	E2	E2f	E2h	E2x	E3	E5c	E4b
Kulcs a törzsben	1	0	0	**8**	3	3	2	2	0	2	0
Nem kérdés	**17**	1	6	12	8	5	8	3	5	**41**	0

A szivárgási szabályok hatása egyértelmű (5.9. táblázat): az E3 kar szivárgása a pilotbeli 20 %-ról 0-ra, nem kérdő törzseinek aránya 47-ről 5 %-ra csökkent, az ellenőrző karok szivárgása pedig 0–3 %. A maradék szivárgó kérdések a végső tartalékok közül kerültek a vizsgába, megjelölve. A legtöbb szivárgás most az ellenőrzés nélküli E1 karban van (8 %), amelyben a szabályok nem futnak: a szivárgás tehát nem az ellenőrzés sajátja, hanem a kis modell egyenkénti generálásáé, amelyet a visszacsatolás a pilotban felerősített, a szabály pedig most kiszűr. A nem kérdő törzsek aránya a rögzített darabolásnál (E5c, 41 %) és a teljes dokumentumos helyi alapvonalnál (B-doc-L, 17 %) a legmagasabb. A bíró a szivárgó kérdéseknek most többnyire közepes helyességi pontot adott (2,0–3,6), szemben a pilot jellemző 5-öseivel; a szivárgó kérdések azonban kevesen vannak (karonként legfeljebb öt), így ebből nem vonható le általános következtetés.

Egy új vakfolt: a forma szerint triviális kérdések. A szervermodell naiv RAG-gal (E4) olyan kérdéseket is írt, amelyek nem a tananyagra, hanem a visszakeresett szövegdarab formájára

kérdeznek rá („Hány szóból áll a »Link to Learning« cím?”, 5.12. táblázat). Ezek a kérdések formailag hibátlanok, „alátámasztottak” és vakon megoldhatók, a bíró 5/5 helyességi pontot adott nekik – a szivárgáshoz hasonlóan felfelé torzítják a mutatókat. Az E4 kar 98 %-os vak megoldhatósága és 9 %-os lefedettsége együtt erre utal: a kérdések a dokumentum kis, tartalmilag szegény részéhez kötődnek.

5.2.8. Darabolás és a naiv RAG törékenysége

A darabolási karok eredménye első ránézésre meglepő: a régi, csonkolt kódoló (E5a, 0,87) és a rögzített, 800 karakteres darabolás (E5c, 0,86) is jobb az alapértelmezett, ablakozott szemantikus darabolásnál (E0, 0,64), a szórásalapú küszöb (E5b, 0,70) pedig az alapvonal szintjén marad. A dokumentumonkénti bontás (5.5. táblázat) megmutatja, honnan ered a különbség: a három rövid magyar szövegen a három szemantikus változat közel azonos (0,87–0,89), a rögzített darabolás gyengébb (0,77); a három angol dokumentumon viszont a két szemantikus változat összeomlik (E0: 0,40, E5b: 0,51; alátámasztottság mindkettőnél 0 %), miközben az E5a 0,87-et, az E5c 0,96-ot ér el.

A bíró ítéletei szerint a naiv karok az angol dokumentumokon gyakorlatilag tartalom nélküli kontextust kaptak. Az OpenStax-szövegek rövid szerkezeti sorokat tartalmaznak („Link to Learning”, „Check Your Understanding”), amelyeket a szemantikus darabolás – minimális darabméret nélkül – önálló darabbá vág, és a naiv RAG általános lekérdezése („10 feleletválasztós kérdés …”) ezekhez a rövid darabokhoz áll a legközelebb, mert azok sem tartalmaznak tartalmi szót. A rögzített darabolás ilyen darabot nem hoz létre, a régi kódoló pedig a dokumentum nagyobbik részén méretalapúan vág. A keresés maga nem hibás: a referenciakérdésekkel végzett próba szerint az igazoló mondatot tartalmazó darab minden karon a referenciakérdések 89–95 %-ánál az első három találat között volt. A hiba a naiv RAG *lekérdezésében* van, amely nem tartalmi kérdés, hanem egy feladatleírás. A tervezett karok ettől nem szenvednek, mert slotonként a tervezett fogalommal keresnek (E1 az angol dokumentumokon: 0,91). Ez a megfigyelés a tervezés mellett szóló új érv: a naiv RAG minősége a darabolás apró részleteitől függ, a tervezett csővezetéké nem. Gyakorlati következménye, hogy a szolgáltatás darabolójának minimális darabméretet kell kapnia.

5.2.9. A teljes dokumentumos alapvonal és a lefedettség

A status quót modellező alapvonalak két, egymástól eltérő képet adnak. A helyi 7B modell a teljes dokumentummal (B-doc-L) 0,83-at ért el: a vizsgák 17 %-a formailag hibás volt (nem tíz, vagy nem négyopciós kérdést tartalmazott), a törzsek 17 %-a nem kérdés, és a leghosszabb dokumentumnak csak az első 30 000 karakterét láthatta. Ugyanazzal a modellel a tervezett és ellenőrzött csővezeték ennél jóval jobb (0,96). A szervermodell a teljes dokumentummal (B-doc-S) viszont 0,95-öt ért el, a helyi E2-vel gyakorlatilag azonosat; a rövid magyar szövegeken 0,98–1,00-t, vagyis a rövid dokumentumokon a nagy modellnek nincs szüksége a felbontásra.

A 3. hipotézist a fő vizsgálat *nem* támasztja alá: a teljes dokumentumos alapvonalak lefedettsége (45 és 47 %) nem alacsonyabb a tervezett karokénál (40–45 %). A kérdések egy szakaszra tömörülése, amelyet a pilot a szervermodellnél mutatott, a fő vizsgálatban a naiv RAG sajátjának bizonyult (E0: 25 %, E4: 9 %). Ennek értelmezéséhez fontos, hogy a lefedettség felső korlátja tíz kérdésnél $10/K$: a négydarabos magyar szövegeken elvben 100 %, a százdarabos jogi szövegen legfeljebb 10 %. Az átlagot így a rövid szövegek határozzák meg, amelyeken tíz kérdés szükségképpen sok darabot érint; a hosszú dokumentumokon a lefedettség minden karnál a korlát közelében van, így a mutató ott nem különbözteti meg a módszereket.

A bíró kontextusablaka. A teljes dokumentumos karoknál a bíró a dokumentum elejét látja, legfeljebb 24 000 karaktert. Az `en-law-long-03` dokumentumon a B-doc-S egyik kérdését („What is the access economy?” – „Mi a hozzáférés-alapú gazdaság?”) a bíró azért ítélte alá nem támasztottnak, mert a fogalom a dokumentum 38 603. karakterénél szerepel; a B-doc-L egy kérdése (29 030. karakter) ugyanígy járt. Ezen a dokumentumon a B-doc-S alátámasztottsága mindhárom vizsgában 40 %, vak megoldhatósága viszont 100 % volt: a bíró a kérdéseket a saját tudásából helyesen megoldotta, de az igazoló mondatot az ablakában nem találta. A teljes dokumentumos karok alátámasztottsága a hosszú dokumentumokon ezért alsó becslés; a tervezett és a naiv karokat ez nem érinti, mert ott a bíró a kérdés saját forrásdarabjait látja. Az eset arra is rámutat, hogy a vak megoldhatóságot egy nagy bíró általános tudással is teljesítheti, ezért önmagában nem bizonyítja, hogy a kérdés a forrásból megválaszolható.

5.2.10. Szervermodell és helyi modell

A szervermodell két RAG-változata más dokumentumokon futott, ezért azokat a közös három angol dokumentumon vetjük össze. Ezeken a helyi E2 0,95-öt, a szervermodell naiv RAG-gal (E4) 0,93-at, a teljes dokumentumot kapó szervermodell (B-doc-S) 0,90-et, a tervezett és ellenőrzött szervermodell (E4b) 1,00-t ért el. A helyi, tervezett csővezeték tehát a szervermodell naiv változatát elérte (különbség $< 0{,}1$). Ugyanezen a három dokumentumon a naiv alapvonal helyben 0,40-et, a szerveren 0,93-at adott ($+0{,}54$, $n = 3$, szignifikanciára nem elegendő): a nagy modell a tartalom nélküli kontextusból is hibátlan formájú, bár részben triviális kérdést írt (5.2.7. szakasz).

A legmagasabb indexet a szervermodell a tervezett és ellenőrzött csővezetékben érte el (E4b, 0,99; alátámasztottság 98 %, vak megoldhatóság 100 %) hat angol dokumentumon. Ez a módszer modellfüggetlenségét mutatja: ugyanaz a csővezeték a nagyobb modellel közel hibátlan vizsgát ad, és a lefedettsége (28 %) az E4-énél (9 %) háromszor nagyobb ugyanazokon a dokumentumokon. Az ára a megosztott egyetemi szerveren 47,7 perc vizsgánként (a helyi E2-é 3,5 perc), és a tananyag elhagyja a gépet (P3).

5.2.11. A bíró rubrikapontjai és a kérdések jellege

Az 5.10. táblázat a bíró rubrikapontjait, a „felhasználnám” arányt, a kérdések hosszát és a megvalósult Bloom-szinteket mutatja.

5.10. táblázat. A bíró rubrikapontjai (1–5, átlagok), a „felhasználnám” arány, a kérdések átlagos hossza (karakter) és a bíró szerinti magasabb rendű (alkalmazás, elemzés, értékelés) kérdések aránya karonként (fő vizsgálat). Helyes.: helyesség; Érth.: érthetőség; Diszt.: disztraktorok; Szint: szintillesztés.

Kar	*n*	Helyes.	Érth.	Diszt.	Szint	Felhasz.	Törzs	Opciók	Magasabb rendű
B-doc-L	180	4,0	4,8	3,8	4,3	68 %	86	126	6 %
B-doc-S	180	4,6	4,9	4,2	4,5	87 %	68	162	11 %
E0	180	2,7	4,8	2,9	4,4	34 %	53	56	2 %
E1	60	3,7	4,3	4,0	4,5	65 %	113	346	8 %
E2	60	4,5	4,5	4,2	4,6	80 %	114	343	8 %
E3	60	3,9	4,6	3,8	4,6	73 %	90	293	10 %
E2f	60	4,0	4,5	3,9	4,5	73 %	116	336	5 %
E2h	60	4,1	4,4	4,1	4,6	77 %	114	370	13 %
E2x	60	4,1	4,5	4,2	4,6	75 %	110	356	10 %
E5a	180	3,8	4,7	4,0	4,3	67 %	76	162	11 %
E5b	180	2,5	4,7	3,2	4,4	36 %	72	125	4 %
E5c	170	4,0	4,6	3,7	4,4	68 %	83	158	2 %
E4	180	4,1	4,7	4,2	4,5	77 %	52	19	13 %
E4b	60	4,9	4,8	4,7	4,9	98 %	112	421	20 %

Felhasználhatóság. A „felhasználnám” arány a minőségi indexszel összhangban rangsorolja a karokat: a naiv RAG kérdéseinek csak 34 %-át, a helyi E2 kérdéseinek 80 %-át, a szerveres E4b kérdéseinek 98 %-át tenné a bíró egy valódi dolgozatba. A helyesség pontszám ugyanezt mutatja (2,7, 4,5, illetve 4,9). Az érthetőség minden karon magas (4,3–4,9), a tervezett karoknál kissé alacsonyabb.

A kérdések jellege. A tervezett karok kérdései lényegesen hosszabbak: a törzs átlagosan 110–116 karakter (a naiv RAG-nál 53), a négy válaszlehetőség együtt 290–370 karakter (a naiv RAG-nál 56, az E4-nél mindössze 19). A naiv karok tehát jellemzően rövid, egy-két szavas válaszokat adnak („9. század”, „3”), a tervezett karok teljes mondatokat. Ez a fogalmi, magyarázó kérdéseknek kedvez (a disztraktorpontszám nő), de a kérdés olvasási terhét is növeli, ami az érthetőségi pontszám kis csökkenésében is megjelenik.

Tervezett és megvalósult Bloom-szint. A vizsgaterv a hat dokumentum kért nehézsége szerint a tervezett karokban a 60 kérdésből 16-ot (27 %) magasabb rendű szintre (alkalmazás, elemzés, értékelés) tervezett. A bíró szerint azonban a helyi E2 kérdéseinek csak 8 %-a lett ténylegesen magasabb rendű, és a tervezett és a megvalósult szint csak a kérdések 35 %-ánál egyezett; a „megértés” és „alkalmazás” slotokból is gyakran tényfelidéző kérdés lett. A szervermodell (E4b, a saját hat dokumentumán) a terv által előírt 20 % magasabb rendű kérdést meg is valósította

(20 %), és 62 %-ban találta el a tervezett szintet. A kis modell tehát a kért kognitív szintet nem valósítja meg megbízhatóan – ez egyezik a pilot megfigyelésével és a szakirodalommal [20] –, a szintillesztési pontszám ennek ellenére magas (4,5–4,6), mert a könnyebb nehézségekhez az alacsonyabb szint is elfogadható. A Bloom-kiosztás tehát a *kért* szintet garantálja; a *megvalósult* szint ellenőrzése egy további, eddig hiányzó lépés.

5.2.12. Magyar és angol dokumentumok

A dokumentumonkénti bontás (5.5. táblázat) szerint a tervezett karok az angol dokumentumokon kissé jobbak (átlagosan 0,91–0,95), mint a magyarokon (0,84–0,96), egyetlen kivétellel: az ellenőrzés (E2) a magyar szövegeken emelte a legtöbbet (0,85 → 0,96). A magyar szövegek rövidek (négy-öt darab), így tíz eltérő, alátámasztott kérdés megírása rajtuk nehezebb – ezt mutatja a duplikátumok magas száma is (5.7. táblázat) –, és a 7B modell magyar nyelvi hibái (5.12. táblázat) is itt jelentkeznek. Az egyhívásos karok nyelvi különbségei a darabolásból (5.2.8. szakasz) és a bíró kontextusablakából (5.2.9. szakasz) erednek, nem a nyelvből. Mivel a magyar részhalmaz három rövid saját szöveg, az angol pedig három OpenStax-szöveg, a nyelvi különbség leíró, nem ok-okozati.

5.2.13. Erőforrásigény és költség

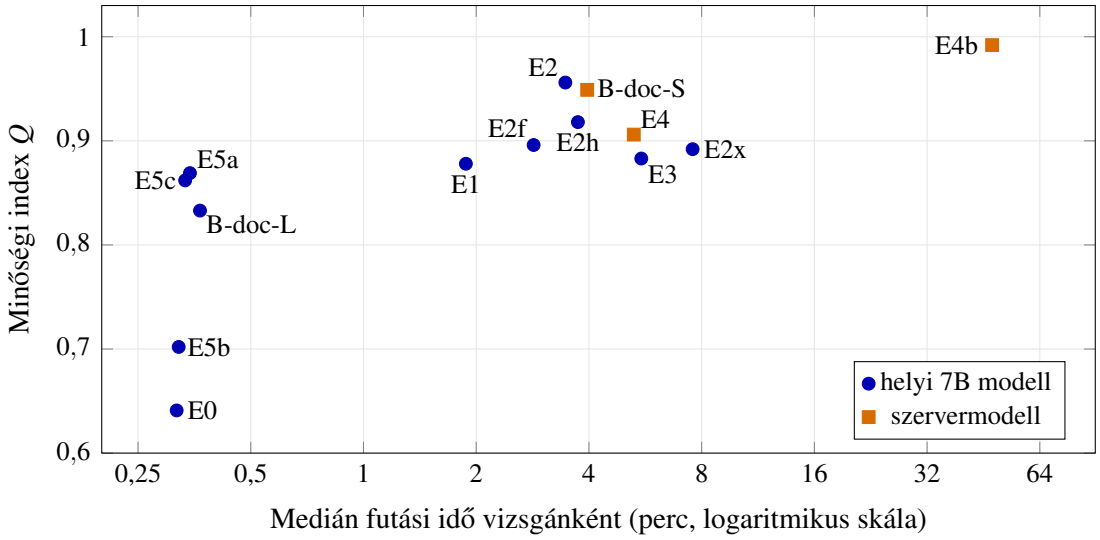
GPU-memória. A fő vizsgálat munkaállomásán nem futott asztali környezet, így a kártya alapterhelése mindössze kb. 0,95–1 GiB volt (5.11. táblázat). A generálás alatti csúcs a 8 192 tokenes kontextusú karoknál 6 039–6 263 MiB, a 16 384 tokenes B-doc-L-nél 6 726 MiB volt; a modell és a futtatókörnyezet tehát kb. 5,0–5,1 GiB-ot, illetve 5,6 GiB-ot foglalt. A két kontextushossz közötti különbség (618 MiB) nagyságrendben egyezik a gyorsítótár (3.1) szerinti 448 MiB-os többletével, a fennmaradó rész a futtatókörnyezet nagyobb puffereiből ered. Az E2x kar csúcsa (6 106 MiB) azt is mutatja, hogy a második modell nem töltődött be. Az eredmény megerősíti a pilotot: a helyi csővezeték egy 8 GB-os kártyán az asztali környezet mellett is elfér.

5.11. táblázat. Mért GPU-memória a fő vizsgálatban (MiB, RTX A4500). Alap: a kártya foglalása a modell betöltése előtt; Csúcs: a legnagyobb mért érték a generálás alatt; Modell: a különbség.

Karok	Kontextus	Alap	Csúcs	Modell
E0, E1, E2, E2f, E2h, E2x, E3	8 192	993	6 102–6 263	5 109–5 270
E5a, E5b, E5c	8 192	940–957	6 039–6 083	5 099–5 143
B-doc-L	16 384	993	6 726	5 733

Futási idő. Az 5.1. ábra a minőséget a futási idő függvényében mutatja. A helyi karok között két csoport különül el: az egyhívásos karok 20 másodperc körül, erősen változó minőséggel (0,64–0,87), és a tervezett karok 1,9–7,6 perc alatt, egyenletesebben magas minőséggel (0,88–0,96). Az E2 3,5 perccel és 51 hívással a legjobb ár–érték arányú helyi kar: egy oktató számára egy tízkérdéses vizsga néhány perces várakozása elfogadható, különösen ha a kérdések négyötöde

javítás nélkül használható. A szerveren futó karok ideje a megosztott szerver terhelésétől függ, ezért csak tájékoztató jellegű. A pilotban ugyanez a kar 75 hívást és 6,2 percet igényelt egy másik GPU-n; a kevesebb hívásban az $r = 1$ korlát is szerepet játszik, így a futásidők közvetlenül nem hasonlíthatók össze.



5.1. ábra. Minőség és futási idő a fő vizsgálatban. A tervezett helyi karok egy nagyságrenddel lassabbak az egyhívásos karoknál, de minőségük egyenletesebb; az E4 és az E4b más dokumentumokon futott, az E2x idejét a sikertelen ellenőrző hívások növelték.

5.2.14. Példák

Az 5.12. táblázat négy kérdést mutat a fő vizsgálatból, eredeti nyelvükön, az angol kérdéseknél magyar fordítással, a bíró ítéletével. A teljes gyűjtemény (karonként egy jó és egy rossz kérdés) a fő vizsgálat jelentésének `peldak.md` fájljában található (`tests/eval/report_main/main`).

5.12. táblázat. Kérdések a fő vizsgálatból eredeti nyelven, zárójelben magyar fordítással (* = megjelölt kulcs), a bíró ítéletével.

E4b	*Which statement correctly compares how dsRNA, +ssRNA, and -ssRNA viral genomes produce translatable +ssRNA ?* (Melyik állítás hasonlítja össze helyesen, hogyan állít elő a dsRNS, a +ssRNS és a -ssRNS vírusgenom fehérjévé átírható +ssRNS-t?) Kulcs: a +ssRNS közvetlenül átírható, a -ssRNS-t a vírus RdRP enzime +ssRNS-sé másolja, a dsRNS pedig negatív szálát használja sablonként.*; a disztraktorok a három genomtípus szerepét keverik össze. **Bíró:** alátámasztott, vakon helyes, minden pontszám 5/5 – egy valódi, magasabb rendű (összehasonlító) kérdés.
E4	*How many words are in Link to Learning ?* (Hány szóból áll a »Link to Learning«?) 3* / 2 / 4 / 5. **Bíró:** alátámasztott (bizonyíték: „Link to Learning"), vakon helyes, helyesség 5/5 – noha a kérdés a visszakeresett szakaszcímre, nem a tananyagra kérdez.
B-doc-S	*What is the access economy ?* (Mi a hozzáférés-alapú gazdaság?) Kulcs: olyan erőforrás-áramlási rendszer, amelyben a fogyasztók az erőforrások szolgáltatóiként és igénybe vevőiként is részt vesznek.* **Bíró:** nem alátámasztott, „a forrás nem említi" – a fogalom a dokumentum 38 603. karakterénél áll, a bíró 24 000 karakteres ablakán kívül.
E2	*A Robusta kávé alacsonyabb területeken termelésének és koffeintartalma jellemzői.* Kulcs: *A Robusta kávé alacsonyabb területeken termelésének és koffeintartalma 1.5-2 során fejlődik.**; a disztraktorok csak a számokban térnek el. **Bíró:** nem alátámasztott (a forrás csak annyit mond, hogy a koffeintartalom az Arabicáénak majdnem kétszerese), helyesség 1/5. A nem kérdő törzs miatt az ellenőrző elutasította; végső tartalékként, megjelölve maradt a vizsgában – jól mutatja a 7B modell magyar nyelvi korlátait és a megjelölés szükségességét.

6. Az eredmények értékelése

Ebben a fejezetben a két vizsgálat eredményeit a kutatási kérdések és a hipotézisek szempontjából értékeljük, majd megvizsgáljuk, mit tanultunk a módszerről, a mérésről és a gyakorlati alkalmazásról. A fejezetet az érvényességet veszélyeztető tényezők és az etikai megfontolások zárják.

6.1. A hipotézisek értékelése

A 6.1. táblázat hipotézisenként összeveti a pilot és a fő vizsgálat bizonyítékát. A fő vizsgálat karonként hat dokumentumon futott, így a Holm-korrekció után egyik összevetés sem szignifikáns; az értékelés ezért a hatás irányára, nagyságára és a dokumentumok közötti konzisztenciájára épül, és megerősítő következtetéshez a teljes adatkészleten végzett futás szükséges.

6.1. táblázat. A hipotézisek és a pilot, illetve a fő vizsgálat által szolgáltatott bizonyíték.

Hipotézis	Pilot (1 dokumentum)	Fő vizsgálat (6 dokumentum)	Értékelés
1. Tervezés	alátámasztottság +6, lefedettség +8 százalékpont; a zajsávon belül	Q: 0,64 → 0,88; alátámasztottság 43 → 80 %, lefedettség 25 → 45 %, forma 100 %; $r_{rb} = 0{,}62$, $\tilde{p} = 0{,}875$; a javulás az angol dokumentumokon jelentkezik	támogató, nem szignifikáns
2. Ellenőrzés	alátámasztottság változatlan; $\kappa \in [-0{,}14; 0{,}07]$	Q: 0,88 → 0,96, mind a 6 dokumentumon ($p = 0{,}031$, $\tilde{p} = 0{,}188$); alátámasztottság 80 → 90 %, vak 80 → 97 %; $\kappa \in [0{,}02; 0{,}22]$	első fele támogató; az egyezésre vonatkozó rész csak gyengén
3. Lefedettség	közvetett: a szervermodell naiv RAG-gal 25 %	B-doc-L: 45 %, B-doc-S: 47 % vs. tervezett karok 40–45 %; naiv RAG: 9–25 %	nem támogatott (a teljes dokumentumra)
4. Helyi vs. szerver	különbség 0,09–0,11; memória 5,4–5,9 GiB	közös dokumentumokon E2 0,95 vs. E4 0,93; E2 0,96 vs. B-doc-S 0,95 (hat dokumentumon); memória 5,0–5,6 GiB	támogató (leíró)
5. Mérés	oktatói értékelés nincs; a szivárgást a bíró nem bünteti	oktatói értékelés nem készült; két új bírói vakfolt: a 24 000 karakteres ablak és a forma szerint triviális kérdések	nem dönthető el

1. hipotézis (tervezés). A vizsgaterv azonos generátormodell mellett jelentősen növelte az alátámasztottságot és a lefedettséget, a formai megfelelés romlása nélkül. A hatás azonban nem egyenletes: a hosszabb angol dokumentumokon nagy (0,40 → 0,91), a rövid magyar szövegeken nincs. A hipotézis tehát azokon a dokumentumokon teljesül, ahol a naiv RAG a dokumentumnak csak kis részét látja – vagyis éppen ott, ahol a tervezésre szükség van. *Támogatott, de nem szignifikáns.*

2. hipotézis (ellenőrzés). A hipotézis első fele – az ellenőrzés tovább növeli az alátámasztottságot és a vak megoldhatóságot – a fő vizsgálatban mind a hat dokumentumon teljesült, a pilotban viszont nem; a fordulatot a javított tartalékkérdés és a szivárgási szabályok hozták. A második fele – az ellenőrző ítélete pozitívan egyezik a bíróéval – formálisan teljesül ($\kappa > 0$), de az egyezés csekély ($\kappa \leq 0{,}22$). *Részben támogatott:* az ellenőrzés a vizsga egészét javítja, a kérdésenkénti jelzése azonban nem megbízható.

3. hipotézis (lefedettség). A teljes dokumentumot kapó alapvonalak lefedettsége nem volt alacsonyabb a tervezett karokénál. A kérdések tömörülése a naiv RAG-nál jelentkezett, nem a teljes dokumentumos promptnál. *Nem támogatott* – azzal a megszorítással, hogy a vizsgált dokumentumok fele négy-ötdarabos, ahol tíz kérdés szükségképpen sok darabot fed le, a hosszú dokumentumokon pedig a lefedettség felső korlátja (tíz kérdés, száz darab) minden kart egyformán korlátoz.

4. hipotézis (helyi vs. szerver). A helyi, tervezett és ellenőrzött csővezeték a közös dokumentumokon elérte a szervermodell naiv változatát (0,95 vs. 0,93), sőt a teljes dokumentumot kapó szervermodellt is (0,96 vs. 0,95 hat dokumentumon), miközben a modell 5,0–5,6 GiB GPU-memóriát foglalt, vagyis egy 8 GB-os kártyán is fut. *Támogatott*, a kis minta miatt leíró szinten.

5. hipotézis (mérés). Az oktatói értékelés a dolgozat lezárásáig nem készült el, így a bíró emberi validálása nem történt meg. Mindkét vizsgálat feltárt ugyanakkor olyan bírói vakfoltokat (szivárgás, triviális kérdések, kontextusablak), amelyek miatt a bíró ítéleteit óvatosan kell kezelni. *Nem dönthető el.*

6.2. Miért módszer, és nem prompt?

A dolgozat központi állítása, hogy a vizsgagenerálás megbízhatóságát nem egy jobb prompt, hanem a feladat explicit, ellenőrizhető lépésekre bontása biztosítja. A két vizsgálat együtt négy ponton támasztja alá ezt az érvelést.

Először, ugyanaz a 7B modell a tervezés és az ellenőrzés hatására a naiv RAG 0,64-es és a teljes dokumentumos prompt 0,83-as indexéről 0,96-ra javult, és elérte a teljes dokumentumot kapó szervermodellt. A különbség nem a modell tudásából, hanem a feladat szerkezetéből ered: a modellnek a tervezett csővezetékben egyszerre csak egy, rövid kontextusú kérdést kell megírnia. Ez a szakirodalom azon megállapításával cseng össze, hogy a feladat lépésekre bontása és a következtetési időben végzett többletmunka részben helyettesítheti a nagyobb modellt [42, 98].

Másodszor, a tervezett csővezeték *robusztus*. Az E2 mind a hat dokumentumon legalább 0,89-et ért el (5.5. táblázat), miközben a naiv RAG a darabolás apró részletei miatt az angol dokumentumokon 0,33–0,44-re esett, a teljes dokumentumos prompt pedig a leghosszabb dokumentumon gyengült meg. Egy oktató szempontjából a robusztusság fontosabb az átlagnál: egy új dokumentumon nem tudja előre, hogy a „szerencsés” vagy a „szerencsétlen” esetbe tartozik-e.

Harmadszor, a kérdésenkénti forráshivatkozás lehetővé tette, hogy egy olvasó – a kiértékelésben a bíró, a gyakorlatban az oktató – minden kulcsot a saját forrásával szemben ellenőrizzen. Éppen ez tárta fel a naiv alapvonal hibás kulcsait, az ellenőrző karok szivárgó kérdéseit és a szervermodell forma szerint triviális kérdéseit. A teljes dokumentumos promptnál ilyen visszakövetés nincs: a kérdésről nem derül ki, honnan származik.

Negyedszer, ugyanaz a csővezeték a nagy szervermodellel 0,99-et ért el, 98 %-os „felhasználnám" aránnyal és háromszor nagyobb lefedettséggel, mint ugyanaz a modell naiv RAG-gal. A módszer tehát nem a kis modell mankója, hanem modelltől független keret, amely nagy modellel is javít.

A vizsgálatok a módszer határait is megmutatták. A teljes dokumentumot kapó nagy modell a rövid szövegeken (0,98–1,00) sem minőségben, sem lefedettségben nem maradt el a módszertől. A MIMIR előnye vele szemben tehát nem a rövid dokumentumokon mért minőség, hanem az ellenőrizhetőség (P1), az adatvédelem (P3) és a helyi futtathatóság (P4); a lefedettségi előny (P2) a naiv RAG-gal szemben mutatható ki. A fogalomgráf és a hibrid keresés a jelen adatokon nem érte meg a többletköltségét, a kis modell pedig a kért Bloom-szintet csak a kérdések harmadában valósította meg.

6.3. Mit tanultunk az ellenőrzésről?

Az ellenőrzés volt a dolgozat legmeglepőbb komponense: a pilotban rontott, a fő vizsgálatban mind a hat dokumentumon javított, a kérdésenkénti ítélete pedig mindkét vizsgálatban alig egyezett a bíróéval. Az elutasítási okok elemzése (5.7. táblázat) megmagyarázza ezt a látszólagos ellentmondást.

Az ellenőrzés a vizsgát javítja, nem a jelzést. A kis modell az alátámasztottsági hívásban a kulcsot gyakorlatilag mindig elfogadta, a disztraktorokat viszont gyakran gyanúsnak találta, a vak próbában pedig időnként mást választott. Ezek a jelzések egyenként zajosak, de az újrapróbálkozás miatt *összegződnek*: ha egy kérdést elutasítunk, és a generátor egy újat ír, az új kérdés átlagosan jobb disztraktorokat tartalmaz, és egyértelműbb. Az ellenőrzés így szűrőként és „második esélyként" működik, nem pedig megbízható osztályozóként. Ez összeegyeztethető Huang és munkatársai [10] eredményével: a modell saját ítélete önmagában nem megbízható, de ha külső információval – itt a forrásszöveggel és determinisztikus szabályokkal – kombináljuk, és a hibát a generálás megismétlésére használjuk, javíthat.

A modellalapú ítélet többet ad a szabályoknál. Az `E2x` kar – amelyben az ellenőrző hívások hiba miatt nem futottak – véletlenül szétválasztotta a szabályalapú és a modellalapú ellenőrzés hatását. A szabályok önmagukban szinte nem javítottak a minőségi indexen (0,88 → 0,89), de a szivárgást elfojtották; a modellalapú ítéletek adták a javulás nagyobb részét (0,89 → 0,96). Mindkettőre szükség van: a szabály megakadályozza, hogy a modell „kijátssza" az ellenőrzést (Goodhart-hatás), a modell pedig olyan tartalmi hibákat jelez, amelyeket szabállyal nem lehet

megfogalmazni.

A visszacsatolás veszélyes is lehet. A pilot megmutatta, hogy egy rosszul specifikált ellenőrzés a generátort nemkívánatos irányba tolja: a szó szerinti másolás a legkönnyebb út az alátámasztottsági ellenőrzésen át. A tanulság általános: minden automatikus visszacsatolási hurkot olyan mutatókkal kell kiegészíteni, amelyek a „csalás” legolcsóbb módjait is mérik.

Gyakorlati következmény. A javasolt helyi konfiguráció az E2: tervezés, önellenőrzés szabályokkal és vak próbával. Az ellenőrzés jelzését az oktatónak *figyelmeztetésként* kell megmutatni („ezt a kérdést nézd meg alaposabban”), nem ítéletként, mert a megjelölt kérdések háromnegyede valójában rendben van, az átengedettek kb. hetede pedig nem. Ha a rendszer az átengedett kérdéseket „ellenőrzöttként” hirdetné, az automatizálási torzítás [134] miatt az oktató éppen ezeket nézné át kevésbé figyelmesen.

6.4. A mérés mint kutatási eredmény

A dolgozat egyik legfontosabb eredménye módszertani: a mérés több ponton is torzított volna, ha nem ellenőrizzük. A tartalékvizsga-hiba a generálási sikert, a csonkolt kódoló a darabolás minőségét, a szivárgás pedig a tartalmi mutatókat és a bíró ítéletét torzította – mindhárom esetben *felfelé*, vagyis jobb eredményt mutatva a valósnál. A fő vizsgálat két újabb bírói vakfoltot tárt fel: a 24 000 karakteres ablak a hosszú dokumentumok végéről írt helyes kérdéseket lefelé, a szervermodell tartalmilag üres, formai kérdései pedig felfelé torzították a mutatókat.

Az E2x kar egy negyedik, tanulságos esetet adott. A csővezeték hibatűrő módon viselkedett: ha az ellenőrző modell nem érhető el, a kérdést nem blokkolja, hanem megszámolja a kihagyott ellenőrzéseket. Ez éles üzemben helyes döntés, a kísérletben viszont azt eredményezte, hogy egy teljes kar más konfigurációt mért, mint amit a neve ígért, és ez a jelentésben nem jelent meg figyelmeztetésként; csak a nyers naplók utólagos átnézése fedte fel. A közös vonás minden esetben az, hogy a mérőrendszer „működött”: nem adott hibaüzenetet, és hihető számokat állított elő. A tanulság az, hogy a nyelvi modellekre épülő rendszerek kiértékelésében (i) a nyers kimenetek kézi átolvasása és a szélsőértékek tudatos vizsgálata nem helyettesíthető automatizmussal, és (ii) a kísérleti keretrendszernek minden csendes tartalékágat (kihagyott ellenőrzés, csonkolás, tartalékkérdés) a jelentésben is láthatóvá kell tennie.

A futásról futásra jelentkező zaj ($\approx 0{,}07$ egyetlen dokumentumon) hasonló tanulság: kevés dokumentumon, kevés ismétléssel mért különbségek jelentős része zaj lehet, ezért a fő vizsgálatban a dokumentumonkénti konzisztenciát (hány dokumentumon azonos irányú a különbség) legalább annyira figyelembe vettük, mint az átlagot.

6.5. Gyakorlati ajánlás

Az eredmények alapján egy oktatási intézmény számára a következő ajánlás fogalmazható meg.

- **Ha a tananyag nem hagyhatja el az intézményt** (személyes adatot tartalmaz, vagy az intézmény nem kíván adatfeldolgozási szerződést kötni): a helyi E2 konfiguráció egy 8 GB-os fogyasztói kártyán, vizsgánként 3–5 perc alatt, a vizsgált dokumentumokon a nagy szervermodellel azonos minőségű vizsgát ad, a kérdések kb. 80 %-a javítás nélkül használható.
- **Ha a tananyag nyilvános, és van hozzáférés nagy modellhez**: ugyanaz a csővezeték a szervermodellel (E4b) a legjobb minőséget adja, de lényegesen lassabb a megosztott szerveren.
- **Rövid dokumentumnál** a teljes dokumentum átadása egy nagy modellnek is jó eredményt ad, de a kérdések forrása ilyenkor nem követhető vissza.
- **A naiv RAG nem ajánlott**: a minősége a darabolás részleteitől függően kiszámíthatatlan.
- **Minden esetben** oktatói átnézés szükséges, a megjelölt kérdésekre különös figyelemmel; ezt a rendszer kötelezővé is teszi.

6.6. Az érvényességet veszélyeztető tényezők

A tapasztalati szoftvertechnológiai kutatás szokásos felosztását [148] követve négy érvényességi szempontot vizsgálunk.

Belső érvényesség (a különbséget valóban a vizsgált tényező okozza-e?). Az egytényezős terv a karok közötti különbséget egyetlen tényezőhöz köti, ám a tényezők nem mindig függetlenek: az ellenőrzés például a kérdések hosszát és formáját is megváltoztatja, ami közvetve hat a bíró ítéletére. A GPU-következtetés nem determinisztikus, így azonos konfiguráció mellett is eltérő kimenetek születnek; a tervezett karok egyetlen maggal futottak, így dokumentumonkénti értékükben ez a zaj is benne van. A pilot és a fő vizsgálat között a csővezeték változott, így a két vizsgálat eredményei nem közvetlenül összevethetők. Az E4 és az E4b kar más dokumentumokon futott, mint a többi, az E2x kar pedig a tervezettől eltérő konfigurációt mért (csak szabályalapú ellenőrzés).

Konstrukciós érvényesség (azt mérjük-e, amit mérni akarunk?). A minőségi index egyenlő súlyú komponensei közül a formai megfelelés vizsgaszintű bináris változó, ezért egyetlen formai hiba aránytalanul nagy hatású; ezt tudatosan vállaljuk, de minden komponenst külön is közlünk. A lefedettség a beágyazási térben legközelebbi darabra épül, ami csak közelítése annak, hogy a kérdés „miről szól”, és a hosszú dokumentumokon a kérdésszám korlátozza. Az alátámasztottság és a vak megoldhatóság a bíró ítéletén alapul, amely a kérdés kontextusát látja, így a dokumentum más részeiben lévő ellentmondást nem veheti észre; a szivárgó és a forma szerint triviális kérdéseket nem bünteti; a teljes dokumentumos karoknál pedig legfeljebb a dokumentum első 24 000 karakterét látja. Az oktatói validálás hiányában a tartalmi mutatók egyetlen, emberileg nem validált bíróra épülnek.

Külső érvényesség (általánosíthatók-e az eredmények?). A fő vizsgálat a 39 dokumentumból kilencen futott (karonként hat); magyar részhalmaza három rövid saját szöveg, a Wikipédia-cikkek egyike sem szerepelt benne, így a nyelv hatása a forrás és a hossz hatásával keveredik. A vizsgált dokumentumok többsége rövid, ezért a hosszú dokumentumokra jellemző jelenségek csak egy-két dokumentumon jelenhettek meg. Csak feleletválasztós kérdéseket értékeltünk. Az eredmények a vizsgált modellekre (Qwen2.5-7B, a szervermodell) vonatkoznak; egy másik modellcsalád eltérően viselkedhet.

Következtetési érvényesség (statisztikailag megalapozottak-e a következtetések?). A dokumentumszintű nemparaméteres próbák konzervatívak. A fő vizsgálat karonként hat dokumentuma éppen az a legkisebb szám, amelyen $p < 0{,}05$ egyáltalán elérhető; a hat összevetés közül egy (E2–E1) érte el, a Holm-korrekció után egyik sem. A fő vizsgálat következtetései ezért leíró jellegűek; a 39 dokumentum közepes hatásméretek kimutatására elegendő lenne, kis hatások kimutatására nem. A bootstrap-intervallumok kis mintán alulfedhetnek, ezért a pontbecslések mellett a dokumentumonkénti értékeket is közöljük.

6.7. Etikai és jogi megfontolások

A rendszer hallgatói adatot nem kezel, a feltöltött dokumentumok a feladat végén törlődnek (3.3. szakasz), minden generált kérdés oktatói jóváhagyást igényel, az export pedig feltünteti az MI-közreműködést és a modellt [136]. A kiértékelő dokumentumok saját vagy nyílt licencű (CC BY 4.0, CC BY-SA 4.0) művek; a szerverkarok és a bíró az egyetem saját GenAI-infrastruktúráján futnak, így a kiértékelés során sem került tananyag külső szolgáltatóhoz. A rendszer célja a vázlatírás gyorsítása és ellenőrizhetővé tétele, nem az oktatói döntés kiváltása.

7. Összefoglalás és további munka

7.1. Összefoglalás

Dolgozatunkban a vizsgakérdés-generálás négy gyakorlati problémájából indultunk ki: a kulcsok helyessége nincs ellenőrizve (P1), a vizsga szerkezete és lefedettsége nincs kontrollálva (P2), a tananyag egy harmadik félhez kerül (P3), és a módszer nagy, távoli modellekre támaszkodik (P4). Ezekre a MIMIR rendszerrel válaszoltunk, amely az egyetlen promptot explicit, ellenőrizhető módszerrel váltja fel, és egyetlen fogyasztói GPU-n, adatmegőrzés nélkül fut.

A munka eredményei a következőkben foglalhatók össze.

(1) **Szakirodalmi megalapozás.** Áttekintettük a feleletválasztós kérdés tesztelméleti követelményeit, az automatikus kérdésgenerálás fejlődését, a visszakereséssel kiegészített generálást, a hosszú kontextus korlátait, az ellenőrzés és önjavítás eredményeit, a kis és kvantált modelleket, valamint a nyelvi modellel végzett kiértékelést, és megfogalmaztuk a kutatási rést.

(2) **Generálási módszer és architektúra.** Kidolgoztuk és implementáltuk a tervezésvezérelt, forráshivatkozásos csővezetéket (szemantikus darabolás, lefedettségvezérelt vizsgaterv Bloom-kiosztással, slotonkénti keresés, egyenkénti generálás, ellenőrző lánc visszacsatolással és tartalékokkal, fogalomgráf), és egy zéró adatmegőrzésű, kapcsolható módon kizárólag helyben futó mikroszolgáltatás-architektúrát.

(3) **Kiértékelési módszertan.** Tizennégy egytényezős kísérleti kart, 39 dokumentumos kétnyelvű adatkészletet, forrásalapú mutatókat, modellcsaládon kívüli bírót, közös bíró–oktató rubrikát és dokumentumszintű statisztikát tartalmazó, nyílt és reprodukálható keretrendszert hoztunk létre.

(4) **Pilot eredmények.** Egyetlen dokumentumon a tervezés kis mértékben javított; az azonos modellel végzett önellenőrzés a bíróval csak véletlenszintű egyezést mutatott; a visszacsatolás a kulcs kérdésbe szivárgását idézte elő, amely a mutatókat és a bírót egyaránt félrevezette; a futásról futásra jelentkező zaj ($\approx 0{,}07$) pedig megmutatta, hogy egyetlen dokumentumon a legtöbb különbség nem értelmezhető. Ezekből a megfigyelésekből közvetlenül következtek a fő vizsgálat javításai.

(5) **A fő vizsgálat eredményei.** Tizennégy karral, kilenc magyar és angol dokumentumon (karonként hat), 1 670 kérdésen: a helyi 7B modellel futó tervezett és ellenőrzött csővezeték érte el a legmagasabb minőségi indexet a közös dokumentumokon (0,96), mind a hat dokumentumon legalább 0,89-cel, szemben a naiv RAG 0,64-es, a helyi teljes dokumentumos prompt 0,83-as és a teljes dokumentumot kapó szervermodell 0,95-ös értékével. A tervezés $+0{,}24$-dal, az ellenőrzés mind a hat dokumentumon $+0{,}08$-dal javított; az ellenőrzés haszna főként a modellalapú ítéletekből – a gyanús disztraktorok és a vak próba jelzéseiből – ered, a szabályok a szivárgást szorították le 0–3 %-ra. A fogalomgráf rontott,

a hibrid keresés nem javított; a naiv RAG az angol dokumentumokon a rövid szerkezeti darabok miatt összeomlott; ugyanaz a csővezeték a szervermodellel 0,99-et ért el. A helyi modell 5,0–5,6 GiB GPU-memóriát foglalt. A Holm-korrekció után egyik összevetés sem szignifikáns.

A kutatási kérdésekre a két vizsgálat alapján a következő válaszokat adhatjuk. **RQ1:** a strukturált generálás a vizsgált dokumentumokon érvényesebb és egyenletesebb minőségű vizsgát adott, mint ha ugyanannak a modellnek a dokumentumot vagy annak visszakeresett részleteit egyetlen promptban adjuk át (0,96 vs. 0,83 és 0,64), és a lefedettsége jobb volt a naiv RAG-énál; a teljes dokumentumos promptnál azonban nem volt jobb a lefedettsége (3. hipotézis nem teljesült). **RQ2:** a tervezés 17 hívásért, az ellenőrzés további 34 hívásért javított, a vak megoldási próba a lánc hasznos eleme; a fogalomgráf és a hibrid keresés a többletköltségéért nem javított; a naiv RAG-ot a darabolás apró részletei is jelentősen befolyásolták. **RQ3:** a helyi 7B modell a tervezett és ellenőrzött csővezetékben a közös dokumentumokon elérte a szervermodell naiv RAG-os (0,95 vs. 0,93) és teljes dokumentumos (0,96 vs. 0,95) változatát, vizsgánként 3,5 perc alatt, egy 8 GB-os kártyán is elférő memóriaigénnyel; ugyanazzal a csővezetékkel a szervermodell 0,99-et ért el.

7.2. További munka

A közvetlen folytatás a fő vizsgálat kiterjesztése a 4. fejezetben rögzített protokoll szerint: a fő karok futtatása mind a 39 dokumentumon, köztük a 24 magyar Wikipédia-cikken, azonos dokumentumokon a helyi és a szerverkarokkal; a bíró validálása három oktató vak értékelésével (4.7. szakasz); és a bíró kontextusablakának bővítése a teljes dokumentumos karokra. Ezen túl a következő irányokat tartjuk ígéretesnek.

- **A független ellenőrző újramérése.** Az E2x kar a futtató gépen nem érte el a Llama-ellenőrzőt, így az a kérdés, hogy egy más modellcsaládba tartozó ellenőrző jobb-e az önellenőrzésnél, nyitva maradt. A kart úgy kell újrafuttatni, hogy a keretrendszer a kihagyott ellenőrzéseket hibaként jelezze.
- **Minimális darabméret.** A naiv RAG angol dokumentumokon mért összeomlását a szerkezeti sorokból képzett, tartalom nélküli darabok okozták; a darabolóba illesztett minimális darabméret egyszerű javítás, amelynek hatása egy újabb E0-futással mérhető.
- **Megbízhatóbb ellenőrző.** Az ellenőrzés javítja a vizsgát, de a kérdésenkénti jelzése a bíróval csak gyengén egyezik. Természetes nyelvi következtetésre (NLI) tanított kisebb osztályozó [96] vagy atomi tényellenőrzés [93] lehet a következő lépés.
- **A megvalósult Bloom-szint ellenőrzése.** A kis modell a kért kognitív szintet a kérdések harmadában valósította meg; egy szintosztályozó ellenőrzés az ellenőrző láncba illeszthető.
- **Adaptív ellenőrzés.** Az ellenőrzés költségét csökkentené, ha csak a bizonytalan kérdésekre futna.

– **Nyelvi összevetés.** Az angol dokumentumok egy részének magyar fordítása lehetővé tenné a nyelv hatásának a forrástól független mérését; a magyar nyelvre hangolt helyi modellek (például a Llama-3.1 alapú PULI-LlumiX) összevetése a Qwen2.5-7B-vel szintén ide tartozik.
– **Tanórai kipróbálás.** Az igaz–hamis és a kifejtős kérdések kiértékelése, valamint a generált vizsgák pszichometriai elemzése (nehézségi és diszkriminációs index, nem funkcionáló disztraktorok [16]) valós hallgatói válaszokon.

A MIMIR nyílt forráskódú: a kód, a konfigurációk, az adatkészlet-manifesztek, a pilot és a fő vizsgálat nyers kimenetei és jelentései a reprodukáláshoz rendelkezésre állnak.

Irodalomjegyzék

[1] T. M. Haladyna, S. M. Downing és M. C. Rodriguez. „A Review of Multiple-Choice Item-Writing Guidelines for Classroom Assessment”. *Applied Measurement in Education* 15.3 (2002), 309–333. old.

[2] M. J. Gierl, O. Bulut, Q. Guo és X. Zhang. „Developing, Analyzing, and Using Distractors for Multiple-Choice Tests in Education: A Comprehensive Review”. *Review of Educational Research* 87.6 (2017), 1082–1116. old.

[3] T. B. Brown, B. Mann, N. Ryder, M. Subbiah, J. Kaplan, P. Dhariwal és tsai. „Language Models are Few-Shot Learners”. *Advances in Neural Information Processing Systems*. 33. köt. 2020, 1877–1901. old.

[4] E. Kasneci, K. Sessler, S. Küchemann, M. Bannert, D. Dementieva, F. Fischer és tsai. „ChatGPT for Good? On Opportunities and Challenges of Large Language Models for Education”. *Learning and Individual Differences* 103 (2023), 102274. old.

[5] G. Kurdi, J. Leo, B. Parsia, U. Sattler és S. Al-Emari. „A Systematic Review of Automatic Question Generation for Educational Purposes”. *International Journal of Artificial Intelligence in Education* 30.1 (2020), 121–204. old. DOI: 10.1007/s40593-019-00186-y.

[6] E. Alhazmi, Q. Z. Sheng, W. E. Zhang, M. Zaib és A. Alhazmi. „Distractor Generation in Multiple-Choice Tasks: A Survey of Methods, Datasets, and Evaluation”. *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. 2024, 14437–14458. old.

[7] Z. Ji, N. Lee, R. Frieske és tsai. „Survey of Hallucination in Natural Language Generation”. *ACM Computing Surveys* 55.12 (2023), 1–38. old.

[8] A. Madaan, N. Tandon, P. Gupta, S. Hallinan, L. Gao, S. Wiegreffe és tsai. „Self-Refine: Iterative Refinement with Self-Feedback”. *Advances in Neural Information Processing Systems*. 36. köt. 2023.

[9] S. Dhuliawala, M. Komeili, J. Xu és tsai. „Chain-of-Verification Reduces Hallucination in Large Language Models”. *Findings of the Association for Computational Linguistics: ACL 2024*. 2024.

[10] J. Huang, X. Chen, S. Mishra és tsai. „Large Language Models Cannot Self-Correct Reasoning Yet”. *International Conference on Learning Representations (ICLR)*. 2024.

[11] N. F. Liu, K. Lin, J. Hewitt és tsai. „Lost in the Middle: How Language Models Use Long Contexts”. *Transactions of the Association for Computational Linguistics* 12 (2024), 157–173. old.

[12] C.-P. Hsieh, S. Sun, S. Kriman és tsai. „RULER: What’s the Real Context Size of Your Long-Context Language Models?”: *Conference on Language Modeling (COLM)*. 2024.

[13] Európai Parlament és a Tanács. *Az Európai Parlament és a Tanács (EU) 2016/679 rendelete (általános adatvédelmi rendelet)*. Az Európai Unió Hivatalos Lapja, L 119. 2016.

[14] S. M. Downing. „The Effects of Violating Standard Item Writing Principles on Tests and Students: The Consequences of Using Flawed Test Items on Achievement Examinations in Medical Education”. *Advances in Health Sciences Education* 10.2 (2005), 133–143. old. DOI: 10.1007/s10459-004-4019-5.

[15] M. C. Rodriguez. „Three Options Are Optimal for Multiple-Choice Items: A Meta-Analysis of 80 Years of Research”. *Educational Measurement: Issues and Practice* 24.2 (2005), 3–13. old. DOI: 10.1111/j.1745-3992.2005.00006.x.

[16] M. Tarrant, J. Ware és A. M. Mohammed. „An Assessment of Functioning and Non-Functioning Distractors in Multiple-Choice Questions: A Descriptive Analysis”. *BMC Medical Education* 9 (2009), 40. old. DOI: 10.1186/1472-6920-9-40.

[17] B. S. Bloom, szerk. *Taxonomy of Educational Objectives: The Classification of Educational Goals. Handbook I: Cognitive Domain*. New York: David McKay, 1956.

[18] L. W. Anderson és D. R. Krathwohl, szerk. *A Taxonomy for Learning, Teaching, and Assessing: A Revision of Bloom's Taxonomy of Educational Objectives*. New York: Longman, 2001.

[19] D. R. Krathwohl. „A Revision of Bloom's Taxonomy: An Overview”. *Theory Into Practice* 41.4 (2002), 212–218. old. DOI: 10.1207/s15430421tip4104_2.

[20] D. Scully. „Constructing Multiple-Choice Items to Measure Higher-Order Thinking”. *Practical Assessment, Research, and Evaluation* 22.4 (2017).

[21] L. Crocker és J. Algina. *Introduction to Classical and Modern Test Theory*. New York: Holt, Rinehart és Winston, 1986.

[22] R. Zhang, J. Guo, L. Chen, Y. Fan és X. Cheng. „A Review on Question Generation from Natural Language Text”. *ACM Transactions on Information Systems* 40.1 (2021). DOI: 10.1145/3468889.

[23] R. Mitkov és L. A. Ha. „Computer-Aided Generation of Multiple-Choice Tests”. *Proceedings of the HLT-NAACL 03 Workshop on Building Educational Applications Using Natural Language Processing*. 2003, 17–22. old.

[24] M. Heilman és N. A. Smith. „Good Question! Statistical Ranking for Question Generation”. *Human Language Technologies: The 2010 Annual Conference of the North American Chapter of the Association for Computational Linguistics*. 2010, 609–617. old.

[25] P. Rajpurkar, J. Zhang, K. Lopyrev és P. Liang. „SQuAD: 100,000+ Questions for Machine Comprehension of Text”. *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing*. 2016, 2383–2392. old.

[26] G. Lai, Q. Xie, H. Liu, Y. Yang és E. Hovy. „RACE: Large-scale ReAding Comprehension Dataset From Examinations”. *Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing*. 2017, 785–794. old.

[27] J. Welbl, N. F. Liu és M. Gardner. „Crowdsourcing Multiple Choice Science Questions”. *Proceedings of the 3rd Workshop on Noisy User-generated Text*. 2017, 94–106. old.

[28] X. Du, J. Shao és C. Cardie. „Learning to Ask: Neural Question Generation for Reading Comprehension”. *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics*. 2017, 1342–1352. old.

[29] C. Liang, X. Yang, N. Dave, D. Wham, B. Pursel és C. L. Giles. „Distractor Generation for Multiple Choice Questions Using Learning to Rank”. *Proceedings of the Thirteenth Workshop on Innovative Use of NLP for Building Educational Applications*. 2018, 284–290. old.

[30] Y. Gao, L. Bing, P. Li, I. King és M. R. Lyu. „Generating Distractors for Reading Comprehension Questions from Real Examinations”. *Proceedings of the AAAI Conference on Artificial Intelligence*. 33. köt. 2019, 6423–6430. old.

[31] N. Mulla és P. Gharpure. „Automatic Question Generation: A Review of Methodologies, Datasets, Evaluation Metrics, and Applications”. *Progress in Artificial Intelligence* 12.1 (2023), 1–32. old.

[32] K. Papineni, S. Roukos, T. Ward és W.-J. Zhu. „BLEU: A Method for Automatic Evaluation of Machine Translation”. *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics*. 2002, 311–318. old.

[33] C.-Y. Lin. „ROUGE: A Package for Automatic Evaluation of Summaries”. *Text Summarization Branches Out*. 2004, 74–81. old.

[34] A. Vaswani, N. Shazeer, N. Parmar és tsai. „Attention Is All You Need”. *Advances in Neural Information Processing Systems*. 30. köt. 2017.

[35] J. Devlin, M.-W. Chang, K. Lee és K. Toutanova. „BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”. *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics*. 2019, 4171–4186. old.

[36] R. Sennrich, B. Haddow és A. Birch. „Neural Machine Translation of Rare Words with Subword Units”. *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics*. 2016, 1715–1725. old.

[37] A. Holtzman, J. Buys, L. Du, M. Forbes és Y. Choi. „The Curious Case of Neural Text Degeneration”. *International Conference on Learning Representations (ICLR)*. 2020.

[38] B. T. Willard és R. Louf. *Efficient Guided Generation for Large Language Models*. arXiv:2307.09702. 2023.

[39] J. Kaplan, S. McCandlish, T. Henighan, T. B. Brown, B. Chess, R. Child és tsai. *Scaling Laws for Neural Language Models*. arXiv:2001.08361. 2020.

[40] J. Hoffmann, S. Borgeaud, A. Mensch, E. Buchatskaya, T. Cai, E. Rutherford és tsai. „Training Compute-Optimal Large Language Models”. *Advances in Neural Information Processing Systems*. 35. köt. 2022.

[41] L. Ouyang, J. Wu, X. Jiang, D. Almeida, C. L. Wainwright, P. Mishkin és tsai. „Training Language Models to Follow Instructions with Human Feedback”. *Advances in Neural Information Processing Systems*. 35. köt. 2022.

[42] J. Wei, X. Wang, D. Schuurmans és tsai. „Chain-of-Thought Prompting Elicits Reasoning in Large Language Models”. *Advances in Neural Information Processing Systems*. 35. köt. 2022.

[43] X. Wang, J. Wei, D. Schuurmans és tsai. „Self-Consistency Improves Chain of Thought Reasoning in Language Models”. *International Conference on Learning Representations (ICLR)*. 2023.

[44] Z. Wang, J. Valdez, D. Basu Mallick és R. G. Baraniuk. „Towards Human-Like Educational Question Generation with Large Language Models”. *Artificial Intelligence in Education (AIED 2022)*. 13355. köt. Lecture Notes in Computer Science. Springer, 2022, 153–166. old.

[45] S. Elkins, E. Kochmar, J. C. K. Cheung és I. Serban. „How Useful Are Educational Questions Generated by Large Language Models?”: *Artificial Intelligence in Education. Posters and Late Breaking Results (AIED 2023)*. 1831. köt. Communications in Computer and Information Science. Springer, 2023, 536–542. old.

[46] J. Doughty, Z. Wan, A. Bompelli, J. Qayum, T. Wang, J. Zhang és tsai. „A Comparative Study of AI-Generated (GPT-4) and Human-crafted MCQs in Programming Education". *Proceedings of the 26th Australasian Computing Education Conference*. 2024, 114–123. old.

[47] S. K. Bitew, J. Deleu, C. Develder és T. Demeester. *Distractor Generation for Multiple-Choice Questions with Predictive Prompting and Large Language Models*. arXiv:2307.16338. 2023.

[48] A. Hadifar, S. K. Bitew, J. Deleu, C. Develder és T. Demeester. „EduQG: A Multi-Format Multiple-Choice Dataset for the Educational Domain". *IEEE Access* 11 (2023), 20885–20896. old.

[49] F. Fawzi, S. Amini és S. Bulathwela. „Small Generative Language Models for Educational Question Generation". *NeurIPS 2023 Workshop on Generative AI for Education (GAIED)*. 2023.

[50] F. Fawzi, S. Balan, M. Cukurova, E. Yilmaz és S. Bulathwela. „Towards Human-Like Educational Question Generation with Small Language Models". *Artificial Intelligence in Education. Posters and Late Breaking Results (AIED 2024)*. 2150. köt. Communications in Computer and Information Science. Springer, 2024.

[51] C. D. Jaldi, A. Saini, S. Zhang, N. Schroeder, C. Shimizu és E. Ilkou. *Small, Private Language Models as Teammates for Educational Assessment Design*. 2026. arXiv: 2605.15015.

[52] F. Miao és W. Holmes. *Guidance for Generative AI in Education and Research*. Paris: UNESCO, 2023.

[53] Y. Gao, L. Bing, W. Chen, M. R. Lyu és I. King. „Difficulty Controllable Generation of Reading Comprehension Questions". *Proceedings of the Twenty-Eighth International Joint Conference on Artificial Intelligence (IJCAI-19)*. 2019, 4968–4974. old.

[54] D. Zhou, N. Schärli, L. Hou, J. Wei, N. Scales, X. Wang és tsai. „Least-to-Most Prompting Enables Complex Reasoning in Large Language Models". *International Conference on Learning Representations (ICLR)*. 2023.

[55] L. Wang, W. Xu, Y. Lan és tsai. „Plan-and-Solve Prompting: Improving Zero-Shot Chain-of-Thought Reasoning by Large Language Models". *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics*. 2023, 2609–2634. old.

[56] T. Khot, H. Trivedi, M. Finlayson és tsai. „Decomposed Prompting: A Modular Approach for Solving Complex Tasks". *International Conference on Learning Representations (ICLR)*. 2023.

[57] S. Yao, D. Yu, J. Zhao és tsai. „Tree of Thoughts: Deliberate Problem Solving with Large Language Models". *Advances in Neural Information Processing Systems*. 36. köt. 2023.

[58] T. Wu, M. Terry és C. J. Cai. „AI Chains: Transparent and Controllable Human-AI Interaction by Chaining Large Language Model Prompts". *Proceedings of the 2022 CHI Conference on Human Factors in Computing Systems*. 2022.

[59] S. Yao, J. Zhao, D. Yu és tsai. „ReAct: Synergizing Reasoning and Acting in Language Models". *International Conference on Learning Representations (ICLR)*. 2023.

[60] O. Khattab, A. Singhvi, P. Maheshwari, Z. Zhang, K. Santhanam és tsai. „DSPy: Compiling Declarative Language Model Calls into Self-Improving Pipelines". *International Conference on Learning Representations (ICLR)*. 2024.

[61] J. Maynez, S. Narayan, B. Bohnet és R. McDonald. „On Faithfulness and Factuality in Abstractive Summarization”. *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*. 2020, 1906–1919. old.

[62] L. Huang, W. Yu, W. Ma, W. Zhong, Z. Feng, H. Wang és tsai. „A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions”. *ACM Transactions on Information Systems* 43.2 (2025).

[63] K. Guu, K. Lee, Z. Tung, P. Pasupat és M.-W. Chang. „REALM: Retrieval-Augmented Language Model Pre-Training”. *Proceedings of the 37th International Conference on Machine Learning*. 119. köt. PMLR. 2020.

[64] P. Lewis, E. Perez, A. Piktus és tsai. „Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks”. *Advances in Neural Information Processing Systems*. 33. köt. 2020, 9459–9474. old.

[65] G. Izacard és E. Grave. „Leveraging Passage Retrieval with Generative Models for Open Domain Question Answering”. *Proceedings of the 16th Conference of the European Chapter of the Association for Computational Linguistics*. 2021, 874–880. old.

[66] S. Borgeaud, A. Mensch, J. Hoffmann, T. Cai, E. Rutherford és tsai. „Improving Language Models by Retrieving from Trillions of Tokens”. *Proceedings of the 39th International Conference on Machine Learning*. 162. köt. PMLR. 2022.

[67] K. Shuster, S. Poff, M. Chen, D. Kiela és J. Weston. „Retrieval Augmentation Reduces Hallucination in Conversation”. *Findings of the Association for Computational Linguistics: EMNLP 2021*. 2021, 3784–3803. old.

[68] Y. Gao, Y. Xiong, X. Gao és tsai. *Retrieval-Augmented Generation for Large Language Models: A Survey*. 2023. arXiv: 2312.10997.

[69] A. Asai, Z. Wu, Y. Wang, A. Sil és H. Hajishirzi. „Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection”. *International Conference on Learning Representations (ICLR)*. 2024.

[70] C. D. Manning, P. Raghavan és H. Schütze. *Introduction to Information Retrieval*. Cambridge University Press, 2008.

[71] S. Robertson és H. Zaragoza. „The Probabilistic Relevance Framework: BM25 and Beyond”. *Foundations and Trends in Information Retrieval* 3.4 (2009), 333–389. old.

[72] V. Karpukhin, B. Oğuz, S. Min és tsai. „Dense Passage Retrieval for Open-Domain Question Answering”. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. 2020, 6769–6781. old.

[73] N. Reimers és I. Gurevych. „Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks”. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP-IJCNLP)*. 2019, 3982–3992. old.

[74] L. Wang, N. Yang, X. Huang és tsai. *Text Embeddings by Weakly-Supervised Contrastive Pre-training*. 2022. arXiv: 2212.03533.

[75] L. Wang, N. Yang, X. Huang, L. Yang, R. Majumder és F. Wei. *Multilingual E5 Text Embeddings: A Technical Report*. 2024. arXiv: 2402.05672.

[76] O. Khattab és M. Zaharia. „ColBERT: Efficient and Effective Passage Search via Contextualized Late Interaction over BERT”. *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*. 2020, 39–48. old.

[77] R. Nogueira és K. Cho. *Passage Re-ranking with BERT*. arXiv:1901.04085. 2019.

[78] N. Thakur, N. Reimers, A. Rücklé, A. Srivastava és I. Gurevych. „BEIR: A Heterogeneous Benchmark for Zero-shot Evaluation of Information Retrieval Models". *Thirty-fifth Conference on Neural Information Processing Systems Datasets and Benchmarks Track*. 2021.

[79] N. Muennighoff, N. Tazi, L. Magne és N. Reimers. „MTEB: Massive Text Embedding Benchmark". *Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics*. 2023, 2014–2037. old.

[80] G. V. Cormack, C. L. A. Clarke és S. Buettcher. „Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods". *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval*. 2009, 758–759. old.

[81] L. Gao, X. Ma, J. Lin és J. Callan. „Precise Zero-Shot Dense Retrieval without Relevance Labels". *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics*. 2023, 1762–1777. old.

[82] L. Wang, N. Yang és F. Wei. „Query2doc: Query Expansion with Large Language Models". *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. 2023.

[83] X. Ma, Y. Gong, P. He, H. Zhao és N. Duan. „Query Rewriting for Retrieval-Augmented Large Language Models". *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. 2023.

[84] R. Qu, R. Tu és F. Bao. *Is Semantic Chunking Worth the Computational Cost?* 2024. arXiv: 2410.13070.

[85] T. Chen, H. Wang, S. Chen és tsai. „Dense X Retrieval: What Retrieval Granularity Should We Use?": *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. 2024.

[86] T. Gao, H. Yen, J. Yu és D. Chen. „Enabling Large Language Models to Generate Text with Citations". *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. 2023, 6465–6488. old.

[87] H. Rashkin, V. Nikolaev, M. Lamm, L. Aroyo, M. Collins, D. Das és tsai. „Measuring Attribution in Natural Language Generation Models". *Computational Linguistics* 49.4 (2023), 777–840. old.

[88] D. Edge, H. Trinh, N. Cheng és tsai. *From Local to Global: A Graph RAG Approach to Query-Focused Summarization*. 2024. arXiv: 2404.16130.

[89] J. Su, M. Ahmed, Y. Lu, S. Pan, W. Bo és Y. Liu. „RoFormer: Enhanced Transformer with Rotary Position Embedding". *Neurocomputing* 568 (2024), 127063. old.

[90] P. Xu, W. Ping, X. Wu, L. McAfee, C. Zhu, Z. Liu és tsai. „Retrieval meets Long Context Large Language Models". *International Conference on Learning Representations (ICLR)*. 2024.

[91] Z. Li, C. Li, M. Zhang, Q. Mei és M. Bendersky. „Retrieval Augmented Generation or Long-Context LLMs? A Comprehensive Study and Hybrid Approach". *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing: Industry Track*. 2024.

[92] P. Manakul, A. Liusie és M. J. F. Gales. „SelfCheckGPT: Zero-Resource Black-Box Hallucination Detection for Generative Large Language Models”. *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. 2023, 9004–9017. old.

[93] S. Min, K. Krishna, X. Lyu és tsai. „FActScore: Fine-grained Atomic Evaluation of Factual Precision in Long Form Text Generation”. *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. 2023, 12076–12100. old.

[94] S. R. Bowman, G. Angeli, C. Potts és C. D. Manning. „A Large Annotated Corpus for Learning Natural Language Inference”. *Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing*. 2015, 632–642. old.

[95] A. Williams, N. Nangia és S. Bowman. „A Broad-Coverage Challenge Corpus for Sentence Understanding through Inference”. *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics*. 2018, 1112–1122. old.

[96] P. Laban, T. Schnabel, P. N. Bennett és M. A. Hearst. „SummaC: Re-Visiting NLI-based Models for Inconsistency Detection in Summarization”. *Transactions of the Association for Computational Linguistics* 10 (2022), 163–177. old.

[97] O. Honovich, R. Aharoni, J. Herzig, H. Taitelbaum, D. Kukliansy, V. Cohen és tsai. „TRUE: Re-evaluating Factual Consistency Evaluation”. *Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics*. 2022, 3905–3920. old.

[98] C. Snell, J. Lee, K. Xu és A. Kumar. „Scaling LLM Test-Time Compute Optimally Can be More Effective than Scaling Parameters for Reasoning”. *International Conference on Learning Representations (ICLR)*. 2025.

[99] M. Strathern. „‘Improving Ratings’: Audit in the British University System”. *European Review* 5.3 (1997), 305–321. old.

[100] A. Q. Jiang, A. Sablayrolles, A. Mensch, C. Bamford, D. S. Chaplot és tsai. *Mistral 7B*. arXiv:2310.06825. 2023.

[101] M. Abdin és tsai. *Phi-3 Technical Report: A Highly Capable Language Model Locally on Your Phone*. arXiv:2404.14219. 2024.

[102] Qwen Team. *Qwen2.5 Technical Report*. 2024. arXiv: 2412.15115.

[103] A. Grattafiori és tsai. *The Llama 3 Herd of Models*. 2024. arXiv: 2407.21783.

[104] G. Hinton, O. Vinyals és J. Dean. *Distilling the Knowledge in a Neural Network*. arXiv:1503.02531. 2015.

[105] V. Sanh, L. Debut, J. Chaumond és T. Wolf. *DistilBERT, a Distilled Version of BERT: Smaller, Faster, Cheaper and Lighter*. arXiv:1910.01108. 2019.

[106] T. Dettmers, M. Lewis, Y. Belkada és L. Zettlemoyer. „LLM.int8(): 8-bit Matrix Multiplication for Transformers at Scale”. *Advances in Neural Information Processing Systems*. 35. köt. 2022.

[107] E. Frantar, S. Ashkboos, T. Hoefler és D. Alistarh. „GPTQ: Accurate Post-Training Quantization for Generative Pre-trained Transformers”. *International Conference on Learning Representations (ICLR)*. 2023.

[108] J. Lin, J. Tang, H. Tang, S. Yang, W.-M. Chen, W.-C. Wang és tsai. „AWQ: Activation-aware Weight Quantization for On-Device LLM Compression and Acceleration”. *Proceedings of Machine Learning and Systems (MLSys)*. 2024.

[109] T. Dettmers, A. Pagnoni, A. Holtzman és L. Zettlemoyer. „QLoRA: Efficient Finetuning of Quantized LLMs”. *Advances in Neural Information Processing Systems*. 36. köt. 2023.

[110] G. Gerganov és tsai. *llama.cpp: LLM inference in C/C++*. `https://github.com/ggml-org/llama.cpp`. Szoftver, GGUF formátum és K-kvantálás. 2023.

[111] Ollama. *Ollama: Get up and running with large language models locally*. `https://github.com/ollama/ollama`. Szoftver. 2024.

[112] S. Li, X. Ning, L. Wang és tsai. „Evaluating Quantized Large Language Models”. *Proceedings of the 41st International Conference on Machine Learning (ICML)*. 235. köt. PMLR. 2024, 28480–28524. old.

[113] E. Kurtic, A. N. Marques, S. Pandit, M. Kurtz és D. Alistarh. „“Give Me BF16 or Give Me Death”? Accuracy-Performance Trade-Offs in LLM Quantization”. *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (ACL)*. 2025.

[114] U. Kurt. *Which Quantization Should I Use? A Unified Evaluation of llama.cpp Quantization on Llama-3.1-8B-Instruct*. 2026. arXiv: `2601.14277`.

[115] J. Ainslie, J. Lee-Thorp, M. de Jong, Y. Zemlyanskiy, F. Lebrón és S. Sanghai. „GQA: Training Generalized Multi-Query Transformer Models from Multi-Head Checkpoints”. *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. 2023, 4895–4901. old.

[116] W. Kwon, Z. Li, S. Zhuang és tsai. „Efficient Memory Management for Large Language Model Serving with PagedAttention”. *Proceedings of the 29th ACM Symposium on Operating Systems Principles (SOSP)*. 2023, 611–626. old.

[117] P. M. Zähl és A. Hennig. *Energy Efficiency of Locally Deployed LLMs: A Preliminary Quantitative GPU Power Benchmark on Consumer Hardware*. 2026. arXiv: `2608.00008`.

[118] L. Zheng, W.-L. Chiang, Y. Sheng, S. Zhuang, Z. Wu, Y. Zhuang és tsai. „Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena”. *Advances in Neural Information Processing Systems (Datasets and Benchmarks Track)*. 36. köt. 2023.

[119] C.-H. Chiang és H.-y. Lee. „Can Large Language Models Be an Alternative to Human Evaluations?”: *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics*. 2023, 15607–15631. old.

[120] Y. Liu, D. Iter, Y. Xu, S. Wang, R. Xu és C. Zhu. „G-Eval: NLG Evaluation using GPT-4 with Better Human Alignment”. *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. 2023, 2511–2522. old.

[121] S. Es, J. James, L. Espinosa-Anke és S. Schockaert. „RAGAs: Automated Evaluation of Retrieval Augmented Generation”. *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations*. 2024, 150–158. old.

[122] P. Wang, L. Li, L. Chen és tsai. „Large Language Models are not Fair Evaluators”. *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics*. 2024, 9440–9450. old.

[123] A. Panickssery, S. R. Bowman és S. Feng. „LLM Evaluators Recognize and Favor Their Own Generations”. *Advances in Neural Information Processing Systems*. 37. köt. 2024.

[124] OpenAI. *gpt-oss-120b & gpt-oss-20b Model Card*. 2025. arXiv: 2508.10925.

[125] R. Artstein és M. Poesio. „Inter-Coder Agreement for Computational Linguistics”. *Computational Linguistics* 34.4 (2008), 555–596. old.

[126] J. Cohen. „A Coefficient of Agreement for Nominal Scales”. *Educational and Psychological Measurement* 20.1 (1960), 37–46. old.

[127] K. Krippendorff. *Content Analysis: An Introduction to Its Methodology*. 2. kiad. Thousand Oaks, CA: Sage, 2004.

[128] J. R. Landis és G. G. Koch. „The Measurement of Observer Agreement for Categorical Data”. *Biometrics* 33.1 (1977), 159–174. old.

[129] X. Bouthillier, P. Delaunay, M. Bronzi, A. Trofimov, B. Nichyporuk, J. Szeto és tsai. „Accounting for Variance in Machine Learning Benchmarks”. *Proceedings of Machine Learning and Systems (MLSys)*. 2021.

[130] R. Dror, G. Baumer, S. Shlomov és R. Reichart. „The Hitchhiker’s Guide to Testing Statistical Significance in Natural Language Processing”. *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics*. 2018, 1383–1392. old.

[131] P. Koehn. „Statistical Significance Tests for Machine Translation Evaluation”. *Proceedings of the 2004 Conference on Empirical Methods in Natural Language Processing*. 2004, 388–395. old.

[132] S. Holm. „A Simple Sequentially Rejective Multiple Test Procedure”. *Scandinavian Journal of Statistics* 6.2 (1979), 65–70. old.

[133] O. Sainz, J. A. Campos, I. García-Ferrero, J. Etxaniz, O. Lopez de Lacalle és E. Agirre. „NLP Evaluation in Trouble: On the Need to Measure LLM Data Contamination for each Benchmark”. *Findings of the Association for Computational Linguistics: EMNLP 2023*. 2023.

[134] R. Parasuraman és D. H. Manzey. „Complacency and Bias in Human Use of Automation: An Attentional Integration”. *Human Factors* 52.3 (2010), 381–410. old.

[135] N. Carlini, F. Tramèr, E. Wallace, M. Jagielski, A. Herbert-Voss, K. Lee és tsai. „Extracting Training Data from Large Language Models”. *30th USENIX Security Symposium*. 2021, 2633–2650. old.

[136] Európai Parlament és a Tanács. *Az Európai Parlament és a Tanács (EU) 2024/1689 rendelete a mesterséges intelligenciára vonatkozó harmonizált szabályok megállapításáról (mesterséges intelligenciáról szóló rendelet)*. Az Európai Unió Hivatalos Lapja, L sorozat. 2024.

[137] J. Zsibrita, V. Vincze és R. Farkas. „magyarlanc: A Toolkit for Morphological and Dependency Parsing of Hungarian”. *Proceedings of the International Conference Recent Advances in Natural Language Processing (RANLP 2013)*. 2013, 763–771. old.

[138] K. Ahuja, H. Diddee, R. Hada, M. Ochieng, K. Ramesh, P. Jain és tsai. „MEGA: Multilingual Evaluation of Generative AI”. *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. 2023.

[139] D. M. Nemeskey. „Introducing huBERT”. *XVII. Magyar Számítógépes Nyelvészeti Konferencia (MSZNY 2021)*. Szeged, 2021, 3–14. old.

[140] N. Ligeti-Nagy, G. Ferenczi, E. Héja és tsai. „HuLU: Hungarian Language Understanding Benchmark Kit”. *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*. 2024, 8360–8371. old.

[141] A. Novák, B. Novák, D. Zombori, G. Szabó, Z. Szántó és R. Farkas. „A Question Answering Benchmark Database for Hungarian”. *Proceedings of the 17th Linguistic Annotation Workshop (LAW-XVII)*. 2023, 188–198. old.

[142] The PostgreSQL Global Development Group. *PostgreSQL 16 Documentation: SELECT – The Locking Clause (FOR UPDATE SKIP LOCKED)*. `https://www.postgresql.org/docs/16/sql-select.html`. 2024.

[143] Qdrant. *Qdrant: Vector Similarity Search Engine*. `https://github.com/qdrant/qdrant`. Szoftver. 2024.

[144] M. L. Balinski és H. P. Young. *Fair Representation: Meeting the Ideal of One Man, One Vote*. 2. kiad. Washington, D.C.: Brookings Institution Press, 2001.

[145] B. Efron és R. J. Tibshirani. *An Introduction to the Bootstrap*. New York: Chapman & Hall, 1993.

[146] F. Wilcoxon. „Individual Comparisons by Ranking Methods”. *Biometrics Bulletin* 1.6 (1945), 80–83. old.

[147] D. S. Kerby. „The Simple Difference Formula: An Approach to Teaching Nonparametric Correlation”. *Comprehensive Psychology* 3 (2014).

[148] C. Wohlin, P. Runeson, M. Höst, M. C. Ohlsson, B. Regnell és A. Wesslén. *Experimentation in Software Engineering*. Berlin, Heidelberg: Springer, 2012.

Ábrák jegyzéke

3.1. A MIMIR szolgáltatásai és adatfolyama. A szaggatott keretben lévő komponensek a feltöltött tartalmat kizárólag a feladat élettartama alatt, memóriában tartják; a nyelvi modell az egyetlen GPU-t használó összetevő. 23
3.2. A naiv RAG és a MIMIR tervezett csővezetéke. Kék: a kísérleti karokban ki- és bekapcsolt komponensek. A terv a vizsga szerkezetét még az első kérdés megírása előtt rögzíti, és minden kérdést a saját, hivatkozott kontextusával szemben ellenőriz. 25

5.1. Minőség és futási idő a fő vizsgálatban. A tervezett helyi karok egy nagyságrenddel lassabbak az egyhívásos karoknál, de minőségük egyenletesebb; az E4 és az E4b más dokumentumokon futott, az E2x idejét a sikertelen ellenőrző hívások növelték. 54

Táblázatok jegyzéke

2.1. A kérdésgenerálási megközelítések összevetése a P1–P4 problémák szempontjából (✓: megoldott, ○: részben, –: nem kezelt). 21

3.1. Tervezési célok: a dokumentum csevegő LLM-nek való átadása és a MIMIR összevetése. 22
3.2. Adatfajták életciklusa a MIMIR rendszerben. 24
3.3. Becsült GPU-memóriaigény 8 192 tokenes kontextusnál, $M_0 \approx 0{,}6$ GB futtatókörnyezeti többlettel. A súlyok a GGUF-fájlok mérete, a gyorsítótár a publikált architektúrákból számolt érték. 25
3.4. A tervezett csővezeték paraméterei és alapértékei a fő vizsgálatban. 26
3.5. A nehézségi szintekhez rendelt Bloom-eloszlások és egy 10 kérdéses vizsga kiosztása. 28
3.6. Az ellenőrző lánc lépései végrehajtási sorrendben, a hiba esetén adott visszajelzéssel. 29

4.1. Az `eval-v1` kiértékelő adatkészlet. R/K/H: rövid ($\leq 6\,000$), közepes (6 000–25 000) és hosszú (25 000–90 000 karakteres) dokumentumok száma. 33
4.2. A kísérleti karok. Ref.: a referenciakar, amelytől a kar egyetlen tényezőben eltér; Magok: dokumentumonkénti ismétlések száma. 34
4.3. A pilot és a fő vizsgálat beállításai. 36

5.1. A pilot fő eredményei: egy magyar dokumentum, 3 mag, karonként 30 kérdés. Ráták %-ban. Q: minőségi index; Form.: formai megfelelés; Alát.: alátámasztottság; Vak: vak megoldhatóság; Diszt.: disztraktor-validitás; Lef.: lefedettség; Sziv.: kulcs a törzsben; Hívás: átlagos modellhívás vizsgánként; Perc: medián futási idő vizsgánként (RTX 3070 Ti). 41
5.2. A 7B ellenőrző mint osztályozó a pilotban, a bíró alátámasztottsági ítéletéhez képest. Átengedett: az ellenőrzésen átjutott kérdések aránya (%). 42
5.3. A fő vizsgálatban kiértékelt dokumentumok. Ref.: referenciakérdések száma; Darab: a szemantikus darabolás által előállított darabok száma. 44
5.4. A fő vizsgálat eredményei. Q: minőségi index (a dokumentumonkénti átlagok átlaga) 95 %-os bootstrap-konfidenciaintervallummal; a ráták %-ban. Nell.: nem ellenőrzött kérdések száma vizsgánként; Hívás: átlagos modellhívás vizsgánként; Perc: medián futási idő vizsgánként (helyi karok: RTX A4500). A többi rövidítés az 5.1. táblázatéval azonos. Az első tizenkét kar ugyanazon a hat dokumentumon futott; az E4 és az E4b hat angol dokumentumon, amelyek közül három közös a többiekével. 45
5.5. Minőségi index dokumentumonként (fő vizsgálat; az egyhívásos karoknál a három mag átlaga). Min.: a kar leggyengébb dokumentuma. Félkövér: 0,70 alatti érték. 46
5.6. Páros Wilcoxon-próbák a dokumentumonkénti minőségi indexen (fő vizsgálat). n: a közös dokumentumok száma; r_{rb}: rangbiszeriális hatásméret ($r_{rb} > 0$: az új kar jobb); $\tilde{p}$: a hat összevetésre Holm-korrigált p-érték. 46

5.7. Az ellenőrző lánc működése a fő vizsgálatban (karonként 60 slot). Első kísérlet: az első próbálkozásra elfogadott slotok aránya; Kísérlet/slot: a generálási kísérletek átlagos száma; Átengedett: az ellenőrzöttként elfogadott kérdések aránya; a további oszlopok az egyes elutasítási okok előfordulásai az összes kísérletben (egy kísérlet több okból is elbukhat). 48
5.8. Az ellenőrző pontossága, felidézése és Cohen-κ együtthatója a bíró alátámasztottsági ítéletéhez képest, karonként (fő vizsgálat). † Csak szabályalapú ellenőrzés. 49
5.9. Válaszszivárgás és nem kérdő törzsek aránya karonként (fő vizsgálat, %; a 4.5. szakasz definíciói szerint). A ki nem írt karok (E4, E5a, E5b) értékei 0–2, illetve 0–11 %. 49
5.10. A bíró rubrikapontjai (1–5, átlagok), a „felhasználnám” arány, a kérdések átlagos hossza (karakter) és a bíró szerinti magasabb rendű (alkalmazás, elemzés, értékelés) kérdések aránya karonként (fő vizsgálat). Helyes.: helyesség; Érth.: érthetőség; Diszt.: disztraktorok; Szint: szintillesztés. 52
5.11. Mért GPU-memória a fő vizsgálatban (MiB, RTX A4500). Alap: a kártya foglalása a modell betöltése előtt; Csúcs: a legnagyobb mért érték a generálás alatt; Modell: a különbség. 53
5.12. Kérdések a fő vizsgálatból eredeti nyelven, zárójelben magyar fordítással (* = megjelölt kulcs), a bíró ítéletével. 55

6.1. A hipotézisek és a pilot, illetve a fő vizsgálat által szolgáltatott bizonyíték. . . . 56

C.1. A fő vizsgálat futtatási terve. 83
C.2. A dolgozat táblázatainak és ábráinak adatforrásai a tárolóban (a `tests/eval` könyvtárhoz viszonyítva). 84

A. Promptok

Ez a függelék a csővezetékek promptjait közli (rövidítve, a JSON-sémák elhagyásával ott, ahol a törzsszövegből egyértelműek). A belső lépések (tervező, gráf, ellenőrző) promptjai angol nyelvűek, mert a kis helyi modellek ezeket megbízhatóbban követik; a generátor promptja magyar, és megismétli az éles prompt szabályait, így az E0 és az E1+ karok szerkezetben, nem szabályokban különböznek.

A.1. A naiv alapvonal (E0) és a teljes dokumentumos alapvonal promptja

```
Te egy kiemelkedő tudású oktatásmódszertani szakértő és professzionális vizsgakészítő vagy.

KÖTELEZŐ SZABÁLYOK, AMIKET SZIGORÚAN BE KELL TARTANOD:
1. ZÉRÓ HALLUCINÁCIÓ: KIZÁRÓLAG a megadott KONTEXTUS alapján dolgozz! Ha a kontextus nem
  tartalmazza a választ, ne találj ki semmit!
2. FELHASZNÁLÓI UTASÍTÁS KÖVETÉSE: ... Pontosan a kért mennyiséget és típust generáld le!
3. DISZTRAKTOROK: Feleletválasztós (mcq) kérdés esetén 1 helyes és 3 hihető, de helytelen vá
    lasz.
4. NO LATEX: Szigorúan TILOS LaTeX formázást vagy dollárjeleket ($) használni!
5. META-REFERENCIA TILALOM: Szigorúan TILOS a dokumentum szerkezetére kérdezni.

KONTEXTUS:
{context_text}

FELADAT (A felhasználó pontos kérése):
"{query}"

KIMENETI FORMÁTUM: kizárólag egy érvényes JSON objektum:
{"title": "Mimir AI Vizsga", "format": "pdf", "questions": [
 {"type": "mcq", "text": "...?", "answers": [{"text": "...", "is_correct": true}, ...]}]}
```

A.2. A tervező promptja

```
[planner] You design exam blueprints. Reply with one valid JSON object only.

Below is a document split into numbered chunks (C0, C1, ...). Some chunks are shortened.
{overview}
List the {n_concepts} most important, clearly distinct concepts, facts or ideas a student
    should
be tested on. Cover the whole document: every major part should have at least one concept.
    Prefer
central ideas over trivia. Write concept names and descriptions in {language}.
JSON shape:
{"concepts": [{"concept": "short name", "description": "one sentence: what exactly should be
 tested", "chunk_ids": ["C0"], "importance": 3}]}
importance: 3 = central, 2 = important, 1 = detail.
```

A.3. A generátor promptja

```
[generator] Te egy kiemelkedő tudású oktatásmódszertani szakértő és professzionális vizsgakész
    ítő
vagy. Kizárólag érvényes JSON formátumban válaszolj, markdown formázás nélkül!

Készíts PONTOSAN EGY vizsgakérdést az alábbi terv szerint.
TERV:
- Fogalom: {concept}
- Mit kérdezzen: {description}
- Kérdéstípus: feleletválasztós ("mcq"): pontosan 4 válasz, ebből pontosan 1 helyes és 3 hihet
    ő,
  de a kontextus szerint egyértelműen helytelen disztraktor; a válaszok hossza és formája
      legyen
  hasonló.
- Bloom-szint: {pl. Megértés (magyarázat, összehasonlítás, saját szavakkal)}
- Vizsga nehézsége: {difficulty}
- Nyelv: a kérdést és a válaszokat {magyar} nyelven írd.
KÖTELEZŐ SZABÁLYOK:
1. ZÉRÓ HALLUCINÁCIÓ: KIZÁRÓLAG a KONTEXTUS alapján dolgozz. A helyes válasznak a kontextusból
   igazolhatónak kell lennie.
2. HIVATKOZÁS: a "citations" mezőbe írd azoknak a részleteknek az azonosítóját (pl. "C3"),
   amelyek igazolják a helyes választ.
3. NO LATEX. 4. META-REFERENCIA TILALOM.
5. NE ISMÉTELD a már elkészült kérdéseket: {existing}
[DISZTRAKTOR-ÖTLETEK (rokon fogalmak a dokumentumból) - csak E3]
[AZ ELŐZŐ PRÓBÁLKOZÁS HIBÁS VOLT, JAVÍTSD: {feedback}]
KONTEXTUS:
[C3] ...
[C1] ...
KIMENETI FORMÁTUM (csak ez a JSON objektum):
{"type": "mcq", "text": "A kérdés szövege?", "answers": [...], "citations": ["C0"],
 "bloom": "understand", "explanation": "egy mondat: miért ez a helyes válasz"}
```

A.4. Az ellenőrző promptjai

```
[verifier] You check exam questions against source text. Reply with one valid JSON object only.


SOURCE: """{source}"""
QUESTION (mcq): {text}
A. ... <-- marked correct
B. ...
Check strictly against the SOURCE only:
1. key_supported: is the marked-correct answer clearly supported by the SOURCE?
2. For every option NOT marked correct: is it clearly wrong according to the SOURCE?
   (options_wrong, in order)
3. ambiguous: could a careful reader argue that more than one option is correct?
4. problems: one short sentence describing any problem ("" if none).
JSON shape: {"key_supported": true, "options_wrong": [true, true, true], "ambiguous": false,
          "problems": ""}

--- vak megoldás ---
SOURCE: """{source}"""
Answer the question using only the SOURCE. Exactly one option is correct.
{text}
```

```
A. ... B. ... C. ... D. ... (véletlen permutáció)
JSON shape: {"answer": "A"}
```

A.5. A fogalomgráf promptja (E3)

```
[graph] You extract knowledge graphs from teaching material. Reply with one valid JSON object
    only.

Extract the knowledge in these chunks as a small concept graph. Chunk ids are in brackets.
{chunks_block}
Rules:
- concepts: the key terms, entities, processes or ideas (max 8 per chunk). "parent" is the
    broader
  category the concept belongs to (e.g. "T-sejt" -> "limfocita"), or "" if none.
- facts: short atomic statements from the text (max 6 per chunk), with the concepts they
    mention.
- relations: typed links between concepts: is_a, part_of, causes, contrasts_with, used_for,
  related_to.
JSON shape: {"concepts": [...], "facts": [...], "relations": [...]}
```

B. A bíró és az oktatók rubrikája

A rubrika szövege a bíró és az oktatói értékelőlap számára azonos (a bíró az angol, az oktatók a magyar változatot kapják).

Helyesség

A megjelölt válasz a forrás szerint helyes, és más opció nem helyes. 1 = hibás kulcs vagy két helyes opció; 3 = helyes, de pontatlan; 5 = teljesen helyes, egyértelmű.

Érthetőség

A kérdés önmagában érthető, nyelvtanilag helyes, egyértelmű, nem hivatkozik „a szövegre” vagy a dokumentum szerkezetére. 1 = zavaros; 3 = nehezen érthető; 5 = vizsgakész megfogalmazás.

Disztraktorok

A rossz válaszok a forrás szerint egyértelműen rosszak, de egy felkészületlen diák számára hihetők (azonos téma, hasonló hossz és forma). 1 = abszurd vagy szintén helyes; 3 = részben hihető; 5 = mind hihető és rossz. Kifejtős kérdésnél üresen marad.

Szintillesztés

A kognitív szint megfelel a kért nehézségnek (könnyű: felidézés/megértés; közepes: alkalmazás/megértés; nehéz: elemzés/értékelés). 1 = egyértelműen rossz szint; 3 = határeset; 5 = illik.

Felhasználnám

Beraknád ezt a kérdést egy valódi dolgozatba legfeljebb apró javítással? (igen/nem)

A bíró áttekintő hívása ezen felül kéri a kulcsot igazoló mondat szó szerinti idézését (`key_evidence` mező), disztraktoronként a `is_wrong` és `on_topic` ítéletet, a kérdés Bloom-szintjét és egy egy-két mondatos indoklást kér.

C. Konfigurációk és reprodukálás

C.1. Példakonfigurációk

Minden kísérleti kar egy YAML-fájl a `tests/eval/configs` könyvtárban. Az alábbi két konfiguráció az E2 és az E3 kart írja le; a két fájl egyetlen kulcsban (`graph`) különbözik, ami az egytényezős tervet a konfiguráció szintjén is láthatóvá teszi.

```
# E2 - E1 + verifier chain ("Thorough" mode): schema, meta-reference, citations, grounding +
# distractor check, blind answer test; max 1 retry per slot with feedback, then 1 replacement.
name: E2
description: "Blueprint + verifier (max 1 retry, blind answer test on)"
seeds: [1]
exam: {n_questions: 10, types: [mcq]}
pipeline: {kind: blueprint, retrieval: dense, retrieval_k: 3, verifier: true, blind_test: true,

        max_retries: 1, graph: false}
chunking: {mode: service, method: percentile, threshold: 85, target_size: 1000}
generator: {provider: ollama, model: "qwen2.5:7b", temperature: 0.2, num_ctx: 8192}

# E3 - E2 + concept graph
name: E3
pipeline: {kind: blueprint, retrieval: dense, retrieval_k: 3, verifier: true, blind_test: true,

        max_retries: 1, graph: true}
```

C.2. A reprodukálás lépései

```
# 1. Szolgáltatások és helyi modell
ollama pull qwen2.5:7b
docker-compose up -d --build

# 2. Kiértékelő környezet
cd tests/eval
pip install -r requirements.txt
python -m mimir_eval check configs/e0_naive_local.yaml # adatkészlet és szolgáltatások

# 3. Egy kar futtatása, pontozása és a jelentés
python -m mimir_eval run configs/e1_blueprint.yaml
python -m mimir_eval score results/E1_<időbélyeg>
python -m mimir_eval report --results results --name main

# 4. A teljes mátrix (Windows PowerShell)
./run_all.ps1
```

C.3. A fő vizsgálat futtatási terve

C.1. táblázat. A fő vizsgálat futtatási terve.

Lépés	Tartalom	Erőforrás	Becsült idő
R0	füstteszt minden karon 2 dokumentumon (egy hosszú)	helyi GPU + szerver	2–3 óra
R1	helyi karok mind a 39 dokumentumon	helyi GPU	2–3 nap
R2	szerverkarok mind a 39 dokumentumon	egyetemi szerver	kb. 1 nap
R3	pontozás a bíróval	egyetemi szerver	kb. 1 nap
R4	oktatói értékelés: 3 oktató $\times$ (60 + 10) kérdés	oktatók	1–2 hét
R5	`report`: táblázatok, ábrák, tesztek	–	1–2 nap

A terv végrehajtásának állapota a dolgozat lezárásakor: az R1 és R2 lépés a 2026. szeptember 27–28-i futásban karonként hat dokumentumon készült el (5.2.1. szakasz), az R3 pontozás és az R5 jelentés megtörtént (`tests/eval/report_main/main`), az R4 oktatói értékelés a dolgozat lezárásáig nem készült el.

C.4. A közölt számok forrásai

C.2. táblázat. A dolgozat táblázatainak és ábráinak adatforrásai a tárolóban (a `tests/eval` könyvtárhoz viszonyítva).

Dolgozatbeli elem	Forrás
5.1. táblázat	`results_pilot/*/exam_metrics.csv`, `questions.jsonl`; `report_pilot/pilot`
5.2. táblázat	`results_pilot/{E2,E2f,E2h,E3}_*/exams.jsonl` (`verified`) és `questions.jsonl` (`grounded`)
Pilot: szivárgás, zaj, GPU-memória	`results_pilot/*/questions.jsonl` (`key_in_stem`, `stem_is_question`); `exams.jsonl` (`retrieved`, `vram_baseline_mib`, `vram_peak_mib`)
Pilotpéldák	`results_pilot/{E0,E3}_*/questions.jsonl`, 1. mag
3.3. táblázat	publikált modellarchitektúrák és GGUF-fájlméretek; M_0 becslés
4.1. táblázat	`dataset/manifest*.yaml`
5.4. táblázat, 5.1. ábra	`report_main/main/latex/tab_main.tex`, `fig_quality_time.dat`, `paper_numbers.json`
5.3. táblázat	`report_main/main/adatkeszlet.csv`; `configs/e4*_server_*.yaml` (`documents`); darabszám: `exam_metrics.csv` (`n_chunks`)
5.5. táblázat	`results/*/exam_metrics.csv`: Q vizsgánként a négy komponensből, majd dokumentumonként a magokra átlagolva
5.6. táblázat	`report_main/main/szignifikancia.csv`
5.7. táblázat	`results/*/exams.jsonl`, `blueprint.slot_logs[].attempts[].problems`; az E2x kihagyott ellenőrzései: `blueprint.verifier_skipped`, `llm.errors`
5.8. táblázat	`report_main/main/latex/tab_verifier.tex`, `tab_verifier_arms.tex`
5.9. táblázat	`report_main/main/latex/tab_leakage.tex`
5.10. táblázat	`results/*/questions.jsonl` (`judge_*`, `bloom`, `judge_bloom_level`, `text`, `options`)
5.11. táblázat	`results/*/exams.jsonl` (`vram_baseline_mib`, `vram_peak_mib`); GPU: `run.json` (`hardware.gpus`)
Nyelvenkénti értékek, rangsor	`report_main/main/abra*.pdf`, `eredmenyek.md` (5. táblázat)
5.12. táblázat	`report_main/main/peldak.md`; karakterpozíciók: `dataset/docs/eduqg/en-law-long-03.txt`